[VAE] Auto-Encoding Variational Bayes #GM

0. Abstract

📢 1️⃣ **확률 모델**

> 데이터가 어떻게 생성되느지를 "확률"로 표현한 모델

→ 우리가 관측하는 데이터 x는 그냥 생신 게 아니라 어떤 **확률적인 과정**을 통해 생성됐다고 보는 것.

$$p(x, z) = p(z)p(x \mid z)$$

z : 숨겨진 원인 (잠재변수)
x : 우리가 관측한 데이터
예) 동전의 확률 모델

$$p(x = \text{앞면}) = 0.7$$

: 동전을 던지면 앞면이 70% 확률로 나온다는 데이터 생성 규칙

- 확률 모델을 만든다면

1. 데이터 생성 가능

→ 샘플링해서 새로운 데이터를 만들 수 있음
⇒ 생성모델

2. 불확실성 표현 가능
3. 추론 가능

→ 데이터 보고 원인 추정 가능
⇒ 이 데이터는 어떤 원인에서 나왔을까?

2️⃣ **Posterior 계산**

> 데이터를 보고 숨겨진 원인(latent variable)을 추정하는 것

$$p(z \mid x)$$

x : 관측 데이터
z : 숨겨진 변수
→ 이 데이터 x가 주어졌을 때, 어떤 z였을 확률?

3️⃣ **변분 추론 (Variantional Inference)**

> 어려운 posterior를 직접 구하지 말고, 쉬운 분포로 근사

$$q(z \mid x) \approx p(z \mid x)$$

1. Introduction

논문이 다루는 분야

📖 **1️⃣ 확률 모델 (Probabilistic Modeling)**

> 데이터 생성 과정을 확률적으로 모델링

$$p(x, z) = p(z)p(x \mid z)$$

→ latent variable을 통해 데이터 구조를 설명

2️⃣ 변분 추론 (Variational Inference)

> posterior$p(z|x)$ 계산이 어려운 문제를 해결하기 위해 근사 분포 $q(z|x)$를 학습하여 추론 수행

3️⃣ 딥 생성 모델 (Deep Generative Models)

> latent variable을 이용해 새로운 데이터 생성

→ neural network 기분 생성 모델

📢 연구 주제

> 복잡한 **확률 생성모델에서 빠르고 효율적인 추론 및 학습 방법**을 만드는 연구

해당 task에서 기존 연구의 한계점

⚠️ 1️⃣ **Posterior 계산의 어려움**
구하고자 하는 것 :

$$p(z \mid x) = p(x)p(x \mid z)p(z)$$

구하기 위해 고차원 적분 → 계산 어려움

2️⃣ **Variational Bayes (VB)의 한계**

1. Mean_field assimption

$$q(z) = i \prod q(zi)$$

: 잠재변수들을 서로 독립이라고 가정

😈 실제 posterior 변수들 사이에 복잡한 관계(상관관계)를 가짐
⇒ 근사 분포가 너무 단순해져서 정확도가 떨어질 수 있음

2. 기대값 계산 문제

ELBO를 계산할 때

$$Eq(z \mid x)[logp(x \mid z)]$$

😈 기대값의 경우 적분 형태로 계산되어 계산이 불가능
⇒ posterior는 못 구하고, ELBO 계산도 불가능한 상태

3️⃣ **Sampling 기반 방법(MCMC)의 한계**
😇 이론적으로 적확한 posterior 근사 가능
😈 많은 반복 샘플링이 필요해 매우 느리고, 데이터 마다 별도로 inference 수행 필요
→ 데이터가 많아지면 현실적으로 사용하기 어려움

📢 **결론**

> 기존 방법들은 **posterior를 계산하기 어렵**고, 근사하려고 해도 **계산이 복잡하거나 너무 느리다**는 문제 존재

이 논문의 contributions

📌 **1️⃣ Reparameterization을 통한 ELBO 최적화**

> variational lower bound(ELBO)를 재파라미터화하여 미분 가능한 estimator를 제안

😇 standard stochastic gardient 방법으로 최적화 가능

2️⃣ SGVB (Stochastic Gradient Variational Bayes) 제안

> ELBO를 샘플링 기반으로 추정하는 방법 제안

😇 연속 latent variable을 가지는 다양한 모델에서 효율적인 posterior 근사 추론 가능

3️⃣ AEVB (Auto-Encoding Variational Bayes) 알고리즘 제안

> i.i.d 데이터와 datapoint별 latent variable 구조에서 SGVB를 활용한 효율적인 inference 및 learning 방법 제안

4️⃣ Recognition Model을 통한 효율적인 추론

> approximate posterior를 근사하는 recognition model 도입

😇 이를 통해 간단한 샘플링 기법 으로 효율적인 posterior inference 도입

5️⃣ 반복적 추론 방법 (MCMC) 없이 학습 가능
😇 데이터마다 MCMC와 같은 반복적 inference 없이 효율적으로 모델 파라미터 학습 가능

6️⃣ Vatiational Autoencoder (VAE) 구조 도출

📢 **제안**

> **reparameterization과 SGVB, recognition model을 통해 효율적인 variational inference를 수행하는 방법**을 제안

2. Related Work

📌 **Wake-Sleep Algorithm**

- recognition model을 사용해 posterior를 근사
- 하지만 두 개의 objective를 따로 최적화
  → marginal likelihood와 직접 연결되지 않음

🔖 본 논문: ELBO 하나를 직접 최적화하여 일관된 학습 수행

📌 **Stochastic Variational Inference (SVI)**

- 기존 방법들은 gradient variance가 큼
- control variate 등을 통해 variance 감소 시도

🔖 본 논문: reparameterization을 통해 variance 문제를 직접 해결

📌 **Autoencoder 관련 연구**

- 기존 autoencoder는 reconstruction 기반 학습
  → representation 학습에 한계 존재
- 다양한 regularization (denoising, sparse 등) 필요

🔖 본 논문: KL term이 자연스럽게 regularization 역할 수행

📌 **기존 Encoder-Decoder / Generative 모델**

- PCA: linear Gaussian model의 특수 경우
- Boltzmann Machine, GSN 등:
  → 특정 모델에 제한되거나 undirected model

🔖 본 논문: 일반적인 directed probabilistic model에 적용 가능

📌 **기타 유사 연구**

- DARN: binary latent variable만 가능
- 일부 연구: reparameterization 사용

🔖 본 논문: continuous latent variable에 대한 일반적인 framework 제안

3. 제안 방법론

Main Idea

💡 **Main idea**

> intractable posterior를 직접 계산하지 않고, reparameterization trick을 통해 ELBO를 미분 가능하게 만들어 stochastic gradient로 학습하는 방법 제안

😈 기존 variational inference는
→ expectation 계산과 gradient 계산이 어려움

😇 이를 해결하기 위해

> $z \sim q_\phi(z \mid x)$를 $z = g_\phi(\epsilon, x),\ \epsilon \sim p(\epsilon)$로 변환

→ sampling을 deterministic 구조로 바꿔 gradient 계산 가능하게 만듦
⇒ variational inference를 neural network 기반으로 효율적으로 학습 가능

Contribution

💡 📌 **Reparameterization Trick 도입**

> 확률적 sampling 과정을 deterministic function + noise 형태로 변환

$$z = g_\phi(\epsilon, x), \quad \epsilon \sim p(\epsilon)$$

→ expectation을 $q_\phi(z \mid x)$대신 p(ϵ) 기준으로 계산
⇒ variational objective를 미분 가능하게 만듦

📌 **SGVB (Stochastic Gradient Variational Bayes) Estimator 제안**

> ELBO를 Monte Carlo sampling으로 근사

$$\mathcal{L}(\theta, \phi; x) \approx \frac{1}{L} \sum_{l=1}^{L} \left[\log p_\theta(x|z^{(l)}) - D_{KL}(q_\phi(z|x) \| p_\theta(z)) \right]$$

→ stochastic gradient descent로 최적화 가능
⇒ 대규모 데이터에서도 효율적 학습 가능

📌 **AEVB (Auto-Encoding Variational Bayes) Algorithm 제안**

> approximate posterior $q_\phi(z \mid x)$를 neural network (encoder)로 모델링

→ generative model pθ(x ∣ z)p_\theta(x|z)pθ(x ∣ z)와 함께 joint optimization 수행
⇒ 기존처럼 데이터마다 반복 inference 필요 없음

📌 **Efficient Inference Framework 구축**
→ 하나의 encoder로 posterior를 빠르게 근사
⇒ MCMC 같은 반복적 sampling 없이 inference 가능
+) representation learning, denoising 등 다양한 task에 활용 가능

추가적인 내용

💡 **ELBO를 샘플링 기반 목적함수로 만드는 방법 제시**

▼ 샘플링 기반 목적함수
: 복잡한 적분(기댓값)을 직접 계산하지 않고, 샘플을 뽑아서 근사한 목적함수

→ 다양한 확률 모델에 적용 가능

📌 **VAE (Variational Autoencoder)**

> 데이터를 압축(encode)하고 다시 생성(decode)하면서, 새로운 데이터까지 생성할 수 있는 확률 기반 모델

1️⃣ Encoder (인코더)

$$q\phi(z \mid x)$$

입력 : 데이터 x
출력 : latent variable z의 분포
→ 이 데이터는 어떤 latent에서 왔을까?

2️⃣ Decoder (디코더)

$$p\theta(x \mid z)$$

입력 : z
출력 : 데이터 x
→ 이 latent로 어떤 데이터를 만들 수 있을까?

⚙️ 데이터 구조

- i.i.d 데이터셋
- 각 데이터마다 latent variable 존재

⚙️ 학습 방식

- global patameter → ML / MAP
- latent variable → Variational Inference

1️⃣ 문제 설정

📌 데이터 가정

$$X = \{x^{(i)}\}_{i=1}^{N}$$

→ N개의 i.i.d. 데이터로 구성됨.

📌 생성 과정

1. latent variable 생성

$$z \sim p\theta(z)$$

2. 데이터 생성

$$x \sim p\theta(x \mid z)$$

📌 주요 문제

1. marginal likehood $p(x)$ 계산 불가능
2. posterior $p(z \mid x)$ 계산 불가능
3. 기존 variational inference도 계산 어려움

📌 해결하고자 하는 목표

1. 파라미터 θ 추정
2. posterior $p(z|x)$ 근사
3. 데이터 분포$p(x)$ 기반 inference 수행

📌 핵심 아이디어

$$q_\phi(z \mid x)$$

→ posterior를 직접 계산하지 않고 recognition model로 근사

2️⃣ The Variational Bound (ELBO)

📌 Marginal Likelihood 분해

$$\log p_\theta(x^{(1)}, \cdots, x^{(N)}) = \sum_{i=1}^{N} \log p_\theta(x^{(i)})$$

→ 전체 데이터 likelihood는 각 데이터의 합으로 표현됨

📌 Variational Decomposition

$$\log p_\theta(x^{(i)}) = D_{KL}(q_\phi(z|x^{(i)}) \| p_\theta(z|x^{(i)})) + \mathcal{L}(\theta, \phi; x^{(i)})$$

→ log likelihood를 KL divergence + ELBO로 분해

📌 Variational Lower Bound

KL divergence는 항상 0 이상이므로

$$\log p_\theta(x^{(i)}) \geq \mathcal{L}(\theta, \phi; x^{(i)})$$

→ ELBO는 log likelihood의 하한으로 성립

📌 ELBO 표현

$$\mathcal{L}(\theta, \phi; x^{(i)}) = -D_{KL}(q_\phi(z|x^{(i)}) \| p_\theta(z)) + \mathbb{E}_{q_\phi(z|x^{(i)})}[\log p_\theta(x^{(i)}|z)]$$

ELBO = KL term + reconstruction으로 구성
⇒ 따라서 모델은 ELBO를 최대화하도록 학습됨.

📌 문제점

1. ϕ에 대한 gradient 계산이 어려움
2. naive Monte Carlo 방법은 variance가 커서 비효율적

3️⃣ The SGVB Estimator and AEVB Algorithm

> reparameterization을 통해 ELBO를 샘플링으로 근사하고, 이를 SGD로 최적화하는 variational ingerence 방법

📌 Reparameterization Trick

확률변수$z \sim q\phi(z \mid x)$ 를 다음과 같이 표현

$$z = g_\phi(\epsilon, x), \quad \epsilon \sim p(\epsilon)$$

→ latent variable을 noise 변수로부터 생성하도록 변환하여
⇒ gradient 계산이 가능하도록 함

📌 Expectation의 샘플링 근사

이 변환을 통해 기대값을 다음과 같이 근사 가능

$$\mathbb{E}_{q_\phi(z|x^{(i)})}[f(z)] \approx \frac{1}{L}\sum_{l=1}^{L} f(g_\phi(\epsilon^{(l)}, x^{(i)}))$$

→ 복잡한 적분을 sampling으로 계산

📌 SGVB Estimator

이를 ELBO에 적용하여 다음과 같은 estimator를 얻음

$$\mathcal{L}(\theta, \phi; x^{(i)}) \approx \frac{1}{L}\sum_{l=1}^{L} \left[\log p_\theta(x^{(i)}, z^{(i,l)}) - \log q_\phi(z^{(i,l)}|x^{(i)})\right]$$

→ ELBO를 직접 계산하지 않고 샘플링으로 근사

📌 ELBO의 분리된 형태

$$\mathcal{L}(\theta, \phi; x) = -D_{KL}(q_\phi(z|x)\|p_\theta(z)) + \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)]$$

- KL term = regularization 역할
- reconstruction term = 데이터 복원

📌 Minibatch 기반 학습

$$\mathcal{L}(\theta, \phi; X) \approx \frac{N}{M} \sum_{i=1}^{M} \mathcal{L}(\theta, \phi; x^{(i)})$$

→ minibatch를 이용해 대규모 데이터 학습 가능

📌 **AEVB 핵심 아이디어**

- $q_\phi(z \mid x)$: approximate posterior (encoder)
- $p_\theta(x \mid z)$: generative model (decoder)

→ 두 모델을 동시에 학습하여 효율적인 inference 수행

4️⃣ **Reparameterization Trick**

📌 **기본 아이디어**

확률변수 $z \sim q_\phi(z \mid x)$를 다음과 같이 표현

$$z = g_\phi(\epsilon, x), \quad \epsilon \sim p(\epsilon)$$

→ 확률적 샘플링을 결정적 함수 + 노이즈로 변환

📌 **목적**

이 변환을 통해 기대값을 다음과 같이 변경

$$\mathbb{E}_{q_\phi(z|x)}[f(z)] = \mathbb{E}_{p(\epsilon)}[f(g_\phi(\epsilon, x))]$$

→ 분포$q_\phi(z \mid x)$대신 노이즈 분포$p(\epsilon)$기준으로 계산

📌 **핵심 효과**

→ Monte Carlo 추정이 가능하면서 ϕ에 대해 미분 가능

⇒ gradient 계산 문제 해결

⚙️ **Variational Auto-Encoder (Example)**

📌 **모델 구조**

- Encoder: $q_\phi(z \mid x)$
- Decoder:$p_\theta(x \mid z)$

→ 두 네트워크를 동시에 학습

📌 **Prior 가정**

$$p(z) = \mathcal{N}(0, I)$$

→ latent variable은 표준 정규분포를 따름

📌 **Approximate Posterior**

$$q_\phi(z|x) = \mathcal{N}(z; \mu(x), \sigma^2(x)I)$$

→ encoder가 $\mu(x), \sigma(x)$를 출력

📌 **Reparameterization**

$$z = \mu(x) + \sigma(x)\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

→ sampling을 미분 가능하게 변환

📌 **Likelihood (Decoder)**

- 연속 데이터: Gaussian
- 이진 데이터: Bernoulli

→ neural network로 파라미터 생성

📌 **학습 목표 (ELBO)**

$$\mathcal{L} = -D_{KL}(q_\phi(z|x) \| p(z)) + \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)]$$

→ KL term + reconstruction term

📌 **핵심 의미**

→ encoder는 latent 분포를 학습
→ decoder는 데이터를 복원
⇒ autoencoder 구조 + 확률 모델

4. 실험 및 결과

Dataset

📌 **Dataset**

- **MNIST**
  - 손글씨 숫자 이미지 (이진 데이터)
  - Bernoulli decoder 사용
- **Frey Face**
  - 얼굴 이미지 (연속 데이터)
  - Gaussian decoder 사용

Baseline

📌 **Baseline**

- **Wake-Sleep Algorithm**
  - recognition model 기반 generative 학습 방법
- **Monte Carlo EM (MCEM, HMC sampler)**
  - sampling 기반의 확률 모델 학습 방법
- 동일한 encoder 구조 및 초기화 조건 사용
- Adagrad 기반 stochastic gradient로 학습
- Minibatch: $M = 100$, 샘플 수:$L = 1$

→ 기존 generative model 학습 방법과 공정한 비교 수행

결과

📌 **Results**

✅ **Variational Lower Bound**

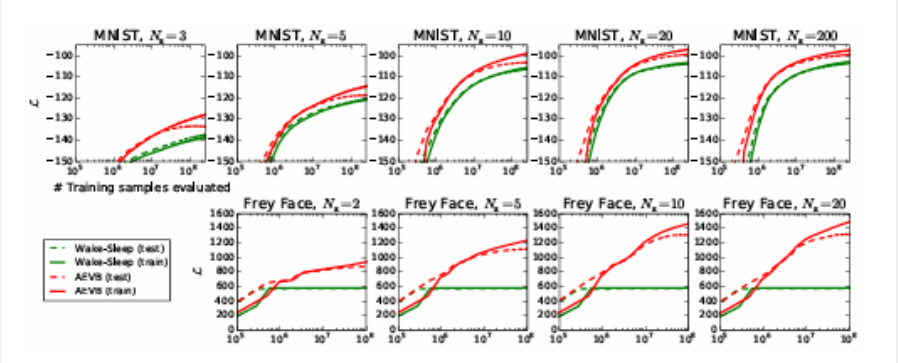

- AEVB는 Wake-Sleep보다 더 높은 ELBO를 달성
- latent 변수 수 증가에도 overfitting 발생하지 않음

→ ELBO의 KL term이 regularization 역할 수행

✅ **Marginal Likelihood**

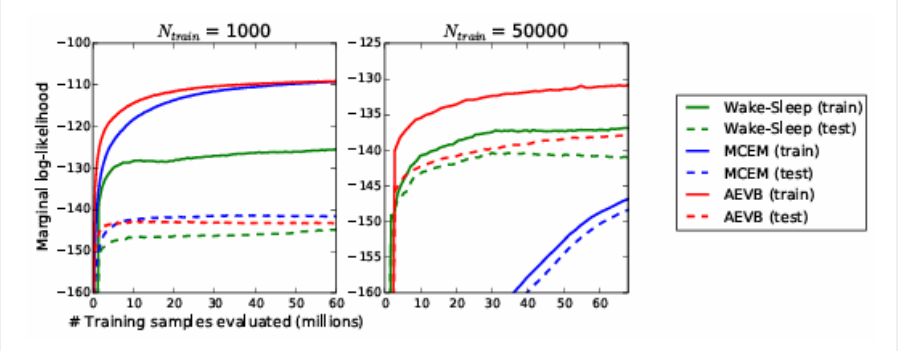

- AEVB는 MCEM 및 Wake-Sleep보다 빠르게 수렴
- 작은 데이터셋과 큰 데이터셋 모두에서 효율적인 학습 확인

→ stochastic gradient 기반 학습의 효율성 확인

✅ **Representation Learning**

- encoder를 통해 고차원 데이터를 저차원 latent space로 매핑
- latent 공간에서 데이터의 구조를 시각적으로 확인 가능

→ 의미 있는 latent representation 학습

5. 결론 (배운점)

📌 **Conclusion**

✅ **핵심 아이디어**

- posterior 계산이 어려운 문제를 해결하기 위해
  → ELBO를 sampling으로 근사하고
  → reparameterization을 통해 미분 가능하게 만들어
  → stochastic gradient 기반으로 학습 가능하게 함

✅ **AEVB 알고리즘**

- encoder$q_\phi(z \mid x)$를 학습하여 posterior를 직접 근사하고
- generative model과 함께 jointly 학습

→ 데이터마다 반복적인 inference 없이 효율적인 학습과 추론 가능

✅ **결과**

> 제안된 방법은 실험을 통해 더 높은 성능과 빠른 수렴을 보이며, 효율적인 variational inference가 가능함을 확인