13장. 생성 모델

13.1 생성 모델이란

📢 **생성 모델 개념**

> 주어진 데이터를 학습하여 데이터 분포를 따르는 유사한 데이터를 생성하는 모델

💡 입력 이미지에 대한 데이터 분포를 학습하여 새로운 이미지를 생성하는 것이 "목표"
→ 새로운 이미지면서 기존 이미지에서 특성을 추출했기 때문에 최대한 입력 이미지와 유사한 이미지

📢 **생성 모델의 유형**

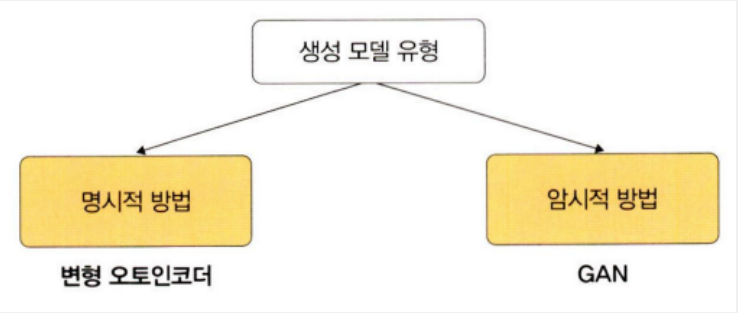

1️⃣ 명시적 방법 (explicit density)
: 확률 변수 $p(x)$를 정의하여 사용
→ 대표적인 모델 : 변형 오토인코더

2️⃣ 암시적 방법 (implicit density)
: 확률 변수 $p(x)$에 대한 정의 없이 $p(x)$를 샘플링하여 사용
→ 대표적인 모델 : GAM

13.2 변형 오토인코더

📎 오토인코더

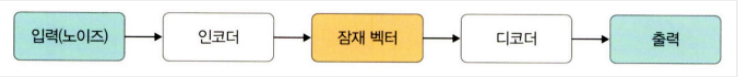

> 입력 데이터를 출력으로 복원하도록 학습하는 신경망으로, 입력보다 작은 차원의 병목층을 통해 데이터를 압축하고 그 과정에서 중요한 특징을 추출하는 모델

- 오토인코더의 주요 부분

1️⃣ 인코더
: 인지 네트워크라고 하며, 특성에 대한 학습을 수행하는 부분
2️⃣ 병목층(은닉층)
: 모델의 뉴런 개수가 최소인 계층
→ 차원이 가장 낮은 입력 데이터의 압축 표현 포함
3️⃣ 디코더
: 생성 네트워크라고 하며, 병목층에서 압축된 데이터를 원래대로 재구성하는 역할
→ 최대한 입력에서 가까운 출력을 생성하도록 함
4️⃣ 손실 재구성
: 압축된 입력을 출력층에서 재구성하며, 손실 함수는 입력과 출력(인코더와 디코더)의 차이를 가지고 계산함

- 오토인코더의 수학적 표현

1️⃣ Encoder (인코더)
: 입력 데이터 x를 압축하여 잠재 벡터 z 생성

$$z = h(x)$$

2️⃣ Decoder (디코더)
: 잠재 벡터 z를 다시 원래 차원의 데이터로 복원

$$y = g(x) = g(h(x))$$

3️⃣ Loss Function (손실 함수)
: 입력 x와 출력 y의 차이를 최소화

$$Loss = \sum L(x, g(h(x))) = \|x - y\|2$$

- 오토인코더가 중요한 이유

1️⃣ 데이터 압축
→ 중요 특성만 압축하면 용량도 작고 품질이 더 좋아짐
2️⃣ 차원의 저주 예방
→ 데이터 차원이 감소하여 차원의 저주 피할 수 있음
3️⃣ 특성 추출
→ 비지도 학습으로 자동으로 중요한 특성을 찾음

13.2.2 변형 오토인코더

📎 변형 오토인코더

> 입력 데이터를 하나의 고정된 벡터로 압축하는 대신, 평균과 분산을 이용해 잠재 공간을 확률 분포로 표현하고 그 분포에서 샘플링 한 값을 통해 데이터를 복원하는 모델

→ 입력과 완전히 동일한 데이터가 아닌 입력과 유사한 새로운 데이터 생성 가능

- 변형 오토인코더의 인코더와 디코더

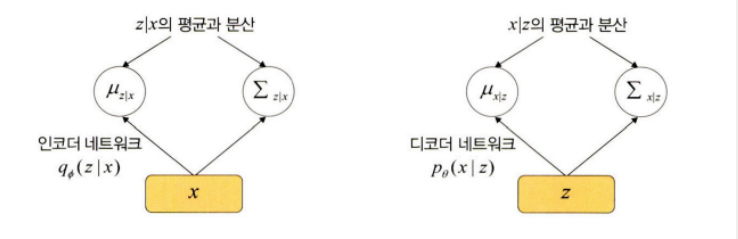

1️⃣ $q\theta(z \mid x)$ (Encoder)
: 입력 x를 받아 잠재 변수 z의 평균과 분산을 추정하는 확률 분포
→ 인코더 네트워크
2️⃣ $p\theta(x \mid z)$ (Decoder)
: 잠재 변수 z를 받아 원래 데이터 x의 평균과 분산을 추정하는 확률 분포
→ 디코더 네트워크

- 변형 오토인코더의 학습 과정

1️⃣ Encoder 단계
→ 입력 ⇒ 인코더 $q\theta(z \mid x)$
→ 평균 μ, 분산 Σ계산
→ 이를 통해 잠재 변수 z 생성

$$z \sim N(\mu, \Sigma)$$

2️⃣ Decoder 단계
→ 잠재 변수 z ⇒ 디코더 $p\theta(x \mid z)$
→ 데이터 x' 복원

📌 Loss Function

$$L(x) = Eq\theta(z \mid x)[logp\phi(x \mid z)] - DKL(q\theta(z \mid x) \| p(z))$$

- 재구성 손실 : 입력과 출력이 얼마나 비슷한지
- KL Divergence : 잠재 분포$q\theta(z \mid x)$가 정규 분포 $p(z)$와 얼마나 다른지

📌 Reparameterization Trick

$$z = \mu + \sigma \cdot \epsilon, \epsilon \sim N(0, 1)$$

→ 확률적 샘플링을 미분 가능하게 만드는 핵심 기술