논문 리뷰

[NLP] BERT 논문 리뷰

letterhill | 2026. 4. 6. 22:25

논문: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding
링크: https://arxiv.org/abs/1810.04805

BERT: Pre-training of Deep Bidirection...
We introduce a new language representation model called BERT, which stands for Bidirectional Encoder Representation...
arxiv.org

Abstract

BERT = **B**idirectional **E**ncoder **R**epresentations from **T**ransformers
본 논문에서는 BERT라는 새로운 언어 모델을 제시한다.
- 모든 layer에서 양쪽 문맥을 모두 파악하도록 양방향으로 사전 학습을 하는 모델이다.
- 단 하나의 추가 layer만으로 다양한 작업에서 최고 성능을 생성하도록 fine-tuning할 수 있으며 다양한 작업에서 구조 수정 없이 강력한 성능을 보였다.

Introduction

언어 모델 사전 학습은 많은 NLP tasks의 성능 향상에 효과적인 것으로 드러났다.

사전 학습된 언어 표현을 downstream tasks에 적용하는 기존의 두 가지 전략에 대해 살펴보자.

1. feature-based

- 특징 기반 접근법은 사전 학습 표현을 추가 feature로 포함하는 tasks별 구조를 사용한다.
- ex) ELMo

2. fine-tuning

- 미세 조정 접근법은 최소한의 tasks별 파라미터를 도입하여, 단순히 모든 사전 학습된 파라미터를 미세 조정해 사용한다.
- ex) Generative Pre-trained Transformer, OpenAI GPT

> 두 접근법의 공통점은 사전 학습 동안 동일한 objective function을 사용하며, **unidirectional** 하다는 점이다.

Unidirectional vs Bidirectional

	Unidirectional$단방향$	Bidirectional$양방향$
개념	텍스트를 한 방향$주로왼쪽에서오른쪽으로만$ 읽음	텍스트의 문맥을 양방향 $왼쪽과오른쪽모두에서$ 동시에 고려함
대표 모델	OpenAI GPT, ELMo $feature-based일부$	**BERT** $본논문이제안하는방식$
Attention 구조	현재 토큰은 **이전 토큰**$Previoustokens$에만 주목할 수 있음	현재 토큰이 문장 내의 **모든 토큰**을 동시에 참조할 수 있음
한계점	전체 문맥 파악이 중요한 문장 단위 작업이나 정밀한 토큰 단위 작업$QA등$에서 성능이 제한됨	기존의 단방향 제약을 해결하여 더 강력한 표현력을 가짐
학습 방식	다음 단어를 예측하는 표준적인 언어 모델 방식	문맥 전체를 보고 빈칸을 채우는 등의 방식 $MaskedLM$

BERT

- 본 논문에서 제시하는 모델
- BERT$BidirectionalEncoderRepresentationfromTransformer$을 제안하여 파인튜닝 기반 접근 방식을 개선한다.
- Cloze task로부터 영감받은 'Masked Language ModelMLM'을 사전 학습한다.
- MLM: 입력에서 일부 토큰을 랜덤으로 마스킹하며, 양방향에서 마스킹된 단어를 예측한다.

Contributes

- 언어 표현을 위한 양방향 사전 학습의 중요성을 보여줌
- 너무 과하게 정교한 파인튜닝의 불필요성을 보여줌
- 11개의 NLP 작업에서 특화된 성능을 보여줌

Related Work

해당 파트에서는 언어 표현 사전학습 방법의 긴 역사와, 가장 널리 사용되는 접근법들에 대해 간략하게 소개한다.

Unsupervised Feature-based Approaches 비지도 특성기반 접근법

- 문장 임베딩, 구절 임베딩과 같은 분야로 세분화됨
- 문장 표현을 학습하기 위해, 이전의 연구들은 다음 문장 후보를 랭킹화하고, left-to-right 생성 방법, denoising auto-encoder 파생 방법 등을 사용했다.
- ELMo와 같은 후속 모델들은 이전 연구들과 달리 left-to-right와 right-to-left 언어 모델을 통해 context-seneitive feature을 추출했다.
=> 다만 해당 모델들은 deep bidirectional하지 않았다.

Unsupervised Fine-tuning Approaches 비지도 미세조정 접근법

- 라벨이 없는 텍스트로부터 단어 임베딩 파라미터만을 학습하는 연구
- 최근에는 문맥 토큰을 생성하는 문장이나 문서 인코더를 라벨없는 텍스트로 사전 학습하고 지도 downstram task를 위해 미세조정된다.
- 장점: 처음부터 학습할 파라미터가 거의 없어 문장 수준의 작업에서 좋은 성능을 기록했다.

Transfer Learning from Supervised Data 지도 데이터로부터의 전이 학습

- 자연어 추론 및 기계 번역, CV와 같은 대규모 데이터셋에서 효과적인 성과를 보여주는 연구
- ImageNet으로 사전 학습된 모델을 미세 조정하여 사용

3. BERT

BERT에서는 두 개의 과정을 거친다.
1. Pre-train 2. Fine-tunning

사전 학습$pre-training$ 단계에서, 모델은 라벨링되지 않은 데이터로 각각의 사전 학습 작업을 수행하고, 미세 조정$fine-tunning$ 단계에서는 사전학습된 파라미터로 초기화를 진행하고, 모든 파라미터는 downstream 작업에서 얻은 라벨링된 데이터를 사용하여 미세조정한다.

Model Architecture

구조: 양방향 트랜스포머 인코더를 여러 층으로 쌓은 구조
L: # of layers
H: hidden size
A: # of self-attention heads

| 대표적인 두 가지 모델
1. $BERT_{BASE}$ $L=12, H=768, A=12, TotalParams=110M$
2. $BERT_{LARGE}$ $L=24, H=1024, A=16, TotalParams=340M$

$BERT_{BASE}$모델의 경우 OpenAI의 GPT와 같은 모델 사이즈를 가졌지만, 한 방향으로 학습하는 $unidirectional$ 지피티와 달리, bidirectional하다는 점이 차이점이다.

Input/Output Representations
모든 시퀀스의 첫 입력 토큰은 [CLS]이다. 시작을나타내는토큰
[문장들을 구분하는 방법]
1. 스페셜 토큰인 [SEP]를 넣어 구분한다.
2. 문장 A인지, 문장 B인지 구분하는 학습된 임베딩 E를 모든 토큰에 넣는다.

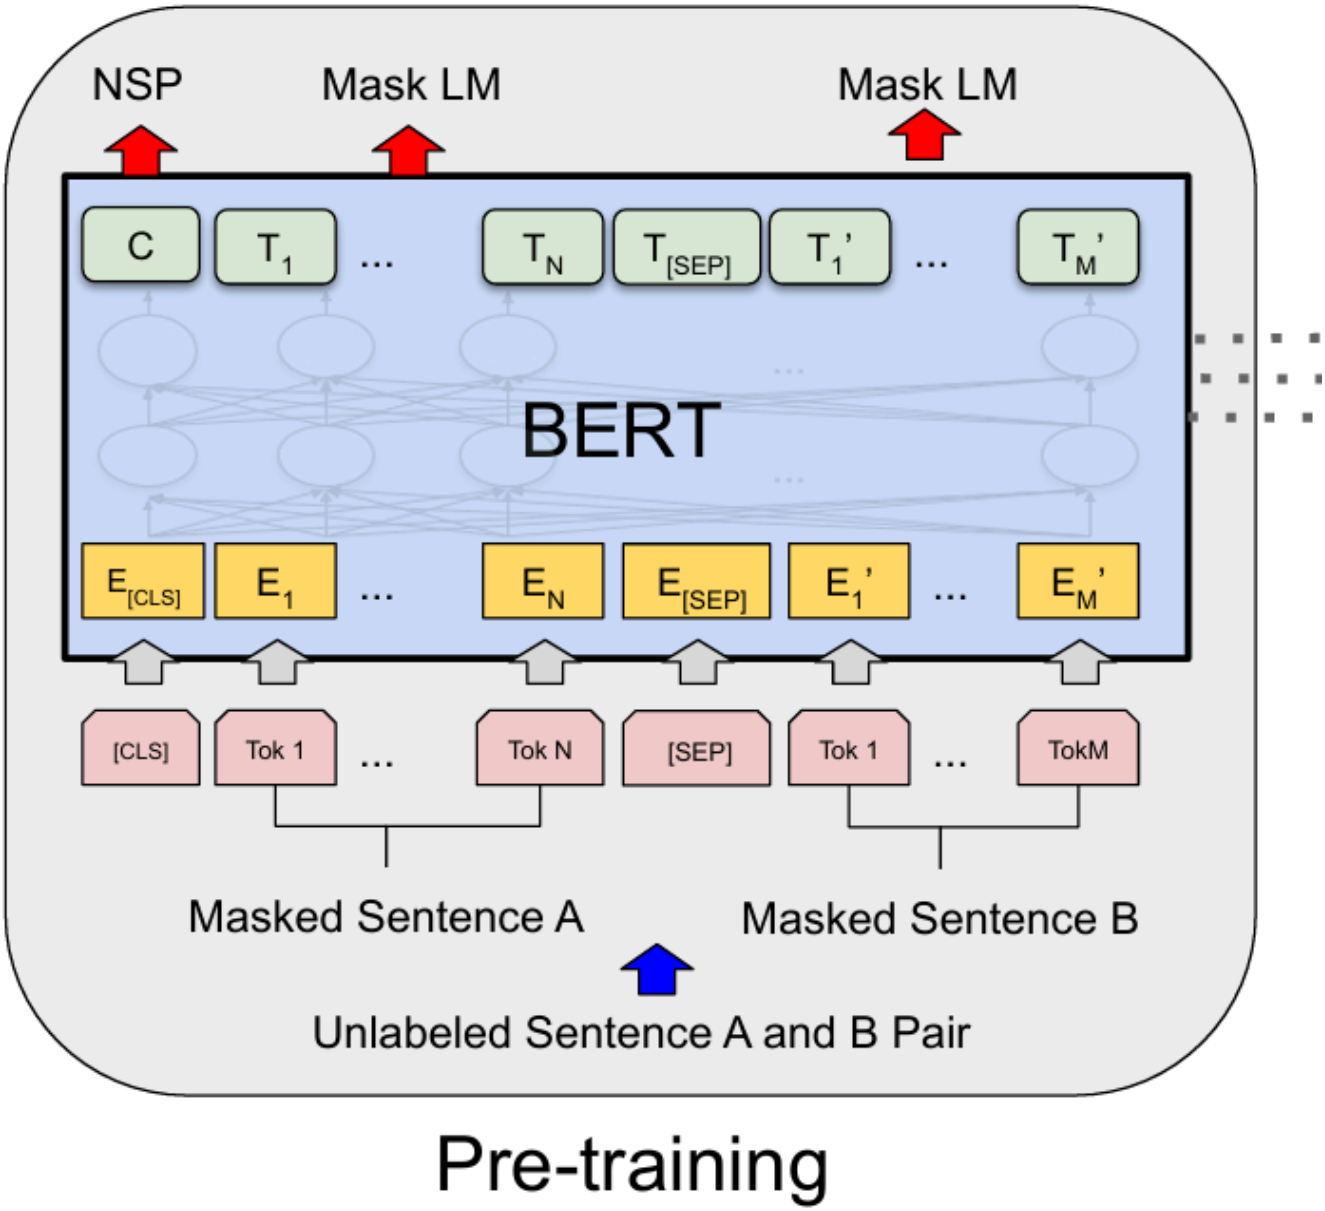

Figure 1

따라서, input seqence가 주어지면 token embedding, segmentation문장구분, position embedding입력시퀀스에서의단어위치를나타내는토큰 으로 나뉘게 된다.

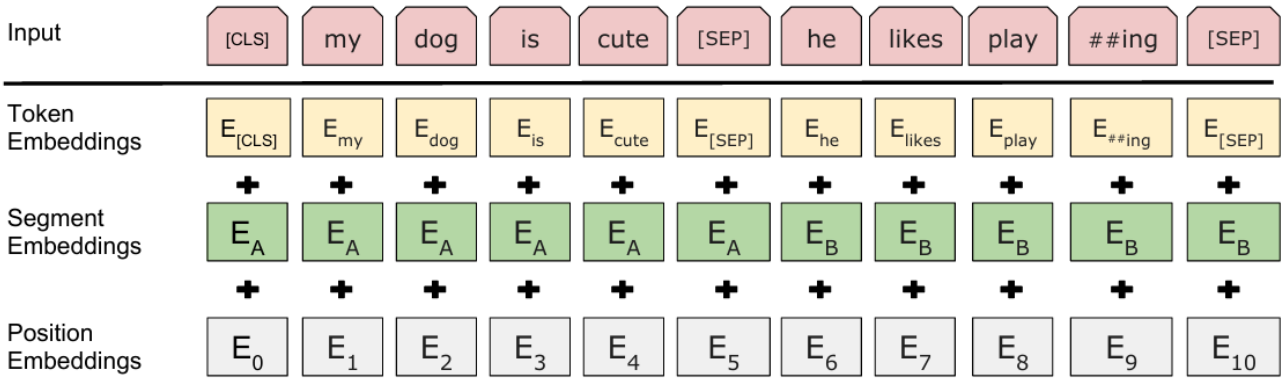

Pre-training BERT

입력 시퀀스를 왼쪽에서 오른쪽 단방향으로 탐색하는 기존의 방법을 사용하지 않고, 크게 두 가지 unsupervised-tasks를 사용한다. 해당 방법에 대해 아래에서 살펴본다.

Task #1: MLM $MaskedLM$
- 입력 시퀀스의 일정 비율을 랜덤으로 마스킹하고, 마스킹된 단어를 양방향에서 예측하는 과정이다.

> **문제점: Mismatch between pre-training and fine-tuning**
> 사전 학습 단계에서는 마스킹을 할 수 있지만 fine-tuning 단계에서는 [MASK] 토큰이 나타나지 않아 그 사이 간극이 있다는 단점이 있다.

토큰 위치를 15%를 랜덤으로 선택
1) 80%의 확률로 [MASK] ex) I love [MASK]
2) 10%의 확률로 random word로 대체 ex) I love apple
3) 10%의 확률로 i번째 토큰기존단어그대로으로 두기 ex) I love you
-> Cross Entropy Loss

Task #2: NSP (Next Sentence Prediction
: 두 문장 사이의 관계를 예측하는 작업
문장 A,B를 선택할 때,
- 50%는 A의 다음 문장인 B를 고르고 $IsNext$
- 50%는 랜덤 문장인 NotNext를 고름
- C: NSP를 나타내는 토큰

Fine-tuning BERT
- 미세 조정 과정은 단방향 작업으로 진행된다.
- 입출력은 downstream tasks에 따라 달라진다.
- 사전 학습 과정에 비해 계산 비용이 덜 든다.

4. Experiments

그렇다면, BERT의 실제 적용 실험 결과에 대해서 살펴보자.
본 논문에서는 11개의 NLP tasks에서 fine-tuning 결과를 보여주었다.

1) GLUE

> The General Language Understanding Evaluation

: 다양한 자연어 이해 작업의 collection

- GLUE에서 fine-tuning을 위해 입력 시퀀스를 3절에서 소개한대로 표현하고, 첫 번째 입력 토큰 $[CLS]$에 해당하는 최종 hidden vection C가 출력된다. 미세 조정 단계에서 추가된 유일한 새로운 파라미터는 분류 층 가중치 W이다.
- $W \in R^{K \times H}$:
- K: # of labels
- 표준 분류 손실 계산: $log(softmax(CW^T))$

- batch_size = 32, epoch=3으로 파인 튜닝

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	**Average** -
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.8	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	82.3	56.0	75.1
$BERT_{BASE}$	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
$BERT_{LARGE}$	**86.7/85.9**	**72.1**	**92.7**	**94.9**	**60.5**	**86.5**	**89.3**	**70.1**	**82.1**

GLUE Test Results

- 결과표를 살펴보면 모든 작업에서 다른 모델에 비해 높은 성능을 보인 것을 확인할 수 있다.

2) SQuADv1.1

> The Stanford Question Answering Dataset

: 10만개의 군중 source question/answer 쌍으로 구성된 데이터셋

- 답을 포함한 Wikipedia로부터 주어진 질문에, 구문 중 답의 범위를 예측하는 작업
- input question과 구절을 single packed sequence로 표현한다.
- '질문과 답'이 포함되어있는 '구절'이 주어지면 그 구절에서 어디부터 어디까지 answer에 해당하는 범위인지 예측하는 모델 학습

학습 방법

질문: A 임베딩
구절: B 임베딩
A와 B 두 sentence를 하나의 시퀀스로 연결하여 passage 내 토큰이 answer 범위의 시작/끝 토큰이 도리 확률을 구한다.
- start vector $S \in R^H$과 end vector $E \in R^H$만 추가 도입한다.
- i: answer 구간의 시작일 확률이 가장 높은 index
T_i와 S의 내적으로 구한다.
- j: answer 구간의 끝일 확률이 가장 높은 index

token이 answer의 시작이 될 확률 = softmax$tokenT_i$와S의내적
token이 answer의 끝이 될 확률 = softmax$tokenT_i$와S의내적

$$P_i = \frac{e^{S \cdot R_i}}{\sum_j e^{S \cdot R_j}} \qquad P_i = \frac{e^{E \cdot R_i}}{\sum_j e^{E \cdot R_j}}$$

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	-	-	82.3	91.2
#1 Ensemble - nlnet	-	-	86.0	91.7
#2 Ensemble - QANet	-	-	84.5	90.5
Published				
BiDAF+ELMo (Single)	-	85.6	-	85.8
R.M. Reader (Ensemble)	81.2	87.9	82.3	88.5
Ours				
$\text{BERT}_{\text{BASE}}$ (Single)	80.8	88.5	-	-
$\text{BERT}_{\text{LARGE}}$ (Single)	84.1	90.9	-	-
$\text{BERT}_{\text{LARGE}}$ (Ensemble)	85.8	91.8	-	-
$\text{BERT}_{\text{LARGE}}$ (Sgl.+TriviaQA)	**84.2**	**91.1**	**85.1**	**91.8**
$\text{BERT}_{\text{LARGE}}$ (Ens.+TriviaQA)	**86.2**	**92.2**	**87.4**	**93.2**

Table 2: SQuAD 1.1 results. The BERT ensemble is 7x systems which use different pre-training checkpoints and fine-tuning seeds.

SQuAD 1.1 Results

3) SQuADv2.0

SQuADv1.1의 문제를 확장하여 문제를 더 현실적으로 만든다.

제공된 paragraph에 정답이 포함되어 있지 않을 확률 고려!

- 답변이 없는 질문 -> [CLS] 토큰에서 시작하고 끝난다고 처리

$$s_{null} = S \cdot C + E \cdot C \qquad \hat{s_{i,j}} = \max_{j \geq i} S \cdot T_i + E \cdot T_j.$$

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	86.3	89.0	86.9	89.5
#1 Single - MIR-MRC (F-Net)	-	-	74.8	78.0
#2 Single - nlnet	-	-	74.2	77.1
Published				
unet (Ensemble)	-	-	71.4	74.9
SLQA+ (Single)	-		71.4	74.4
Ours				
$\text{BERT}_{\text{LARGE}}$ (Single)	78.7	81.9	80.0	83.1

SQuAD 2.0 Results

4) SWAG

> The Situations With Adversarial Generations

: 현실적인 상식추론을 평가하는 113,000개의 문장 쌍 완성 예제 포함

- 주어진 문장에 대해, 네 가지 선택지 중 가장 그러듯한 이어질 문장을 선택하는 task 수행
- 미세 조정 시 문장 A와 가능한 이어지는 문장 B를 연결한 네 개의 입력 시퀀스를 구성한다.
- 추가된 점: [CLS] 토큰 표현과 내적을 통해 각 선택지의 점수를 나타내는 벡터 -> 소프트맥스

System	Dev	Test
ESIM+GloVe	51.9	52.7
ESIM+ELMo	59.1	59.2
OpenAI GPT	-	78.0
$\text{BERT}_{\text{BASE}}$	81.6	-
$\text{BERT}_{\text{LARGE}}$	**86.6**	**86.3**
Human (expert)†	-	85.0
Human (5 annotations)†	-	88.0

SWAG Results

Ablation Studies

이 챕터에서는 BERT의 여러 부분에 대해 조정하는 실험을 수행하여 각 요소의 상대적인 중요성을 이해해본다.

Effect of Pre-training Tasks

동일한 파라미터를 사용하여 BERT의 deep bidirectional의 중요성을 보여준다.
- NO NSP: NSP 없이 MLM만 사용하여 학습된 양방향 모델
- LTR&NoNSP
: MLM이 아닌, 표준 L->RLTR 사용, NSP 사용X

Tasks	Dev Set MNLI-m (Acc)	QNLI (Acc)	MRPC (Acc)	SST-2 (Acc)	SQuAD (F1)
$\text{BERT}_{\text{BASE}}$	84.4	88.4	86.7	92.7	88.5
No NSP	83.9	84.9	86.5	92.6	87.9
LTR & No NSP	82.1	84.3	77.5	92.1	77.8
+ BiLSTM	82.1	84.1	75.7	91.6	84.9

=> 모든 경우에서 성능이 떨어졌다.

Effect of Model Size

- 모델 크기가 미세 조정 과제 정확도에 미치는 영향에 대해 알아본다.
- layer 수, hidden unit 수, attention head 수를 다르게 함

Hyperparams				Dev Set Accuracy		
#L	#H	#A	LM (ppl)	MNLI-m	MRPC	SST-2
3	768	12	5.84	77.9	79.8	88.4
6	768	3	5.24	80.6	82.2	90.7
6	768	12	4.68	81.9	84.8	91.3
12	768	12	3.99	84.4	86.7	92.9
12	1024	16	3.54	85.7	86.9	93.3
24	1024	16	3.23	86.6	87.8	93.7

=> 모델 사이즈가 클수록 정확도가 높아진다는 것을 볼 수 있다.

Feature-based Approach with BERT

특징 기반 접근법이 장점을 가지는 경우

1) 모든 task가 transformer encoder로 표현하기 힘들기 때문에 task-specific architecure가 추가되어야 하는 경우

2) pre-trained된 features를 고정적으로 사용하여 연산량을 줄일 수 있는 장점

System	Dev F1	Test F1
ELMo (Peters et al., 2018a)	95.7	92.2
CVT (Clark et al., 2018)	-	92.6
CSE (Akbik et al., 2018)	-	**93.1**
Fine-tuning approach		
$\text{BERT}_{\text{LARGE}}$	96.6	92.8
$\text{BERT}_{\text{BASE}}$	96.4	92.4
Feature-based approach ($\text{BERT}_{\text{BASE}}$)		
Embeddings	91.0	-
Second-to-Last Hidden	95.6	-
Last Hidden	94.9	-
Weighted Sum Last Four Hidden	95.9	-
Concat Last Four Hidden	96.1	-
Weighted Sum All 12 Layers	95.5	-

=> fine-tuning approach의 성능이 더 높지만 feature-based approach와의 차이가 적음

- BERT는 두 가지 접근법에서 모두 효과적이라는 사실을 알 수 있다.

Conclusion

전이 학습을 통한 최근의 경험 향상은 비지도 사전 학습이 많은 언어 이해 시스템의 핵심 요소임을 시사했다.

특히, resource가 적은 작업에서도

공감

'논문 리뷰' 카테고리의 다른 글

[강화학습] Playing Atari with Deep Reinforcement Learning DQN 논문 리뷰 0 2026.03.30

'논문 리뷰' Related Articles

NO IMAGE

[강화학습] Playing Atari with Deep...

letterhill 님의 블로그

letterhill 님의 블로그 입니다.

댓글 0

letterhill

내용을 입력하세요.

등록

DESIGN BY TISTORY | 관리자