

논문 리뷰

[paper] AN IMAGE IS WORTH 16X16 WORDS:TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE 논문리뷰

letterhill | 2026. 5. 5. 17:36 ⓘ

1. Introduction

NLP 분야에서 Self-attention 기반의 모델들은

연산 효율성과 확장성이라는 장점 덕에 1000억 개 이상의 parameters를 가진 모델까지도 훈련 가능해져 모델과 데이터셋이 계속해서 늘어나도 saturating 현상이 없었다.

하지만 Computer vision에서는 여전히 convolution 구조가 우세하다.

NLP에서 뛰어난 성능을 보였기 때문에 CNN에 self-attention의 결합을 시도하는 다양한 연구들이 있다.

합성곱을 완전히 대체하는 모델들은 이론적으로 효율적이지만, specialized된 attention patterns을 사용하기에 현대 하드웨어 accelerators에서는 논문 출범 당시 효과적으로 확장되지 않아, 고전적인 resnet을 cv 분야에서 주로 사용하였던 시기였다.

NLP에서 transformer의 성공에 영감받아, 본 논문에서는 가능한 작은 수정으로 이미지에 standard transformer를 적용하는 실험을 진행하였다. 이를 위해 이미지를 patches로 나누고, 패치의 linear embedding 시퀀스를 transformer의 입력으로 제공한다. 이미지 패치는 NLP에서의 token단어와 동일하다고 보면 된다. 모델은 지도 학습 방식으로 이미지 분류에 대해 학습하였다.

중간 규모나 작은 크기의 데이터셋에 vit를 적용하면, resnet보다 낮거나 비슷한 수준의 정확도를 보이지만,
큰 데이터셋에 ViT를 적용한 결과 높은 정확도를 보인 것을 실험으로 증명하였다.

2. Related Work

트랜스포머는 기계 번역을 위해 제안되어 이후 NLP task에서 가장 효과적인 method가 되었다. 대규모 트랜스포머 기반 모델은 large corpora로 학습 -> 특정 task에 적합하게 fine-tune된다.

- BERT: 자기 학습 denoising을 사전 학습 task로 사용

- GPT 계열: 언어 모델링을 사전 학습 task로 사용

self-attention을 이미지에 단순히 적용하는 것은 임지 | 의 모든 pixel이 다른 모든 pixel에 attends한다. -> 픽셀 수에 따라 quadratic한 const 발생하는 문제가 있다.

sol) 다양한 approximate 방법들로 해결

- 1 local neighbor에만 self-attention을 적용하는 방법

- 2 Sparse Transformers

- 3 다양한 크기의 block이나 개별 축을 따라서만 attention 적용

논문에서 다룰 ViT와 가장 관련 있는 모델: "Cordonnier 모델"

- 입력 이미지에서 2x2 사이즈의 patch들을 추출하여 그 위에 self-attention을 적용

- ViT와 매우 유사하지만 더 큰 resolution의 이미지에도 적용 가능하다는 것이 ViT의 차별성이다.

3. Method

모델 디자인에서는 기존 Transformer의 작동 원리와 유사하다.




Figure 1

3.1 Vision Transformer ViT

standard transformer 모델에는 1차원 토큰 임베딩 시퀀스를 입력으로 넣어야 한다.

우리가 다룰 이미지는 2차원이므로, 이를 1차원으로 펼쳐주는 *flatten* 과정이 필요하다.

$$H * W * C \rightarrow N * (P^2 * C)$$

* P , P : 각 이미지 패치의 해상도

* $N = HW/P^2$: 결과 패치의 수 = 트랜스포머의 입력 시퀀스 길이

BERT의 [class] 토큰과 같이, 학습 가능한 임베딩 $z_0^0 = x_{class}$ 을 미리 추가한다.

Transformer 인코더의 출력 상태 z_L^L 는 이미지 representation y 에 사용된다.

사전학습과 fine-tuning 둘 다에서 분류 헤드는 z_L^0 에 부착된다.

- 사전 학습 시: 하나의 hidden layer를 가진 MLP로 구현

- Fine-tuning: 단일 linear layer로 구현

[Positional embedding]

- 위치 정보를 유지하기 위해 패치 임베딩에 추가됨

- 1D positional embedding을 사용 -> 결과로 생성된 임베딩 벡터의 시퀀스는 인코더의 input으로 들어감

[인코더의 구조]

멀티헤드된 self-attention MSA - MLP 블록 - LN 적용 - residual connections

[Inductive bias]

ViT가 CNN보다 훨씬 더 적은 이미지 특화 inductive bias를 가진다.

CNN

- locality 커널범위만 탐색하기 때문
- 2차원 neighborhood 구조
- translation equivariance: 입력데이터가 이동하면 출력도 함께 이동

ViT

- MLP 층만 local, self-attention 층은 global
- 2차원 neighbor 구조는 드물게 사용됨
- 위치 임베딩이 2D 위치에 대한 정보 제공X
- 패치 간 모든 spatial 관계 -> 처음부터 학습

** inductive bias란?

: 모델이 학습 데이터로부터 일반적인 패턴을 추론할 때 특정 방식으로 추론하려는 경향

[Hybrid Architecture]

- raw image 패치 대신하여, CNN으로부터 얻은 feature map을 input으로 넣는 모델
- 위 모델에서는 식1이 CNN feature map에서 추출된 patches에 적용된다.
- feature map은 이미 공간적 정보를 포함하므로 1x1 패치도 가능하다.
- classification/positional embedding 추가는 동일한 방식

3-2 Fine-Tuning and higher resolution

- ViT는 large 데이터셋으로 사전 학습 -> downstream tasks로 fine-tune한다.
- 위의 과정을 위해, 사전 학습의 예측 헤드를 제거하고 $D * K$ 의 0으로 초기화된 feedforward layer를 붙이는 과정이 필요하다.

* K: downstream 클래스의 수

- 사전학습보다 더 높은 해상도에서 fine-tune하는 것이 종종 유리함
- fine-tuning 시에 더 높은 해상도의 이미지를 입력한다면, patch size는 동일하지만 시퀀스 길이는 더 커지게 된다.
- ViT는 다른 길이의 패치 처리가 가능하지만, 사전 학습의 positional embedding은 의미를 잃게 되기 때문에, 원본 이미지의 위치에 따라 2d 보간을 거치게 된다. => inductive bias

4. Experiments

본 논문에서는 ResNetCNN기반, ViT, 그리고 하이브리드 모델들을 비교하는 실험을 다양한 크기의 데이터셋에서 진행한다.

4.1 Setup

[Datasets]

데이터셋	이미지 수	클래스 수
ILSVRC-2012	130만 장	1k
ImageNet-21k	1400만 장	21k
JFT	3억 30만 장	18k

[Model Variants]

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

Table 1: Details of Vision Transformer model variants.

[Traning&Fine-tuning]

- Optimizer: Adam
- batch_size: 4096
- weight decay: 0.1
- SGD+momentum
- 더 높은 해상도로 fine-tune하는 기법 사용

[Metrics]

두 가지의 metrics 사용

1 few-shot

- training images의 subset에 대한 *frozen* representation을 $\{-1, 1\}^K$ 에 매핑

2 fine-tuning accuracy

- 각 데이터셋에서 모델의 fine-tune 이후의 성능

4.2 Comparison to State of the Art

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet ReaL	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

- 논문에서 제안한 모델: ViT-H/14, ViT-L/16

- 비교 모델: BiT, Noisy Student

* BiT: 대형 ResNet, supervised learning 수행

* Noisy Student: ImageNet과 라벨 제거 JFT 300M에서 semi-supervised learning을 수행하는 대형 EfficientNet




Figure 2: Breakdown of VTAB performance in *Natural*, *Specialized*, and *Structured* task groups.

[결과]

* ViT-H/14: Natural&Structued 과제에서 특히 우수한 성능을 보인다.

* ViT-L/16: 대부분의 데이터셋에서 좋은 성능을 나타내며, 사전 학습에 더 적은 data를 사용한다.

4.3 Pre-training data requirements

ViT는 ResNet보다 inductive bias가 적기 때문에 대규모 데이터셋에서 더 성능이 좋다.

작은데이터셋에서는비교적낮은성능

- 아래는 데이터셋 크기에 따른 성능을 알아보기 위해 다양한 실험을 진행한 결과의 표들이다.




Figure 3: Transfer to ImageNet. While large ViT models perform worse than BiT ResNets (shaded area) when pre-trained on small datasets, they shine when pre-trained on larger datasets. Similarly, larger ViT variants overtake smaller ones as the dataset grows.




Figure 4: Linear few-shot evaluation on ImageNet versus pre-training size. ResNets perform better with smaller pre-training datasets but plateau sooner than ViT, which performs better with larger pre-training. ViT-b is ViT-B with all hidden dimensions halved.




Figure 5: Performance versus pre-training compute for different architectures: Vision Transformers, ResNets, and hybrids. Vision Transformers generally outperform ResNets with the same computational budget. Hybrids improve upon pure Transformers for smaller model sizes, but the gap vanishes for larger models.

[결과]

- **작은 데이터셋:** CNN *BiT*은 이미지 특유의 공간적 구조를 이해하는 'inductive bias' 덕분에 ViT보다 성능이 우수하다. 반면, ViT는 bias이 부족하여 작은 데이터에서는 쉽게 과적합된다.
- **대규모 데이터셋:** 데이터가 90M9천만장을 넘어서기 시작하면 ViT가 ResNet 기반 모델의 성능을 앞지르는 것을 볼 수 있다. 데이터가 충분하면 모델이 스스로 유용한 패턴을 학습하는 것이 더 유리하다는 것을 보여준다.

4.4 Scaling study

모델 size와 computation 대비 성능을 분석한다.

모델	결과
ResNet <i>CNN</i>	ViT 대비 성능이 떨어짐
ViT <i>Transformer</i>	같은 성능에서 CNN보다 2~4배 적은 연산량
Hybrids <i>CNN + ViT</i>	낮은 데이터셋에서만 좋은 성능

4.5 Inspecting Vision Transformer

ViT가 image데이터를 처리하는 방법을 내부 표현을 통해 분석한다.


1 Patch Embedding

- ViT의 첫 번째 층에서 이미지의 flatten patches들을 저차원으로 linearly projection 수행할 때, 패치 내부의 미세 구조를 표현하는 **기저 함수** *Basis functions* 형태로 학습된다.

2 Position Embeddings 학습


- 각 패치의 위치 정보를 나타내는 positional embedding이 2D Topology을 스스로 학습하는 과정
 - 가까운 패치끼리는 비슷한 positional embedding 값을 가진다.
 - low-column 구조**: 같은 행이나 열에 있는 패치들끼리 유사한 패턴을 보인다.
- 모델이 스스로 2D 구조를 학습하기 때문에, 사람이 직접 설계한 복잡한 2D 위치 임베딩을 써도 성능 향상이 거의 없는 것입니다.

3 Attention Distance



- 모델이 정보를 통합할 때 참조하는 이미지 상의 물리적 거리를 의미
- **주요 특징:**
 - 최하위 레이어에서도 이미지 전체를 한꺼번에 보는 'Head'가 존재합니다.
CNN과의 차이점
 - **local information:** 동시에 일부 헤드는 매우 local한 영역에 집중한다.
CNN의 initial conv layer와 유사한 기능
 - **깊이에 따른 변화:** 레이어가 깊어질수록 attention distance가 커지며, 최종적으로는 위의 사진처럼 분류에 중요한 의미 있는 영역 *Semantically relevant regions*에 attention하게 된다.

4.6 Self-Supervision



- BERT처럼 masked patch에 대한 예측 학습 실험도 수행하본 결과, 처음부터 학습했을 때보다 2% 향상된 성능을 보였지만, supervised pre-training보다 4% 낮은 성능을 보였다.

5. Conclusion

- 본 논문의 제안 method: 이미지 인식에 Transformer를 직접 적용
- 차별점: 초기 patch 추출 단계 외에는 image-specific inductive biases를 구조에 더하지 않음.
- 결과: ViT는 많은 image classification dataset에서 우수한 성능을 보였으며, 학습 효율성도 뛰어나다는 결과를 실험을 통해 증명했음

<YOLO-Introduction>

인간은 이미지를 한눈에 보고 빠르게 이미지의 전체 내용을 파악한다.

-> 인간과 같이 객체를 감지하는 알고리즘이 있다면? 에서 YOLO가 시작되었다.

[기존 system의 limitations]

- DPM: Sliding Window 방식을 통해 이미지 전체를 스캔
 - R-CNN: 탐색할 후보 영역인 Bounding box를 생성하고, 분류기를 실행한다.
- = Post-processing, 중복 제거, rescoring 등의 복잡한 과정을 거쳐야 한다는 문제점이 있다.

[YOLO]

- 이미지를 딱 한 번 보고 객체의 위치를 탐지할 수 있는 알고리즘이다.
- Single regression problem: 객체 탐지를 임지 | 픽셀에서 bounding box의 좌표 -> class 확률로 바로 연결한다.
- Single ConvNet으로 여러 바운딩 박스와 그에 해당하는 class 확률을 동시 예측한다.

[YOLO의 장점]

- 복잡한 과정 없이 한 번의 ConvNet 실행으로 끝나기 때문에 속도가 빠르다.
- 이미지 전체를 보기 때문에 local하지 않고 contextual information까지 학습하여 오류가 적다.



'논문리뷰' 카테고리의 다른 글

deep residual 논문 리뷰 2	2026.05.02
[NLP] BERT 논문 리뷰 1	2026.04.06
[강화학습] Playing Atari with Deep Reinforcement Learning_DQN 논문 리뷰 0	2026.03.30

'논문 리뷰' Related Articles

NO IMAGE

deep residual 논문 리뷰

NO IMAGE

[NLP] BERT 논문 리뷰

NO IMAGE

[강화학습] Playing Atari with Deep...

letterhill 님의 블로그

letterhill 님의 블로그입니다.

