letterhill 님의 블로그

메뉴바를 클릭하면
계정을 관리할 수 있어요

카테고리 없음

[paper] Attention is All You Need

letterhill 2026. 3. 16. 22:58

1. Abstract

💡
논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

연속 데이터를 다루는 모델 → 인코더와 디코더를 포함하는 복잡한 재귀 or CNN 모델
가장 효과적인 모델 : 어텐션 메커니즘을 사용하는 인코더-디코더 연결 모델
위 논문에서는 반복과 합성곱을 배제하고 오로지 Attetion mechanism을 기반으로 한 새롭고 간단한 Transformer 네트워크 구조를 제안한다.
RNN, LSTM 및 게이트 RNN은 시퀀스 모델링(ex. 언어 모델링, 기계 번역 분야에서 최첨단 접근 방식으로 확고히 자리 잡았다.
그 이후로 수많은 노력이 계속되어 순환 언어 모델과 인코더-디코더 구조의 경계를 허물고 있다.

2. Introduction

기존 RNN 모델

- 시퀀스 데이터를 처리할 때 위치 정보도
- 이전 은닉층 h_{t-1}과 현재 시점 t의 입력 데이터를 기반으로 현재 시점의 은닉층 h_t를 생성

→ 병렬 처리 불가, 입력 시퀀스가 길어질수록 비효율적이고 연산량 증가

Transformer

- 위 논문에서 제안하는 모델 구조
- 입출력 간의 전역성에만 집중하는 Attention Mechanism에만 전적으로
- 병렬 처리

메뉴바를 클릭하면
계정을 관리할 수 있어요

3. Model Architecture

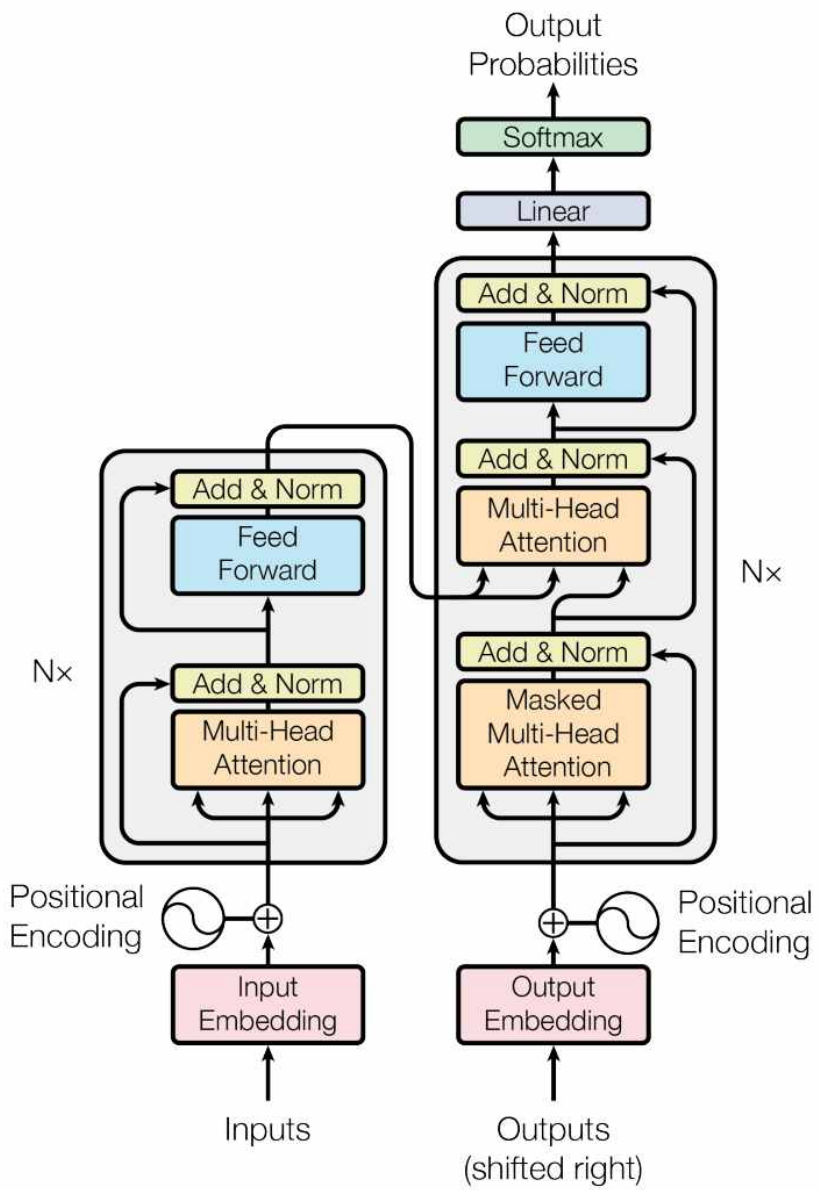

Figure 1: The Transformer - model architecture.

트랜스포머 구조

Transformer는 위와 같은 전반적인 구조를 따른다.

- 왼쪽은 Encoder, 오른쪽은 Decoder

- self-attention과 point-wise, 완전 연결층 인코더-디코더 형태

3.1 Encoder and Decoder Stacks

Encoder

- 인코더는 N=6개의 동일한 층으로 구성된다.
- 각각의 층은 2개의 하위 레이어를 가진다.

첫 번째 sub-layer: multi-head self-attention mechanism

두 번째 sub-layer : 간단한, position-wise fully connected 순방향 네트워크

-> 2개의 하위 레이어에 residual connection & normalization 수행

=> 하위 계층의 출력: $LayerNorm(x + Sublayer(x))$

Decoder

- 디코더도 동일하게 N=6의 동일한 층으로 구성된다.
- 디코더는 2개의 하위 레이어에 더불어, multi-head attention을 수행하는 3번째 레이어를 추가로 가진다.
- 인코더와 동일하게 resudual connection & normalization 수행

메뉴바를 클릭하면
계정을 관리할 수 있어요

Attention

- query, keys, values로 구성
- output은 값들의 가중합으로 계산됨
- 각 values에 할당된 가중치는 query와 key의 상호 관계성에 의해 계산된다.

> self-attentin은 입력 시퀀스 안에서의 단어들 간의 관계를 나타내는 것이다.

Query$Q$, Key$K$, Value$V$의 3가지로 표현해 output을 출력한다.

주체가 Q, 연관성을 알아보려는 그 대상이 K, 유사도 값이 Value이다.

Scaled Dot-Product Attention

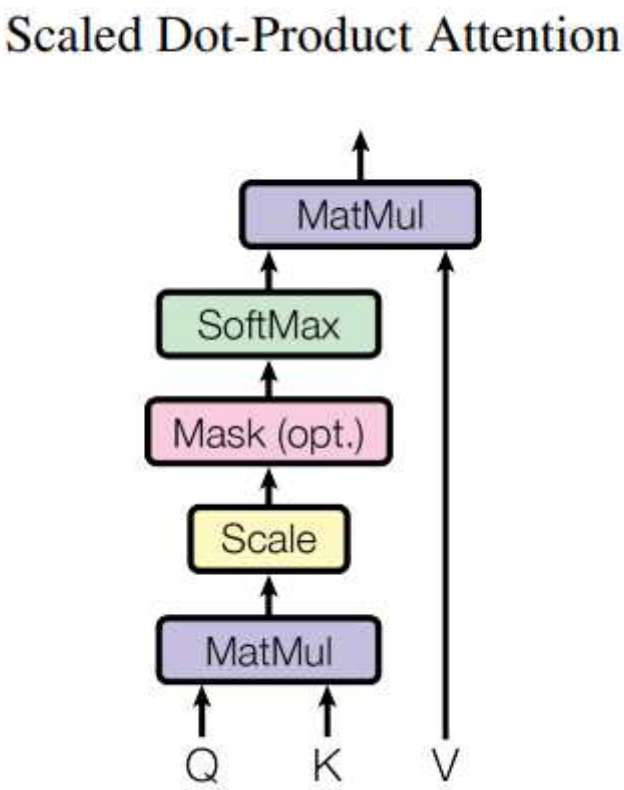

메뉴바를 클릭하면
계정을 관리할 수 있어요

Input은 d_k 차원의 쿼리와 키로 구성되며, values의 차원은 d_v이다.
쿼리와 키 값을 모두 내적하고, $ \sqrt d_k$로 나눈 뒤 softmax 함수를 적용한다.

$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

Attention 행렬 계산 수식

Multi-Head Attention

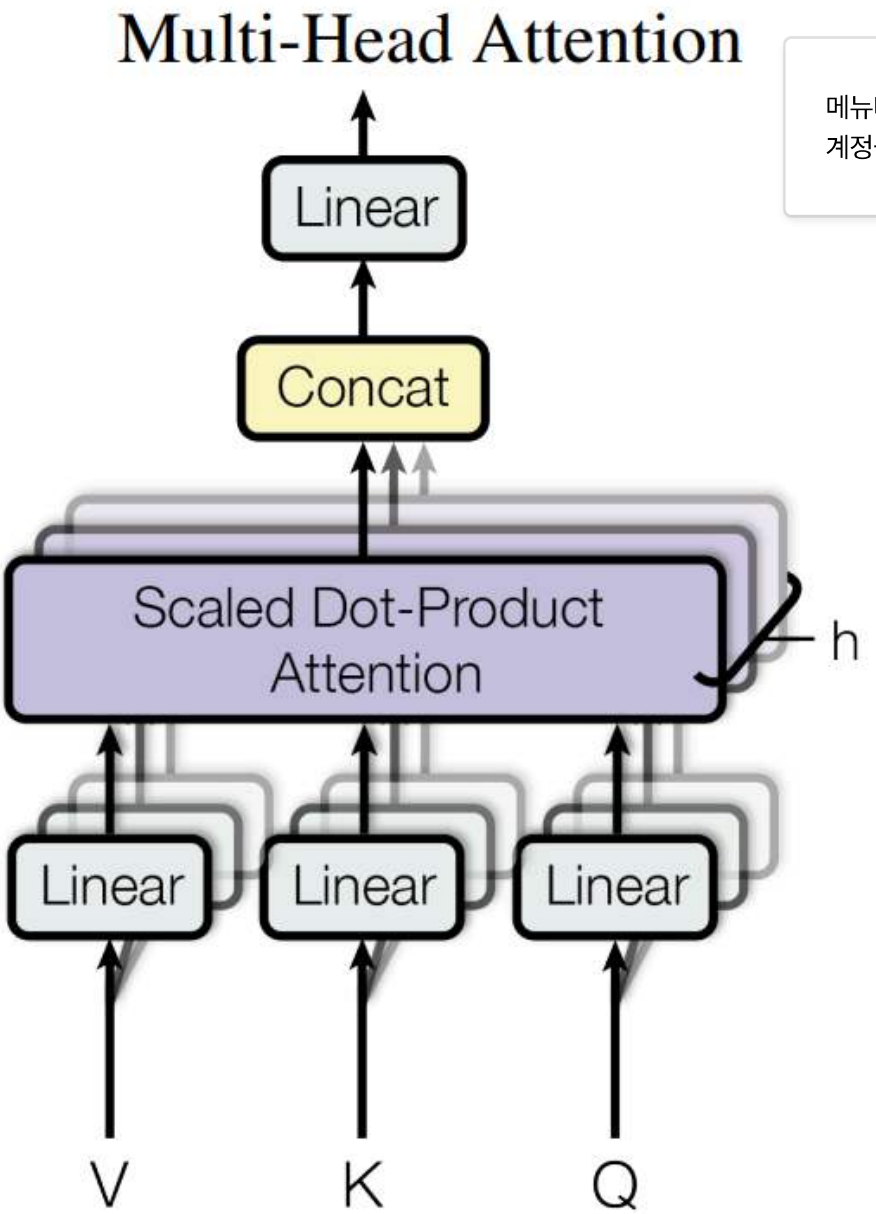

메뉴바를 클릭하면
계정을 관리할 수 있어요

- Multi-Head Attention은 여러 개의 Self-Attention Layer를 가짐
- 서로 다른 Representation Subspaces를 학습함

Positional Encoding

- 입력 시퀀스의 위치 정보를 기억하기 위해 positional encoding을 수행한다.
- 이 계산 과정에서 sin, cos 함수를 활용한다.

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{\text{model}}})$$
$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{\text{model}}})$$

메뉴바를 클릭하면
계정을 관리할 수 있어요

i가 짝수인 경우에는 1번 수식, 홀수인 경우에는 2번 수식 활용

왜 셀프 어텐션인가

1) 계산 복잡도가 낮음
2) 병렬적 계산이 가능
3) 입력 시퀀스 길이에 영향받지X

실험 및 결과

Data: WMT 2014 English-German, French dataset
- 4.5 milion sentence pair로 구성
- 문장들은 byte-pair 인코딩

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$\mathbf{3.3 \cdot 10^{18}}$	
Transformer (big)	**28.4**	**41.8**	$2.3 \cdot 10^{19}$	

최고의 성능을 내고 training cost도 가장 낮음, 일반화 성능 또한 좋음

결론

기존에는 sequential data를 처리하기 위해 hidden state를 순차적으로 전달하는 RNN 기반 구조가 사용되었지만, 이러한 방식은 병렬 처리가 어렵고 긴 문장에서 정보 전달이 비효율적이라는 한계가 있었

다. 해당 논문에서는 Transformer 구조와 Self-Attention 메커니즘을 제안하여 이러한 문제를 해결하고, 문장 전체의 관계를 한 번에 계산할 수 있도록 하였다. 이를 통해 학습 속도와 성능을 동시에 개선했다는 점이 인상 깊었다.

2017년에 발표된 논문임에도 불구하고 최근까지도 다양한 모델에서 해당 구조가

AI 분야에서 효율적인 구조 설계가 얼마나 중요한지 다시 한번 느낄 수 있었다.

메뉴바를 클릭하면
계정을 관리할 수 있어요

공감

letterhill 님의 블로그

letterhill 님의 블로그 입니다.

댓글 0

letterhill

내용을 입력하세요.

등록

DESIGN BY TISTORY 관리자