



메뉴바를 클릭하면
계정을 관리할 수 있어요

논문 리뷰

[paper] BART 논문 리뷰 <BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension>

letterhill | 2026. 5. 31. 02:42 ⓘ

Abstract

본 논문에서 제시하는 모델인 BART는 seq2seq 모델의 사전학습을 위한 노이즈 제거 autoencoder이다. BART는 1 임의의 노이즈 처리를 통해 text를 손상시키고, 2 원본 텍스트를 복원하는 모델을 학습하여 훈련된다. 표준 Transformer 기반 신경망 번역 구조를 사용하며, 다양한 노이즈 방식 실험 결과 문장 순서 무작위 셔플링과 텍스트 스패를 단일 마스크 토큰으로 대체하는 조합이 가장 성능이 좋았다. 결과적으로 텍스트 생성과 comprehension task 둘 다에서 뛰어난 성능을 보이는 범용 사전학습 모델이 바로 BART이다.

1. Introduction

Background: Self-supervised Learning

Self-supervised 학습 방법은 다양한 NLP 과제에서 놀라운 성능을 보였다. 그 중 가장 성공적인 예시로는 masked language model로, 무작위로 일부 단어를 마스킹하고 텍스트를 다시 알아 내도록 훈련된 denoising autoencoder이다. 최근 연구는 아래의 방법을 통해 더욱 개선되어 왔다.

- 마스킹된 토큰 분포의 개선
- 마스킹된 토큰이 예측되는 순서 개선
- 마스킹된 토큰을 대체하기 위해 사용할 수 있는 문맥 개선

-> 이 방법들은 일반적으로 특정 유형의 task에만 초점을 맞추기 때문에 확장성은 상대적으로 떨어지는 것을 알 수 있다.

BART

본 논문에서는 Bidirectional+Auto-Regressive Transformer를 결합한 모델인 BART를 제안한다.

사전학습 2단계;

1) corrupt: 임의의 노이즈 함수로 텍스트 손상

2) reconstruct: seq2seq 모델로 원본 텍스트 복원

장점은 텍스트 길이 변경과 같은 임의의 변환이 가능하고, 다음 문장 예측을 일반화하여 noise는 것이다.

가장 효과적인 노이즈 조합: 문장 순서 무작위 + 임의 길이의 text를 single masked token으로 대체

-> 문장이 전체 문장 길이를 추론하고 더 넓은 범위의 변환에 대응하게 한다.

아래의 분야에서 성과를 보임

- comprehension tasks: RoBERTa와 동등한 성능
- generative tasks에서 우수한 성능
- machine translation

메뉴바를 클릭하면
계정을 관리할 수 있어요

BERT vs GPT vs BART 비교

	BERT	GPT	BART
구조	양방향 인코더만	self-regressive 디코더만	양방향 인코더+self-regressive 디코더
특징	양방향으로 문맥 이해	텍스트 생성 가능	이해+생성 둘 다 가능
한계	생성 불가	단방향만 가능	-

2. Model

2.1 Architecture

기본 구조:

- 표준 Seq2Seq 모델 사용
- ReLU -> GeLU로 수정 *GPT* 모방
- 파라미터 초기화 $N(0, 0.02)$

모델 크기:

base model 인디코더 각각 6 layers

large model은 각각 12층

BERT vs BART

	BERT	BART
--	------	------

디코더 cross=attention	X	O	인코더의 최종 <i>hiddenlayer</i> 에 수행
단어 예측 전 FFN	O	X	
파라미터 수	-	BERT보다 10%	메뉴바를 클릭하면 계정을 관리할 수 있어요

2.2 Pre-training BART

BART의 목표:

- 문서 text를 corrupt한 뒤, decoder output 과 원본 간의 CE Loss minimize
- 극단적인 case: 원본 정보가 완전히 손실되는 경우에는 인코더로부터 받는 정보가 없어 디코더는 자신이 이전에 생성한 토큰들에만 의존하여 다음 토큰을 예측한다 *self - regressive* -> 결과적으로 언어 모델 *GPT*와 동일한 동작을 수행하게 된다.

기존 denoising auto-encoder는 특정 노이즈 방식에만 특화되었지만, BART는 어떤 종류의 문서 손상 방식에도 적용이 가능하다는 것이 차별성이다!

왜 BART는 어떤 노이즈 방식도 적용 가능한걸까?

위에서 기존 방식들의 한계점을 알아볼 때 BERT는 입출력 길이가 항상 동일해야하며, mask의 위치가 명시적으로 fixed되어 있어 오직 Token Masking 방식에만 특화되어 있었다.
토큰삭제, 문장순서변경노이즈불가 또한 GPT는 단방향 생성만 가능하므로 양방향 이해는 불가능했다.
하지만 BART의 경우, 인코더와 디코더의 입출력이 완전히 분리되어 있기 때문에 훨씬 자유롭다!

BART의 Noise Transformation 기법 5

원본 문장:"ABC.DE."

1 Token Masking: 랜덤 토큰을 [MASK]로 대체

ex ABC.DE. -> A _ C . _ E.

2 Token Delection: 랜덤 토큰을 삭제

ex) ABC.DE. -> A . C E .

3 Text Infilling: 텍스트 채우기

ex) ABC.DE. -> A _ . D _ E .

- 여러 텍스트 스패를 샘플링하고 포아송 분포를 통해 span 길이를 결정
- 각 스패를 single [MASK] 토큰 하나로 대체
- 0-length 스패 -> [MASK] 삽입 효과
- SpanBERT와의 차이

- SpanBERT: 스패 길이만큼 [MASK] 여러 개 사용
- BART: 단 하나의 [MASK]로 대체 -> 모델이 빠진 토큰 수까지 예측해야 한다

4 Sentence Permutation: 문장 순서 무작위로 섞기

ex) DE. ABC. → ABC. DE.

5 Document Rotation: 임의의 토큰을 시작점으로 잡고 문서를 회전

ex) AC. DE. AB → ABC. DE.

메뉴바를 클릭하면
계정을 관리할 수 있어요




Figure 2

3. Fine-tuning BART

BART는 downstream task에 여러 방식으로 활용 가능하다. task의 유형마다 fine-tuning 전략이 다르므로 이에 대해 3장에서 알아본다.

3.1 Sequence Classification Tasks

: 문장/문서 전체를 하나의 클래스로 분류 예 : 감성분석, *NLI*

방법:

동일한 입력 → 인코더 + 디코더 동시 입력
↓
디코더 마지막 토큰의 최종 hidden state
↓
새로운 멀티클래스 선형 분류기

[CLS] 토큰을 문장 시작에 추가하는 BERT와 달리, BART는 문장 끝에 특수 토큰을 추가하여 디코더가 전체 입력의 디코더 상태를 참조할 수 있어 풍부한 표현을 가능하게 한다.

3.2 Token Classification Tasks

: 각 토큰을 개별적으로 분류

방법:

전체 문서 → 인코더 + 디코더 입력

↓

디코더 top hidden state

↓

각 단어의 표현으로 사용 → 토큰별 분류

메뉴바를 클릭하면
계정을 관리할 수 있어요

3.3 Sequence Generation Tasks

: 입력을 받아 새로운 텍스트 생성

방법:

- BART는 **self-regressive 디코더**를 이미 갖고 있으므로 **직접 파인튜닝** 가능
- 인코더에서 읽은 정보를 디코더로 복사하며 생성
- 별도 구조 변경 없이 바로 적용 가능

3.4 Maching Translation

기존 연구의 한계:

pre-trained 인코더는 성능 향상 가능

디코더에 pre-trained 언어 모델을 사용하는 건 어려웠음

왜 디코더엔 사전학습 모델을 활용하는 게 제한적이었을까?

- 인코더: 입력 언어를 이해하는 작업을 하기 때문에 대규모 텍스트를 깊이 학습한 사전학습 인코더의 지식을 그대로 활용 가능
- 디코더의 경우, 입력 때 받았던 것과 출력하려는 것이 도메인이 달라 *ex.* 영어 → 프랑스어 사전학습 때와 완전히 다른 분포를 받게 되어, 사전학습한 지식을 활용하지 못한다.

BART의 접근:

[새로운 인코더] → 프랑스어를 노이즈 영어로 매핑

↓

[BART 전체 인코더 + 디코더] → 영어로 디노이징

- BART는 **새로운 인코더를 추가**하여, 프랑스어를 BART가 사전학습 때 본 것과 같은 유사한 영어 노이즈 표현으로 변환 시킨 뒤 BART 디코더에 전달한다.

학습 전략:

- 1단계: 새 인코더가 외국어를 BART가 이해할 수 있는 형태로 매핑하는 법을 학습
- 2단계: 전체 파라미터를 학습

4. Comparing Pre-training Objectives

4.1 Comparison Objectives

기존 연구들은 각자 다른 학습 데이터, 컴퓨팅 자원, 아키텍처, 파인튜닝 방식을 사용해서 직
이 논문에서는 모든 모델을 동일 조건으로 재구현:

메뉴바를 클릭하면
계정을 관리할 수 있어요

- 동일 데이터 *Books + Wikipedia*, $1Msteps$
- 동일 모델 크기 인코더6층, 디코더6층, $hiddensize768$
- 동일 파인튜닝 방식

비교 대상 모델들

모델	설명	대응되는 원본
Language Model	좌→우 단방향, cross-attention 없음	GPT
Permuted LM	토큰 1/6 샘플링 후 무작위 순서로 자기회귀 생성	XLNet
Masked LM	15% 토큰을 [MASK]로 교체 후 독립 예측	BERT
Multitask Masked LM	다양한 self-attention 마스크 혼합 $1/6L \rightarrow R, 1/6R \rightarrow L, 1/3$ 언마스크, $1/3$ 혼합	UniLM
Masked Seq2Seq	50% 토큰 스패ن 마스킹 후 seq2seq 복원	MASS

4.2 Tasks

태스크	유형	설명
SQuAD	이해 $F1$	Wikipedia 단락에서 정답 span 추출
MNLI	이해 Acc	두 문장의 함의 관계 분류
ELI5	생성 PPL	긴 형식의 추상적 질의응답
XSum	생성 PPL	뉴스 요약 고도로 추상적
ConvAI2	생성 PPL	페르소나 기반 대화 생성
CNN/DM	생성 PPL	뉴스 요약 원문과 유사한 형태

4.3 Results

Model	SQuAD 1.1 F1	MNLI Acc	ELI5 PPL	XSum PPL	ConvAI2 PPL	CNN/DM PPL
BERT Base (Devlin et al., 2019)	88.5	84.3	-	-		
Masked Language Model	90.0	83.5	24.77	7.87		
Masked Seq2seq Language Model	87.0	82.1	23.40	6.80		
Permuted Language Model	76.7	80.1	21.40	7.00		
Multitask Masked Language Model	89.1	83.7	24.03	7.69	12.23	6.96
	89.2	82.4	23.73	7.50	12.39	6.74
BART Base						
w/ Token Masking	90.4	84.1	25.05	7.08	11.73	6.10
w/ Token Deletion	90.4	84.1	24.61	6.90	11.46	5.87
w/ Text Infilling	90.8	84.0	24.26	6.61	11.05	5.83
w/ Document Rotation	77.2	75.3	53.69	17.14	19.87	10.59
w/ Sentence Shuffling	85.4	81.5	41.87	10.93	16.67	7.89
w/ Text Infilling + Sentence Shuffling	90.8	83.8	24.17	6.62	11.12	5.41

메뉴바를 클릭하면
계정을 관리할 수 있어요

Table 1

① 성능은 태스크마다 크게 다름

같은 모델도 태스크에 따라 결과가 극적으로 달라짐. 예: Language Model은 ELI5 최고 but SQuAD 최악.

② Token Masking/Deletion은 필수

문서 회전, 문장 셔플만 단독 사용하면 성능 저하. 반드시 토큰 수준 노이즈와 결합해야 함.

③ 좌→우 자기회귀는 생성에 필수

Masked LM, Permuted LM처럼 자기회귀가 없으면 생성 태스크에서 약함.

④ 양방향 인코더는 이해에 필수

SQuAD 같은 이해 태스크는 미래 문맥까지 봐야 하므로 단방향 디코더만으로는 부족.

⑤ 아키텍처도 성능에 영향

Permuted LM이 XLNet보다 낮은 건 학습 목표 차이가 아니라 상대적 위치 임베딩 등 아키텍처 차이 때문.

5 Large-scale Pre-training Experiments

5.1 Experimental Setup

4장에서 실험한 base 모델 -> large model로 확장

종류	설정
레이어 수	인코더 12층 + 디코더 12층
Hidden size	1024
배치 크기	8,000
학습 스텝	500,000
토큰나이저	GPT-2와 동일한 BPE
학습 데이터	160GB 뉴스, 책, 이야기, 웹텍스트

5.2 DiscriminativeTasks

메뉴바를 클릭하면
계정을 관리할 수 있어요

	SQuAD 1.1 EM/F1	SQuAD 2.0 EM/F1	MNLI m/mm	SST Acc	QQP Acc	QNLI Acc	STS-B Acc	RTE Acc	MRPC Acc	Mcc
BERT	84.1/90.9	79.0/81.8	86.6/-	93.2	91.3	92.3	90.0	70.4	88.0	60.6
UniLM	-/-	80.5/83.4	87.0/85.9	94.5	-	92.7	-	70.9	-	61.1
XLNet	89.0/94.5	86.1/88.8	89.8/-	95.6	91.8	93.9	91.8	83.8	89.2	63.6
RoBERTa	88.9/ 94.6	86.5/89.4	90.2/90.2	96.4	92.2	94.7	92.4	86.6	90.9	68.0
BART	88.8/ 94.6	86.1/89.2	89.9/90.1	96.6	92.5	94.9	91.2	87.0	90.4	62.8

Table 2: Results for large models on SQuAD and GLUE tasks. BART performs comparably to RoBERTa and XLNet, suggesting that BART's uni-directional decoder layers do not reduce performance on discriminative tasks.

“

BART는 디코더가 단방향임에도 불구하고 RoBERTa와 거의 동일한 판별 성능 달성 → 생성 능력 향상이 이해
능력 저하를 유발하지 않음

5.3 GenerationTasks

	CNN/DailyMail			XSum		
	R1	R2	RL	R1	R2	RL
Lead-3	40.42	17.62	36.67	16.30	1.60	11.95
PTGEN (See et al., 2017)	36.44	15.66	33.42	29.70	9.21	23.24
PTGEN+COV (See et al., 2017)	39.53	17.28	36.38	28.10	8.02	21.72
UniLM	43.33	20.21	40.51	-	-	-
BERTSUMABS (Liu & Lapata, 2019)	41.72	19.39	38.76	38.76	16.33	31.15
BERTSUMEXTABS (Liu & Lapata, 2019)	42.13	19.60	39.18	38.81	16.50	31.27
BART	44.16	21.28	40.90	45.14	22.27	37.25

Table 3: Results on two standard summarization datasets. BART outperforms previous work on summarization on two tasks and all metrics, with gains of roughly 6 points on the more abstractive dataset.

5.4 Translation

	RO-EN
Baseline	36.80
Fixed BART	36.29
Tuned BART	37.96

메뉴바를 클릭하면
계정을 관리할 수 있어요

Table 6: The performance (BLEU) of baseline and BART on WMT’16 RO-EN augmented with back-translation data. BART improves over a strong back-translation (BT) baseline by using monolingual English pre-training.

전체 결과 요약

Tasks	Result
이해 <i>SQuAD, GLUE</i>	RoBERTa와 동등
추상적 요약 <i>XSum</i>	+6 ROUGE 압도적 SOTA
추출적 요약 <i>CNN/DM</i>	기존 모델 모두 능가
대화 생성 <i>ConvAI2</i>	SOTA
추상적 QA <i>ELI5</i>	SOTA
기계 번역 <i>RO → EN</i>	+1.16 BLEU

6. Qualitative Analysis

BART의 사전학습은 자연어 이해 *NLU*와 자연어 생성 *NLG*의 강력한 조합을 학습했음을 질적 분석으로 확인한다.

7. Related Work

모델	Method	BART와의 차이
GPT	좌→우 단방향 LM	우측 문맥 미활용 → 일부 태스크 불리
ELMo	좌전용 + 우전용 표현 연결	두 방향 간 상호작용 학습 안 함
BERT	마스크 언어 모델 양방향	자기회귀 아님 → 생성 태스크에 약함
UniLM	다양한 어텐션 마스크 앙상블	예측이 조건부 독립 → BART는 자기회귀라 더 자연스러운 생성

MAS S	스팬 마스크 seq2seq	BART와 가장 유사하나, 인코더/디코더에 분리된 토큰 집합 입력 → 판별 태스크에 불리
XLNet	마스크 토큰을 순열 순서로 자기회귀 예측	좌우 문맥 모두 활용하나, 디코더가 학습 시 좌→우 시 불일치

메뉴바를 클릭하면 계정을 관리할 수 있어요

8. Conclusion

BART는 손상된 문서를 원본으로 복원하는 방식의 사전학습 방법을 제안했다. 판별 태스크에서는 RoBERTa와 동등한 수준의 성능을 보이면서도, 요약·대화·질의응답 등 다양한 생성 태스크에서는 새로운 최고 성능 *SOTA*을 달성했다. 이는 BART가 이해와 생성 두 영역 모두에서 강력한 범용 사전학습 모델임을 보였다.

<Dropout 논문 Intro Review>

Dropout은 Deep Neural Network의 overfitting을 해결하기 위한 정규화 기법
모델 학습 시에 네트워크의 각 유닛(뉴런, 노드)를 일정한 확률 p 로 무작위로 꺼버린다. *drop*

Background

- Deep Neural net은 깊어질수록 표현력은 강해지지만 과적합이 심각한 문제가 있다.
- 여러 모델을 앙상블하면 성능은 오르지만, huge한 network를 여러 개 훈련하는 건 computational cost가 너무 크다.

Dropout 작동

단계	작동
train	각 유닛을 확률 p 로 유지, 나머지는 drop
test	모든 유닛을 사용하되 가중치에 p 를 곱해 scale 조정

효과

- 랜덤하게 노드를 drop하면 그만큼 다양한 조합을 학습하는 것과 같으므로 많은 네트워크를 앙상블하는 효과가 있다.
- ex) n 개 유닛 $\rightarrow 2^n$ 가지 가능한 sub network

[paper] GAN 논문 리뷰 : Generative Adversarial Nets 0

2026.05.24

Denoising Diffusion Probabilistic Models 0

[paper] Efficient Memory Management for Large LanguageModel Serving with PagedAt 0

[paper] AN IMAGE IS WORTH 16X16 WORDS:TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE 논문

deep residual 논문 리뷰 2

메뉴바를 클릭하면
계정을 관리할 수 있어요

'논문 리뷰' Related Articles

NO IMAGE

[paper] GAN 논문 리뷰 :
Generative Adversarial...

NO IMAGE

Denoising Diffusion
Probabilistic Models

Parameters (26GB, 65%)	KV Cache (>30%)
	Others

NVIDIA A100 40GB

[paper] Efficient Memory
Management for Large...

NO IMAGE

[paper] AN IMAGE IS
WORTH 16X16...

letterhill 님의 블로그

letterhill 님의 블로그입니다.



댓글 0

letterhill

내용을 입력하세요.

등록

메뉴바를 클릭하면
계정을 관리할 수 있어요