



메뉴바를 클릭하면
계정을 관리할 수 있어요

논문 리뷰

[paper] Efficient Memory Management for Large LanguageModel Serving with PagedAt

letterhill | 2026. 5. 11. 18:20 ⓘ

논문을 선택한 이유

최근 챗지피티, 클로드, 제미니 등 llm 챗봇들이 쏟아져나오는 상황에서 경쟁력을 갖추기 위해서는 질문을 넣었을 때 빠르게 답안을 내놓는 것이 중요해졌다. llm 모델들은 우리가 이전에 공부했던 transformer 모델을 기반으로 하고 있기 때문에 연산 속도에 가장 큰 영향을 미치는 부분은 바로 key와 value의 행렬 연산이라고 한다. 이 연산의 속도를 올리는 데에서 '토큰 가성비'를 올리는 것과 이어지는 데, 이 부분에 대해 궁금증이 요즘 들어 부쩍 생겼기 때문에 해당 논문을 선택했다.

Abstract

LLM 모델의 큰 throughput처리량 제공은 한 번에 충분이 많은 요청을 배치하는 것을 요구한다. 하지만 현존하는 시스템들은 KV cache 메모리가 매우 크고 동적으로 증감하기 때문에 어려움을 겪고 있다. 이 메모리가 비효율적으로 관리될 때, memory fragmentation과 불필요한 중복으로 인해 낭비되고 배치 크기를 제한한다. 메모리단편화에 대해서는아래에서알아보도록하자. 이 문제를 해결하기 위해, 본 논문에서는 PagedAttention이라는 기법을 제안한다. 이 알고리즘은 os에서 고전 가상 메모리와 페이징 기법에 영감을 받았다. 그 위에, vLLM을 구축한다. vLLM의 특징은 두 가지가 있다. 1 KV 캐시 메모리의 낭비가 거의 0이며, 2 메모리 사용을 더 줄이기 위해 KV 캐시를 유연하게 공유한다. 평가를 거친 결과, vLLM은 LLM의 처리량을 2-4배 증가시켰으며, 긴 시퀀스와 복잡한 모델에서 그 효과가 더욱 두드러졌다.

Introduction

메뉴바를 클릭하면
계정을 관리할 수 있어요

GPT나 PaLM과 같은 LLM의 등장은 우리의 업무와 일상 루틴에 엄청난 영향을 끼쳤다. 많은 기업과 회사들은 이것을 서비스로 적용하기 위해서 엄청난 경쟁중이다. 그러나, 이 applications은 매우 비싸고, GPU같은 하드웨어 가속기를 아주 많이 요한다는 문제가 있다. 최근 추정에 따르면, LLM 요청을 수행하는 것은 전통적인 키워드 쿼리보다 무려 10배나 expensive하다고 한다. 이러한 high cost를 고려하면, 처리량을 늘리는 것, LLM 서비스 요청 당 비용을 줄이는 것이 아주 중요해진다는 것을 알 수 있다. LLM의 중심은 자기 회귀 transformer 모델에 있다. 이 모델은 현재 시점의 input과 지금까지 생성해온 출력 토큰의 이전 시점 시퀀스를 기반으로 한 번에 하나씩 출력을 생성하며 이걸 종료 토큰이 나올 때까지 반복한다. 이처럼 순차적으로 생성하는 과정이 모델을 메모리에 의존적으로 만들어 GPU의 연산 능력을 충분히 활용하지 못하게 하고, 서비스 throughput을 제한한다. 처리량을 향상시키는 것은 많은 요청을 동시 배치하여 가능하게 할 수 있다. 다만, 많은 요청을 하나의 배치로 처리하기 위해서는 각 요청 당 메모리 공간이 효율적으로 관리되어야 한다.




Figure 1-1. 메모리 분할

어떤 식으로 메모리를 효율적으로 관리할 수 있을지 알아보기 위해 위의 사진으로 살펴보자. Figure 1-1은 40GB RAM을 지닌 NVIDIA의 A100 GPU 메모리이다. 메모리의 65%는 정적으로 유지되는 모델 가중치이며, 30%는 요청의 동적인 상태를 저장하는 데에 사용된다. 트랜스포머 모델에서는 이 상태는 어텐션 메커니즘을 수행하기 위한 key와 value 텐서로 이루어져있고, 일반적으로 이것을 이전 토큰으로부터 새로운 output 토큰을 생성해내는 KV cache라고 한다. 남은 작은 공간은 LLM 평가에 쓰이는 임시 텐서로 활용한다. 모델 가중치 파라미터는 고정된 부분이고 활성화는 GPU 메모리의 아주 작은 부분만

을 차지하기 때문에, KV 캐시를 관리하는 방식이 최대 배치 크기 결정에 매우 중요한 요소이다. 비효율적으로 관리가 되면, 이 캐시 메모리는 배치 사이즈를 제한하고 LLM의 처리량을 제한하는 것을 아래의 Figure1-2를 통해 알 수 있다.




Figure 1-2. 캐시 관리에 따른 처리량 그래프

본 논문에서는 기존 LLM이 KV캐시 메모리를 효율적으로 관리하지 못하고 있다는 지점에 주목한다. 이는 딥러닝 프레임워크가 텐서를 연속 메모리 공간에 저장하도록 요구하기 때문에 KV 캐시도 해당 공간에 저장하기 때문이다. 그러나, 전통적인 딥러닝과 달리, KV캐시는 독특한 특징을 지닌다. 이는 동적으로 증감한다는 점이다. 이 독특한 특징 때문에 기존의 방법은 비효율적이다. 왜일까?

1) Memory Fragmentation 메모리 단편화

기존 시스템은 메모리 단편화 문제를 지닌다. KV캐시를 연속적인 공간에 저장하기 위해서, 미리 할당된 메모리 청크가 요청의 최대 길이만큼 필요하다. 이는 중간의 극심한 메모리 단편화를 발생시킨다. 왜냐

면 요청의 실제 길이는 maximum length보다 훨씬 짧을 수 있기 때문이다. 검토해본 결과, 기존 시스템에서 캐시 메모리는 20~40% 정도만이 실제 토큰 저장에 사용된다는 것을 보여주었다.

2) 메모리 공유 불가

LLM 서비스는 병렬 샘플링, beam search와 같은 발전된 디코딩 알고리즘을 청마다 여러 개의 결과를 출력한다. 그러나 KV 캐시가 분리된 연속 공간에 저장할 수 없다.

메뉴바를 클릭하면
계정을 관리할 수 있어요

위와 같은 제한점을 다루기 위해, PagedAttention을 제안한다.

PagedAttention

KV 캐시를 블록으로 분리한다.

2. Background

2.1 Transformer-Based Large Language Models

Autogressive decomposition: 전체 시퀀스에 대한 결합 확률 -> 조건부 확률의 곱으로 분해
위의 기법을 활용하여 토큰 list의 확률을 모델링 한다.

eq1:

$$P(x) = P(x_1) \cdot P(x_2|x_1) \dots P(x_n|x_1, \dots, x_{n-1}).$$

트랜스포머는 대규모로 위의 확률을 모델링하는데, 가장 중요한 구성 요소는 self-attention이다.

Self-Attention은 현재 위치 i 에 대해 linear transformation을 적용하여 query, key, value 벡터를 얻는다.

$$q_i = W_q x_i, k_i = W_k x_i, v_i = W_v x_i.$$

그 다음 i 위치의 쿼리 벡터를 그 이전의 모든 키 벡터와 곱하여 attention score를 구하고, 가중 평균으로 출력 o_i 를 계산한다.

$$a_{ij} = \frac{\exp(q_i^\top k_j / \sqrt{d})}{\sum_{t=1}^i \exp(q_i^\top k_t / \sqrt{d})}, \quad o_i = \sum_{j=1}^i a_{ij} v_j.$$

2.2 LLM Service & Autoregressive Generation

요청=토큰 list $x_1, \dots, x_n$ -> LLM 서비스에 전달 $eq1$ 수행 -> 출력 토큰 list $x_{n+1}, \dots, x_{n+T}$ 생성
생성하는 토큰은 그 이전 모든 키, 값 벡터에 의존하므로 한 토큰의 KV 캐시는 그 이전 모든 토큰에 의존

한다는 점을 명심해야 한다.

요청 프롬프트가 들어오면, LLM의 생성 연산은 두 단계로 나뉜다.

1 The prompt phase

user prompt 전체 $x_1 \dots x_n$ 을 입력으로 받고 첫 새로운 토큰의 확률을 계산한다.

이 과정동안, key와 value 벡터를 행렬 간 곱 연산을 통해 병렬적으로 계산한다.

메뉴바를 클릭하면
계정을 관리할 수 있어요

2 The autogressive generation phase

남은 new tokens을 순차적으로 생성하는 단계이다.

iteration t에서 x_{n+t} 를 입력으로 받고 $P(x_{n+t+1} | x_1, \dots, x_{n+t})$ 를 이전 시점까지의 K,V 벡터를 활용해서 계산한다.

이 반복 계산은 시퀀스가 max length에 도달하거나, 종료 토큰을 만날 때 종료된다.

이전 토큰에 의존하기 때문에 서로 다른 iteration에서는 병렬적인 계산이 불가능하여 GPU를 비효율적으로 활용하는 문제가 생긴다.

2.3 Batching Techniques for LLMs

request들은 동일한 모델 가중치를 공유하기 때문에, 여러 개의 요청을 batch하여 효율성을 높일 수 있을 것으나 두 가지 문제점이 있다.

첫 번째 문제, request들은 서로 다른 시간에 도착할 수 있다.

두 번째 문제, request들은 입출력 길이가 크게 다를 수 있다.

solution

더 세밀한 단위의 배치와 iteration-level scheduling

요청 단위가 아닌 반복 단위로 작동을 하여 처리량을 크게 한다.

3. Memory Challenges in LLM Serving

위의 방법들로 성능을 향상시키더라도, 여전히 GPU 메모리 용량에 영향을 받는다.

이 서비스 처리량이 memory-bound 하다는 문제를 해결하기 위해서는 다음과 같은 메모리 관리의 문제들을 해결해야 한다.

Large KV cache: KV 캐시는 요청의 수에 따라 빠르게 커진다.

ex)

13B 파라미터 OPT 모델의 단일 토큰의 KV 캐시가 요구하는 공간 크기:

$2K + V * 5120_{hiddenstatesize} * 40_{layer}수 * 2_{FP16}당바이트 = 800KB$

OPT는 최대 2048 토큰 시퀀스 생성 가능

-> one request의 KV캐시를 저장하는 데 필요한 메모리: $800KB * 2048 \sim$ 최대 1.6GB

=> 하나의 request를 기억하는 데에 거의 모든 GPU 공간을 사용하는 문제!

아래의 Figure2에서 볼 수 있듯이, 만약 메모리 관리 시스템이 비효율적이면 Batch Size가 더 줄어들 수 있다는 문제도 있다.




Figure 2

GPU 연산 속도가 빨라져도 수용가능한 공간은 고정되기 때문에 메모리가 bottleneck이 된다.

Complex decoding algorithms

모델의 디코딩 방식에 따라 메모리를 절약할 수 있지만, 관리는 더욱 복잡해진다.

- Shared Prompt: 만약 사용자가 하나의 프롬프트를 입력하고 여러 가지 답변을 줘! 라고 했을 때, 프롬프트에 대한 데이터는 모든 답변 후보가 동일하게 공유하므로 KV캐시 메모리가 공유될 수 있다.
- Unshared Generation: 하지만 답안을 생성하는 단계, 즉 autoregressive 생성 단계기 시작되면 문맥과 현재 위치에 따라 KV 캐시가 달라지기 때문에 메모리 공유가 불가하다.
- Beam Search: 여러 경로를 탐색하여 가장 좋은 답을 찾는 알고리즘은 공유 가능한 부분이 최대 55%로 더 많지만, 관리 패턴이 계속 변동되기 때문에 어렵다.

Scheduling for unknown input&output lengths

얼마나 긴 질문이 들어올지, 얼마나 긴 답변을 출력할지 미리 예측할 수 없기 때문에 이에 맞춰 데이터를 지우거나 옮기는 'scheduling'이 필수적이다.

3.1 Memory Management in Existing Systems

앞서 설명했듯이, 우리는 입출력 길이가 가변적이기 때문에 딥러닝 프레임워크는 정적인 연속된 메모리 덩어리 공간을 할당한다. 그렇게 되면 불필요한 공간이 발생하는 문제가 있는데, 아래의 그림의 예시처럼 최대 max seq가 2048, 512인 두 가지 요청이 있을 때 기존 시스템은 아래 진한 갈색 공간과 진초록 공간의 낭비되는 공간을 갖는다는 것을 확인할 수 있다.




Figure 3

메뉴바를 클릭하면
계정을 관리할 수 있어요

4. Method

4.1 PagedAttention

기존: 연속적인 Key, Value ->

불연속적인 key, value blocks에 저장한다.

각 블록은 블록 크기가 고정되어 있다.

아래의 fig5를 보면 "forth"라는 쿼리 토큰에 연결하는 세 개의 블록들이 떨어져 존재하는 것을 확인할 수 있다. eq4에 적용해보면 "forth" 쿼리 토큰의 쿼리 벡터 q_i 와 block0의 key 벡터인 K_{ij} 를 곱해 attention score A_{ij} 를 구하고 그 값을 값 벡터인 V_{ij} 와 weighted summation하여 출력 o_i 를 생성한다.

이 4.1 기법을 통해 vLLM이 불연속적인 메모리를 활용할 수 있게 하여 유연한 메모리 관리를 가능케 한다.

4.2 KV cache manager

- **핵심 구성 요소:**

- **Physical Blocks:** GPU VRAM에 실제로 존재하는 고정 크기의 **빈 슬롯**
- **Logical Blocks:** 각 요청의 입장에서 **내 KV 캐시의 첫 번째, 두 번째, 세 번째 블록...**처럼 연속적으로 보이는 **가상의 블록**
- **Block Table:** 각 요청마다 **논리 블록과 물리 블록을 1:1로 매핑mapping**해주는 **지도**
예 : 요청 A의 논리블록3은 물리블록72번에 저장되어있다. * OS의 캐시 테이블과 동일한 역할

- **작동 방식:**

- 요청이 들어오면, **당장 필요한 만큼의 물리 블록만 할당**하고 이를 논리 블록에 매핑합니다.

- KV 캐시가 더 필요해지면, 관리자는 **비어있는 물리 블록을 아무 데서나 하나 더 가져와서** 이 요청의 논리 블록 리스트에 추가

4.3 Decoding with PagedAttention and vLLM

메뉴바를 클릭하면
계정을 관리할 수 있어요




Figure 7. Storing the KV cache of two requests at the same time in vLLM.

[디코딩 과정]

Step1. Prefill 단계

- 입력 프롬프트를 처리하는 단계
- 총 입력 토큰 7개 중, 첫 4개 토큰은 logical block 0에, 나머지 3개를 block 1에 저장한다. 여기서, 각 블록은 고정된 크기를 가진다.

Step2. 첫 번째 토큰 생성

- 새로운 토큰을 생성하는 단계
- 입력 토큰을 채우고 block1의 마지막 칸이 빈 공간이므로 해당 칸에 새로운 첫 토큰을 생성한다.
- > 새 블록 할당X, 기존 블록 재사용

Step3. 다음 토큰 생성

이제 logical block 1이 꽉 찼으므로 logical block2를 생성하여 넣는다.

이 단계에서 새로운 physical block을 할당하고 block table도 업데이트한다.

[장점]

이렇게 메모리를 관리하면 작은 블록 단위로 할당하여 메모리 낭비와 단편화를 완화하고 하나의 요청이 끝난 즉시 physical block들을 free시킬 수 있다.

4.4 Application to other Decoding Scenarios

앞서 도입한 method를 통해 어떤 식으로 메모리를 효율적으로 관리 및 공유하는지에 대해 알아본다.

- Parallel Sampling

: 하나의 prompt에서 여러 개의 결과물을 생성할 때, 모든 outputs은 동일한 prompt에 대해 생성되므로, 해당하는 kv캐시 블록도 공유한다.

메뉴바를 클릭하면
계정을 관리할 수 있어요

- Beam Search

: 여러 후보군들 중 최적을 찾는 과정에서, 후보들이 갈라지기 전까지의 데이터를 공유해 메모리 낭비를 줄인다.

- Shared Prefix

: prompt의 여러 요청에서 공통으로 쓰이는 앞부분이 있을 때, vLLM은 이를 미리 physical block에 캐싱해두고 재사용 가능하게 한다.

4.5 Scheduling and Preemption

: 요청이 엄청나게 많이 들어올 때 GPU 메모리가 부족해지는 상황을 잘 해결하는 전략

- FCFS: 요청이 들어온 순서대로 처리하고, new KV cache를 저장할 공간이 부족해지면 진행 중인 request 중 일부를 잠시 중단한다.

- 중단된 데이터의 관리: GPU 메모리에서 밀려난 KV cache를 CPU RAM에 잠시 옮겨두는 Swapping, 메모리가 극도로 부족한 경우 캐시를 버리고 나중에 처음부터 계산하는 Recomputation이 있다.

4.6 Distributed Execution

모델이 너무 커서 GPU에 한 번에 들어가지 않는 경우를 처리하는 방식

- Tensor Parallelism: 여러 GPU가 모델을 나눠 가지는 Megatron-LM과 같은 방식을 사용할 때도 중앙 집중식 관리를 한다.

- Common Mapping: 스케줄러는 명령을 모든 GPU에게 똑같이 내리고, logical-physical block mapping 테이블을 공유한다.

5. Implementation

System 구조

- Python&C++/CUDA Hybrid

- 프론트엔드:python

- 백엔드/engine: C++/CUDA

5.1 Kernel-level Optimization

메모리의 불연속성으로 인한 성능 저하를 해결하기 위한 3가지 핵심 맞춤형 CUDA 커널

1 Fused reshape and block write

- KV캐시가 생성되면, 이를 block단위로 분리, reshape, 테이블 주소에 맞는 ph 과정을 거친다.
- 이 과정들을 따로 실행하면 Launch overhead가 발생하므로 이 전 과정을 Fused 하나의 커널로 합쳐 한 번에 처리 한다.

2 Fusing block read and attention

- 흩어져 있는 블록들을 읽어와서 연산을 해야하는 문제가 있어 블록 테이블을 참조해 이 데이터들을 읽어오면서 바로 연산한다.

3 Fused block copy

- physical block을 복사할 때 하나의 커널 실행으로 한 번에 처리한다.

5.2 Supporting Various Decoding Algorithms

vLLM의 디코딩 알고리즘 구현 주요 방법 3가지

- fork: 기존 시퀀스 -> 새로운 시퀀스 생성
- append: 시퀀스에 새로운 토큰 추가
- free: 시퀀스 삭제

6. Evaluation

6.1 Setup


아래의 테이블과 같은 실험환경을 세팅한다.

Table 1. Model sizes and server configurations.

Model size	13B	66B	175B
GPUs	A100	4×A100	8×A100-80GB
Total GPU memory	40 GB	160 GB	640 GB
Parameter size	26 GB	132 GB	346 GB
Memory for KV cache	12 GB	21 GB	264 GB
Max. # KV cache slots	15.7K	9.7K	60.1K

6.2 Basic Sampling

메뉴바를 클릭하면
계정을 관리할 수 있어요






Figure 12. Single sequence generation with OPT models on the ShareGPT and Alpaca dataset

- vLLM이 다른 시스템에 비해 훨씬 높은 throughput

<- 메모리 낭비를 줄여, 동일한 GPU에서 훨씬 더 많은 요청을 Batching하게 한 번에 처리하기 때문

6.3 Parallel Sampling & Beam Search




Figure 14. Parallel generation and beam search with OPT-13B on the Alpaca dataset.

- 메모리 절감과 처리량 향상의 결과를 확인할 수 있다.

6.4 Special Workload

- Shared Prefix: 프롬프트 앞부분을 공유할 때도 vLLM의 성능이 좋아졌다.

- Chatbot: 긴 대화 맥락을 다루는 챗봇 상황에서도 훨씬 높은 처리량을 유지했다.

7. Ablation Studies

7.1 Kernel Microbenchmark

- PagedAttention은 여러 가지 중간 과정이 있어 어텐션 커널 지연이 생기지만, 이 오버헤드에도 불구하고 전체적인 성능은 더 향상됐다.

7.2 Impact of Block Size

- 블록 크기는 성능에 큰 영향을 끼친다.

블록 크기가 너무 작으면 -> GPU의 병렬 처리 능력을 활용하지 못하고

블록 크기가 너무 크면 -> 단편화가 증가한다.

7.3 Comparing Recomputation and Swapping

메뉴바를 클릭하면
계정을 관리할 수 있어요

- 블록 크기가 작을 때는 recomputation, 클 때는 Swapping이 더 효과적이다.

8~9

- vLLM은 동적 메모리 할당이 필요한 작업에서 매우 효과적일 것이라는 고찰에 대해 다루고, vLLM의 등장 이전에도 스케줄링 개선 시도가 있었지만 메모리 단편화 문제는 해결하지 못했다는 내용이다.

10. Conclusion

- vLLM: **PagedAttention**이라는 혁신적인 알고리즘을 도입
- 이를 통해 메모리 낭비를 거의 0으로 줄였고, 복잡한 디코딩빔서치, 공유프롬프트에서도 메모리를 효율적으로 공유
- 결과적으로 기존 최신 시스템 *SOTA*들보다 **처리량Throughput을 2~4배 향상**시킴

ADAM: A METHOD FOR STOCHASTIC OPTIMIZATION

- Momentum+RMSProp의 장점을 결합한 optimization 알고리즘

- **Momentum의 장점:** 기울기의 진행 방향을 기억해 가속도를 붙임
- **RMSProp의 장점:** 매개변수마다 학습률을 다르게 조절 가능
- **Adam의 차별점:** 학습 초기 단계에서 모멘트 값이 0으로 편향되는 문제(**Bias**)를 수학적으로 보정

Algorithm 1: *Adam*, our proposed algorithm for stochastic optimization. See section 2 for details, and for a slightly more efficient (but less clear) order of computation. g_t^2 indicates the elementwise square $g_t \odot g_t$. Good default settings for the tested machine learning problems are $\alpha = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$ and $\epsilon = 10^{-8}$. All operations on vectors are elementwise. We denote β_1 and β_2 to the power t .

Require: α : Stepsize

Require: $\beta_1, \beta_2 \in [0, 1)$: Exponential decay rates for the moment estimates

Require: $f(\theta)$: Stochastic objective function with parameters θ

Require: θ_0 : Initial parameter vector

$m_0 \leftarrow 0$ (Initialize 1st moment vector)

$v_0 \leftarrow 0$ (Initialize 2nd moment vector)

$t \leftarrow 0$ (Initialize timestep)

while θ_t not converged **do**

$t \leftarrow t + 1$

$g_t \leftarrow \nabla_{\theta} f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)

$m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)

$v_t \leftarrow \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$ (Update biased second raw moment estimate)

$\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$ (Compute bias-corrected first moment estimate)

$\hat{v}_t \leftarrow v_t / (1 - \beta_2^t)$ (Compute bias-corrected second raw moment estimate)

$\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$ (Update parameters)

end while

return θ_t (Resulting parameters)

메뉴바를 클릭하면
계정을 관리할 수 있어요

♡ 공감 📌 📄 🗑️ 👤 🔄 🔄

'논문 리뷰' 카테고리의 다른 글

[paper] AN IMAGE IS WORTH 16X16 WORDS:TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE 논문 리뷰 0	2026.05.05
deep_residual 논문 리뷰 2	2026.05.02
[NLP] BERT 논문 리뷰 1	2026.04.06
[강화학습] Playing Atari with Deep Reinforcement Learning_DQN 논문 리뷰 0	2026.03.30

'논문 리뷰' Related Articles

NO IMAGE

NO IMAGE

NO IMAGE

NO IMAGE

[paper] AN IMAGE IS
WORTH 16X16...

deep residual 논문 리뷰

[NLP] BERT 논문 리뷰

[강화학습] Playing Atari
with Deep...

메뉴바를 클릭하면
계정을 관리할 수 있어요

letterhill 님의 블로그

letterhill 님의 블로그입니다.



댓글 0



letterhill

내용을 입력하세요.



등록