Improving Language Understanding by Generative Pre-Training (GPT-1)

1. Introduction

논문이 다루는 분야

- 자연어 처리 (NLP)
- 언어 이해 (Natural Language Understanding)
- 준지도 학습 (Semi-supervised Learning): 비지도 사전학습 + 지도 미세조정

해당 task에서 기존 연구 한계점

- 레이블된 데이터의 부족
  - 대부분의 딥러닝 방법은 대량의 수동 레이블 데이터를 필요로 하여, 주석 자원이 부족한 도메인에서의 적용이 제한됨
- 비지도 표현 활용의 어려움
  - 어떤 최적화 목표(언어 모델링, 기계 번역, 담화 일관성 등)가 전이에 효과적인지 불분명
  - 학습된 표현을 타겟 태스크로 전이하는 방법에 대한 합의 부재 (태스크별 아키텍처 변경, 복잡한 학습 스케줄, 보조 목적함수 추가 등)
- 기존 사전학습 모델(LSTM 기반)의 한계
  - Dai et al., Howard & Ruder 등은 LSTM 모델을 사용하여 텍스트 분류를 개선했지만, LSTM의 구조적 특성상 장거리 의존성 포착에 한계
  - 좁은 범위의 태스크(텍스트 분류)에만 효과를 검증

논문의 contributions

1. **범용 사전학습-미세조정 프레임워크 제안**: 대규모 비지도 텍스트 코퍼스에서 생성적 사전학습(Generative Pre-Training) 후, 각 태스크에 맞게 판별적 미세조정(Discriminative Fine-Tuning)하는 2단계 학습 방식 제안
2. **Transformer 디코더 아키텍처 채택**: LSTM 대신 Transformer 디코더를 사용하여 장거리 의존성을 효과적으로 처리
3. **태스크별 입력 변환(Task-specific Input Transformations)**: 모델 구조를 최소한으로 변경하면서 다양한 태스크에 적용할 수 있는 traversal-style 입력 변환 방식 제안(delimiter 토큰 활용)
4. **광범위한 벤치마크에서 SOTA 달성**: 12개 태스크 중 9개에서 당시 최고 성능 달성(Story Cloze +8.9%, RACE +5.7%, MultiNLI +1.5%)
5. **보조 언어 모델링 목적함수 활용**: 미세조정 시 보조 LM 목적함수(λ=0.5)를 추가하여 일반화 성능 및 수렴 속도 향상

2. Related Work

💡 Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- **NLP를 위한 준지도 학습**: 단어 수준 임베딩(Word2Vec, GloVe)이 다양한 NLP 태스크 성능을 향상시켰지만, 단어 수준 정보만 전이한다는 한계. 본 논문은 더 높은 수준의 의미(higher-level semantics)를 포착하고자 함
- **비지도 사전학습**: 이미지 분류, 음성 인식 등에서 사전학습의 효과가 입증됨. 언어 모델링 후 미세조정하는 접근은 Dai et al., Howard & Ruder가 시도했으나 LSTM 사용으로 예측 범위가 제한적이었음. 본 논문은 Transformer를 채택하여 장거리 언어 구조를 포착하고, 더 넓은 범위의 태스크에서 효과를 검증
- **보조 학습 목표**: Collobert & Weston은 다양한 보조 NLP 태스크를, Rei는 보조 LM 목적함수를 활용. 본 논문도 보조 목적함수를 사용하되, 비지도 사전학습만으로도 태스크 관련 언어 지식을 충분히 학습한다는 점을 보임

3. 제안 방법론

Main Idea

- 대규모 비지도 텍스트 코퍼스에서 언어 모델을 사전학습한 후, 레이블된 데이터로 미세조정하여 범용 언어 표현을 학습

- 핵심: **Transformer 디코더 기반 언어 모델 + 태스크별 입력 변환 + 보조 LM 목적함수**

Contribution

- **비지도 사전학습 (Unsupervised Pre-training)**
  - BooksCorpus(7,000권 이상의 미출판 도서) 데이터 사용
  - 12-layer Transformer 디코더 (768차원, 12 attention heads)
  - 표준 언어 모델링 목적함수: $L_1(U) = \Sigma_i \log P(u_i \mid u_{i-k}, \ldots, u_{i-1}; \Theta)$
  - BPE(40,000 merges), GELU 활성화 함수, 학습된 위치 임베딩 사용
- **지도 미세조정 (Supervised Fine-tuning)**
  - 사전학습된 모델의 마지막 Transformer 블록 활성값에 선형 출력 레이어 추가
  - 태스크 목적함수: $L_2(C) = \Sigma(x,y) \log P(y \mid x^1, \ldots, x^m)$
  - 보조 LM 목적함수 결합: $L_3(C) = L_2(C) + \lambda \times L_1(C)$ (λ=0.5)
  - 추가 파라미터는 Wy와 delimiter 토큰 임베딩뿐
- **태스크별 입력 변환**
  - 텍스트 함의(Textual Entailment): [전제; $; 가설]
  - 유사도(Similarity): 두 문장의 순서를 바꿔 2개 시퀀스 생성 → 요소별 합산
  - QA/상식 추론: [문맥; 질문; $; 답변 후보] → 각 후보별 독립 처리 후 softmax
  - 분류(Classification): 직접 미세조정

4. 실험 및 결과

💡 Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- **자연어 추론 (NLI)**: SNLI, MultiNLI, QNLI, RTE, SciTail
- **질의응답 및 상식 추론**: RACE (중·고교 시험), Story Cloze Test
- **의미 유사도**: MRPC, QQP, STS-B
- **분류**: SST-2 (감성 분석), CoLA (언어적 수용 가능성)

Baseline

- ESIM + ELMo, CAFE, Stochastic Answer Network (NLI)
- val-LS-skip, Hidden Coherence Model, Dynamic Fusion Net, BiAttention MRU (QA)
- Single/Multi-task BiLSTM + ELMo + Attn (GLUE 벤치마크)

결과

- **NLI**: MNLI에서 82.1% (기존 대비 +1.5%), SciTail +5%, QNLI +5.8% 달성
- **QA**: Story Cloze 86.5% (+8.9%), RACE 59.0% (+5.7%)
- **유사도**: STS-B에서 82.0 (+1점), QQP에서 70.3% (+4.2%)
- **분류**: CoLA 45.4 (기존 35.0 대비 대폭 상승), SST-2 91.3%
- **GLUE 종합**: 72.8 (기존 68.9 대비 상승)
- **Ablation 결과**:
  - 사전학습 제거 시 평균 14.8% 성능 하락
  - Transformer → LSTM 교체 시 평균 5.6점 하락
  - 보조 LM 목적함수는 대규모 데이터셋에서 효과적

5. 결론 (배운점)

💡 연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- **의의**: 태스크에 구애받지 않는 단일 모델로 생성적 사전학습과 판별적 미세조정을 결합하여 9/12 태스크에서 SOTA를 달성. 이후 GPT-2, GPT-3, BERT 등 사전학습 기반 모델의 폭발적 발전의 초석이 됨
- **한계점**: RTE 등 소규모 데이터셋에서는 성능이 다소 부족했으며, 멀티태스크 학습과의 결합은 탐구되지 않음. 디코더 전용 구조로 양방향 문맥 활용이 불가능 (이후 BERT가 이 한계를 보완)
- **배운점**: 단순하지만 강력한 아이디어 — "큰 코퍼스에서 언어 모델을 학습하고, 소량의 레이블 데이터로 미세조정한다"는 패러다임이 NLP의 판도를 바꾼 논문. 태스크별 입력 변환이라는 아이디어가 모델 아키텍처 수정 없이 다양한 태스크를 통합할 수 있음을 보여줌

1. Introduction

논문이 다루는 분야

- 컴퓨터 비전 (Computer Vision)
- 이미지 분류 (Object Recognition)
- 합성곱 신경망 아키텍처 설계

해당 task에서 기존 연구 한계점

- **기울기 소실 문제 (Vanishing Gradient)**
  - 네트워크가 깊어질수록 입력/기울기 정보가 많은 레이어를 거치면서 사라지거나 희석됨
- **ResNet의 한계**
  - ResNet은 skip connection을 통해 기울기 소실을 완화하지만, identity mapping과 H_ℓ의 출력을 **덧셈(summation)**으로 결합 → 정보 흐름을 방해할 수 있음
  - Stochastic Depth 연구에서 ResNet의 많은 레이어가 사실 불필요하며 학습 중 랜덤으로 제거 가능하다는 것이 밝혀짐 → 깊은 네트워크에 상당한 중복성(redundancy)이 존재
- **파라미터 비효율성**
  - 기존 네트워크는 각 레이어가 독자적인 가중치를 가지며, 이전 레이어에서 학습한 특성맵을 재학습해야 함 → 파라미터 낭비

논문의 contributions

1. **Dense Connectivity Pattern 제안**: 각 레이어를 이전의 모든 레이어와 직접 연결하는 DenseNet 아키텍처 제안. L개 레이어에서 L(L+1)/2개의 직접 연결 생성
2. **특성 재사용 (Feature Reuse) 촉진**: 연결(concatenation) 방식으로 이전 레이어의 특성맵을 보존하여 네트워크 전체에서 특성 재사용 가능
3. **파라미터 효율성 극대화**: 좁은 레이어(예: k=12)만으로도 높은 성능 달성. ResNet 대비 약 1/3의 파라미터로 동등한 성능
4. **기울기 소실 완화 및 암묵적 깊은 감독(Implicit Deep Supervision)**: 모든 레이어가 손실 함수로부터 직접 기울기를 받을 수 있어 학습이 용이
5. **CIFAR-10/100, SVHN, ImageNet에서 SOTA 달성**