Auto-Encoding Variational Bayes(VAE)

[개념 정리] 딥러닝 파이토치 교과서 13.1-13.2 (p.682~708)

📒 생성모델이란

1.1 개념

- **discriminative model:** 기존 합성곱 신경망에서는 입력 이미지(x)가 있을때 정답(y)를 찾는 문제들을 다룸. 이미지를 정확히 구분해야하므로 대표 특성을 잘 찾는 것이 목표
- **generative model:** 추출한 특성들의 조합으로 새로운 이미지 생성. 입력 이미지의 데이터 분포 p(x)를 학습해 새로운 이미지(입력과 유사한)를 생성하는 것이 목표

1.2 유형

- **변형 오토인코더 모델**(명시적 방법): 확률변수 p(x)를 정의하여 사용
  - 이미지의 잠재공간(latent space)에서 샘플링하여 새로운 이미지나 기존 이미지 변형해 학습
- **GAN 모델**(암시적 방법): 확률 변수 정의 없이 p(x)를 샘플링하여 사용
  - 생성자와 판별자가 경쟁하면서 최대한 진짜 이미지와 비슷하게 만들도록 학습

📒 변형 오토인코더

2.1 오토인코더

단순히 입력을 출력으로 복사하는 신경망. 입력과 출력보다 뉴런보다 적은 은닉층(병목층)의 뉴런으로 데이터를 잘 표현할 수 있음

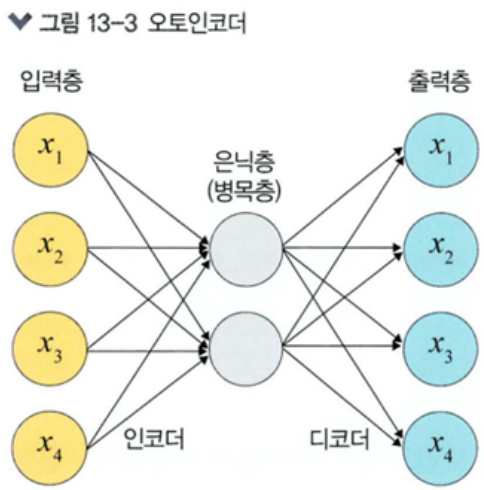

- 인코더: 특성에 대한 학습
- 은닉층(병목층): 모델의 뉴런개수가 최소인 계층. 차원이 가장 낮은 입력 데이터의 압축 표현 포함
- 디코더: 생성 네트워크. 은닉층에서 압축된 데이터를 원래대로 재구성. 즉, 입력에 가까운 출력을 생성
- 손실 재구성: 압축된 입력을 출력층에서 재구성. 손실함수는 입력과 출력(인코더와 디코더)의 차이를 가지고 계산. (입력층과 출력층의 뉴런 개수가 같은 다층 퍼셉트론 구조)

- 입력값 x → 압축 잠재벡터 h(x) → 입력과 같은 크기의 출력 값 g(h(x))

$$Loss = \sum_{L}(x, g(h(x))) = ||x - y||^2$$

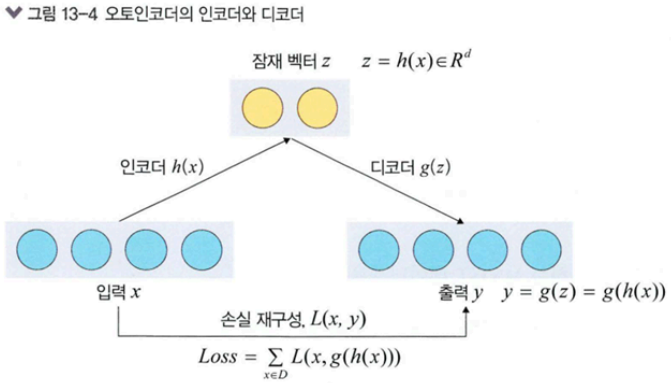

- 오토인코더의 장점
  1. 데이터 압축: 이미지나 음성의 중요 특성만 압축하여 용량도 작고 품질도 더 좋아짐
  2. 차원의 저주 예방: 특성 개수를 줄여주므로 차원이 감소
  3. 특성 추출: 비지도 학습으로 자동으로 중요 특성(ex. 눈 모양, 털 색, 꼬리 길이) 찾아줌
- 입력(노이즈) → 인코더 → 잠재 벡터 → 디코더 → 출력

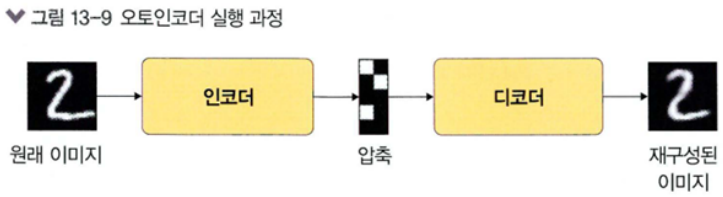

2.2 변형 오토인코더

가우시안 분포를 이용해 입력 데이터와 조금 다른 출력 데이터를 생성함. 중요 특성 파라미터를 담은 z(가우시안) 분포에서 벡터를 랜덤하게 샘플링하고 분포의 오차를 이용해 입력과 **유사한 다양한** 데이터를 생성

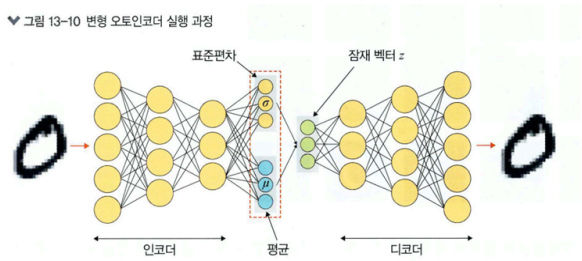

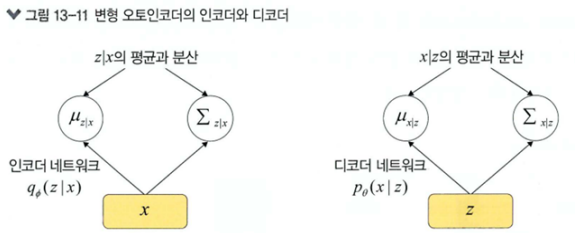

- 데이터가 만들어지는 확률 분포를 찾아 비슷한 데이터를 생성
  - **인코더:** x를 입력받아 잠재벡터 z와 대응되는 평균과 분산을 구함
    - 입력x → $z|x$ 의 평균, 분산 출력 → 가우시안 분포에서 z 샘플링 & 오차함수(2) 값
  - **디코더:** z를 입력받아 x와 대응되는 평균과 분산을 구함
    - 입력z → $x|z$ 의 평균, 분산 출력 → 가우시안 분포에서 z 샘플링 + x' 구함 & 오차함수(1) 값
    - 역전파를 이용해 L 값이 높아지는 방향으로 기울기 업데이트. 가능도(likelihood)가 증가하는 방향으로 파라미터 업데이트
    - x와 유사한 x'이미지 생성!
  - **전체 오차함수 L**
    (1) 재구성 오차: $x'|z$의 확률밀도 함수. 디코더 가능도가 늘수록 θ가 데이터 잘 표현함. 가능도가 커짐
    (2) KLD 오차: $z|x$의 확률밀도 함수. 인코더와 가우시안 분포가 얼마나 유사한지 나타냄. 유사할수록 D_{KL}이 낮은 값을 가지므로 모델 가능도가 커짐.

$$\underbrace{E_z[\log p_\theta(x^{(i)} \mid z)]}_{①} - \underbrace{D_{KL}(q_\phi(z \mid x^{(i)}) \,\|\, p_\theta(z))}_{②}$$

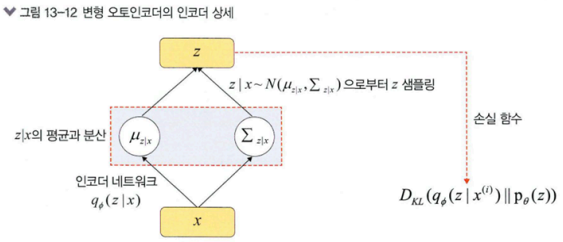

그림 13-12 변형 오토인코더의 인코더 상세

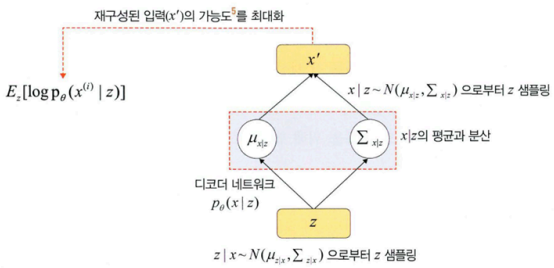

그림 13-13 변형 오토인코더의 디코더 상세

📗 논문 링크: Auto-Encoding Variational Bayes

1. Introduction

논문이 다루는 분야

Continuous latent variables를 활용한 효율적인 근사 추론(approximate inference) 및 학습(learning)분야. 특히 신경망과 확률 모델을 결합하여 데이터의 본질적 특징을 학습하고 새로운 데이터를 생성하는 변형 오토인코더(Variational Auto-Encoder)의 이론을 다룸.

해당 task에서 기존 연구 한계점

1. Intractability: 비선형 은닉층을 가진 신경망과 같이 모델이 조금만 복잡해져도, posterior distribution를 계산하거나 marginal likelihood를 구하기 위한 적분 값을 분석적으로 풀어내는 것이 불가능
2. Large dataset: 데이터 양이 방대한 경우 기존의 batch optimization 방식은 비용이 높음. MCMC(Markov Chain Monte Carlo)같은 샘플링 기반 방법은 데이터 포인트마다 반복적인 샘플링 루프를 거쳐야해 속도가 느리고 실용적이지 못함.

- Variational lower bound의 gradient를 구하기 위해 사용되던 일반적인 몬테카를로 추정 방식은 분산이 매우 커서 학습이 불안정함.
- Wake-Sleep과 같은 기존 방식은 두 개의 서로 다른 목적 함수를 동시에 최적화해야 했으며, 이는 marginal likelihood의 하한을 최적화한다는 수학적 보장이 부족했음.

논문의 contributions

- **Reparameterization Trick:** 미분이 불가능하던 확률적인 샘플링 과정을 결정론적인 함수와 외부 노이즈의 조합으로 재정의하여, 확률 모델임에도 Backpropagation와 경사 하강법을 통해 효율적으로 학습할 수 있게 함.

- z = $g\varphi(\varepsilon,x)$, where ε is an auxiliary variable with independent marginal $p(\varepsilon)$, and $g\varphi(.)$ is some vector-valued function parameterized by φ

- **SGVB(Stochastic Gradient Variational Bayes) 추정량:** variational lower bound을 Reparameterization Trick하여, 거의 모든 연속형 잠재 변수 모델에서 표준 확률적 경사 상승 기법을 통해 직접 최적화할 수 있는 미분 가능한 불편 추정량을 제안
- **AEVB(Auto-Encoding VB) 알고리즘:** 데이터 포인트당 잠재 변수가 있는 i.i.d. 데이터셋에 대해, 인식 모델(인코더)을 최적화하여 매우 효율적인 추론과 학습을 수행하는 알고리즘 도입
- 인식 모델에 신경망을 적용하여 복잡한 데이터를 저차원의 잠재 공간으로 요약하고 다시 복원하는 VAE 모델을 제시, 실험을 통해 기존 방식보다 수렴 속도와 성능 면에서 뛰어남을 보임.

2. Related Work

1. Wake-Sleep

- 연속형 잠재 변수 모델에 적용 가능한 거의 유일한 온라인 학습 방법이었음. 두 개의 별도 목적 함수를 동시에 최적화해야 하는데 이 방식은 주변 우도의 (하한) 경계를 최적화한다는 수학적 보장이 없음.
  → AEVB는 하나의 일관된 variational lower bound을 최적화하며, 데이터 포인트당 계산 복잡도는 동일하면서도 실험적으로 더 빠른 수렴과 더 나은 성능을 가짐

2. Stochastic variational inferenc(SVI)

- 기존엔 나이브한 경사 추정량의 높은 분산 문제를 해결하기 위해 control variates와 같은 복잡한 기법을 도입해옴.
  → 복잡한 control variates 대신 Reparameterization trick을 사용하여 하한에 대한 단순하고 미분 가능한 불편 추정량(SGVB)을 도출함. 이는 표준적인 확률적 경사 상승 기법으로 직접 최적화가 가능.

3. Auto-encoders

- 비규제화된 오토인코더는 유용한 표현을 학습하기에 부족하며, 이를 해결하기 위해 Denoising, Contractive, Sparse 오토인코더 등 다양한 규제화 기법 필요했고, 번거로운 규제화 하이퍼파라미터를 직접 설정해야했음.
  → SGVB의 목적 함수는 variational lower bound 수식 자체에 KL 발산이라는 규제화 항이 포함되어 있어, 추가적인 하이퍼파라미터 없이도 자동으로 유용한 표현을 학습가능

4. 기타 모델

- DARN 모델은 오토인코딩 구조를 사용하지만 binary 잠재 변수에 국한됨. Deep Boltzmann Machine과 같은 모델들은 비정규화 모델을 대상으로 하거나 sparse coding에만 제한됨.
  → 연속형 잠재 변수를 가진 일반적인 directed probabilistic models 전체를 아우르는 범용적인 알고리즘을 제안함.

본 논문의 방법이 수학적으로 하한 최적화 보장하며, 별도의 규제화 파라미터가 필요 없고, 딥러닝의 역전파를 확률 모델에 그대로 적용할 수 있게 만든 효율적인 방식임

3. 제안 방법론

Main Idea

1. **방법론의 base idea**

- **Recognition Model**
  데이터 *x* 가 관찰되지 않은 잠재 변수 *z*를 포함하는 무작위 과정에 의해 생성된다고 가정할 때, 실제 $p\theta(z \mid x)$는 수학적으로 계산이 불가능하며, 데이터가 너무 많아 전통적인 샘플링 방식은 너무 느림.

  → 진짜 posterior distribution를 근사하기 위해 $q_\phi(z \mid x)$라는 **Recognition Model** 도입. 데이터 x를 입력받아 잠재 코드 z의 분포를 생성함

- **Variational Bound**

  주변 우도의 로그 값을 직접 최적화하는 대신, 그 하한선인 ELBO(Evidence Lower Bound)를 최대화함. 이 하한선은 '데이터를 얼마나 잘 복원하는가(기대 로그 우도)'와 '근사 분포가 사전 분포와 얼마나 유사한가(KL 발산)'의 합으로 구성됨

$$\mathcal{L}(\boldsymbol{\theta}, \boldsymbol{\phi}; \mathbf{x}^{(i)}) = -D_{KL}(q_{\boldsymbol{\phi}}(\mathbf{z}|\mathbf{x}^{(i)})||p_{\boldsymbol{\theta}}(\mathbf{z})) + \mathbb{E}_{q_{\boldsymbol{\phi}}(\mathbf{z}|\mathbf{x}^{(i)})}\left[\log p_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}|\mathbf{z})\right]$$

- **Reparameterization Trick**
  확률 변수 *z*를 $z = g_\phi(\epsilon, x)$로 재정의함. 여기서 ϵ은 외부의 보조 노이즈 변수. 이 트릭을 통해 확률 변수*z*가 매개변수 ϕ 에 대해 직접적인 함수가 되어 미분 가능해지며 표준 SGD로 모델을 학습할 수 있게 됨

Reparameterization Trick된 Lower Bound을 사용하여 미분 가능한 **SGVB**(Stochastic Gradient Variational Bayes) **추정량**을 도출하고,이를 미니배치 단위로 최적화하는 **AEVB**(Auto-Encoding VB) 알고리즘 제안

2. **변형 오토인코더 (VAE)**
   제안된 방법론을 신경망에 적용한 것

- 인식 모델(인코더)와 생성 모델(디코더)에 MLP 같은 신경망을 사용함
- latent 변수의 prior distribution $p_\theta(z)$는 표준 가우시안 분포로 설정, 근사 posterior distribution $q_\theta(z|x)$도 대각 공분산을 가진 가우시안 분포로 가정

$$\log q_{\boldsymbol{\phi}}(\mathbf{z}|\mathbf{x}^{(i)}) = \log \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}^{(i)}, \boldsymbol{\sigma}^{2(i)}\mathbf{I})$$

- 학습 과정
  - 인코더가 데이터 x를 받아 평균(μ)과 분산(σ)을 출력
  - Reparameterization Trick($z=\mu+\sigma\odot\epsilon$) 을 사용해 latent 변수 z를 샘플링

    - 디코더가 z를 받아 원래 데이터 x를 다시 복원함
- 최종 목적 함수:
    - 우리가 직접 계산하기 힘든 주변 우도 $logp_\theta(x(i))$의 하한선이 됨. 즉, 이 목적 함수를 최대화하면 우리가 가진 데이터가 나타날 확률(우도)을 간접적으로 최대화하게 되어 모델이 데이터를 더 잘 설명하게 됨

$$\tilde{\mathcal{L}}_B(\theta, \phi; x^{(i)}) = -D_{KL}(q_\phi(z|x^{(i)})||p_\theta(z)) + \frac{1}{L}\sum_{l=1}^{L}(\log p_\theta(x^{(i)}|z^{(i,l)}))$$

    - 가우시안 가정을 사용할 경우 KL 발산 항을 분석적으로 계산할 수 있어, 더욱 분산이 낮은 효율적인 학습이 가능
    - 재구성 오차를 줄이는 것과 잠재 공간을 규제화하는 것 사이의 균형을 맞춤

4. 실험 및 결과

Dataset

- **MNIST:** 손글씨 숫자 이미지 데이터셋
- **Frey Face:** 사람의 얼굴 이미지 데이터셋. MNIST와 달리 연속적인(continuous) 값으로 구성되어 있어 출력층에 시그모이드 활성화 함수를 가진 가우시안 디코더를 사용함

Baseline 및 결과

AEVB 알고리즘의 성능을 검증하기 위해 다음의 기존 방법들과 비교함.

- **Wake-Sleep 알고리즘 -** AEVB와 동일한 네트워크 구조(인식 모델)를 사용하여 공정한 비교
- **Monte Carlo EM (MCEM) -** HMC 샘플러를 사용하는 전통적인 방식(대규모 데이터셋에 효율적X)

1. **Likelihood Lower Bound (우도 하한) 실험**
   AEVB 알고리즘이 목적 함수인 ELBO를 얼마나 효과적으로 최적화하는지 측정함

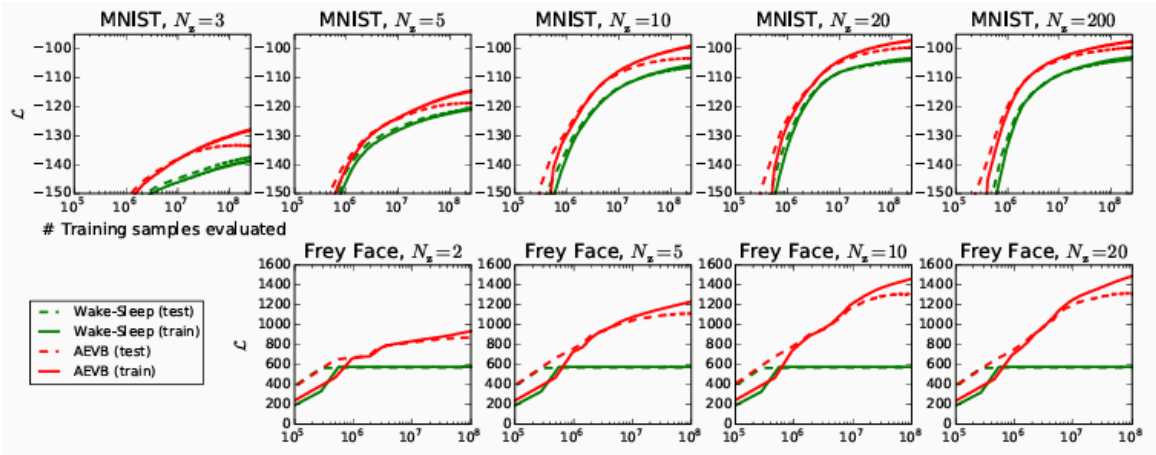

- 실험 방법: 다양한 잠재 변수 차원(N_z=3,5,10,20,200)에 대해 Wake-Sleep 알고리즘과 성능비교
- 결과:
  - **수렴 속도 및 성능:** 모든 실험에서 AEVB가 Wake-Sleep보다 훨씬 빠르게 수렴했으며 최종적으로 도달한 하한값(Lower Bound)도 더 높았음
  - **규제화 효과:** 잠재 변수의 차원(N_z)이 늘어나도 Overfitting이 발생하지 않음. 이는 변분 하한 수식 내의 KL 발산 항이 자동으로 모델을 Regularizing하여 유용한 표현을 학습하도록 유도하기 때문

2. Marginal Likelihood (주변 우도) 실험

변분 하한은 실제 우도의 근사치이므로, 모델의 진짜 성능을 확인하기 위해 실제 주변 우도 ($\log p_\theta(x)$)를 추정하여 비교

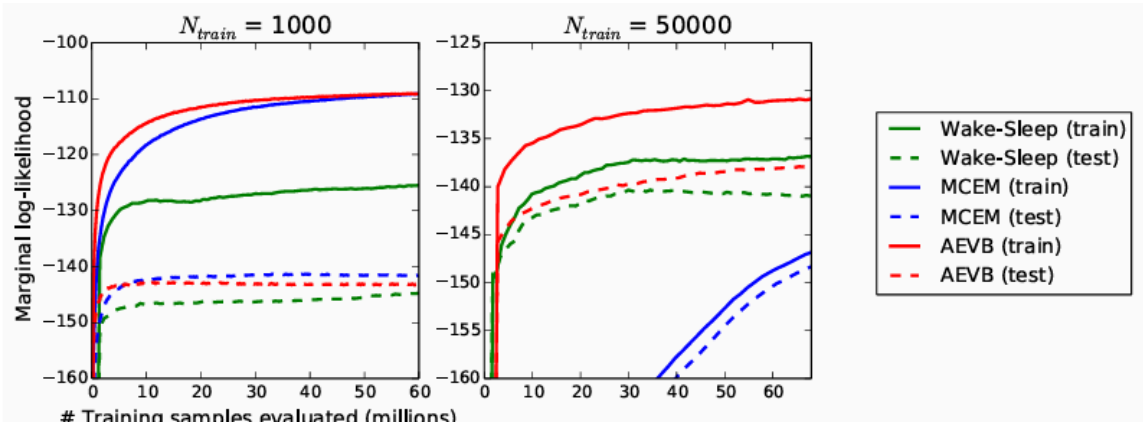

- 실험 방법: 잠재 공간이 저차원(N_z=3)인 경우에 대해 MCMC 추정기를 사용하여 실제 주변 우도를 계산. 비교 대상으로는 Wake-Sleep + Monte Carlo EM 방식을 추가
- 주요 결과:

- 학습 효율성: AEVB는 소규모(N=1000) 및 대규모(N=50000) 데이터셋 모두에서 가장 빠른 수렴 성능을 보임
- MCEM은 데이터 포인트마다 복잡한 샘플링 루프(HMC leapfrog steps)를 거쳐야 하므로 대규모 데이터셋(Full MNIST)에는 실용적으로 적용할 수 없었으나, AEVB는 대규모 데이터도 효율적으로 처리해냄

3. Visualization 및 결론

- 2차원 잠재 공간으로 학습시킨 모델을 시각화한 결과, 숫자의 모양이나 얼굴의 표정이 급격하게 변하지 않고 부드럽게 전이되는 구조(Manifold)가 성공적으로 학습됨
- 실험을 통해 SGVB 추정량과 AEVB 알고리즘이 이론적인 장점(낮은 분산, 효율적인 미분 가능성)뿐만 아니라 실제 대규모 데이터 학습에서도 기존 방식보다 뛰어난 성능을 가짐

5. 결론 (배운점)

근사 추론과 재매개변수화 트릭으로 기존 연구들의 한계를 해결한게 인상깊었다... 수학적 근사를 이렇게 활용해야함을 다시 배웠다. 또한 variational lower bound 수식 자체에 KL 발산 항을 포함해 모델을 자동으로 규제하여 과적합을 방지하는 방식도 기발한 것 같다. 이 논문의 아이디어를 통해 딥러닝과 변분 추론을 결합해 효율적인 생성 모델을 만든 것이 현대 연구에 큰 혁신을 가져온 것 같다.