

BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension

☰ Multi-select



arxiv.org

<https://arxiv.org/pdf/1910.13461>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

3. 제안 방법론

Model (모델 구조 및 사전 학습)

Fine-tuning BART (미세 조정 방법)

Comparing Pre-training Objectives (사전 학습 목적 함수 비교)

4. 실험 및 결과

5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

자연어 생성(Generation), 번역(Translation), 그리고 이해(Comprehension)를 위한 **시퀀스 투 시퀀스 (Sequence-to-Sequence, Seq2Seq) 모델의 사전 학습(Pre-training) 방법론**

해당 task에서 기존 연구 한계점

기존의 Self-supervised 방식들은 성공을 거두었으나, 다음과 같은 기술적 한계와 적용상의 제약이 있었음

- **특정 태스크에 국한:** 마스크드 언어 모델(MLM)과 같은 기존 방식들은 대개 스패ן(span) 예측이나 텍스트 생성 등 특정 유형의 최종 작업(end tasks)에만 집중되어 있어, 모델의 범용적인 적용이 제한적임
- BERT는 무작위 토큰을 마스크로 대체하고 양방향으로 인코딩하지만, 누락된 토큰을 독립적으로 예측하기 때문에 텍스트 생성 작업에는 쉽게 사용하기 어렵다는 단점
- GPT와 같은 모델은 토큰을 자기회귀적(auto-regressively)으로 예측하므로 생성 작업에는 유리하지만, 왼쪽 문맥에만 의존하기 때문에 양방향 상호작용을 학습X
- 기존의 노이즈 제거 오토인코더들은 대개 특정한 노이즈 방식에 맞춰 설계되어 있어, 원본 텍스트를 손상시키는 방식이 제한적이었음
- 사전 학습된 표현을 통해 인코더 성능을 높이는 연구는 많았으나, 기계 번역의 디코더에서 사전 학습된 언어 모델을 활용해 얻는 이득은 제한적이었음

논문의 contributions

BART는 이러한 한계점들을 극복하기 위해 다음과 같은 기여를 했음

- BART는 양방향 인코더와 자기회귀 디코더를 결합한 표준적인 Seq2Seq Transformer 아키텍처 사용.
 ⇒ 양방향 문맥을 활용하는 BERT의 장점과 자기회귀적 생성이 가능한 GPT의 장점을 모두 포괄하며 기존의 여러 사전 학습 기법들을 일반화
- **노이즈 함수(Arbitrary Noising) 도입:** 원본 텍스트의 길이를 바꾸거나 순서를 섞는 등 **임의의 변환을 허용하는 유연한 노이즈 기법**을 제안. 특히, 여러 토큰을 단일 [MASK]로 바꾸는 텍스트 인필링(Text Infilling)과 문장 순서를 섞는 **문장 순열(Sentence Permutation)** 방식이 모델로 하여금 전체적인 문장 길이를 추론하고 더 긴 범위의 변화를 학습하게 함
- BART는 생성 작업에 특화되어 있으면서도, GLUE나 SQuAD와 같은 판별 작업(Discriminative tasks)에서도 **RoBERTa와 대등한 성능**을 보임. 이는 생성 위주의 사전 학습이 이해 능력을 저해하지 않음을 입증한 것
- **생성 작업의 SOTA 달성:** 추상적 요약(Summarization), 대화(Dialogue), 질의응답(QA) 등에서 기존 모델들을 크게 앞지름. 특히 XSum 데이터셋 요약에서 **ROUGE 점수를 약 6점 가량 향상**시키는 등 비약적인 성능 발전
- BART 전체 모델을 사전 학습된 타겟 언어 디코더로 활용하고, 그 위에 새로운 인코더를 쌓는 방식을 제안. 이 방식은 강력한 역번역(Back-translation) 시스템보다 **1.1 BLEU 점수 향상**을 기록하며 사전 학습된 언어 모델의 디코더 활용 가능성을 증명함.
- 단순히 점수만 높은 것이 아니라, 생성된 텍스트가 매우 추상적이고 유창하며 **배경 지식을 통합하여 논리적인 추론**을 수행할 수 있음을 확인 (예: 특정 사건이 발생한 지역을 문맥으로 유추)




Figure 1: A schematic comparison of BART with BERT (Devlin et al., 2019) and GPT (Radford et al., 2018).

2. Related Work 관련 연구

- **BERT 및 변형들:** BERT는 마스크드 언어 모델링을 통해 양방향 문맥을 학습하지만, 자기회귀적으로 예측하지 않아 생성 작업에서의 효과가 떨어짐
- **UniLM:** BERT를 여러 마스크 양상블로 미세 조정하여 생성과 이해 작업 모두에 사용할 수 있게 했으나, BART와 달리 예측이 조건부 독립적이라는 차이
- **MASS:** BART와 가장 유사한 모델로, 연속된 토큰 스패를 마스크하고 이를 예측하도록 학습. 하지만 인코더와 디코더에 입력되는 토큰 세트가 분리되어 있어 판별 작업(Discriminative tasks)에는 덜 효과적임
- **XLNet:** 마스크된 토큰을 순열 순서로 자기회귀적으로 예측하여 양방향 문맥을 고려하지만, BART의 디코더는 생성 시 환경과 일치하도록 왼쪽에서 오른쪽으로 작동한다는 점이 다름

3. 제안 방법론

Model (모델 구조 및 사전 학습)

BART는 손상된 문서를 원래의 문서로 복구하도록 설계된 노이즈 제거 오토인코더(Denoising Autoencoder)

- **아키텍처 특징 (Section 2.1):**

- 표준적인 시퀀스 투 시퀀스(Seq2Seq) Transformer 구조를 따르되, ReLU 활성화 함수를 **GeLU**로 변경하고 파라미터 초기화 방식을 조정함
- Base 모델**은 인코더와 디코더 각각 6개 층, **Large 모델**은 각각 12개 층으로 구성됨
- BERT와 비교했을 때, 디코더의 각 층에 인코더의 마지막 은닉층에 대한 교차 어텐션(Cross-attention)이 추가되었으며, 단어 예측 전 추가적인 피드포워드 네트워크는 사용하지 않음. 이로 인해 BERT보다 약 10% 더 많은 파라미터를 가짐
- 사전 학습 방법 (Section 2.2):**
 - 텍스트를 손상시킨 후 디코더 출력과 원본 문서 사이의 교차 엔트로피 손실을 최적화




Figure 2: Transformations for noising the input that we experiment with. These transformations can be composed.


- 모델 학습에 사용된 다양한 노이즈 변환 기법들
 - Token Masking:** 무작위 토큰을 [MASK]로 대체
 - Token Deletion:** 토큰을 삭제하여 모델이 실종된 위치를 찾게 함
 - Text Infilling:** 포아송 분포($\lambda=3$)에 따라 결정된 길이의 텍스트 스패를 **단일 [MASK] 토큰**으로 대체하며, 이는 모델이 빠진 토큰의 개수까지 예측하게 학습시킴
 - Sentence Permutation:** 마침표를 기준으로 문서를 분할하고 순서를 무작위로 섞음
 - Document Rotation:** 무작위 토큰을 선택해 문서의 시작점이 되도록 회전시켜 문서의 시작을 찾게 함

Fine-tuning BART (미세 조정 방법)

BART가 생성한 표현은 다양한 하위 작업(Downstream tasks)에 유연하게 활용될 수 있음

- 시퀀스 분류 (Section 3.1):**
 - 인코더와 디코더에 동일한 입력을 넣고, **마지막 디코더 토큰의 최종 은닉 상태**를 새로운 선형 분류기에 통과시킴
 - [Figure 3a]는 분류 문제를 위해 BART를 미세 조정하는 구조를 보여줌
- 토큰 분류 (Section 3.2):** 문서 전체를 인코더와 디코더에 입력하고, 디코더의 최상단 은닉 상태를 각 단어의 표현으로 사용하여 분류

- **시퀀스 생성 (Section 3.3):** 인코더에 입력 시퀀스를 넣고 디코더가 자기회귀적으로 출력을 생성함
⇒ 요약이나 추상적 질의응답 작업에 직접 적용
- **기계 번역 (Section 3.4):**
 - BART 전체를 **사전 학습된 타겟 언어 디코더**로 활용. 무작위로 초기화된 새로운 인코더를 추가하여 외국어를 BART가 이해할 수 있는 '노이즈가 섞인 영어'로 매핑하도록 학습
 - [Figure 3b]는 이 기계 번역용 구조를 보여주며, 새로운 인코더는 별도의 어휘집을 가질 수 있음



(a) To use BART for classification problems, the same input is fed into the encoder and decoder, and the representation from the final output is used.

(b) For machine translation, we learn a small additional encoder that replaces the word embeddings in BART. The new encoder can use a disjoint vocabulary.

Figure 3: Fine tuning BART for classification and translation.

Comparing Pre-training Objectives (사전 학습 목적 함수 비교)

BART 프레임워크 내에서 기존의 다양한 사전 학습 기법들을 구현하여 성능을 공정하게 비교

- **비교 대상 (Section 4.1):** 언어 모델(GPT 방식), 순열 언어 모델(XLNet 방식), 마스크드 언어 모델(BERT 방식), 멀티태스크 MLM(UniLM 방식), 마스크드 Seq2Seq(MASS 방식) 등이 포함됨
- **주요 실험 결과 (Section 4.3):**
 - [Table 1]: 다양한 사전 학습 목적 함수에 따른 태스크별 성능 결과
 - **태스크별 의존성:** 성능은 작업에 따라 크게 다름. 예를 들어 순수 언어 모델은 ELI5(질의응답)에서 최고였으나 SQuAD에서는 최악
 - **토큰 마스크의 중요성:** 문서 회전이나 문장 셔플링만으로는 성능이 좋지 않았으며, 토큰 마스크가 필수적임
 - **결론:** 텍스트 인필링(Text Infilling)을 사용한 BART 모델이 거의 모든 작업(ELI5 제외)에서 가장 일관되게 강력한 성능을 보임. 특히 생성 작업에서는 왼쪽에서 오른쪽으로 학습하는 디코더의 존재가 결정적인 역할을 함

Model	SQuAD 1.1 F1	MNLI Acc	ELI5 PPL	XSum PPL	ConvAI2 PPL	CNN/DM PPL
BERT Base (Devlin et al., 2019)	88.5	84.3	-	-	-	-
Masked Language Model	90.0	83.5	24.77	7.87	12.59	7.06
Masked Seq2seq Language Model	87.0	82.1	23.40	6.80	11.43	6.19
Permutated Language Model	76.7	80.1	21.40	7.00	11.51	6.56
Multitask Masked Language Model	89.1	83.7	24.03	7.69	12.23	6.96
	89.2	82.4	23.73	7.50	12.39	6.74
BART Base						
w/ Token Masking	90.4	84.1	25.05	7.08	11.73	6.10
w/ Token Deletion	90.4	84.1	24.61	6.90	11.46	5.87
w/ Text Infilling	90.8	84.0	24.26	6.61	11.05	5.83
w/ Document Rotation	77.2	75.3	53.69	17.14	19.87	10.59
w/ Sentence Shuffling	85.4	81.5	41.87	10.93	16.67	7.89
w/ Text Infilling + Sentence Shuffling	90.8	83.8	24.17	6.62	11.12	5.41

Table 1: Comparison of pre-training objectives. All models are of comparable size and are trained for 1M steps on a combination of books and Wikipedia data. Entries in the bottom two blocks are trained on identical data using the same code-base, and fine-tuned with the same procedures. Entries in the second block are inspired by pre-training objectives proposed in previous work, but have been simplified to focus on evaluation objectives (see §4.1). Performance varies considerably across tasks, but the BART models with text infilling demonstrate the most consistently strong performance.

4. 실험 및 결과

- **이해 작업(Discriminative Tasks):** GLUE 및 SQuAD 벤치마크에서 RoBERTa와 유사한 성능을 기록하며, 생성 위주의 학습이 판별 성능을 저해하지 않음을 입증했음
- **생성 작업(Generation Tasks):**
 - **요약(Summarization):** CNN/DailyMail 및 XSum 데이터셋에서 이전 기록을 크게 경신했으며, 특히 XSum에서는 ROUGE 점수가 약 6점 상승하는 성과
 - **대화 및 QA:** ConvAI2(대화) 및 ELI5(추상적 질의응답) 데이터셋에서도 기존 모델들을 능가하는 SOTA 결과
- **기계 번역:** BART의 전체 모델을 사전 학습된 타겟 쪽 언어 모델로 활용하고, 새로운 인코더를 추가하여 학습시킨 결과 기존 모델보다 BLEU 점수가 향상됨

5. 결론 (배운점)

- BART는 단순한 구조임에도 불구하고 인코더-디코더 구조를 통해 언어 이해와 생성을 모두 아우르는 통합적인 사전 학습이 가능하다는 것을 보여줌
- 단순히 토큰을 가리는 것(Masking)을 넘어, 텍스트의 길이를 바꾸거나 순서를 섞는 방식의 유연한 노이즈 기법이 모델이 문맥과 구조를 더 잘 파악하게 만든다는 점을 배움
- BART는 원본 문서를 단순히 복사하는 수준을 넘어, 배경지식을 결합하고 문맥을 추론하여 매우 추상적이고 유창한 요약문을 생성할 수 있음을 확인
- 특정 태스크에 최적화된 새로운 문서 손상 방법론을 탐구하는 것이 향후 연구 방향으로 제시됨

