



ViT(Vision Transformer)

An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale

1. Introduction

논문이 다루는 분야

- 컴퓨터 비전, 그중에서도 이미지 분류(image classification)
- NLP에서 표준이 된 Transformer 아키텍처를 비전 영역으로 확장하려는 시도
- 대규모 사전학습(pre-training) → 전이학습(transfer learning) 패러다임을 비전에 적용

해당 task에서 기존 연구 한계점

- **CNN의 지배적 위치:** ResNet 계열이 대규모 이미지 인식에서 여전히 SOTA (Mahajan 2018, Xie 2020, Kolesnikov 2020)
- **Self-attention의 비전 적용 시도들의 한계:**
 - 픽셀 단위 self-attention은 **계산량이 픽셀 수에 대해 quadratic**하게 증가
→ 실제 이미지 크기에 적용 불가
 - 지역(local) attention만 적용
 - 특수한 **attention 패턴** 사용
 - 이런 특수 attention은 **현대 하드웨어 가속기(GPU/TPU)에서 효율적으로 구현하기 어려움**
- **CNN과 attention의 하이브리드** 접근들도 결국 CNN 백본을 떠나지 못함
- 가장 유사한 선행 연구인 Cordonnier et al. (2020)은 **2×2 패치만 사용**
→ 작은 해상도 이미지에만 적용 가능

논문의 contributions

- 표준 Transformer를 거의 수정 없이 이미지에 직접 적용 (이미지를 패치 시퀀스로 변환만 함)

- **이미지 특화 inductive bias를 최소화**한 채로도 SOTA 달성 가능성을 증명
- **Scale beats inductive bias**: 충분히 큰 데이터셋(JFT-300M)으로 사전학습하면 CNN의 귀납적 편향이 없어도 됨을 실증
- 주요 벤치마크 성능 갱신:
 - ImageNet **88.55%**
 - ImageNet-Real **90.72%**
 - CIFAR-100 **94.55%**
 - VTAB(19 tasks) **77.63%**
- **사전학습 비용이 기존 SOTA(BiT, Noisy Student) 대비 약 4배 적음** (2.5k vs 9.9k TPuv3-core-days)

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- **Transformer 계열 (NLP)**
 - Vaswani 2017 → BERT(denoising) / GPT(LM) : 대규모 사전학습-파인튜닝 패러다임의 성공
- **Naive self-attention의 한계**: 픽셀 단위 attention의 quadratic cost 문제
- **이전 시도들을 카테고리화**:
 - Local self-attention (Parmar 2018, Ramachandran 2019)
 - Sparse / Approximation 기법 (Child 2019)
 - Axial / Block attention (Ho 2019, Wang 2020a)
 - CNN+attention 하이브리드 (Bello 2019, Carion 2020 DETR, 등)
 - iGPT (Chen 2020a) - 생성 모델 기반 비지도 학습, ImageNet 72%에 그침
- **공통적 평가**: "promising results"이지만 "complex engineering" 필요, 하드웨어 가속기 효율성 부족

제안 방법의 차별성 표현


- **Cordonnier et al. (2020)과의 차이**를 명시적으로 비교:

- 가장 유사하지만, ViT는 더 큰 패치(16×16) 사용 → 중간 해상도 이미지까지 처리 가능
- 대규모 사전학습을 통해 vanilla Transformer가 SOTA CNN을 능가할 수 있음을 보임
- "vanilla Transformer" 강조 → 특수 attention 설계 없이도 됨
- "large scale pre-training"

3. 제안 방법론

Main Idea

- 이미지를 토큰 시퀀스로 처리: 이미지 → 패치 분할 → 선형 임베딩 → Transformer 입력
- 핵심 변환:
 - 이미지 $x \in R^{H \times W \times C}$ 를 N개의 패치 $x_p \in R^{N \times (P^2 \cdot C)}$ 로 분할
 - $N = HW/P^2$ 가 시퀀스 길이가 됨
 - 각 패치를 D차원으로 선형 투영(patch embedding)



구조 상세

- [class] 토큰: BERT 방식 차용. 학습 가능한 임베딩을 시퀀스 맨 앞에 추가, 최종 출력이 이미지 표현 y

yy

- **위치 임베딩**: 표준 **1D learnable position embedding** (2D-aware 임베딩 시도해도 성능 향상 없음)
- **Transformer Encoder**: MSA(Multi-head Self-Attention) + MLP 블록의 반복
 - **Pre-LayerNorm** 구조 (block 앞에 LN, 뒤에 residual)
 - MLP는 2층 + **GELU** 비선형
- **분류 헤드**:
 - 사전학습 시: 1-hidden-layer MLP
 - 파인튜닝 시: 단일 linear layer

모델 3가지 크기

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

Table 1: Details of Vision Transformer model variants.

Inductive Bias

- **CNN 대비 image-specific inductive bias가 훨씬 적음**
 - CNN: 지역성, 2D 이웃 구조, 평행이동 등변성이 모든 층에 내재
 - ViT: MLP 레이어만 local-equivariant, self-attention은 global
 - 2D 구조는 **(1) 패치 분할 시 (2) 파인튜닝 시 위치 임베딩 보간에서만 사용**
 - 모든 패치 간 공간 관계는 **데이터로부터 학습**

Hybrid Architecture

- 원시 패치 대신 **CNN feature map의 패치**를 입력으로 사용 가능
- 1×1 패치를 쓰면 단순히 feature map을 펼쳐 투영하는 것과 동일

Fine-tuning과 고해상도 처리

- 사전학습된 prediction head 제거 후 **zero-initialized $D \times K \times K$ feedforward layer** 부착

- 고해상도 파인튜닝이 일반적으로 성능 향상에 도움
- 패치 크기는 유지 → 시퀀스 길이가 길어짐 → 위치 임베딩은 **2D 보간(interpolation)**으로 조정

Contribution

- **단순함**: 표준 Transformer 거의 그대로 사용 → NLP의 효율적 구현체를 그대로 활용 가능
- **확장성**: 시퀀스 길이가 메모리만 허락하면 임의 크기 처리 가능
- **인덱티브 바이어스 최소화**: 데이터로 학습할 여지를 최대화

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

사전학습 데이터셋 (스케일 비교):

- **ImageNet** (ILSVRC-2012): 1.3M 이미지, 1k 클래스
- **ImageNet-21k**: 14M 이미지, 21k 클래스
- **JFT-300M**: 303M 이미지, 18k 클래스 (Google 내부)

전이학습 평가용:

- ImageNet (원본 + cleaned-up ReaL labels)
- CIFAR-10/100, Oxford-IIIT Pets, Oxford Flowers-102
- **VTAB (19-task suite)**: 1000개 학습 예제로 저데이터 전이 평가
 - Natural / Specialized / Structured 세 그룹으로 분할

Baseline

- **BiT (Big Transfer, ResNet152×4)**: 대규모 ResNet 지도 사전학습의 SOTA (Kolesnikov 2020)
- **Noisy Student (EfficientNet-L2)**: ImageNet+JFT 준지도 학습 SOTA (Xie 2020)
- 기타 VTAB 비교군: VIVI, S4L

- 모든 ResNet은 BatchNorm → GroupNorm + standardized convolutions로 변경 ("ResNet (BiT)")
- **사전학습**: Adam ($\beta_1=0.9, \beta_2=0.999$), batch=4096, weight decay=0.1
- **파인튜닝**: SGD with momentum, batch=512
- 파인튜닝 해상도: ViT-L/16은 512, ViT-H/14는 518 (ImageNet의 경우)
- Polyak averaging (factor 0.9999) 사용

결과




Figure 3: Transfer to ImageNet. While large ViT models perform worse than BiT ResNets (shaded area) when pre-trained on small datasets, they shine when pre-trained on larger datasets. Similarly, larger ViT variants overtake smaller ones as the dataset grows.




Figure 4: Linear few-shot evaluation on ImageNet versus pre-training size. ResNets perform better with smaller pre-training datasets but plateau sooner than ViT, which performs better with larger pre-training. ViT-b is ViT-B with all hidden dimensions halved.

- 데이터셋 크기별 성능
 - **ImageNet 사전학습**: ViT-Large가 ViT-Base보다 못함 (overfitting), ResNet에 뒤짐
 - **ImageNet-21k**: ViT와 ResNet이 비슷한 수준
 - **JFT-300M**: ViT가 ResNet을 명확히 능가, 큰 모델일수록 효과 큼
 - JFT 부분집합 실험(9M/30M/90M/300M): 데이터가 적을 땐 CNN 우위, 클수록 ViT 우위
 - → **convolutional inductive bias**는 작은 데이터에 유용, 큰 데이터에선 불필요하거나 오히려 방해




Figure 5: Performance versus pre-training compute for different architectures: Vision Transformers, ResNets, and hybrids. Vision Transformers generally outperform ResNets with the same computational budget. Hybrids improve upon pure Transformers for smaller model sizes, but the gap vanishes for larger models.

• 연산량 대비 성능

- ViT가 같은 연산량에서 ResNet보다 **2-4배 더 적은 compute로 동일 성능 달성**
- 하이브리드는 소규모에서만 ViT 대비 우위, 큰 모델에선 차이 사라짐
- ViT는 시도된 범위 내에서 **saturation 보이지 않음** → 추가 스케일링 여지 있음




Figure 7: **Left:** Filters of the initial linear embedding of RGB values of ViT-L/32. **Center:** Similarity of position embeddings of ViT-L/32. Tiles show the cosine similarity between the position embedding of the patch with the indicated row and column and the position embeddings of all other patches. **Right:** Size of attended area by head and network depth. Each dot shows the mean attention distance across images for one of 16 heads at one layer. See Appendix D.7 for details.

Figure 6: Representative examples of attention from the output token to the input space. See Appendix D.7 for details.

• ViT 내부 분석

- **임베딩 필터:** 학습된 패치 임베딩의 주성분이 CNN의 저차원 기저 함수와 유사
- **위치 임베딩:** 2D 토폴로지를 **자동으로 학습** (가까운 패치끼리 유사도 높음, row/column 구조 출현, 큰 그리드에선 sinusoidal 구조도)
- **Attention distance** (CNN 수용영역과 유사):
 - 일부 헤드는 **최저층부터 이미지 전체를 attend** → global 통합 능력 활용 확인
 - 다른 헤드는 저층에서 매우 local → CNN의 초기 conv와 유사한 역할

- Hybrid에선 local attention이 줄어들 → 실제로 CNN이 그 역할을 대체
- 깊이가 깊어질수록 attention distance 증가
- **Attention map**: 분류에 의미 있는 영역에 attention이 집중됨

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

연구의 의의

- 이미지 인식에 Transformer를 직접 적용한 최초의 본격적 성공 사례
- Patch extraction 외에 image-specific inductive bias를 거의 사용하지 않고도 SOTA 달성
- NLP-비전의 아키텍처 통합 가능성을 실증 → 이후 멀티모달 연구의 발판
- 데이터 스케일이 아키텍처 선택을 좌우한다는 새로운 관점 제시
- 단순한 구조 → NLP의 효율적 Transformer 구현체를 그대로 활용 가능 (실용적 가치)

한계점 (논문에서 명시)

- 다른 비전 태스크 미검증: detection, segmentation 등은 future work
- Self-supervised 방식이 supervised에 못 미침: 4% 격차
- Contrastive pre-training 미탐색: 향후 과제로 남김
- 추가 스케일링의 결과 미확인: saturation 미관찰이지만 어디까지 갈지 불명

추가로 생각해볼 한계점 (배운점 측면)

- JFT-300M 의존성: 핵심 결과들이 비공개 데이터셋에 의존 → 재현성 문제
- 막대한 사전학습 비용: 2.5k TPuv3-core-days는 여전히 진입장벽
- 작은 데이터셋에서의 underperform: 실무에서 ImageNet 정도 규모 데이터로는 ResNet이 여전히 유리할 수 있음
- 위치 임베딩 보간의 ad-hoc 성격: 해상도 변경 시 깔끔한 해법 부재

좋았던 점

- "패치를 단어처럼 다룬다"는 한 문장으로 요약되는 깔끔한 아이디어
- "데이터가 많으면 학습 가능"이라는 명제를 정량적으로 보임
- Attention distance 분석이 직관적이면서도 강력해 CNN의 receptive field와 자연스럽게 비교됨

배운점 (개념적)

- **아키텍처 vs 데이터의 trade-off**: 인덱티브 바이어스는 데이터가 부족할 때의 prior일 뿐, 데이터가 충분하면 모델이 직접 학습 가능
- **모듈 통합의 가치**: NLP와 비전의 인프라/지식이 공유되면 양 분야 모두 가속
- **simplicity wins at scale**: 복잡한 특수 attention 설계보다 단순하고 확장 가능한 vanilla 구조가 결국 이김
- **사전학습-파인튜닝 패러다임의 보편성**: NLP에서 검증된 transfer learning 방식이 비전에도 통한다

YOLO (You Only Look Once)

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- **객체 탐지 (Object Detection)** — 이미지 안에 어떤 객체가 어디에 있는지를 찾는 컴퓨터 비전의 핵심 문제
- 특히 **실시간(real-time) 객체 탐지**에 초점
- **단일 통합 신경망(unified neural network)** 으로 객체 탐지를 수행하는 새로운 접근법 제안
 - 인간의 시각 시스템은 빠르고 정확해 운전 같은 복잡한 작업도 거의 무의식적으로 수행 가능
 - 빠르고 정확한 객체 탐지 알고리즘이 가능해지면:
 - **자율주행** (특수 센서 없이 컴퓨터가 차량 운전)

- 보조 장치 (실시간 장면 정보를 사용자에게 전달)
- 범용 반응형 로봇릭스 시스템 구현
 - 즉, 단순히 정확도뿐 아니라 속도(real-time)와 범용성(generalization)이 모두 필요한 분야

해당 task에서 기존 연구 한계점

(1) "분류기를 재활용하는" 패러다임의 한계

- 기존 탐지 시스템은 분류기(classifier)를 재활용해 탐지를 수행 — 객체 탐지를 분류 문제로 환원
- 이미지의 다양한 위치와 스케일에서 분류기를 반복 평가해야 함

(2) DPM (Deformable Parts Models)의 한계

- Sliding window 방식 — 분류기를 이미지 전체에 균등 간격으로 실행
- 분리된(disjoint) 파이프라인 사용:
 - 정적 특징 추출 → 영역 분류 → 바운딩 박스 예측 → 후처리
- 각 컴포넌트가 따로 학습 → end-to-end 최적화 불가능

(3) R-CNN 계열의 한계

- Region proposal 방식 — Selective Search로 약 2,000개의 후보 박스 생성 후 각각 분류
- 복잡한 다단계 파이프라인:
 - Selective Search로 후보 박스 생성 → CNN 특징 추출 → SVM으로 점수 매김 → 선형 모델로 박스 보정 → NMS로 중복 제거
- 문제점:
 - 매우 느림 — 테스트 시 이미지 한 장당 40초 이상 소요
 - 각 단계를 독립적으로 정밀 튜닝해야 함 → 최적화가 어려움
 - 전역 맥락(global context) 활용 불가 — Fast R-CNN은 작은 영역만 보기 때문에 배경 패치를 객체로 오인 (false positive 多)
- Fast R-CNN, Faster R-CNN도 속도 개선은 했으나 여전히 real-time 미달

(4) 공통적 문제점

- 파이프라인이 복잡 → 느리고 최적화하기 어려움
- 탐지 성능에 직접 대응하는 손실 함수로 **end-to-end 학습 불가**
- 이미지의 **전체 맥락**을 보지 못함 → 배경 오탐 발생
- 새로운 도메인으로의 **일반화(generalization) 능력 약함** — 자연 이미지에서 학습한 R-CNN을 예술 작품(artwork)에 적용하면 성능이 급락

논문의 contributions

핵심 아이디어

- 객체 탐지를 단일 회귀 문제(single regression problem)로 재정의
 - 이미지 픽셀 → 바운딩 박스 좌표 + 클래스 확률을 **직접** 예측
- **"You Only Look Once"** — 이미지를 **한 번만 보고** 어떤 객체가 어디에 있는지 동시에 예측
- 단일 컨볼루션 네트워크가 **여러 바운딩 박스와 그 클래스 확률을 동시에 예측**
- 전체 이미지로 학습하며, 탐지 성능을 직접 최적화

기존 한계점에 대응되는 4가지 핵심 장점

① 매우 빠름 (Extremely Fast)

- 탐지를 회귀 문제로 단순화 → 복잡한 파이프라인 불필요
- 테스트 시 신경망을 한 번만 실행
- 기본 모델: Titan X GPU에서 **45 FPS** (배치 처리 없이)
- Fast YOLO: **150 FPS 초과** → 25ms 미만 지연으로 스트리밍 영상 실시간 처리 가능
- 다른 실시간 시스템 대비 **mAP 2배 이상**
- → R-CNN 계열의 "느림" 한계 해결

② 전역적 추론 (Global Reasoning)

- Sliding window나 region proposal과 달리 학습/테스트 시 **이미지 전체를 봄**
- 클래스의 외형뿐 아니라 **맥락 정보(contextual information)** 를 암묵적으로 인코딩
- Fast R-CNN 대비 **배경 오탐(background error)을 절반 이하로 감소**
- → 기존 방법의 "맥락 부재로 인한 false positive" 문제 해결

③ 일반화 가능한 표현 학습 (Generalizable Representations)

- 자연 이미지로 학습 후 **예술 작품(artwork)에 테스트** → DPM, R-CNN을 큰 차이로 능가
- 새로운 도메인이나 예상치 못한 입력에 **덜 취약**
- → 기존 방법의 "도메인 일반화 약함" 문제 해결

④ 단일 통합 모델 (Unified, End-to-End)

- 전체 탐지 파이프라인이 **하나의 네트워크**
- **end-to-end로 직접 최적화 가능** — 탐지 성능에 대응하는 손실 함수로 학습
- → 기존의 "분리된 파이프라인, 따로 학습" 문제 해결

trade-off

- YOLO는 여전히 **SOTA 정확도에는 못 미침**
- 특히 **작은 객체의 정밀한 위치 추정(localization)에 약함**
- 즉, **localization error는 SOTA보다 크지만, background false positive는 훨씬 적음** — 이 상호보완적 특성 덕분에 후술하는 Fast R-CNN과의 결합에서 큰 이득

추가 기여 (실용적 측면)

- 모든 학습/테스트 코드 **오픈소스** 공개
- 다양한 사전학습 모델 다운로드 제공