



논문 리뷰: BART — Denoising Sequence-to-Sequence Pre-training for NLG, Translation, and Comprehension

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

Contribution

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- **분야:** 자연어 처리(NLP) 범용 사전학습(Pre-training) — 텍스트 생성(NLG), 기계 번역(MT), 질의응답(QA), 텍스트 요약 등 다바람 태스크
- **저자:** Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Ves Stoyanov, Luke Zettlemoyer (Facebook AI)

- **출판:** ACL 2020 (arXiv 2019.10.29)
- **핵심 제안:** 노이즈 제거(Denoising) 방식으로 사전학습된 Seq2Seq 모델 BART (Bidirectional and Auto-Regressive Transformers)

해당 task에서 기존 연구 한계점

- **BERT의 한계:** Bidirectional 인코더 구조로 표현 학습에는 유리하나, 자동회귀적 (autoregressive) 디코더가 없어 **텍스트 생성 태스크에 직접 적용 불가**
- **GPT의 한계:** Left-to-right 자동회귀 디코더로 생성에는 유리하나, **단방향 컨텍스트만 활용**하여 양방향 상호작용 학습 불가
- **기존 사전학습 목표함수의 한계:** Masked LM, Next Sentence Prediction 등 특정 태스크에 연구된 목표함수는 다른 태스크로의 전이 성능이 제한적
- **노이즈 유연성 부재:** 기존 모델들은 특정 노이즈 유형에 특화되어 있어, 다양한 노이즈 스키마를 실험하기 어려움

논문의 contributions

- **BART 아키텍처 제안:** Bidirectional 인코더(BERT식) + Autoregressive 디코더 (GPT식)를 결합한 Seq2Seq Transformer
- **다양한 노이즈 스키마 실험적 평가:** Token Masking, Token Deletion, Text Infilling, Sentence Permutation, Document Rotation 5가지 노이즈를 체계적으로 비교
- **텍스트 생성에서 SOTA:** 요약, 대화, QA 등 추상적 생성 태스크에서 최대 6 ROUGE 개선
- **개선된 번역 전략:** 목표 언어 사전학습만으로 Back-translation 기준선 대비 1.1 BLEU 향상
- **이해(Comprehension) 태스크:** RoBERTa와 동등한 GLUE, SQuAD 성능

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- **BERT** (Devlin et al., 2019): Masked Language Model(MLM)로 특정 토큰의 확률적 마스크 훈련. 텍스트 이해 강점, 텍스트 생성 타겟에는 활용이 불완전

- **GPT** (Radford et al., 2018): 자동회귀 LM 사전학습으로 텍스트 생성 강점. 단내 윌트 큰만 컨디셔닝하여 양방향 정보 활용 불가
- **XLNet** (Yang et al., 2019): Permutation LM으로 양방향 컨텍스트 + 자동회귀 생성을 시도. 토큰 예측 순서를 도입으로 복잡도 증가
- **SpanBERT** (Joshi et al., 2019): 마스크 루트를 스팸 단위로 개선. BART의 Text Infilling이 이를 일반화하며, span 내 토큰 수가 얼마나 빠졌는지를 예측하도록 강제
- **UniLM** (Dong et al., 2019): 마스크를 조절하여 인코더/디코더 모두를 비방향적으로 학습. BART는 완전한 인코더-디코더 분리를 통해 더 유연한 노이즈 적용을 실현

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
 Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
 제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

BART 사전학습 원리 (2단계)

1. **텍스트 손상(Corruption)**: 임의의 노이즈 함수로 원문을 훼손
2. **복원(Reconstruction)**: Seq2Seq 모델로 원래 텍스트를 재구성, 디코더 출력과 원문 간의 Cross-Entropy 로스를 최소화

아키텍처 (Figure 1 참조)

- **인코더**: 원문에서 손상된 텍스트를 Bidirectional Transformer로 인코딩
- **디코더**: 원래 텍스트를 생성하는 Left-to-Right Autoregressive Transformer
- **Figure 1 설명**: BERT, GPT, BART의 구조를 나란히 비교
 - (a) **BERT**: [MASK] 토큰을 양방향으로 인코딩, 토큰을 독립적으로 예측 → 생성에 적합하지 않음
 - (b) **GPT**: 토큰을 좌와우에서만 컨디셔닝하는 자동회귀 디코더 → 양방향 상호작용 학습 불가
 - (c) **BART**: 인코더에 손상된 문서 입력, 디코더에서 원래 문서의 로그리코드 계산. 인코더 입력과 디코더 입력이 정렬되지 않아도 되어 임의의 노이즈 변환 적용 가능

아키텍처 세부 사항

- Vaswani et al. (2017)의 표준 Seq2Seq Transformer 기반
- Activation: ReLU → **GeLU** 대체 (GPT 방식 이용)
- 파라미터 초기화: $\mathcal{N}(0, 0.02)$
- **Base 모델**: 인코더 6레이어 + 디코더 6레이어
- **Large 모델**: 인코더 12레이어 + 디코더 12레이어
- BERT 대비 약 **10% 많은 파라미터** (디코더의 Cross-Attention 레이어 추가 때문)
- 디코더의 각 레이어는 인코더 마지막 hidden layer에 대한 **Cross-Attention** 수행 (BERT의 Feed-Forward Before Word-prediction 레이어 미사용)

노이즈 스키마 (Figure 2 참조)

- **Figure 2 설명**: 5가지 노이즈 변환 예시를 테이블로 시각화 (Token Masking / Token Deletion / Text Infilling / Sentence Permutation / Document Rotation)

노이즈 유형	설명	특이사항
Token Masking	BERT식 [MASK] 대체	위치 정보를 토큰에 응축
Token Deletion	땀 자체를 삭제	어떤 위치가 빠졌는지 뺏코 추론해야 함
Text Infilling	Poisson($\lambda=3$)로 샘플링한 스패م 전체를 [MASK] 하나로	가려진 토큰 수를 예측해야 함
Sentence Permutation	문장 순서를 랜덤 셔플	문서 구조 이해 강제
Document Rotation	랜덤 토큰으로 시작하도록 회전	문서 시작점 식별 훈련

- 최적 조합: **Text Infilling + Sentence Permutation** 조합이 가장 우수한 성능

Contribution

1. Fine-tuning 전략 통일화 (Figure 3 참조)

- **Figure 3 설명**: 다양한 Fine-tuning 시나리오의 스키마 도식
 - (a) **Sequence Classification**: 같은 입력을 인코더·디코더에 주고, 디코더 마지막 토큰의 hidden state를 linear classifier에 입력 (BERT의 [CLS] 토큰과 유사, 뺏 처리)
 - (b) **Token Classification**: SQuAD 답변 세그멘테이션 등, 디코더의 top hidden state를 각 토큰 표현으로 사용

- (c) **Sequence Generation**: 요약, QA 등. 노이즈 제거와 일치하는 구조 — 인코더에 입력 텍스트 주고, 디코더가 자동회귀적으로 출력 생성
- (d) **Machine Translation**: BART 스택 위에 목표 언어용 추가 인코더 레이어 적동. 입력 언어를 활성화 통해 영어로 번역, BART가 노이즈 제거해주는 구조

2. Machine Translation 신규 방식

Encoder_{foreign} → BART Encoder → BART Decoder

- 소수 선형 레이어를 통해 외국어를 노이즈 영어로 매핑하도록 학습
- BART를 목표 언어(English) 언어 모델로 활용, 별도의 back-translation 데이터 불필요
- **2단계 학습**: (1) 외부 인코더만 학습, BART 동결 → (2) 최종 전체 파인튜닝

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- **요약**: CNN/DailyMail, XSum (Narayan et al., 2018), ELI5 (Fan et al., 2019)
- **대화**: ConvAI2 (Zhang et al., 2018)
- **QA**: SQuAD v1.1, Natural Questions (Kwiatkowski et al., 2019)
- **이해 평가**: GLUE Benchmark (Wang et al., 2018)
- **기계 번역**: WMT 2016 Romanian-English
- **사전학습 데이터**: Books + Wikipedia (BERT와 동일 규모)

Baseline

- **이해 태스크**: BERT, RoBERTa
- **생성 태스크**: BERT, UniLM, T5
- **구체적 노이즈 목표**: Language Model, Permuted LM, Masked LM, Multitask Masked LM, Masked Seq2Seq (BART ablation 내 포함)

결과

디노이징 목표함수 ablation 비교 (Table 1)

- **Language Model** (단방향): 디코더만 사용. 이해 태스크에서 으류
- **Permuted LM** (XLNet식): 일부 태스크에서 불안정
- **Masked LM** (BERT식): Token Masking. 이해 주제에는 우수하나 생성 제한
- **Masked Seq2Seq**: 소스를 마스크하고 대상을 생성. BART도니스통신 유리하나 이해 태스크 연보릴 정도는 다름
- **BART (Text Infilling + Sentence Permutation)**: 모든 태스크에서 **가장 일관된 최고 성능**

요약 (Table 2)

모델	XSum (ROUGE-1)	CNN/DM (ROUGE-1)
UniLM	43.35	43.33
T5	43.52	43.52
BART	45.14	44.16

- XSum에서 ROUGE-1 기준 +6 이상 개선
- CNN/DailyMail에서도 SOTA 달성

대화 (Table 3)

- ConvAI2 PPL: 11.81 (이전 SOTA 12.40 대비 개선)

QA / 이해

- SQuAD 1.1 F1: 88.8 (RoBERTa 88.9와 동등)
- GLUE: RoBERTa와 유사한 수준 달성 — 생성 강점 + 이해 능력 모두 유지

번역 (WMT16 Romanian-English)

- BART (back-translation 학습 구조): 30.5 BLEU
- 기존 back-translation 모델: 29.4 BLEU
- **+1.1 BLEU** 향상, 목표 언어 데이터만으로 학습 가능

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

연구의 의의

- BERT와 GPT의 장점을 하나의 아키텍처로 통합한 우아한 설계 — BERT의 양방향 이해 + GPT의 자동회귀 생성을 동시에 확보
- Seq2Seq 프레임워크가 다양한 노이즈 스키마 실험을 자연스럽게 가능하게 한 점이 가장 큰 차별점
- mBART(Multilingual BART), LED(Longformer Encoder-Decoder) 등 후속 연구로 확장됨 — BART가 사전학습 패러다임에 미친 영향이 큼

한계점

- 훈련 데이터 규모가 RoBERTa와 동등수준으로, 데이터 효율이 눈에 띄는 구조적 개선은 아님 — 다양한 노이즈 스키마를 통해 얻은 이득
- Sentence Permutation + Text Infilling 조합이 최적이지만, 다른 조합이 태스크별로 더 유리할 수 있는지 충분한 탐색 없음
- 장문서(Long Document) 처리 능력은 제한적 — 이후 LED 등으로 보완