# Deep Residual Learning for Image Recognition

📗 Deep Residual Learning for Image Recognition
**이미지 인식을 위한 심층 잔차 학습 (Deep Residual Learning for Image Recognition)**
**저자:** Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun (Microsoft Research)
2026.03.10 스터디

1. Introduction
    논문이 다루는 분야
    해당 task에서 기존 연구 한계점
    논문의 contributions
2. Related Work 관련 연구
3. 제안 방법론
    Main Idea - **Deep Residual Learning**
    **3.1. Residual Learning**
    3.2 Identity Mapping by Shortcuts
    3.3 Network Architectures
    3.4.Implementation
    Contribution
4. 실험 및 결과
    **4.1. ImageNet Classification**
    4.2. CIFAR-10 and Analysis
    4.3. Object Detection on PASCAL and MS COCO
5. 결론 (배운점)

## 1. Introduction

### 논문이 다루는 분야

ResNet - 컴퓨터 비전 중 딥러닝을 이용한 이미지 인식(Image Recognition) 분야로, 특히 Deep CNN의 최적화 문제를 다룬 논문

### 해당 task에서 기존 연구 한계점

- 네트워크의 층이 깊어질수록 성능이 포화되다가 급격히 떨어지는 **퇴화(Degradation) 문제**가 발생. 이는 과적합의 문제가 아님. 적절히 깊은 모델에 층을 더 쌓았을 때 오히려 학습 오차(Training Error)가 더 높아지는 현상을 보임.
- 기존의 **vanishing/exploding gradients** 문제 → 표준화된 초기화, BN층으로 상당 부분 해결. 수십 개 층의 네트워크도 SGD로 수렴 가능하게 함.
- 퇴화 문제는 가중치 초기화나 Batch Normalization으로도 해결하지 못함

  *→ 심층 잔차 학습 프레임워크 도입해 해결*

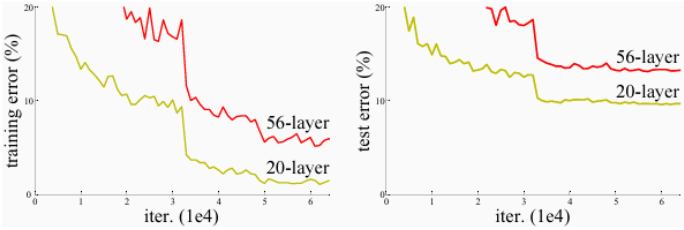


Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer "plain" networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

## 논문의 contributions

- 깊은 네트워크의 학습을 용이하게 하는 **잔차 학습 (Residual Learning)** 제시
  - 잔차 매핑 $F(x) = H(x) - x$를 이용해 원래 매핑인 $H(x)$를 $F(x) + x$로 재구성

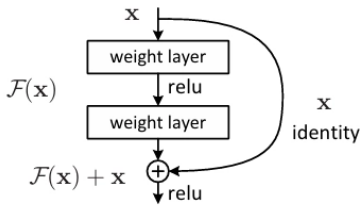


Figure 2. Residual learning: a building block.

- 파라미터 추가 없이 학습을 돕는 **Identity Shortcut Connection**
  - 계산 복잡도를 늘리지 않고 여전히 SGD로 end-to-end 학습 가능, solver 수정없이 일반 라이브러리로 쉽게 구현가능

- VGG보다 8배 깊지만 낮은 복잡도의 152층의 ResNet으로 ImageNet 테스트 오차 3.57% 달성함

# 2. Related Work 관련 연구

### 1. Residual Representations

- **기존 방법 및 연구**
  - 이미지 인식:
    - VLAD & Fisher Vector: 사전(dictionary)에 대한 잔차 벡터를 인코딩하는 방식, 이미지 검색 및 분류에서 강력한 성능을 냄
    - Vector Quantization: 원래의 벡터를 인코딩하는 것보다 잔차 벡터를 인코딩하는 것이 더 효과적임이 입증됨
  - low-level vision 및 그래픽스:
    - Multigrid: 시스템을 여러 규모의 하위 문제로 재구성하여, 각 하위 문제가 서로 다른 규모 사이의 잔차 해를 담당하게 해 수렴 속도를 높임

    - Hierarchical Basis Preconditioning: 두 규모 사이의 잔차 벡터를 나타내는 변수를 활용하여 최적화를 단순화

이러한 기존 방법들은 적절한 재구성(Reformulation)이나 사전 조건화(Preconditioning)가 최적화를 단순화할 수 있음을 시사함.

**2. Shortcut Connections**

- **기존 방법 및 연구**
  - 지름길 연결에 관한 실습과 이론은 오랜 시간 여러 논문에서 연구되어 옴
- **Highway Networks vs ResNet:**
  - **Highway Networks:** 게이트 함수를 사용함. 데이터에 따라 shortcut을 닫을 수 있으며, 이때는 일반적인 non-residual 함수가 됨. 추가 매개변수가 필요함. 100층 이상의 깊은 구조에서 성능 향상X
  - **ResNet:** Identity Shortcut를 사용함. 매개변수가 없고, 정보가 가공되지 않은 채 항상 통과됨. 이를 통해 100층 이상의 극단적인 깊이에서도 성능 향상O

# 3. 제안 방법론

## Main Idea - Deep Residual Learning

### 3.1. Residual Learning

- 여러 비선형 층이 복잡한 함수 $H(x)$를 근사할 수 있을 때, 잔차 함수인 $F(x) = H(x) - x$ 또한 근사할 수 있다는 점에 주목하여 원래 함수$H(x)$를 $F(x) + x$로 재구성
- Identity mapping이 최적이라면, 비선형 층들을 쌓아서 Identity mapping을 맞추는 것보다 잔차$F(x)$를 0으로 수렴하게 만드는 것이 최적화 관점에서 훨씬 쉬움
- 실제 항등 매핑이 최적일 가능성은 낮으나, 잔차 학습 구조는 문제에 합리적인 사전 조건화(Preconditioning)를 제공함

### 3.2 Identity Mapping by Shortcuts

$$y = F(x, Wi) + x$$

*y: 출력 벡터, x: 입력 벡터,*
*F: 학습되어야 하는 잔차*

- 매 몇 개의 층마다 잔차 학습을 적용
- 빌딩 블록은 왼쪽 식으로 정의되며 지름길 연결과 element-wise addition(요소 별 더하기)로 수행됨. 이후 ReLU 적용

- 입력 $x$와 잔차 $F$의 차원이 다를 경우 선형 투영$(W_s)$를 사용하는 Shortcut을 통해 차원을 맞춤.→ $y = F(x, Wi) + W_s x$.
- 파라미터가 추가되지 않아 계산 복잡도가 늘어나지 않는 장점 + Plain 네트워크와 ResNet을 동일한 조건에서 공정하게 비교할 수 있음.

## 3.3 Network Architectures

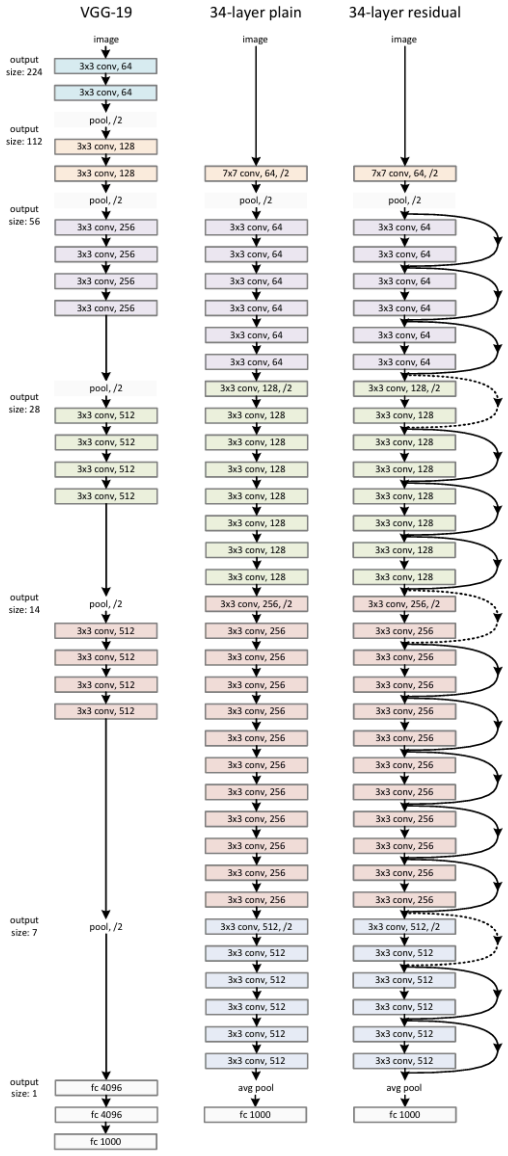


- **Plain Network:**
  - 주로 3x3 필터 사용
  - VGG-19 철학 기반 룰

    (i) 출력 특징 맵 크기가 같으면 필터 수도 같게

    (ii) 특징 맵 크기가 절반이 되면 필터 수를 두 배로 늘려 연산량 유지

    → 34층 모델임에도 VGG-19 연산량의 18% 수준인 3.6G FLOPs
- **Residual Network:** 위 일반 네트워크에 shortcut connections을 추가한 구조
  - 차원이 증가할 때는,

    **(A) Zero-padding:** 차원이 늘어난 부분에 0을 채워 넣는 방식으로, 파라미터가 늘어나지 않음. 항등 매핑

    **(B) Projection Shortcut:** 차원 일치 위해 1×1 컨볼루션 사용

## 3.4.Implementation

- 224×224 랜덤 크롭, 수평 뒤집기, 표준 색상 증강, 각 컨볼루션 직후와 활성화 함수 이전에 BN를 수행, He 초기화
- 미니 배치 256의 SGD 사용
- 학습률은 0.1에서 시작해 오차가 정체될 때마다 10분의 1로 줄임
- 가중치 감쇠(0.0001)와 모멘텀(0.9) 적용, 드롭아웃은 사용X.
- 테스트에서는 비교 연구를 위해 standard 10-crop testing를 사용하며, 멀티 스케일 평균 점수를 내는 fully-convolutional form 채택

## Contribution

- 깊은 네트워크에서도 퇴화 문제 없이 층이 깊어질수록 정확도가 향상됨을 증명함
- 추가 파라미터나 복잡도 증가 없이 성능을 높이는 무파라미터 shortcut connections를 제안

# 4. 실험 및 결과

## 4.1. ImageNet Classification

- **Dataset:**
  - ImageNet 2012 분류 데이터셋
    : 1,000개의 클래스 구성. 128만 장의 훈련 이미지로 학습하고 5만 장의 검증 이미지로 평가, 최종 결과는 테스트 서버의 10만 장의 테스트 이미지로 확인
  - 평가 지표: Top-1 및 Top-5 에러율 사용
- **Baseline:**
  - **Plain Networks**
    : 18층과 34층의 plain 네트워크. 34층 모델은 VGG-19를 따르면서도 연산량은 18% 수준으로 설계

    → 34층이 더 높은 검증 오차, 학습오차를 보이는 퇴화 문제 관찰

| layer name | output size | 18-layer | 34-layer | 50-layer | 101-layer | 152-layer |
|---|---|---|---|---|---|---|
| conv1 | 112×112 | 7×7, 64, stride 2 | | | | |
| conv2_x | 56×56 | 3×3 max pool, stride 2 | | | | |
| | | $\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix}\times2$ | $\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix}\times3$ | $\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$ | $\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$ | $\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$ |
| conv3_x | 28×28 | $\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix}\times2$ | $\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix}\times4$ | $\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$ | $\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$ | $\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times8$ |
| conv4_x | 14×14 | $\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix}\times2$ | $\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix}\times6$ | $\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times6$ | $\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times23$ | $\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times36$ |
| conv5_x | 7×7 | $\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix}\times2$ | $\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix}\times3$ | $\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$ | $\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$ | $\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$ |
| | 1×1 | average pool, 1000-d fc, softmax | | | | |
| FLOPs | | $1.8\times10^9$ | $3.6\times10^9$ | $3.8\times10^9$ | $7.6\times10^9$ | $11.3\times10^9$ |

Table 1. Architectures for ImageNet. Building blocks are shown in brackets (see also Fig. 5), with the numbers of blocks stacked. Down-sampling is performed by conv3_1, conv4_1, and conv5_1 with a stride of 2.

  - **ResNets**
    : 위 Plain 모델들에 각 3x3 필터 쌍+shortcut connections을 추가한 모델. 모든 shortcut connections에는 항등 매핑 사용, 차원이 증가할 때는 제로 패딩을 사용하여 추가 파라미터가 없도록 설계

    → 34층이 18층보다 성능이 2.8% 더 좋고 낮은 학습 오차를 보여 퇴화 문제 해결

    → 18층은 plain 네트워크보다 훨씬 더 빠르게 수렴

| | plain | ResNet |
|---|---|---|
| 18 layers | 27.94 | 27.88 |
| 34 layers | 28.54 | **25.03** |

Table 2. Top-1 error (%, 10-crop testing) on ImageNet validation. Here the ResNets have no extra parameter compared to their plain counterparts. Fig. 4 shows the training procedures.

  - **항등 vs 투영 지름길 (Identity vs. Projection Shortcuts)**

: 세 옵션을 비교

(A) 차원 증가 시 제로 패딩 (파라미터X)

(B) 차원 증가 시에만 Projection Shortcuts 사용

(C) 모든 Shortcut에 Projection Shortcuts 사용

→ 세 옵션 모두 plain보다 뛰어남. 미세하게 C>B>A이나 차이 크지 않음.

- **Deeper Bottleneck Architectures 도입**

  학습 시간 단축을 위해 Bottleneck 설계 도입. 각 잔차 함수 F에 대해 2개 층 대신 3개 층(1x1, 3×3, 1×1) 사용

  - 1×1 : 차원을 줄임 → 3x3: 더 적은 차원 처리 → 1x1: 다시 차원을 늘림

    깊이가 늘어나도 낮은 복잡도 가능

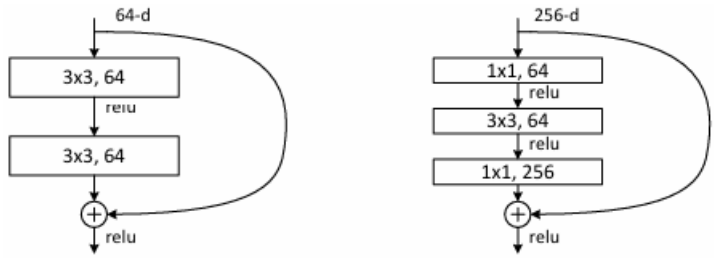


- **결과:**
  - 퇴화 문제 해결: Plain 모델은 34층이 18층보다 에러율이 높았으나, ResNet은 34층(25.03%)이 18층(27.88%)보다 2.8% 우수한 성능을 보이며 깊이에 따른 정확도 향상을 입증
  - ResNet-18은 Plain-18보다 초기 단계에서 훨씬 빠르게 수렴함
  - Bottleneck 구조를 적용한 ResNet-50, 101, 152는 층이 깊어질수록 정확도 향상, 퇴화 문제 없이 깊이의 이점 누림. 152층은 깊이가 늘었음에도 VGG-16/19보다 낮은 복잡도 가짐.
  - 152층 ResNet은 단일 모델로 Top-5 에러율 4.49%를 달성, 6개 모델의 앙상블을 통해 3.57%의 에러율로 ILSVRC 2015 우승

## 4.2. CIFAR-10 and Analysis

- **Dataset:**
  - 10개의 클래스. 5만 장의 훈련 이미지와 1만 장의 테스트 이미지로 구성된 데이터셋
- **Baseline:**
  - 단순한 구조의 Plain/Residual 네트워크 구조
    - 입력은 32x32 이미지, 첫 번째 층은 3x3 컨볼루션. 특징 맵 크기 {32, 16, 8}에 대해 각각 2$n$개의 층을 할당하여 총 6$n$+2개의 가중치 층 생성(20, 32, 44, 56층). 필터 수는 각 크기별로 {16, 32, 64} 사용
    - 잔차 연결: 모든 경우에 Identity Shortcut 사용. 잔차 모델과 일반 모델의 깊이, 너비, 파라미터 수 완전히 동일

- 훈련 설정
  - 가중치 감쇠(0.0001), 모멘텀(0.9), BN(배치 정규화) 적용, 드롭아웃 사용X
  - 학습률은 0.1에서 시작해 32k 및 48k iteration에서 10분의 1로 감소, 총 64k 반복에서 종료
  - 데이터 증강은 4픽셀 패딩 후 32x32 랜덤 크롭 및 수평 뒤집기 적용

- **결과:**
  - Plain Networks에서는 퇴화 문제가 관찰되었으나 (110층 모델의 경우 에러율이 60%를 넘어 그래프에 표시조차 되지 않음) ResNets에서는 깊이가 증가함에 따라 정확도가 꾸준히 향상

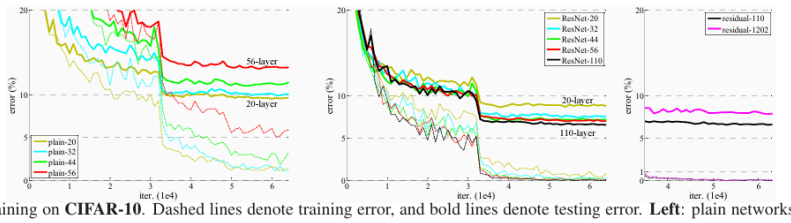


Figure 6. Training on **CIFAR-10**. Dashed lines denote training error, and bold lines denote testing error. **Left**: plain networks. The error of plain-110 is higher than 60% and not displayed. **Middle**: ResNets. **Right**: ResNets with 110 and 1202 layers.

  - **ResNet-110:** 파라미터 수가 다른 깊은 모델(FitNet, Highway 등)보다 적음에도 6.43%의 에러율을 기록함
  - **층 반응 분석 (Layer Responses)**
    층의 출력 응답(std) 분석 결과, ResNet의 응답이 일반 네트워크보다 일반적으로 작음. 이는 잔차 함수가 0에 가깝다는 가설을 뒷받침하며 특히 더 깊은 ResNet일수록 개별 층이 신호를 더 적게 수정(작은 반응)하는 경향을 보임.

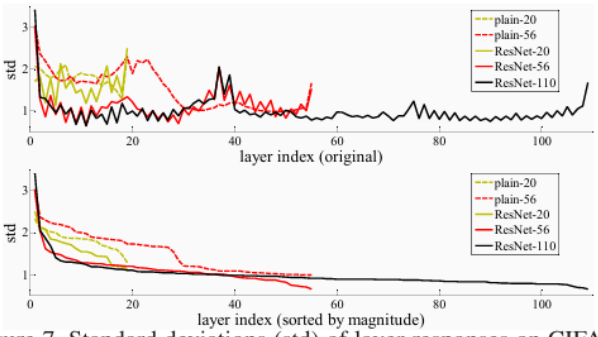


Figure 7. Standard deviations (std) of layer responses on CIFAR-10. The responses are the outputs of each 3×3 layer, after BN and before nonlinearity. **Top**: the layers are shown in their original order. **Bottom**: the responses are ranked in descending order.

  - **1202층 모델 탐색**
    1000층 이상의 아주 깊은 모델에서도 최적화 문제 없이 학습 오차 0.1% 미만을 달성했으나, 테스트 에러(7.93%)는 110층 모델보다 높게 나왔는데 이는 작은 데이터셋 규모에 비해 모델이 너무 커서 발생한 **Overfitting** 때문인 것으로 분석됨

    → 강력한 정규화 적용이 필요

### 4.3. Object Detection on PASCAL and MS COCO

- **Dataset:**
  - PASCAL VOC 2007/2012: 전통적인 객체 검출 벤치마크 데이터셋
  - MS COCO: 80개의 객체 카테고리를 포함한 데이터셋
- **Baseline:**
  - detection 알고리즘으로 Faster R-CNN 채택
  - 기존의 VGG-16을 사용했을 때와 ResNet-101로 교체했을 때의 성능을 비교
- **결과:**
  - COCO 데이터셋: VGG-16대비 ResNet-101이 28%의 상대적 성능 향상 기록
  - ResNet의 강력한 표현 능력을 바탕으로 ILSVRC & COCO 2015의 Detection, Localization, Segmentation 부문에서 모두 1위

## 5. 결론 (배운점)

**연구의 한계와 과제: 모델 크기와 정규화**

인상 깊었던 연구의 한계점은 퇴화 문제를 해결해도 모델이 무조건 깊어진다고 해서 성능이 계속해서 좋아지는 것은 아니라는 점이다. CIFAR-10 데이터셋 실험에서 1202층의 극도로 깊은 모델을 테스트했을 때 성능이 떨어지는 과적합 문제가 나왔는데, 이를 위해 모델 크기를 조절하거나 강력한 정규화 기법과의 결합이 필수적임을 배웠다.

**연구의 의의 및 배운점**

연구한 모델이 특정 데이터셋에만 국한되지 않고 다양한 태스크에서 일반적으로 우수함을 입증한 것이 인상깊었다.

층이 깊어질수록 학습 오차가 높아지는 퇴화문제를 잔차 학습이라는 단순하지만 강력한 아이디어로 해결한 점이 놀랍다. 모델이 깊어짐에도 연산량을 최적화하며 설계하도록 하고, Bottleneck 구조로 시간 복잡도를 늘리지 않으며 층을 깊게 쌓는 설계가 이 매우 효율적인 전략임을 배웠다. 향후 프로젝트에서 컨볼루션 층을 활용한 차원 조절 기술은 꼭 활용해보고 싶고, 앞으로 새로운 모델을 설계할 때 복잡도를 늘리지 않으면서도 핵심 문제를 해결할 수 있는 본질적 접근 방식을 고민해봐야겠다.