



메뉴바를 클릭하면
계정을 관리할 수 있어요

논문 리뷰

Denoising Diffusion Probabilistic Models

letterhill | 2026. 5. 17. 21:16 ⓘ

1. Introduction

최근 모든 종류의 deep generative models은 다양한 데이터들에서 high quality한 샘플들을 추출한다. GAN, autogressive models, flows, VAE는 이미지와 오디오 샘플을 합성해왔으며 에너지 기반 모델링과 스코어 매칭에도 GAN에 본 논문은 diffusion 확률 모델에서의 발전을 제시한다.

Diffusion Model: variational inference로 학습된 파라미터화된 마르코프 체인

- 유한한 시간 후 데이터와 일치하는 샘플을 생성한다.

= t번을 거쳐 노이즈를 복원하는 AI

Markov chain: 현재의 상태만을 보고 다음 상태를 예측하는 방식

parameterization: AI가 학습가능한 숫자들을 가짐

Variational inference: 복잡한 확률을 근사해서 학습하는 방법

[Diffusion 모델의 장점]

- 이 chain의 transition은 diffusion 과정을 역전 시키도록 학습한다.

- 신호가 파괴될 때까지 데이터에 점진적으로 noise 추가

- noise *Gaussian* 추가의 역방향도 노이즈와 같은 종류의 수학 *Gaussian*으로 표현 가능해 신경망 구조가 매우 단순해진다.

- 고품질 샘플을 생성할 수 있다.

한계점: log likelihood가 샘플 품질에 비해 낮다.

2. Background

Diffusion model은 데이터 $\mathbf{x}_0$ 를 만들기 위해 여러 단계의 숨겨진 변수를 거치는 모델이다.

1 Reverse Process

: 노이즈에서 시작해서 이미지를 복구하는 과정

- 순수한 Gaussian noise에서 시작
- 각 step에서 neural net이 평균과 분산을 예측하며 노이즈를 제거한다.

$$p_{\theta}(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t), \quad p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t), \boldsymbol{\Sigma}_{\theta}(\mathbf{x}_t, t)) \quad (1)$$

2 Forward Process

: 이미지에 노이즈를 추가하는 과정으로, 디퓨전 모델에서 이 과정은 학습하는 게 아닌 미리 정해진 규칙에 따라 노이즈가 추가된다.

- 노이즈를 섞을 정도를 상수로 고정한다.

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1}), \quad q(\mathbf{x}_t|\mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I}) \quad (2)$$

3 ELBO

그럼 모델을 어떻게 학습시킬 수 있을까? 직접적인 수식을 계산하는 과정은 어렵기 때문에 VLB라는 수식을 활용해 근사한다.

$$\mathbb{E}[-\log p_{\theta}(\mathbf{x}_0)] \leq \mathbb{E}_q \left[-\log \frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] = \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] =: L \quad (3)$$

- NLL의 variational lower bound를 최소화한다.
- 여기서 다음의 식4의 트릭을 활용하면 T번 반복하지 않고도 임의의 t시점의 노이즈 데이터를 한 번에 계산할 수 있다.

4 ELBO 분해

기존의 식3은 몬테칼로 추정으로 variance가 매우 큼불안정 -> KL divergence 형태로 바뀌서 근사

KL divergence 형태로 바꾸면:

- 두 가우시안의 KL -> closed form으로 계산 가능
- variance 감소 -> 안정성 향상

$$\mathbb{E}_q \left[\underbrace{D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \parallel p(\mathbf{x}_T))}_{L_T} + \sum_{t>1} \underbrace{D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t))}_{L_{t-1}} \right] - L_0$$

메뉴바를 클릭하면
계정을 관리할 수 있어요

항	의미	역할
L_T	$q(\mathbf{x}_T \mathbf{x}_0)$ 와 사전분포 $p(\mathbf{x}_T)$ 의 KL	노이즈 항 — θ 없음, 상수
L_{t-1}	역방향 스텝과 순방향 posterior의 KL	핵심 학습 항
L_0	최종 복원 로그우도	이미지 재구성 항

3. Diffusion models and denoising autoencoders

3장에서는 DDPM 모델이 어떻게 실제로 학습하는지 표현한다.

3.1 Forward process and L_T

- 순방향 과정 variances β_t 를 learnable parameter가 아닌 상수로 고정
- 따라서 q 에 학습 파라미터 θ -> L_T 도 상수

3.2 Reverse process and $L_{1:T-1}$

Step1) 분산 σ_{θ} 설정

- learnable하지 않는 t 에 의존하는 상수

$$\Sigma_{\theta}(\mathbf{x}_t, t) = \sigma_t^2 \mathbf{I}$$

Step2) 평균 μ_{θ} 파라미터화

parameterization을 제안한다.

$$L_{t-1} = \mathbb{E}_q \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) - \mu_\theta(\mathbf{x}_t, t)\|^2 \right] + C$$

메뉴바를 클릭하면
계정을 관리할 수 있어요

-> 모델 μ_θ 가 forward posterior 평균을 예측하도록 학습

Step3) reparameterization trick 적용

$$L_{t-1} - C = \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \tilde{\mu}_t \left(\mathbf{x}_t(\mathbf{x}_0, \epsilon), \frac{1}{\sqrt{\bar{\alpha}_t}} (\mathbf{x}_t(\mathbf{x}_0, \epsilon) - \sqrt{1 - \bar{\alpha}_t} \epsilon) \right) - \mu_\theta(\mathbf{x}_t(\mathbf{x}_0, \epsilon), t) \right\|^2 \right] \quad (9)$$

$$= \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t(\mathbf{x}_0, \epsilon) - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right) - \mu_\theta(\mathbf{x}_t(\mathbf{x}_0, \epsilon), t) \right\|^2 \right] \quad (10)$$

- C도 θ 에 독립적인 상수이므로 L_{t-1} 은 ground truth에 가까워지도록 학습된다.

3.3 Data scaling, reverse process decoder, and L_0

이미지 데이터는 0~255의 정수로 되어있기 있고 -1~1까지의 실수로 scaling되어 주어진다.

-> neural net 역과정이 normal prior $p(x_T)$ 에서 시작해서 일간되게 스케일된 입력에서 작동함을 보장한다.

discrete log likelihood를 얻기 위해 우리는 역과정의 마지막 항 L_0 을 가우시안 분포에서 나온 독립적인 discrete decoder로 설정한다.

$$p_\theta(\mathbf{x}_0 | \mathbf{x}_1) = \prod_{i=1}^D \int_{\delta_-(x_0^i)}^{\delta_+(x_0^i)} \mathcal{N}(x; \mu_\theta^i(\mathbf{x}_1, 1), \sigma_1^2) dx \quad (13)$$

$$\delta_+(x) = \begin{cases} \infty & \text{if } x = 1 \\ x + \frac{1}{255} & \text{if } x < 1 \end{cases} \quad \delta_-(x) = \begin{cases} -\infty & \text{if } x = -1 \\ x - \frac{1}{255} & \text{if } x > -1 \end{cases}$$

Gaussian을 픽셀 bin 구간으로 적분 -> discrete log likelihood 보장

3.4 Simplified training objective

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2 \right]$$

식 14

기존의 training objective에서 가중치를 제거하여 목적함수를 위와 같이 단순화한다.

기존 가중치 term은 t가 작을수록 가중치가 매우 커지고, t가 클 때는 가중치가 작아져서, 쉬운 task 작은노이즈에 집중하여 어려운 task에 대한 학습이 부족하다는 문제가 있다.

=> L_{simple} 은 모든 t 에 대해 균등한 가중치를 부여하여 t 가 큰 노이즈가 큰 상황에 대해서도 학습을 잘 진행하게 한다.

메뉴바를 클릭하면
계정을 관리할 수 있어요

4. Experiments

Table 1: CIFAR10 results. NLL measured in bits/dim.

Model	IS	FID	NLL Test (Train)
Conditional			
EBM [11]	8.30	37.9	
JEM [17]	8.76	38.4	
BigGAN [3]	9.22	14.73	
StyleGAN2 + ADA (v1) [29]	10.06	2.67	
Unconditional			
Diffusion (original) [53]			≤ 5.40
Gated PixelCNN [59]	4.60	65.93	3.03 (2.90)
Sparse Transformer [7]			2.80
PixelQIN [43]	5.29	49.46	
EBM [11]	6.78	38.2	
NCSNv2 [56]		31.75	
NCSN [55]	8.87 ± 0.12	25.32	
SNGAN [39]	8.22 ± 0.05	21.7	
SNGAN-DDLS [4]	9.09 ± 0.10	15.42	
StyleGAN2 + ADA (v1) [29]	9.74 ± 0.05	3.26	
Ours (L , fixed isotropic Σ)	7.67 ± 0.13	13.51	≤ 3.70 (3.69)
Ours (L_{simple})	9.46 ± 0.11	3.17	≤ 3.75 (3.72)

Table 2: Unconditional CIFAR10 reverse process parameterization and training objective ablation. Blank entries were unstable to train and generated poor samples with out-of-range scores.

Objective	IS	FID
$\tilde{\mu}$ prediction (baseline)		
L , learned diagonal Σ	7.28 ± 0.10	23.69
L , fixed isotropic Σ	8.06 ± 0.09	13.22
$\ \tilde{\mu} - \tilde{\mu}_{\theta}\ ^2$	–	–
ϵ prediction (ours)		
L , learned diagonal Σ	–	–
L , fixed isotropic Σ	7.67 ± 0.13	13.51
$\ \tilde{\epsilon} - \epsilon_{\theta}\ ^2 (L_{\text{simple}})$	9.46 ± 0.11	3.17

4.2 Reverse process parameterization and training objective ablation

1) 예측 대상: $\tilde{\mu}$ vs ϵ

2) 목표 함수: ELBO L vs L_{simple}

[결과 분석]

$\tilde{\mu}$ 예측 + L 완전 $ELBO$ → IS 7.28, FID 23.69 나쁨

$\tilde{\mu}$ 예측 + L_{simple} → IS 8.06, FID 13.22 중간

ϵ 예측 + L 완전 $ELBO$ → IS 7.67, FID 13.51 중간

ϵ 예측 + L_{simple} 최종모델 → IS 9.46, FID 3.17 최고!

=> ϵ 는 더 단순하고 일관된 학습을 하고 L_{simple} 은 어려운 t 에도 균등하게 집중하므로 좋은 성능을 낸다.

4.3 Progressive Cofing

Table1은 CIFAR10 모델의 코드 길이를 보여준다.

train과 test의 차이는 0.03 bits, 다른 LL기반 모델과 비슷 -> DDPM 오버피팅 발생X

단, 에너지 기반 모델이나 AIS보다는 NLL이 높음 -> 확산 모델은 NLL 경쟁력보다 샘플 품질에서 강점

[Rate vs Distortion]

information theory의 손실 압축 관점에서:

보내는 사람: 원본 이미지 x_0 보유, 받는 사람: x_0 를 복원하고 싶음

Rate: 전송에 사용한 비트수통신비용

Distortion: 복원된 이미지-원본 차이품질손실

"Trade off": Rate를 아끼면 Distortion 증가, rate를 많이 쓰면 distortion 감소

메뉴바를 클릭하면
계정을 관리할 수 있어요

ELBO의 Rate-Distortion 해석:

$$L = \underbrace{L_1 + \dots + L_T}_{\text{Rate (전송 비용)}} + \underbrace{L_0}_{\text{Distortion (왜곡)}}$$

Rate항: 각 시간 스텝에서 얼마나 많은 정보를 전송했는가

- forward posterior와 reverse 모델의 차이
- T개 스텝의 KL divergence 합 = 총 전송 비용

Distortion 항 L_0

- 최종 복원된 이미지-원본 차이
- 낮을수록 원본에 가깝게 복원함




Figure 5

Diffusion 모델은 중요한 정보를 먼저 효율적으로 복원하고, 이후 뒤쪽 step에서 인지하기 어려운 세밀한 정보를 복원하는 데 대부분의 비트를 사용한다.

[Progressive generation]



Figure 6: Unconditional CIFAR10 progressive generation ($\hat{x}_0$ over time, from left to right) and sample quality metrics over time in the appendix (Figs. 10 and 14).

- $t=T$ 왼쪽에서는 완전한 노이즈지만 t 가 감소할수록 큰 구조가 보이다가 $t=1$ 인 오른쪽으로 가면 세부 디테일이 완성된다.




Figure 7: When conditioned on the same latent, CelebA-HQ 256×256 samples share high-level attributes. Bottom-right quadrants are x_t , and other quadrants are samples from $p_\theta(x_0|x_t)$.

같은 x_t 에서 샘플링하면 고수준의 속성을 공유한다. t 가 클수록 더 추상적인 개념적 정보를 담당

[Connection to autoregressive decoding]

ELBO식은 다음과 같이 작성할 수 있다.

$$L = D_{\text{KL}}(q(x_T) \parallel p(x_T)) + \mathbb{E}_q \left[\sum_{t \geq 1} D_{\text{KL}}(q(x_{t-1}|x_t) \parallel p_\theta(x_{t-1}|x_t)) \right] + H(x_0) \quad (16)$$

여기에서 특수한 상황을 가정해보자.

- T : 는 데이터의 차원수

- $q(x_t | x_{t-1})$ = t 번째 좌표를 숨김

-> $D_{\text{KL}}=0$, p_θ 는 autoregressive model이 된다.

4.4 Interpolation

두 개의 이미지 x_0, x_0' 를 latent 잠재적 space에서 interpolate한다.



① x_0, x_0' 각각을 노이즈 추가: $x_t \sim q(x_t|x_0), x_t' \sim q(x_t|x_0')$

② 잠재 공간에서 선형 보간:

$$\bar{x}_t = 1 - \lambda x_t + \lambda x_t' \quad \lambda : 0 \rightarrow 1$$

③ 역방향 과정으로 디코딩:

$$\bar{x}_0 \sim p(x_0|\bar{x}_t)$$



메뉴바를 클릭하면
계정을 관리할 수 있어요

Figure 8: Interpolations of CelebA-HQ 256x256 images with 500 timesteps of diffusion.

[픽셀 interpolation vs latent space interpolation]

- 픽셀 interpolation : $\bar{x} = 1 - \lambda x_0 + \lambda x_0' \rightarrow$ 두 이미지가 단순 겹침

- latent 보간: 노이즈 공간에서 보간 후 역과정

→ 이미지 manifold 위에서 자연스러운 이동

→ 자세, 피부색, 머리스타일, 표정이 부드럽게 변화

5. Related Work

- **Flow/VAE와의 차이:** 인코더 q 가 파라미터 없이 고정되어 있고, 잠재 변수 x_T 가 데이터 정보를 담지 않음 이 된다.
- **Score Matching/Langevin Dynamics:** ϵ 예측 = score 예측, 샘플링 = Langevin dynamics와 수학적으로 동치
- **EBM:** score matching과 에너지 기반 모델의 연결고리를 통해 간접적으로 연관
- **AIS:** rate-distortion 곡선을 한 번의 계산으로 뽑는 방식이 유사
- **DRAW:** progressive decoding 아이디어의 선행 연구

6. Conclusion

본 논문은 확산 모델로 고품질 이미지 생성에 성공했고, 변분 추론 / score matching / Langevin dynamics / 자기회귀 모델 / 손실 압축 등 기존 연구들과의 연결고리를 발견했다.

[Word2Vec 논문 Introduction]

| Distributed Representations of Words and Phrases and their Compositionality

단어를 벡터 공간에 표현하면 -> 비슷한 단어끼리 가까이 모이게 된다.

[Skip-gram model]

- 중심 단어 $w(t)$ 로 주변 단어들을 예측한다.

입력: w_t 중심단어

출력: $w_t - 2, w_t - 1, w_t + 1, w_t + 2$ 주변단어들

장점: dense matrix 연산이 없어 학습이 매우 빠르다.

메뉴바를 클릭하면
계정을 관리할 수 있어요

[Vector computation]

학습된 벡터는 언어적 규칙을 linear transformation으로 인코딩할 수 있다

$\text{vec}'' \text{Madrid}'' - \text{vec}'' \text{Spain}'' + \text{vec}'' \text{France}'' \approx \text{vec}'' \text{Paris}''$

$\text{vec}'' \text{Russia}'' + \text{vec}'' \text{river}'' \approx \text{vec}'' \text{VolgaRiver}''$

$\text{vec}'' \text{Germany}'' + \text{vec}'' \text{capital}'' \approx \text{vec}'' \text{Berlin}''$

-> 단어 간 관계가 벡터 공간에서 **방향**으로 표현된다.


본 논문에서 제시한 모델을 통해 비넵ㄴ하게 등장하는 단어의 일부를 건너뛰고, 기존의 계층 소프트맥스보다 더 단순한 방식을 통해 학습속도를 개선하며, 관용 표현을 하나의 토큰으로 통째로 처리할 수 있다.

♡ 공감 ↑ 📄 🗨️ ⓘ ⌂ ⌂



논문 리뷰 카테고리의 다른 글

[paper] Efficient Memory Management for Large LanguageModel Serving with PagedAt 0	2026.05.11
[paper] AN IMAGE IS WORTH 16X16 WORDS:TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE 논 문리뷰 0	2026.05.05
deep residual 논문 리뷰 2	2026.05.02
[NLP] BERT 논문 리뷰 1	2026.04.06
[강화학습] Playing Atari with Deep Reinforcement Learning_DQN 논문 리뷰 0	2026.03.30

'논문 리뷰' Related Articles



NVIDIA A100 40GB



메뉴바를 클릭하면
계정을 관리할 수 있어요

[paper] Efficient Memory Management...

[paper] AN IMAGE IS WORTH 16X16...

deep residual 논문 리뷰

[NLP] BERT 논문 리뷰

letterhill님의 블로그

letterhill님의 블로그입니다.

댓글 0

letterhill

내용을 입력하세요.

등록