

Dropout: A Simple Way to Prevent Neural Networks from Overfitting

☰ Multi-select

DL

CV



jmlr.org

<https://jmlr.org/papers/volume15/srivastava14a/srivastava14a.pdf>

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work 관련 연구

Motivation

관련 연구 (Related Work)

3. 제안 방법론

Model Description

드롭아웃 네트워크 학습 (Learning Dropout Nets)

4. 실험 및 결과

실험 결과 (Experimental Results)

주요 특징 (Salient Features)

Dropout Restricted Boltzmann Machines

드롭아웃 주변화 (Marginalizing Dropout)

곱셈 가우시안 노이즈 (Multiplicative Gaussian Noise)

5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

Deep Neural Networks의 성능을 저해하는 가장 큰 요인 중 하나인 **과적합(Overfitting)** 문제를 해결하기 위한 정규화(Regularization) 기법

해당 task에서 기존 연구 한계점

기존 연구들은 DNN의 강력한 표현력을 활용하면서도 과적합을 피하기 위해 노력했으나, 다음과 같은 명확한 한계가 있었음

- DNN은 다수의 비선형 은닉층을 가져 매우 복잡한 관계를 학습할 수 있지만, 훈련 데이터가 제한적인 경우 샘플링 노이즈로 인한 복잡한 관계까지 학습함.
→ 훈련 데이터에는 존재하지만 실제 테스트 데이터에는 없는 관계이므로 일반화 성능 저하
- Early stopping, L1/L2 가중치 페널티, 가중치 공유(Soft weight sharing) 등의 방법이 개발되었으나, 매우 많은 파라미터를 가진 거대 네트워크의 과적합을 완전히 해결하기에는 한계
- 과적합을 방지하는 가장 이상적인 방법은 다양한 설정을 가진 여러 모델의 예측치를 평균 내는 것이지만, 거대 네트워크에서는 실행 불가능
 - 여러 개의 거대 네트워크를 각각 훈련시키는 데 막대한 계산 자원 소요
 - 각기 다른 아키텍처마다 최적의 하이퍼파라미터를 찾는 것은 매우 어려움
 - 대규모 네트워크는 많은 데이터를 필요로 하는데, 모델별로 데이터를 나누어 학습시키기에는 데이터가 충분X
 - 실시간 응답이 중요한 애플리케이션에서 여러 개의 거대 모델을 동시에 가동하여 결과를 얻는 것은 속도 측면에서 비실용적
- **베이지안 접근법의 확장성 문제:** 베이지안 뉴럴 네트워크는 모델 평균화를 수행하는 이론적으로 올바른 방법이지만, 거대 네트워크로 확장하기 어렵고 테스트 시 예측을 얻는 비용이 매우 컸음

논문의 contributions

본 논문은 드롭아웃(Dropout) 기법을 통해 위에서 언급된 난제들을 효과적으로 해결함

- 드롭아웃은 훈련 시 유닛을 무작위로 제거함으로써 하나의 네트워크 안에서 지수적(Exponential)으로 많은 수의 서로 다른 thinned 네트워크들을 샘플링하여 학습시킴
- **Weight Scaling:** 테스트 시에는 수많은 하위 모델을 실제로 실행하는 대신, 단일 네트워크의 가중치에 유지 확률 p 를 곱하는 가중치 스케일링(Weight scaling)이라는 방법으로 모든 하위 모델을 평균화한 효과를 매우 근사하게 낼 수 있음을 입증. → 계산 효율성 극대화
- **복잡한 Co-adaptation 방지:**
각 유닛이 다른 특정 유닛의 존재 여부에 의존하지 않게 함으로써, 유닛들이 서로의 실수를 보완하려다 발생하는 **Co-adaptation**을 깨뜨림
 - 각 유닛은 다양한 문맥에서 스스로 유용한 특징을 추출할 수 있는 강건한(Robust) 특징을 학습
- **다양한 도메인에서의 범용성:**
비전(MNIST, CIFAR, ImageNet), 음성 인식(TIMIT), 텍스트 분류(Reuters), 계산 생물학 등 서로 다른 분야의 데이터셋에서 드롭아웃이 보편적으로 성능을 향상시킨다는 점을 보여줌

- 드롭아웃이 부수적으로 은닉 유닛의 Sparse activation를 유도하며, 이는 별도의 희소성 규제 없이도 더 나은 특징 표현을 가능하게 함을 시각적으로 분석함
- 피드포워드 신경망뿐만 아니라 RBM(Restricted Boltzmann Machines)과 같은 그래픽 모델에도 드롭아웃을 적용할 수 있는 프레임워크를 제시하고 그 효과를 입증

2. Related Work 관련 연구

Motivation

- **유성 생식과 유전자의 혼합 능력(Mix-ability):**
 - 진화론적 관점에서 유성 생식은 부모의 유전자를 절반씩 섞어 자손을 만들. 이는 개별 적합도 (Individual fitness)를 최적화하는 데 유리한 '기존의 잘 작동하는 유전자 조합'을 깨뜨리는 행위처럼 보일 수 있음
 - 그러나 자연 선택의 진짜 기준은 유전자의 '혼합 능력(Mix-ability)'에 있다는 가설
→ 유전자는 언제나 함께할 파트너가 누구일지 알 수 없으므로, **어떤 무작위 유전자 집단과 섞여도 스스로 유용한 역할을 수행할 수 있도록 강건(Robust)하게 학습해야 함**
- ⇒ 드롭아웃도 이와 마찬가지로, 각 은닉 유닛이 무작위로 선택된 다른 유닛들과 협력하도록 강제함으로써 특정 유닛에 의존하여 실수를 보정하는 **복잡한 공적응(Co-adaptation)**을 방지
- **Successful Conspiracies:**
 - 작은 규모의 Conspiracies(5명씩 10팀)가 큰 규모의 Conspiracies(50명 1팀)보다 성공 확률이 높다는 논리
 - 조건이 변하지 않는 훈련 데이터에서는 거대한 공적응이 잘 작동할 수 있지만, 새로운 테스트 데이터(Non-stationary conditions) 환경에서는 여러 개의 단순한 공적응이 결합된 형태가 훨씬 더 높은 생존력을 가짐

관련 연구 (Related Work)

- **노이즈 주입과 Denoising Autoencoders(DAEs):**
 - 드롭아웃은 은닉 유닛에 노이즈를 추가하여 네트워크를 정규화하는 방식으로 해석될 수 있음
 - 이전 연구인 **DAEs**는 입력 유닛에만 노이즈를 추가하여 무상태(Unsupervised) 특징 학습을 수행했음
→ 본 논문은 이 개념을 **은닉층까지 확장**하고, 이를 단순한 노이즈 주입을 넘어 모델 평균화 (Model averaging)의 관점으로 해석함
 - 특히 DAEs는 보통 5% 정도의 낮은 노이즈를 사용하지만, 드롭아웃은 입력 20%, 은닉층 50%라는 훨씬 높은 노이즈 수준에서도 가중치 스케일링 절차 덕분에 효과적으로 작동함을 강조
- **Marginalizing Dropout:**

- 드롭아웃과 같은 확률적 기법을 수식적으로 주변화하여 결정론적인 형태의 정규화 기법으로 변환하려는 연구들이 있었음
 - 예를 들어 선형 회귀에 드롭아웃을 적용하고 노이즈를 주변화하면 특정 형태의 릿지 회귀(Ridge regression)와 유사해짐
- **Adversarial unit dropping:**
 - 무작위 분포가 아닌 적대적(Adversary) 선택에 의해 유닛이 삭제되는 상황을 가정한 연구(Globerson and Roweis, 2006)가 있었으나, 이는 은닉 유닛이 없는 모델에 국한됨

3. 제안 방법론

Model Description

- **Standard Network의 동작 - 3(a):**
 - L 개의 은닉층을 가진 네트워크에서, 각 층 l 의 입력 벡터를 $z(l)$, 출력 벡터를 $y(l)$, 가중치를 $W(l)$, 편향(bias)을 $b(l)$
 - 표준 피드포워드 과정에서 다음 층의 입력 $z(l+1)$ 은 이전 층의 출력에 가중치를 곱하고 편향을 더해 계산되며, 활성화 함수 f 를 거쳐 출력 $y(l+1)$ 이 됨
- **Dropout Network의 동작 - 3(b):**
 - 훈련 시, 각 층 l 에 대해 확률 p 로 1의 값을 갖는 독립적인 **베르누이 무작위 변수 벡터 $r(l)$ **을 생성
 - 이 벡터 $r(l)$ 을 해당 층의 출력 $y(l)$ 과 요소별 곱(element-wise product)을 수행하여 '얇아진(thinned)' 출력 $y_{\sim}(l)$ 을 만듦
 - 다음 층은 이 $y_{\sim}(l)$ 을 입력으로 받아 계산을 이어감. 이는 큰 네트워크에서 하위 네트워크(sub-network)를 샘플링하는 것과 같음




Figure 3: Comparison of the basic operations of a standard and dropout network.

• 테스트 시의 동작 (Weight Scaling):

- 테스트 시에는 드롭아웃을 사용하지 않음. 대신, 훈련된 가중치 W 에 유지 확률 p 를 곱한 $W_{test}=pW$ 를 사용하여 예측 수행.
- 이 스케일링은 테스트 시의 출력이 훈련 시 드롭아웃 하에서의 기대 출력값과 동일하게 보장하며, 지속적으로 많은 '얇아진' 모델들을 하나의 네트워크로 결합하는 효과




Figure 2: **Left:** A unit at training time that is present with probability p and is connected to units in the next layer with weights $\mathbf{w}$. **Right:** At test time, the unit is always present and the weights are multiplied by p . The output at test time is same as the expected output at training time.

드롭아웃 네트워크 학습 (Learning Dropout Nets)

1) 역전파 (Backpropagation)

- 드롭아웃 네트워크는 표준 뉴럴 네트워크와 유사하게 확률적 경사 하강법(SGD)으로 학습됨
- 차이점: 미니배치의 각 훈련 케이스마다 유닛을 드롭아웃하여 새로운 '얇아진' 네트워크를 샘플링. 순전파(Forward)와 역전파(Backpropagation)는 오직 이 샘플링된 네트워크에 대해서만 수행됨

- 최적화 기법: 모멘텀(Momentum), 어닐링된 학습률(Annealed learning rates), L2 가중치 감쇠(Weight decay) 등이 드롭아웃 네트워크에서도 유용하게 사용됨
- Max-norm 정규화: 드롭아웃과 결합했을 때 특히 효과적인 기법으로, 각 은닉 유닛으로 들어오는 가중치 벡터의 노름(Norm)을 고정된 상수 c 이하로 제한 ($\|w\|_2 \leq c$).
 - 가중치 벡터가 c 를 초과하면 반지름 c 인 구 표면으로 가중치 투영
 - 가중치 폭발 없이 매우 큰 학습률과 높은 모멘텀(0.95~0.99)을 사용할 수 있게 하여 학습 속도를 높이고 최적화 과정에서 가중치 공간의 더 넓은 영역을 탐색하게 함

2) Unsupervised Pretraining

- 드롭아웃은 RBM, 오토인코더(Autoencoders), DBM 등으로 사전학습된 네트워크의 미세 조정(Finetuning) 단계에 적용될 수 있음
- 사전학습 단계에서는 드롭아웃을 쓰지 않으므로, 미세 조정 단계에서 드롭아웃을 적용하기 전 사전학습된 가중치를 $1/p$ 만큼 Scale up 해야 함
 - 이는 드롭아웃 하에서의 각 유닛의 기대 출력값을 사전학습 시의 출력값과 일치시키기 위함입니다.
- 미세 조정 시 학습률이 너무 높으면 사전학습으로 얻은 정보가 지워질 수 있으므로, 무작위 초기화 네트워크보다 상대적으로 작은 학습률을 사용하는 것이 사전학습의 이점을 유지하며 일반화 성능을 높이는 데 효과적임

4. 실험 및 결과

실험 결과 (Experimental Results)

비전, 음성 인식, 텍스트 분류, 계산 생물학 등 7개의 다양한 데이터셋(**Table 1**)을 사용하여 드롭아웃의 효과 검증

6.1 이미지 데이터셋 결과 (Results on Image Data Sets)

MNIST, SVHN, CIFAR-10/100, ImageNet 등 5개의 이미지 데이터셋 사용

- **6.1.1 MNIST: 28×28 픽셀의 손글씨 숫자 분류 데이터**
 - 기존 최고 성능인 1.60%의 오류율을 드롭아웃만으로 1.35%로 개선
 - ReLU 활성화 함수와 Max-norm 정규화를 결합했을 때 오류율은 1.06%까지 떨어졌으며, 레이어 크기를 키워 학습시켰을 때 0.95%라는 매우 낮은 수치를 기록
 - 사전학습된 DBM에 드롭아웃을 적용했을 때는 0.79%로, 당시 해당 설정에서 보고된 수치 중 가장 뛰어난 성과




Figure 4: Test error for different architectures with and without dropout. The networks have 2 to 4 hidden layers each with 1024 to 2048 units.

Method	Unit Type	Architecture	Error %
Standard Neural Net (Simard et al., 2003)	Logistic	2 layers, 800 units	1.60
SVM Gaussian kernel	NA	NA	1.40
Dropout NN	Logistic	3 layers, 1024 units	1.35
Dropout NN	ReLU	3 layers, 1024 units	1.25
Dropout NN + max-norm constraint	ReLU	3 layers, 1024 units	1.06
Dropout NN + max-norm constraint	ReLU	3 layers, 2048 units	1.04
Dropout NN + max-norm constraint	ReLU	2 layers, 4096 units	1.01
Dropout NN + max-norm constraint	ReLU	2 layers, 8192 units	0.95
Dropout NN + max-norm constraint (Goodfellow et al., 2013)	Maxout	2 layers, (5 × 240) units	0.94
DBN + finetuning (Hinton and Salakhutdinov, 2006)	Logistic	500-500-2000	1.18
DBM + finetuning (Salakhutdinov and Hinton, 2009)	Logistic	500-500-2000	0.96
DBN + dropout finetuning	Logistic	500-500-2000	0.92
DBM + dropout finetuning	Logistic	500-500-2000	0.79

Table 2: Comparison of different models on MNIST.

- **Figure 4**는 다양한 아키텍처에서 드롭아웃 유무에 따른 성능 차이를 보여주는데, 드롭아웃을 적용한 모델들이 일관되게 훨씬 낮은 테스트 에러를 기록하며 아키텍처 변화에 강건함을 입증함

- **6.1.2 SVHN (Street View House Numbers):** 구글 스트리트 뷰에서 수집된 실제 집 번호 이미지
 - 합성곱 신경망(CNN)에 드롭아웃을 적용한 결과, 기존 3.95%의 오류율을 전결합층(Fully connected layers)에만 적용 시 3.02%로, 모든 층에 적용 시 2.55%로 낮춤
 - 파라미터가 적어 과적합 우려가 낮은 하위층(합성곱 층)에 드롭아웃을 적용하는 것이 상위층에 노이즈 섞인 입력을 제공하여 전체적인 일반화 성능을 높인다는 점을 발견

Method	Error %
Binary Features (WDCH) (Netzer et al., 2011)	36.7
HOG (Netzer et al., 2011)	15.0
Stacked Sparse Autoencoders (Netzer et al., 2011)	10.3
KMeans (Netzer et al., 2011)	9.4
Multi-stage Conv Net with average pooling (Sermanet et al., 2012)	9.06
Multi-stage Conv Net + L2 pooling (Sermanet et al., 2012)	5.36
Multi-stage Conv Net + L4 pooling + padding (Sermanet et al., 2012)	4.90
Conv Net + max-pooling	3.95
Conv Net + max pooling + dropout in fully connected layers	3.02
Conv Net + stochastic pooling (Zeiler and Fergus, 2013)	2.80
Conv Net + max pooling + dropout in all layers	2.55
Conv Net + maxout (Goodfellow et al., 2013)	2.47
Human Performance	2.0

Table 3: Results on the Street View House Numbers data set.

• 6.1.3 CIFAR-10 및 CIFAR-

100: 자연 이미지 데이터셋

- CIFAR-10에서 드롭아웃을 모든 층에 적용했을 때 오류율이 15.60%에서 12.61%로 감소
- CIFAR-100에서는 43.48%에서 37.20%로 대폭 개선



Figure 5: Samples from image data sets. Each row corresponds to a different category.

Method	CIFAR-10	CIFAR-100
Conv Net + max pooling (hand tuned)	15.60	43.48
Conv Net + stochastic pooling (Zeiler and Fergus, 2013)	15.13	42.51
Conv Net + max pooling (Snoek et al., 2012)	14.98	-
Conv Net + max pooling + dropout fully connected layers	14.32	41.26
Conv Net + max pooling + dropout in all layers	12.61	37.20
Conv Net + maxout (Goodfellow et al., 2013)	11.68	38.57

Table 4: Error rates on CIFAR-10 and CIFAR-100.

• 6.1.4 ImageNet: 1,500만 장 이상의 이미지를 가진 거대 데이터셋

- ILSVRC-2012 대회에서 드롭아웃을 적용한 CNN 모델로 우승

- 기존 비전 특징 기반 모델들이 약 26%의 Top-5 에러를 기록할 때, 드롭아웃을 적용한 모델은 약 16%라는 압도적인 성능 차이

6.2 TIMIT (음성 인식 데이터셋 결과)

- 680명의 화자가 발음한 음성 데이터셋
- 표준 6층 네트워크의 음소 에러율(Phone Error Rate) 23.4%를 드롭아웃을 통해 21.8%로 낮춤
- 사전학습된 DBN(Deep Belief Net)에 드롭아웃을 결합했을 때, 4층 및 8층 네트워크 모두에서 에러율을 19.7%까지 낮추는 성과.

6.3 텍스트 데이터셋 결과 (Results on a Text Data Set)

- Reuters-RCV1 기사 데이터를 50개의 주제로 분류하는 과업
- 드롭아웃 적용 전 31.05%였던 에러율이 29.62%로 감소
- 이미지나 음성에 비해 개선 폭이 작았는데, 이는 데이터셋이 이미 충분히 커서(약 20만 개 이상) 과적합 문제가 상대적으로 덜했기 때문으로 분석됨

6.4 베이지안 신경망과의 비교 (Comparison with Bayesian Neural Networks)

- 데이터가 적은 유전학 분야의 'Alternative Splicing' 데이터셋을 사용하여 모델 평균화의 정석인 베이지안 신경망(BNN)과 비교
- 결과적으로 BNN(623점)이 드롭아웃(567점)보다 높은 성능을 보였으나, 드롭아웃은 표준 신경망(440점)보다 훨씬 뛰어난 성능을 보였으며 다른 모든 기법(SVM 등)을 능가
- 드롭아웃은 수천 개의 유닛을 가진 거대 모델도 과적합 없이 학습시킬 수 있어, 학습 및 테스트 속도가 느린 BNN의 실용적인 대안임을 확인

6.5 표준 정규화 기법과의 비교 (Comparison with Standard Regularizers)

- MNIST 데이터셋에서 L2 가중치 감쇠, L1, KL-sparsity, Max-norm 등 기존 정규화 기법들과 드롭아웃을 비교
- 실험 결과, 드롭아웃과 Max-norm 정규화를 함께 사용했을 때 1.05%로 가장 낮은 에러율을 기록. 이는 드롭아웃이 단순한 가중치 페널티 방식보다 훨씬 강력한 정규화 효과를 제공함을 시사함

Method	Test Classification error %
L2	1.62
L2 + L1 applied towards the end of training	1.60
L2 + KL-sparsity	1.55
Max-norm	1.35
Dropout + L2	1.25
Dropout + Max-norm	1.05

Table 9: Comparison of different regularization methods on MNIST.

주요 특징 (Salient Features)

드롭아웃이 단순히 에러율을 낮추는 것을 넘어, 네트워크가 데이터를 표현하는 방식에 어떤 근본적인 변화를 주는지 심층 분석

7.1 Effect on Features

- **공적응(Co-adaptation) 방지:** 표준 네트워크에서는 특정 유닛이 다른 유닛의 실수를 보완하는 방식으로 학습되는 '복잡한 공적응'이 발생하기 쉬움. 이는 훈련 데이터에는 적합하지만 새로운 데이터에는 일반화되지 않아 과적합의 원인이 됨
- 드롭아웃은 다른 유닛의 존재를 신뢰할 수 없게 만듦으로써, 각 유닛이 다양한 문맥(Context)에서도 스스로 유용한 특징을 추출하도록 강제함
- **시각적 증거:**
 - **드롭아웃 미적용 (Figure 7a):** 유닛들이 서로 복잡하게 얽혀 있어 개별 유닛이 무엇을 학습했는지 명확하지 않고 특징이 흐릿함
 - **드롭아웃 적용 (Figure 7b):** 각 은닉 유닛이 이미지의 특정 부분에서 **에지(Edge)**, **스트로크(Stroke)**, **점(Spot)** 등 의미 있고 구별되는 특징을 명확하게 학습





Figure 7: Features learned on MNIST with one hidden layer autoencoders having 256 rectified linear units.

7.2 희소성에 미치는 영향 (Effect on Sparsity)

별도의 희소성 규제(Regularizer)를 사용하지 않아도 드롭아웃을 적용하면 은닉 유닛의 활성화가 자연스럽게 희소해짐

• 활성화 분포 분석:

- 드롭아웃 미적용 (Figure 8a): 평균 활성화 값이 약 2.0이며, 많은 유닛이 높은 활성화 값을 가짐
- 드롭아웃 적용 (Figure 8b): 평균 활성화 값이 약 0.7로 떨어지며, 대부분의 유닛이 0 근처에서 활성화되는(Sharp peak at zero) 매우 희소한 분포



7.3 드롭아웃 비율(p)의 영향 (Effect of Dropout Rate)

두 가지 상황에서 유지 확률 p 의 영향을 실험

1. 유닛 수(n) 고정: p 가 너무 작으면 유닛이 부족해져 Underfitting이 발생. p 가 0.4에서 0.8 사이일 때 성능이 가장 안정적이며, p 가 1에 가까워지면(드롭아웃 감소) 다시 에러가 증가 [Figure 9a].
2. 기대 유닛 수(pn) 고정: p 가 작을 때 n 을 크게 설정하여 실제 학습에 참여하는 유닛의 기대치를 일정하게 유지한 경우. 이 방식은 p 가 매우 작을 때도 유닛 수 고정 방식보다 훨씬 낮은 에러율을 보였으며, $p=0.6$ 부근에서 최적의 성능을 냄 [Figure 9b]




Figure 9: Effect of changing dropout rates on MNIST.

7.4 데이터셋 크기의 영향 (Effect of Data Set Size)

드롭아웃이 아주 작은 데이터셋에서도 효과적인 정규화 도구인지 확인

- 매우 작은 데이터셋(100~500개)에서는 드롭아웃을 적용해도 모델이 노이즈까지 통째로 외워버려 개선 효과가 미미
- 데이터셋 크기가 일정 수준 이상으로 커지면 드롭아웃의 효과가 극대화되는 'Sweet spot'이 존재하며, 데이터가 아주 방대해지면 드롭아웃 없이도 과적합이 줄어들어 성능 차이가 다시 감소




Figure 10: Effect of varying data set size.

7.5 몬테카를로 모델 평균화 vs. 가중치 스케일링 (Monte-Carlo Model Averaging vs. Weight Scaling)

테스트 시 수많은 '얇아진' 네트워크의 예측을 직접 평균 내는 방식(Monte-Carlo)과, 논문에서 제안한 단순 가중치 스케일링(pW) 방식의 성능을 비교

- 몬테카를로 방식에서 샘플 수 k 가 약 50개 이상이 되면 가중치 스케일링 방식의 성능과 거의 일치. 이는 제안된 **가중치 스케일링 기법이 복잡한 모델 결합을 매우 효율적이고 정확하게 근사하고 있음**을 보여줌




Figure 11: Monte-Carlo model averaging vs. weight scaling.

Dropout Restricted Boltzmann Machines

드롭아웃 기법을 피드포워드 신경망을 넘어 그래픽 모델인 RBM에 적용하는 방법과 그 효과

- **모델 설명 (Model Description):**
 - 일반 RBM은 가시 유닛(v)과 은닉 유닛(h)으로 구성되며, 에너지 기반의 확률 분포를 정의

- 드롭아웃 RBM은 각 은닉 유닛 h_j 가 유지될 확률 p 를 갖는 이진 무작위 변수 벡터 r 을 추가
- $r_j=0$ 이면 해당 은닉 유닛 h_j 는 반드시 0이 되어야 한다는 제약($g(h_j, r_j)$) 부과. 결과적으로 드롭아웃 RBM은 **가중치를 공유하며 은닉 유닛의 서로 다른 부분 집합을 사용하는 지수적으로 많은 RBM들의 혼합 모델**로 볼 수 있음.

- **학습 방법 (Learning):**

- 기존 RBM 학습 알고리즘인 대조적 분산(Contrastive Divergence, CD-1)을 그대로 적용
- 차이점은 각 미니배치의 훈련 케이스마다 r 을 먼저 샘플링하여 선택된 은닉 유닛들만 학습에 참여시킨다는 점

- **주요 효과:**

- **특징의 변화:** 표준 RBM(Figure 12a)이 매우 날카로운 스트로크 형태의 특징을 학습하는 반면, 드롭아웃 RBM(Figure 12b)은 상대적으로 **더 Coarser 형태의 특징**을 포착. 표준 RBM에 비해 **죽은 유닛(Dead units)이 훨씬 적게 발생**




Figure 12: Features learned on MNIST by 256 hidden unit RBMs. The features are ordered by L2 norm.

- **희소성 유도:** 별도의 정규화 장치 없이도 드롭아웃 RBM은 표준 RBM보다 훨씬 희소한 표현 (Sparse representations)을 학습합니다. 활성 히스토그램을 보면 드롭아웃 적용 시 0 근처에 압도적으로 많은 유닛이 몰려 있음을 알 수 있음




Figure 13: Effect of dropout on sparsity. **Left:** The activation histogram shows that a large number of units have activations away from zero. **Right:** A large number of units have activations close to zero and very few units have high activation.

드롭아웃 주변화 (Marginalizing Dropout)

드롭아웃을 은닉 유닛에 노이즈를 더하는 과정으로 볼 때, 이 노이즈를 수학적으로 주변화(Marginalizing out)하여 얻어지는 **결정론적(Deterministic) 버전의 모델**

- 무작위 샘플링(Monte-Carlo 방식) 대신 노이즈의 기댓값을 직접 계산하여 손실 함수를 최소화하는 방식. 이는 무작위 비트가 필요 없으며 주변화된 손실 함수에 대해 직접 경사도를 구할 수 있다는 장점이 있음
- **선형 회귀 (Linear Regression):**
 - 입력 X 에 드롭아웃을 적용하고 노이즈를 주변화하면, 손실 함수는 특수한 형태의 릿지 회귀 (Ridge Regression) 식으로 변환됨
 - 이 식에서 정규화 항은 데이터의 각 차원별 표준편차(σ)에 따라 가중치 비용을 조절. 즉, 변동성이 큰 데이터 차원의 가중치를 더 강하게 압박
 - 유지 확률 p 가 1에 가까우면 정규화 상수가 작아지고, p 가 작아질수록(드롭아웃이 강해질수록) 정규화 효과가 커짐
- **로지스틱 회귀 및 딥 네트워크 (Logistic Regression and Deep Networks):**
 - 비선형 모델의 경우 폐쇄형(Closed-form)으로 주변화된 모델을 얻기가 어렵습니다.
 - 로지스틱 회귀에서는 입력 및 경사도 분포를 가우시안으로 가정하여 근사적으로 주변화된 모델을 학습할 수 있으며, 이는 학습 속도와 일반화 성능 면에서 일반 드롭아웃보다 우수할 수 있음
 - 그러나 층이 깊어질수록 이러한 가우시안 가정이 약해지기 때문에, 딥 네트워크에 직접 적용하는 데에는 한계가 있음

곱셈 가우시안 노이즈 (Multiplicative Gaussian Noise)

표준 드롭아웃은 유닛을 0 또는 1(베르누이 분포)로 곱하여 제거하지만, 본 논문은 이를 일반화하여 다른 분포에서 추출된 무작위 변수를 활성화 값에 곱하는 방식을 제안함

- 작동 원리:

- 각 은닉 유닛의 활성화 값 h 에 $N(1,1)$ 분포에서 추출된 무작위 변수를 곱함
- 이는 각 유닛에 평균이 0이고 표준편차가 해당 유닛의 활성화 값과 같은 가우시안 무작위 변수를 더하는 것($h_i + h_{ir}$, 여기서 $r \sim N(0,1)$)과 수식적으로 동일함
- 이 방식을 확장하여 $N(1, \sigma^2)$ 분포를 사용할 수 있으며, 여기서 σ 는 베르누이 드롭아웃의 p 와 같은 하이퍼파라미터 역할

- 테스트 시의 이점:

- 가우시안 노이즈를 곱하는 방식은 활성화 값의 기댓값을 변화시키지 않음
- 따라서 표준 드롭아웃과 달리 테스트 시에 별도의 가중치 스케일링(Weight scaling) 절차가 필요 없다는 장점!

- 베르누이 드롭아웃과의 관계 및 엔트로피 분석:

- 베르누이 드롭아웃에서 유지 확률 p 를 사용하는 것은 활성화 값에 '확률 p 로 $1/p$, 확률 $1-p$ 로 0'의 값을 갖는 변수를 곱하는 것과 평균과 분산 측면에서 대응될 수 있음
- 가우시안 모델에서 $\sigma^2 = (1-p)/p$ 로 설정하면, 두 방식은 동일한 평균(1)과 분산($(1-p)/p$)을 가지게 됨
- 이때 가우시안 노이즈(rg)는 가장 높은 엔트로피를 가지며, 베르누이 노이즈(rb)는 가장 낮은 엔트로피를 가짐

- 실험 결과:

- MNIST와 CIFAR-10 데이터셋에서 실험한 결과, 높은 엔트로피를 가진 가우시안 드롭아웃이 베르누이 드롭아웃보다 약간 더 나은 성능을 보이거나 유사한 결과
- **MNIST 결과:** 베르누이 드롭아웃(1.08% 에러) 대비 가우시안 드롭아웃은 **0.95% 에러**를 기록하며 더 우수한 성능을 입증
- **CIFAR-10 결과:** 베르누이(12.6%)와 가우시안(12.5%)이 거의 대등한 성능을 보임

Data Set	Architecture	Bernoulli dropout	Gaussian dropout
MNIST	2 layers, 1024 units each	1.08 ± 0.04	0.95 ± 0.04
CIFAR-10	3 conv + 2 fully connected layers	12.6 ± 0.1	12.5 ± 0.1

Table 10: Comparison of classification error % with Bernoulli and Gaussian dropout. For MNIST, the Bernoulli model uses $p = 0.5$ for the hidden units and $p = 0.8$ for the input units. For CIFAR-10, we use $p = (0.9, 0.75, 0.75, 0.5, 0.5, 0.5)$ going from the input layer to the top. The value of σ for the Gaussian dropout models was set to be $\sqrt{\frac{1-p}{p}}$. Results were averaged over 10 different random seeds.

5. 결론 (배운점)

- 표준 역전파 학습은 훈련 데이터에는 잘 작동하지만 새로운 데이터에는 일반화되지 않는 취약한 공적응(Brittle co-adaptations)을 형성함 → 드롭아웃은 어떤 유닛의 존재도 신뢰할 수 없게 만듦으로써 이러한 공적응을 깨뜨리고, 각 유닛이 스스로 더 유용하고 강건한 특징을 학습하게 유도함
- 드롭아웃은 특정 도메인에 국한되지 않고 객체 분류, 숫자 인식, 음성 인식, 문서 분류, 계산 생물학 등 광범위한 응용 분야에서 성능을 개선했음. 특히 SVHN, ImageNet, CIFAR-100, MNIST 등 주요 벤치마크 데이터셋에서 State-of-the-art을 달성
- 큰 모델에서 하위 모델을 반복적으로 샘플링하여 학습시킨다는 드롭아웃의 핵심 아이디어는 RBM(Restricted Boltzmann Machines)과 같은 그래픽 모델에도 성공적으로 적용될 수 있으며, 이를 통해 학습된 '드롭아웃 RBM'은 표준 모델보다 뛰어난 여러 가지 바람직한 특성을 보여줌
- 학습 시간의 트레이드오프(Trade-off):**
드롭아웃의 주요 단점은 학습 시간이 표준 네트워크보다 약 2~3배 더 오래 걸린다는 점. 이는 각 훈련 케이스마다 서로 다른 아키텍처를 학습시키기 때문에 발생하는 노이즈 섞인 파라미터 업데이트 때문이지만, 오히려 이러한 확률성(Stochasticity)이 과적합을 효과적으로 방지하는 원동력이 되기도 함
- 학습 시간과 과적합 사이의 균형을 맞추기 위해, 확률적 샘플링 대신 노이즈를 주변화(Marginalize)하여 동일한 효과를 내는 결정론적 정규화 기법을 개발하는 것이 중요한 연구 과제. 저자들은 선형 회귀와 같은 단순 모델 외에 복잡한 모델에서도 드롭아웃의 학습 속도를 높이는 것이 향후 흥미로운 연구 방향이 될 것이라고 제안함