



논문 리뷰: StarGAN - Unified GANs for Multi-Domain Image-to-Image Translation

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

Contribution

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

SqueezeNet - Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- 본 논문은 **GAN(Generative Adversarial Network)** 기반의 **multi-domain image-to-image translation**을 다룬다.

- Image-to-image translation은 입력 이미지의 특정 속성(attribute)을 다른 속성으로 바꾸는 과제이며, 헤어 컬러 변경, 표정 변경(웃음 ↔ 찡그림), 스케치 → 실사 변환, 계절 변환 등이 대표적인 예시이다.
- 논문에서는 **attribute**를 이미지에 내재된 의미 있는 특징(예: 머리색, 성별, 나이)으로, **attribute value**를 그 attribute의 구체적인 값(예: 머리색의 black/blond/brown)으로, **domain**을 동일한 attribute value를 공유하는 이미지 집합으로 정의한다.
- CelebA(40개 얼굴 속성 라벨), RaFD(8개 표정 라벨)처럼 다중 라벨을 가진 데이터셋이 존재함에 따라, 단일 attribute 변환을 넘어 여러 도메인을 동시에 다루는 **multi-domain image-to-image translation**의 필요성이 제기된다.

해당 task에서 기존 연구 한계점

- 기존 모델들은 두 도메인 간 변환만 학습 가능하여, k 개 도메인 전체를 다루기 위해서는 **$k(k-1)$ 개의 generator를 개별적으로 학습**해야 한다(Figure 2(a): 4개 도메인을 다루기 위해 12개의 개별 generator가 필요한 예시를 도식화).
- **비효율성(inefficiency)**: 도메인 쌍마다 별도 모델이 필요해 모델 수가 기하급수적으로 증가한다.
- **비효과성(ineffectiveness)**: 얼굴형(face shape)처럼 모든 도메인에 공통적으로 존재하는 global feature가 있음에도, 각 generator는 자신이 담당하는 두 도메인의 데이터만 활용 가능해 전체 학습 데이터를 충분히 활용하지 못하고 생성 품질이 제한된다.
- **데이터셋 간 결합 학습 불가**: 각 데이터셋이 서로 다른 라벨 집합으로 부분적으로만 라벨링되어 있어(예: CelebA에는 표정 라벨이 없고 RaFD에는 헤어컬러 라벨이 없음), 기존 모델은 서로 다른 데이터셋의 도메인을 함께 학습할 수 없다.

논문의 contributions

- 단 하나의 generator와 discriminator만으로 다중 도메인 간 매핑을 학습하는 새로운 GAN 구조, **StarGAN**을 제안한다.
- 서로 다른 데이터셋(서로 다른 라벨 집합) 간 결합 학습을 가능하게 하는 **mask vector** 기법을 제안하여, StarGAN이 모든 가용 도메인 라벨을 동시에 제어할 수 있도록 한다.
- Facial attribute transfer 및 facial expression synthesis 과제에 대해 정성적·정량적 실험을 수행하여 기존 baseline 모델 대비 StarGAN의 우수성을 입증한다.

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- **Generative Adversarial Networks:** GAN은 실제/가짜를 판별하는 discriminator와, 구분 불가능한 가짜 샘플을 만드는 generator로 구성되며 이미지 생성·변환·초해상도·얼굴 합성 등에서 성과를 보였다. StarGAN도 생성 이미지를 사실적으로 만들기 위해 adversarial loss를 활용한다.
- **Conditional GANs:** 클래스 정보를 discriminator-generator에 함께 제공해 조건부 생성을 수행하는 연구들이 있으며, 텍스트 조건 이미지 생성, domain transfer, super-resolution, photo editing 등에 응용되었다. StarGAN은 이 아이디어를 발전시켜 다양한 target domain으로 유연하게 변환 가능한 확장형(scalable) GAN 프레임워크를 제안한다.
- **Image-to-Image Translation:** pix2pix는 cGAN 기반 supervised 방식으로 paired 데이터가 필요하며, UNIT(VAE+CoGAN), CycleGAN, DiscoGAN은 cycle consistency loss로 unpaired 데이터에서 두 도메인 간 변환을 학습한다. 그러나 이들 모두 **한 번에 두 도메인 간의 관계만 학습 가능**하다는 한계가 있다.
- **차별성:** 위 기존 프레임워크들과 달리 StarGAN은 **단일 모델로 다중 도메인 간 관계를 동시에 학습**한다는 점에서 본질적으로 차별화된다.

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

- 핵심 목표는 입력 이미지 x 와 목표 도메인 라벨 c 를 받아 $G(x, c) \rightarrow y$ 로 변환하는 **단일 generator G** 를 학습하는 것이다. 학습 시 목표 도메인 라벨 c 를 무작위로 생성하여 generator가 다양한 변환을 유연하게 학습하도록 한다.
- Discriminator는 **auxiliary classifier**를 두어 진짜/가짜를 판별하는 $D_{src}(x)$ 와 도메인을 분류하는 $D_{cls}(x)$ 를 동시에 산출한다: $D : x \rightarrow \{D_{src}(x), D_{cls}(x)\}$.

Figure 1 — 전체 결과 예시

- CelebA 이미지에 대해 단일 generator로 생성한 multi-domain 변환 결과를 보여준다. 첫 번째~여섯 번째 열은 입력 이미지이고 나머지 열은 StarGAN의 생성 결과이다.
- 앞쪽 5개 열은 CelebA 내 도메인(blond hair, gender, aged, pale skin) 변환을, 오른쪽 열들은 RaFD에서 학습한 표정(angry, happy, fearful 등) 특징을 CelebA 이미지에 적용한 결과로, 서로 다른 데이터셋 간 지식 전이가 가능함을 시각적으로 보여준다.

Figure 2 — Cross-domain 모델과 StarGAN 구조 비교

- (a) Cross-domain 모델: 4개 도메인을 다루기 위해 12개(=4×3)의 개별 generator(G12, G21, G14, G41 등)가 필요한 구조.
- (b) StarGAN: 하나의 generator가 모든 도메인 간 매핑을 학습하는 **별(star) 형태의 토폴로지**로, 모든 도메인이 중심의 단일 모델과 연결된다.

Figure 3 — StarGAN 학습 과정 개관 (4단계)

- (a) Discriminator 학습: D는 실제/가짜 이미지를 구분하고, 동시에 실제 이미지를 올바른 도메인으로 분류하도록 학습된다.
- (b) Original-to-target domain: G는 입력 이미지와 목표 도메인 라벨을 받아 가짜 이미지를 생성한다. 목표 도메인 라벨은 공간적으로 복제(spatially replicated)되어 입력 이미지와 depth-wise concatenation된다.
- (c) Target-to-original domain: G는 (b)의 가짜 이미지와 원래 도메인 라벨을 다시 입력받아 원본 이미지를 재구성하려 시도한다(cycle 구조).
- (d) Discriminator 속이기: G는 D가 실제와 구분할 수 없으면서 목표 도메인으로 분류할 수 있는 이미지를 생성하도록 학습된다.

수식 (1) — Adversarial Loss

$$L_{adv} = \mathbb{E}_x[\log D_{src}(x)] + \mathbb{E}_{x,c}[\log(1 - D_{src}(G(x, c)))]$$

- G는 실제와 구분되지 않는 이미지를 생성하기 위해 이 값을 최소화하고, D는 이를 최대화하도록 학습되는 표준적인 min-max adversarial loss이다.

수식 (2) — 실제 이미지에 대한 Domain Classification Loss

$$L_{cls}^r = \mathbb{E}_{x,c'}[-\log D_{cls}(c'|x)]$$

- D가 실제 이미지 x를 원래 도메인 c'로 올바르게 분류하도록 학습시키는 손실이며, 이를 최소화함으로써 D의 분류 성능이 향상된다.

수식 (3) — 가짜 이미지에 대한 Domain Classification Loss

$$L_{cls}^f = \mathbb{E}_{x,c}[-\log D_{cls}(c|G(x, c))]$$

- G가 목표 도메인 c 로 올바르게 분류될 수 있는 이미지를 생성하도록 유도하는 손실로, G가 이를 최소화하도록 학습된다.

수식 (4) — Reconstruction Loss (cycle consistency loss)

$$L_{rec} = \mathbb{E}_{x,c,c'} [\|x - G(G(x, c), c')\|_1]$$

- Adversarial loss와 classification loss만으로는 변환 이미지가 입력의 도메인-무관 콘텐츠를 보존한다는 보장이 없으므로, L1 norm 기반 cycle consistency loss를 추가한다. G를 두 번 사용해(목표 도메인으로 변환 후 다시 원래 도메인으로 재변환) 원본을 복원하도록 학습한다.

수식 (5), (6) — 전체 목적함수

$$L_D = -L_{adv} + \lambda_{cls} L_{cls}^r$$

$$L_G = L_{adv} + \lambda_{cls} L_{cls}^f + \lambda_{rec} L_{rec}$$

- λ_{cls} , λ_{rec} 는 각각 domain classification loss와 reconstruction loss의 상대적 중요도를 조절하는 하이퍼파라미터이며, 실험에서는 $\lambda_{cls}=1$, $\lambda_{rec}=10$ 을 사용한다.

Mask Vector — 다중 데이터셋 결합 학습

- 여러 데이터셋(CelebA, RaFD)을 동시에 학습할 때 각 데이터셋의 라벨이 서로에 대해 일부만 알려진 문제(예: CelebA에는 표정 라벨이 없음)를 해결하기 위해 **n차원 one-hot mask vector m** 을 도입한다(n 은 데이터셋 개수).

수식 (7) — 통합 라벨

$$\tilde{c} = [c_1, \dots, c_n, m]$$

- 알려진 라벨은 그대로 두고, 알려지지 않은 나머지 라벨은 0으로 채운다. 이를 통해 generator는 알려진 라벨에만 집중하고 알려지지 않은 라벨은 무시하도록 학습된다.
- Discriminator의 auxiliary classifier도 모든 데이터셋의 라벨에 대한 확률분포를 산출하도록 확장되며, 각 데이터셋에 대해서는 해당 데이터셋과 관련된 라벨에 대해서만 classification error를 계산하는 **multi-task learning** 방식으로 학습한다.

Figure 8 (Appendix) — CelebA-RaFD 결합 학습 개관

- (a)~(d): CelebA로 학습할 때의 과정. Mask vector가 [1,0]일 때 G는 CelebA 라벨(노란색)에 집중하고 RaFD 라벨(초록색)은 무시한다.
- (e)~(h): RaFD로 학습할 때의 과정. Mask vector가 [0,1]일 때는 반대로 RaFD 라벨에 집중한다.
- D는 각 경우 알려진 라벨에 대해서만 classification error를 최소화하도록 학습되며, 이 과정이 서로 다른 라벨 체계를 가진 두 데이터셋 간 교차 학습을 가능하게 한다.

Contribution

- **WGAN-GP 기반 학습 안정화:** 기존 adversarial loss를 Wasserstein GAN objective with gradient penalty로 대체하여($\lambda_{gp}=10$) 학습 안정성과 생성 품질을 향상시켰다.

수식 (8) — WGAN-GP 기반 Adversarial Loss

$$L_{adv} = \mathbb{E}_x[D_{src}(x)] - \mathbb{E}_{x,c}[D_{src}(G(x, c))] - \lambda_{gp} \mathbb{E}_{\hat{x}}[(\|\nabla_{\hat{x}} D_{src}(\hat{x})\|_2 - 1)^2]$$

- $\hat{x}$ 는 실제 이미지와 생성 이미지를 잇는 직선 위에서 균등하게 샘플링된 점이며, gradient penalty 항이 discriminator의 Lipschitz 제약을 유도해 학습을 안정화한다.
- **네트워크 구조:** CycleGAN을 기반으로, generator는 stride 2의 downsampling convolution 2개 + residual block 6개 + stride 2의 upsampling transposed convolution 2개로 구성되며 instance normalization을 사용한다(Table 4). Discriminator는 PatchGAN 구조를 사용하며 normalization을 적용하지 않는다(Table 5).
- 위 구조적 개선과 mask vector 기법의 결합으로, 단일 모델로도 다중 도메인·다중 데이터셋에 대해 높은 품질의 변환이 가능함을 구현 가능한 수준까지 구체화하였다.

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- **CelebA:** 202,599장의 유명인 얼굴 이미지에 40개의 binary attribute가 라벨링되어 있다. 178×218로 크롭한 뒤 178×178로 자르고 128×128로 리사이즈하며, 2,000장을 테스트셋으로 무작위 선정한다. 머리색(black/blond/brown), 성별(male/female), 나이(young/old) 속성으로 총 7개 도메인을 구성한다.
- **RaFD:** 67명의 참가자가 8가지 표정을 3가지 시선 방향·3가지 각도로 촬영한 4,824장의 이미지로 구성된다. 256×256으로 크롭한 뒤 얼굴을 중심으로 128×128로 리사이즈한다.

Baseline

- **DIAT:** 두 도메인 X, Y 간 매핑을 adversarial loss로 학습하며, 얼굴 인식 기반 feature extractor F를 이용한 $\|x - F(G(x))\|_1$ 형태의 identity 보존 정규화 항을 추가한다.

- **CycleGAN**: 두 도메인 간 cycle consistency loss(양방향 L1 재구성 손실)로 매핑을 학습하며, 도메인 쌍마다 2개의 generator·discriminator가 필요하다.
- **lcGAN**: cGAN에 encoder(E_z , E_c)를 결합하여 latent vector z 와 조건 벡터 c 의 역매핑을 학습하고, conditional vector만 바꿔 이미지를 합성하면서 latent vector(identity 정보)는 보존한다.

결과

정성적 평가

- Figure 4(CelebA attribute transfer): 첫 열은 입력, 다음 4열은 단일 속성(H: 머리색, G: 성별, A: 나이) 변환 결과, 나머지 열은 다중 속성 동시 변환 결과를 보인다. StarGAN이 cross-domain 모델보다 더 높은 시각적 품질을 보이며, 이는 다중 도메인을 함께 학습하는 multi-task 정규화 효과로 해석된다.
- Figure 5(RaFD expression synthesis): StarGAN이 identity와 얼굴 디테일을 유지하면서 가장 자연스러운 표정을 생성하며, DIAT·CycleGAN은 결과가 흐릿하고 선명도가 떨어지며, lcGAN은 identity 보존에 실패(성별이 바뀌는 등)하는 경우가 있었다.

정량적 평가 — AMT 사용자 연구

- Table 1(단일 속성 변환): StarGAN이 머리색 66.2%, 성별 39.1%, 나이 70.6%로 모든 항목에서 최다 득표를 기록했다.
- Table 2(다중 속성 변환): Gender+Aged 조합에서 StarGAN 49.8% vs. lcGAN 20.3%처럼 단일 속성보다 더 큰 격차를 보이며, 다중 속성 변환에서 StarGAN의 우위가 더욱 두드러짐을 보여준다.

정량적 평가 — 표정 분류 정확도 (Table 3)

- RaFD로 학습한 ResNet-18 분류기(정확도 99.55%)로 각 모델의 생성 이미지를 분류했을 때, StarGAN의 분류 오류율이 2.12%로 가장 낮았다(DIAT 4.10%, CycleGAN 5.99%, lcGAN 8.07%, 실제 이미지 0.45%).
- 파라미터 효율성 면에서도 StarGAN($53.2M \times 1$)은 DIAT($52.6M \times 7$)보다 약 7배, CycleGAN($52.6M \times 14$)보다 약 14배 적은 파라미터로 전체 도메인 변환을 수행한다.

CelebA+RaFD 결합 학습 결과

- Figure 6: RaFD 단독 학습 모델(StarGAN-SNG)과 CelebA+RaFD 결합 학습 모델(StarGAN-JNT)을 비교하면, JNT가 더 높은 시각적 품질의 표정을 생성하는 반면 SNG는 배경이 흐릿한 결과를 보인다. 두 데이터셋을 함께 학습함으로써 얼굴 keypoint 검출·세그멘테이션 같은 저수준 공유 task의 성능이 향상되었기 때문으로 해석된다.

- Figure 7: 올바른 mask vector([0,1])가 주어지면 표정이 정상적으로 합성되지만, 잘못된 mask vector([1,0])가 주어지면 모델이 표정 라벨을 무시하고 CelebA의 attribute 라벨(나이)을 적용하여 이미지를 늙게 변환한다. 이는 mask vector가 의도한 대로 라벨 간 구분을 학습했음을 보여주는 실험이다.

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- **연구의 의의:** 단일 generator-discriminator만으로 다중 도메인 변환을 학습할 수 있는 구조를 제시함으로써, 기존 cross-domain 모델들의 $k(k-1)$ 개 모델이 필요하다는 비효율성과 도메인별 데이터를 충분히 활용하지 못하는 비효과성을 동시에 해결했다. 특히 mask vector를 통해 서로 다른 라벨 체계를 가진 데이터셋을 결합 학습할 수 있다는 점은, 라벨링 비용이 큰 이미지 데이터셋 활용 측면에서 실용적 의의가 크다.
- **한계점:** 논문에서 다루는 도메인은 주로 이진(binary) 또는 범주형(categorical) 속성에 한정되어 있어, 연속적(continuous)이거나 자세·형태 변형처럼 복잡한 구조적 변화에 대한 일반화는 본 논문의 범위 밖이다. 또한 mask vector 방식은 데이터셋 수가 늘어날수록 라벨 벡터의 차원이 함께 커지는 구조이므로, 매우 많은 수의 이종 데이터셋을 결합할 때의 확장성은 추가 검증이 필요하다.
- **배운 점:** 여러 개의 독립적인 모델을 두는 대신 조건(label)을 입력에 함께 넣어 단일 모델이 여러 task를 분기 없이 처리하도록 만드는 아이디어(conditioning을 통한 모델 통합)는, GAN뿐 아니라 다양한 멀티태스크 학습 문제에 적용 가능한 일반적인 설계 원칙이라는 점을 배울 수 있었다. 또한 mask vector처럼 "모르는 정보는 0으로 채우고 무시하도록 학습시킨다"는 단순한 트릭이 서로 다른 라벨 체계를 가진 데이터를 결합하는데 효과적으로 작동한다는 점이 인상적이었다.

SqueezeNet - Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안되었는가

논문이 다루는 분야

- 본 논문은 정확도를 유지하면서 파라미터 수와 모델 크기를 획기적으로 줄인 CNN 아키텍처 설계를 다룬다.

- 기존 연구들은 주로 정확도 향상에 초점을 맞췄지만, 동일한 정확도 수준을 달성할 수 있는 아키텍처는 여러 가지가 존재할 수 있다는 점에서, 저자들은 "더 적은 파라미터로 동등한 정확도를 내는 아키텍처"를 직접 탐색하는 문제를 제기한다.
- 작은 CNN이 갖는 실질적 장점을 세 가지로 제시한다: (1) 분산 학습 시 서버 간 통신량이 파라미터 수에 비례하므로 작은 모델이 더 빠르게 학습된다, (2) 자율주행차처럼 클라우드 → 디바이스로 모델을 전송(over-the-air update)할 때 작은 모델이 통신 부담을 줄여 더 자주 업데이트를 가능하게 한다(AlexNet 기준 240MB 필요), (3) FPGA(보통 10MB 미만 온칩 메모리, 오프칩 메모리 없음)나 ASIC처럼 메모리가 제한된 하드웨어에 온칩으로 직접 배포하기 용이하다.

해당 task에서 기존 연구 한계점

- 기존 모델 압축(model compression) 연구들은 공통적으로 **이미 학습된 대형 모델(주로 AlexNet)을 출발점으로 삼아 사후적으로 압축**하는 방식을 취한다. 예: SVD 기반 압축(Denton et al.), Network Pruning(임계값 이하 파라미터를 0으로 만들어 sparse matrix 생성, Han et al.), Deep Compression(Pruning + quantization + Huffman coding 결합, Han et al.).
- 이러한 접근은 "기존 아키텍처를 그대로 두고 압축"하는 데 초점이 있어, **아키텍처 자체를 처음부터 적은 파라미터로 설계**하는 방향은 상대적으로 덜 탐구되었다.
- 또한 신경망 설계 공간(design space) 탐색 연구들(bayesian optimization, simulated annealing, randomized search, genetic algorithm 등)은 더 높은 정확도를 내는 아키텍처를 자동으로 찾는 데 집중할 뿐, **설계 공간의 형태(shape)에 대한 직관**을 제공하지는 않는다는 한계가 있다.

논문의 contributions

- 적은 파라미터로 경쟁력 있는 정확도를 유지하는 CNN 설계 전략 3가지를 제시하고, 이를 구현하는 새로운 빌딩 블록인 **Fire module**을 제안한다.
- Fire module을 기반으로 **SqueezeNet** 아키텍처를 설계하여, AlexNet과 동등하거나 더 나은 정확도를 50배 적은 파라미터로 달성한다.
- 자동화된 탐색 방식 대신, **체계적인 A/B 비교를 통해 microarchitecture·macroarchitecture 설계 선택이 모델 크기와 정확도에 미치는 영향**을 분석하는 더 disciplined한 설계 공간 탐색 방법을 제시한다.
- Deep Compression 등 기존 압축 기법과 결합하여 SqueezeNet을 0.5MB 미만(510배 축소)까지 압축 가능함을 보인다.