ResNet - Deep Residual Learning for Image Recognition

ref	https://www.cv-foundation.org/openaccess/content_cvpr_2016/papers/He_Deep_Residual_Learning_CVPR_2016_paper.pdf
type	예습과제
week	week1

▼ Terminology

SGD(stochastic gradient descent)

: 확률적 경사 하강법, Loss function 계산시 전체 데이터가 아닌 일부 데이터(mini batch)를 사용하여 계산양을 적게하는 방식

identity mapping

: 항등함수, F(x)=x

shortcut connections

: CNN 구조에서 입력 데이터x를 특정 레이어들을 건너뛰어 입력을 출력에 직접 더해주는 설계 기법

Underlying Mapping

: 학습해야할 목표 함수 자체, 신경망의 레이어들이 입력값(xx)을 받아 우리가 최종적으로 얻고자 하는 목표 출력값(H(x)$H(x)$)으로 변환하는 직접적인 함수 관계

perturbation

: 데이터나 학습 매개변수에 노이즈를 추가하여 모델이 지역 최솟값에 갇히지 않고 일반화하도록 조정하는 기법

* Abstract 참고

왜 진행되었는가? Deeper neural networks는 훈련이 어려워서

어떤 것이 목표인가? **residual learning framework** 소개 → 기존의 networks보다 deeper

실험에 의한 결론? residual networks는 1) 최적화하기 쉽고 2) increased depth에서 accuracy를 얻는다

1. Introduction

💡 논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

Deep convolutional neural networks(주로 다루어질 Task : **Image classification**)

: low, mid, high 수준의 features ➕ end-to-end 방식의 multi-layer 구조의 classifiers

- 이때 features의 수준은 # stacked layers로 풍부해진다.
- **network depth**는 모델 성능에서 매우 중요한 요소

해당 task에서 기존 연구 한계점

❓기존 연구에서의 질문

: 네트워크 학습과 depth 사이의 상관성

> *레이어를 더 쌓을수록 더 나은 네트워크 학습이 이루어지는가?*

⁉️ **"vanishing/exploding gradients",** obstacle for ans , 초반부터 수렴을 저지함

→ normalized initialization과 intermediate normalization layers으로 해결함

→ 신경망이 역전파를 이용한 SGD를 통해 수렴하도록

⛰️산 넘어 산 : '수렴에 대한 저지'는 해결함. BUT! still the depth of networks가 increase하면 accuracy가 holded되었다가 degrade 되는 문제가 발생함 ⇒ **Degradation Problem**

Degradation Problem

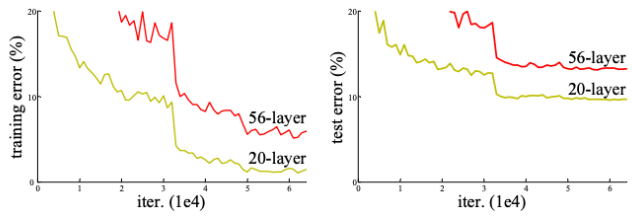

> it is not about overfitting prob, but **the deeper**, the **higher error** being

왼쪽의 figure와 같이 deeper model은 layer가 비교적 shallow한 모델보다 error가 더 높게 나온다.

또한 identity mapping을 통해 기존의 shallow한 architecture에 단순히 layer를 더했을 때 만들어지는 deeper model → sol 찾을 수 X, t 실행할 수 없는 시간 ⇒ 단순하게 deeper the better이라고 할 수 없다.

논문의 contributions

💡 **degradation problem** 해결을 위해 **Deep Residual Learning Framework** 제안

: 여러 layers가 residual mapping을 학습하도록 한다(여러개의 layer가 목표하는 함수를 학습하는 것 대신).

- 목표하는 함수(desired underlying mapping)를 H(x)할 때 대신 F(x) := H(x)−x를 stacked된 비선형 layers가 학습하도록 한다.
  - 실제 H(x)보다 F(x)의 최적화가 더 쉽다.
  - identity mapping이 최적해일 때, residual을 0으로 미는게 stacked된 비선형 layers를 학습시키는 것보다 easy

---

🔑 결국 ImageNet 실험으로 제안하는 key contribution은

1) **최적화**가 쉬운 **extremely deep residual nets**을 제안 → 기존의 plain nets의 깊이가 깊어짐에 따라 training error가 높아지는 문제 극복

2)제안된 **deep residual nets**은 depth가 증가할수록 accuracy가 쉽게 향상되며, 기존의 networks보다 결과가 우수

이를 ImageNet과 비슷한 데이터셋에 국한되지 않음을 보여주는 CIFAR-10 및 기타 대회에서의 성적으로 뒷받침한다.

2. Related Work

💡 Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

Residual Representations

이미지 인식 분야에서 VLAD(residual vectors로 변환된 representation)와 Fisher Vector(VLAD의 확률화된 버전)

→ Image retrieval과 classification에 효과적인 얕은 표현 기법,

→ vector quantization에서 residual vectors로 인코딩 하는 것이 original vectors를 사용하는 것보다 효과적

low-level vision과 computer graphics에서 편미분 방정식 풀이를 위해 **Multigrid method**가 사용됨

→ 대안 : **hierarchical basis pre-conditioning**

⇒ 위의 실험들로 **reformulation***나 **preconditioning** 또한 최적화를 단순화할 수 있다는 것을 입증, 이는 residual의 논의로 이어진다.

Shortcut Connections

highway networks연구에서는 **gating function**과 함께 **shortcut connections**를 제안

기존 연구 vs identity shortcut

- 기존의 gated shortcut는 data-dependent, parameters 존재 <> **parameter-free**
- 기존의 gated shortcut은 closed, 이는 non-residual function을 대표 <> **never closed**

❗ BUT, extremely increased depth(≥100 layers)에서는 accuracy 향상을 입증하지 못함.

3. 제안 방법론

💡 Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

Residual Learning

→ related work에서 언급된 **reformulation**과 연결된다.*

📌 가설 : H(x)를 전체가 아닌 몇몇 stacked layers의 목표함수, x를 layer의 첫번째 input이라 denote하자. 이때 다수의 비선형 layers에 대하여 점근적 근사가 가능 → 이는 residual function, i.e. H(x)-x, 또한 점근적 근사가 가능하다.

: 논문에서는 이 가설을 바탕으로 stacked layers가 H(x)가 아닌 **residual functions F(x)(:=H(x)-x)**에 근사하도록 함. 또한 original function은 F(x)+x 형태로 된다.

→ 두 형태의 함수 모두 근사 가능하지만 학습 복잡도가 다를 것임을 가정한다.

[이상] **degradation problem**에서 유발되는 관념에 의한 reformulation(재공식화)에 의하면 **identity mapping**에 의해 추가된 layers→ deepr model은 shallow model보다 train error가 낮아야한다.

[문제점] **degradation problem**은 solvers가 다수의 **비선형 layers**들에 의한 **identity mapping**을 근사하기 어려울 것이라 시사한다.

[이상적인 해결] **identity mapping**이 **최적해**일 경우, 다수의 비선형 layers의 weight를 0으로 수렴시켜 identity mapping에 도달한다.

[현실] identity mapping가 최적해이기 어렵다;;

[의의] reformulation of residual function에서 identity mapping은 꽤 좋은 전제조건이다. → 최적해가 아닐시 identity에 **perturbation**(작은 변형, 섭동)을 찾는 것이 새로운 함수를 학습하는 것보다 효과적이다.

Identity Mapping by Shortcuts

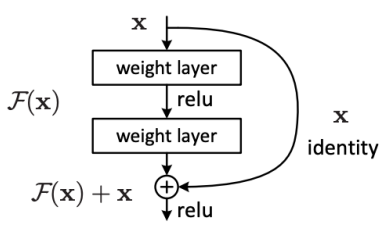

Figure 2. Residual learning: a building block.

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}.$$

$$\mathcal{F} = W_2\sigma(W_1\mathbf{x})$$

Residual network를 구성하는 building block의 구조와 정의는 위의 형태와 같다. x와 y는 각각 입력과 출력, σ는 ReLU 활성화 함수를, F(x,{Wi})는 residual function을 의미한다. F(x,{Wi})+x는 요소 단위의 shortcut connection을 의미한다.

예시) Fig2.의 구조와 식에서 x를 입력값으로 첫번째 레이어에 들어온다 → 첫번째 레이어의 가중치 W1이 곱해진다 → 이때 편향(bias)는 간편화를 위해 표기되지 않는다 → 그후 ReLU σ가 적용되고 두번째 레이어에 들어간다.σ(W1x) → 두번째 레이어의 가중치 W2가 곱해진다 → 다음 결과가 Residual Function F(x)=W2(σ(W1x))가 된다 → shortcut connection으로 x를 받아서 identity mapping을 진행한다. F(x)+x → 마지막 단계로 ReLU σ가 적용된다.

[이점]

수식에서의 **shortcut connection**의 적용은 추가적인 parameter X, 계산 복잡성 X → parameters, depth, width, computational cost가 같으므로 plain network와 residual network 비교에 중요하다.

shortcut connection

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + W_s\mathbf{x}.$$

입출력의 x와 F의 차원이 다를 경우 linear projection Ws를 적용해 맞출 수 있다.

- Residual function F의 형태는 유연하나, 1개의 layer만 가질 경우 선형 레이어와 유사하며 장점을 가지지 못한다.
- fully-connected 만 아니라 convolutional layers도 적용 가능하다.

모델 구조 및 실행

Network Architectures

[Plain Network]

기본 구조

: VGG Nets에서 영감 → 3×3 필터 사용: 거의 모든 conv layers에 3*3 크기의 filter 적용

설계 규칙

(1)
- feature map 크기 동일 : 해당 레이어들은 동일한 개수의 필터 사용
- feature map가 반으로 줄 때: 연산 복잡도를 일정하게 유지하기 위해 필터 수를 2배 증가

(2) stride=2인 conv layer로 다운샘플링

(3)global average pooling 레이어와 1000-way fully-connected layer와 softmax로 네트워크를 끝낸다.

⇒ 34개의 가중치 레이어로 구성된다

VGG와 비교했을 때 효율성

- VGG에 비해 적은 필터와 낮은 복잡도

  : 34 layers 기준 3.6 billion FLOPs → 깊으면서도 가벼운 네트워크 구조

[Residual Network]

=plain network+shortcut connection

- input과 output의 차원이 같을 때 **identity mapping**을 바로 적용한다.
- 차원이 증가할 때
  - shortcut connection이 identity mapping을 수행 + zero-padding으로 차원 맞추기→ no extra parameters)
  - projection shortcut을 사용 + 1×1 Convolution으로 차원을 맞춤

4. 실험 및 결과

💡 Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

ImageNet Classification

ImageNet 2012 datasets

- 1000개의 클래스, 1.28M의 학습 이미지, 50K의 val 이미지
- final 결과에는 100K의 test 이미지 활용, top-1, top-5 error rates로 모델 평가

CIFAR-10 and Analysis

CIFAR-10 datasets

- 10개의 클래스, 50K의 학습 이미지, 10K의 test 이미지

Object Detection on PASCAL and MS COCO

결과

Plain Networks(18-layer와 34-layer에 대한 평가)

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	**25.03**

deep layer model(34-layer)이 shallower model(18-layer)보다 높은 validation error를 보임.

→ **degradation problem**이 발생

이러한 optimization difficulty의 원인? vanishing gradients ❌

→ 전파 및 역전차 모두 BN으로 train → signal이 안 사라짐 ⇒ 오히려 **기하급수적으로 낮은 convergence rate**으로 추정됨

Residual Networks(18-layer와 34-layer에 대한 평가)

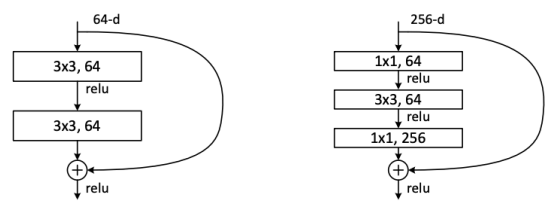

baseline architecture는 plain network와 동일, but 각 3x3 convolution filter 쌍 마다 shortcut connection을 추가.

Erste comparsion을 위해서 모든 shortcuts에 대해 **identity mapping을 적용**하고 output 차원이 증가시 **zero padding**을 사용해서 차원을 맞춤.

⇒ extra parameter는 더하지 않음!

결론

- 34-layer가 18-layer보다 2.8% 높은 성능을 보임 → the deeper, the better
- 34-layer에서 training error가 낮고 degradation problem이 더 잘 다뤄진다.

⇒ ResNet의 경우 depth는 즉 effectiveness, 수렴속도가 더 빨라 최적화에 수월하다.

5. 결론 (배운점)

💡 연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

의의 및 배운점

딥러닝 network에서 단순하게 모델의 깊이만이 model의 성능에 영향을 미치는 것이 아닌 근본적인 구조에 대한 변화로 성능에 영향을 줄 수 있다는 것을 알 수 있었다. 오소프 시간에 배운 VGG net의 구조와 한계에서 나아가 shortcut connection 적용 및 residual function으로의 구조 변화로 모델의 성능을 개선시킴을 확인할 수 있었다.

또한 한가지 dataset 및 기법으로 성능을 입증하는데 그치지 않고 다양한 dataset에서 이를 입증함으로 연구의 Gerneralization에 관해 생각해볼 수 있었다.

궁금한 점

4. Experiments에서 CIFAR-10 dataset에서의 모델 적용시 1000 layer와 같은 매우 깊은 model의 경우 강력한 규제(strong regularization)이 결과를 개선했다고 했는데 어떻게 깊은 layer에서 overfit 문제를 해결했는지 왜 그렇게 되었는지 궁금하다.