1. Deep Residual Learning for Image Recognition

1. Introduction
    논문이 다루는 분야
    해당 task에서 기존 연구 한계점
    논문의 contributions
2. Related Work
3. 제안 방법론
    Main Idea
    Contribution
4. 실험 및 결과
    Dataset
    Baseline
    결과
5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

심층 합성곱 신경망(Deep Convolutional Neural Networks)을 활용한 이미지 분류 (Image classification) 및 시각적 인식(Visual recognition)

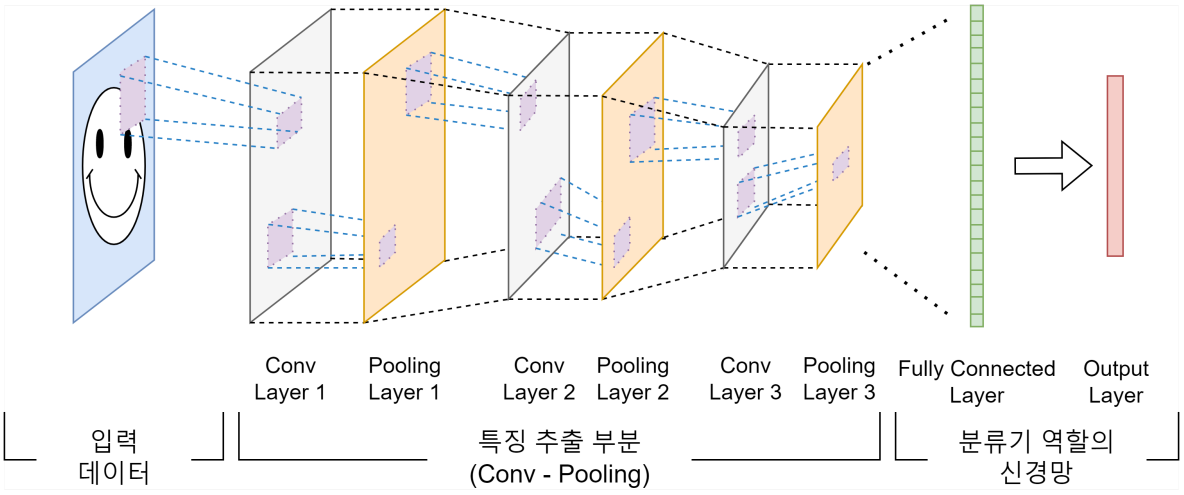

- 네트워크의 depth가 성능에 매우 중요하게 작용하며, 뛰어난 성능을 내는 모델들은 모두 16층에서 30층에 이르는 매우 깊은 아키텍처를 활용함.

⇒ 층을 더 쌓기만 하면 더 좋은 네트워크를 쉽게 학습시킬 수 있는가?

해당 task에서 기존 연구 한계점

1. **Vanishing/exploding gradients**
   초기 수렴을 방해하는 고질적인 문제였으나, Normalized initialization 및 Intermediate normalization layers을 통해 상당 부분 해결됨.

2. **Degradation problem**
   깊은 네트워크가 수렴을 시작할 수 있게 되면서 새롭게 드러난 문제로, 네트워크 깊이가 증가함에 따라 정확도가 Saturated 된 후 오히려 급격히 저하되는 현상 발생.

   - 이러한 성능 저하는 Overfitting에 의한 것이 아니며, 적절히 깊은 모델에 층을 더 추가할 경우 오히려 Training error가 높아짐

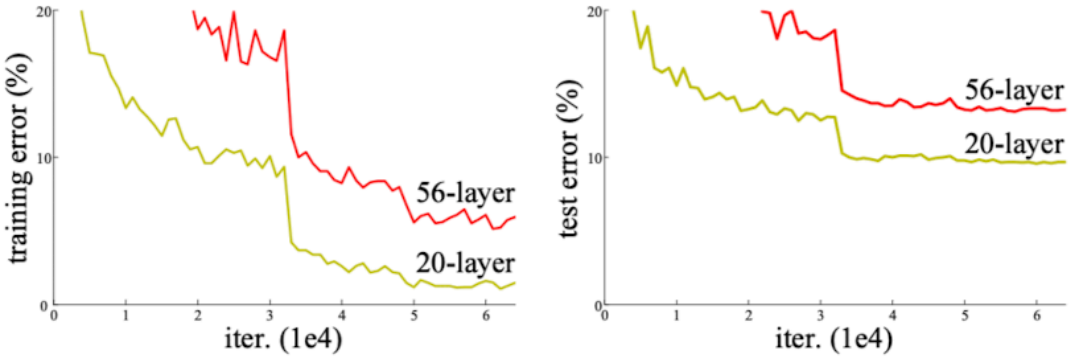

Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer "plain" networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

   - 이론적으로 얕은 모델에 Identity mapping 층만 추가하여 깊은 모델을 구성할 수 있으므로, 깊은 모델이 얕은 모델보다 학습 오차가 높아서는 안 됨.
   - 하지만 실험 결과, 현재의 최적화 도구들은 이처럼 구조적으로 구성된 최적의 해를 찾아내지 못하는 한계 존재

논문의 contributions

Deep Residual Learning Framework

: Deep Network에서 depth가 깊어질수록 발생하는 degradation 문제를 해결하기 위한 프레임워크

- **Residual Mapping 학습 구조**:
  - Stacked layers가 desired underlying mapping $H(x)$를 직접 학습하기를 기대하는 대신, explicit하게 residual mapping $F(x)$를 학습하도록 수식을 재구성.

$$F(x) := H(x) - x$$
$$H(x) = F(x) + x$$

  - 기존의 unreferenced mapping인 H(x)를 처음부터 학습하는 것보다, residual 인 F(x)를 0으로 최적화하는 것이 더 쉽다고 가정.
- **Shortcut Connections 활용**

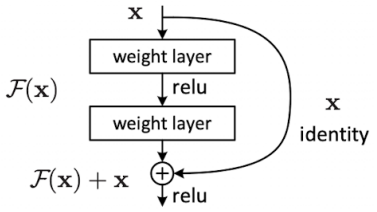

Figure 2. Residual learning: a building block.

  - F(x)+x 구조는 하나 이상의 layer를 건너뛰는 'shortcut connections'를 통해 쉽게 구현됨.
  - 단순히 identity mapping을 수행하므로 extra parameter나 computational complexity가 전혀 추가되지 않음.
  - 기존 solver 수정 없이 end-to-end 훈련 가능.
- **최적화 난이도 극복 및 성능 증명**
  - Plain networks와 달리, extremely deep residual networks는 depth가 깊어져도 쉽게 최적화되며 training error가 감소함을 입증.
  - Depth 증가에 비례하여 쉽게 accuracy gain을 얻을 수 있음.
- **SOTA 달성 및 범용성 (General Applicability)**:
  - VGG net보다 complexity는 낮으면서 8배나 깊은 152-layer ResNet 설계.
  - ILSVRC & COCO 2015 대회의 classification, detection, segmentation 등 다수 부문 1위를 휩쓸며 representations의 범용적 우수성 증명.

2. Related Work

- **Residual Representations**

    - 이미지 인식(VLAD, Fisher Vector) 및 벡터 양자화에서 original vectors보다 residual vectors를 인코딩하는 것이 더 강력하고 효과적임을 서술.
    - PDE(편미분방정식)를 푸는 Multigrid 방법 등에서도 시스템을 residual solution으로 reformulation하거나 preconditioning하는 것이 최적화를 크게 단순화하고 빠른 수렴을 이끈다는 기존 연구들을 근거로 제시.
- **Shortcut Connections (지름길 연결)**:
    - 초기 다층 퍼셉트론(MLPs)부터 vanishing/exploding gradients 해결을 위해 auxiliary classifiers를 연결하는 방식 등 오랜 역사를 가진 기법임을 명시.
    - Inception layer 역시 shortcut branch와 deeper branches의 조합으로 구성되어 있음을 언급.

Highway networks와의 비교

- **Parameter-free**
    - Highway networks의 shortcut은 data-dependent하며 파라미터가 존재하는 gating functions를 사용함.
    - 반면, ResNet의 identity shortcuts는 파라미터가 전혀 없는(parameter-free) 단순 연결임.
- **Always Residual**
    - Highway networks는 gated shortcut이 닫히면(0에 가까워지면) 정보가 통과하지 못해 non-residual functions를 나타내게 됨.
    - 반면, ResNet은 identity shortcut이 절대 닫히지 않아 모든 정보가 항상 통과하며, 추가적인 residual functions만 지속적으로 학습하는 구조임.
- **Extremely Deep 성능 입증**
    - Highway networks는 100 layer 이상의 극단적으로 깊은 depth에서 accuracy gains를 증명하지 못함.
    - 반면, 제안한 ResNet은 100 layer는 물론 1000 layer 이상의 depth에서도 성공적인 최적화와 성능 향상을 증명함.

3. 제안 방법론

Main Idea

1. **Residual Learning Formulation**
   Stacked layers가 desired underlying mapping $H(x)$를 직접 학습하기를 기대하는 대신, explicit하게 residual mapping $F(x)$를 학습하도록 수식을 재구성.

2. **Identity Mapping by Shortcuts**

$$y = F(x, \{w_i\}) + x$$

   - element-wise addition을 통해 연산되므로 extra parameter나 computational complexity 증가가 전혀 없음.

3. **Dimension Matching**
   - 입력 x와 출력 F의 차원이 다를 경우, shortcut에 linear projection W_s를 곱해 차원을 맞춤

$$y = F(x, \{w_i\}) + W_s x$$

⇒ 네트워크의 어떤 위치에서도 구현 가능하도록 구체화

Contribution

- **가설 입증 및 장점의 근거 제시**

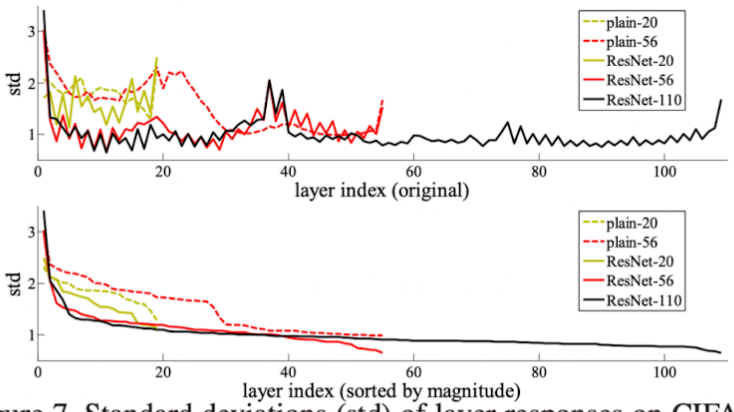

Figure 7. Standard deviations (std) of layer responses on CIFAR-10. The responses are the outputs of each 3×3 layer, after BN and before nonlinearity. **Top**: the layers are shown in their original order. **Bottom**: the responses are ranked in descending order.

  - 최적의 함수가 identity mapping에 가까울 경우, solver가 nonlinear layer의 가중치를 0으로 푸시하는 것이 더 쉽다는 가설을 구체화
  - 실제 실험 결과, learned residual functions의 response가 plain network보다 전반적으로 작게(closer to zero) 나타남을 입증하여, identity mapping이 합리

적인 preconditioning을 제공한다는 명확한 근거를 제시

- **구현 가능성을 보장하는 Architecture 설계 (Figure 3 참고)**
  - VGG 철학을 기반으로 34-layer Plain network를 설계하고, 여기에 shortcut connections를 추가해 Residual network로 변환하는 과정을 직관적으로 제시
  - 차원(dimensions)이 증가할 때의 처리 방식으로
    (A) Zero-padding (parameter-free 유지)
    (B) 1*1 convolutions를 통한 Projection shortcuts 제공
- **완벽한 재현을 위한 Implementation Details**
  - Data augmentation (224×224 randomly sampled crop, color augmentation) 방식을 명시함.
  - Batch Normalization (BN)의 정확한 위치(convolution 직후, activation 이전)를 지정함.
  - Optimizer 하이퍼파라미터 (SGD, mini-batch size 256, learning rate 0.1부터 시작, weight decay 0.0001, momentum 0.9, dropout 미사용) 등 모델을 from scratch로 훈련하기 위한 모든 구체적 조건을 서술하여 완벽한 구현 가능성을 제공함.

4. 실험 및 결과

Dataset

- **ImageNet 2012 classification dataset**: 1000개의 클래스로 구성되며, 128만 장의 training images, 5만 장의 validation images, 10만 장의 test images를 평가에 사용함.
- **CIFAR-10 dataset**: 10개의 클래스로 구성된 5만 장의 training images와 1만 장의 testing images를 사용하여 극도로 깊은 네트워크의 동작을 심층 분석함.
- **PASCAL VOC 2007/2012 및 MS COCO**: Object detection 및 Segmentation 태스크에서 학습된 표현의 일반화 성능을 평가하기 위해 활용됨.

Baseline

- **Plain Networks (일반 네트워크)**: VGG nets의 철학에서 영감을 받아 shortcut connections 없이 층만 쌓은 18-layer 및 34-layer 모델을 기본 비교군으로 설정함.
- **State-of-the-art Methods**: VGG-16, GoogLeNet, PReLU-net, BN-inception 등 기존 대회에서 최고 수준의 성적을 거둔 단일 및 앙상블 모델들과 성능을 비교함.

결과

- **Degradation problem (Plain Network)**
  ImageNet 실험에서 34-layer plain net이 18-layer plain net보다 전체 학습 과정 내내 더 높은 training error와 validation error를 보이며 퇴화 현상을 실제로 입증함.
- **퇴화 문제 극복 및 최적화의 용이성 증명 (ResNet)**
  동일한 층수의 ResNet 실험에서는 상황이 반전되어, 34-layer ResNet이 18-layer ResNet보다 훨씬 낮은 training error를 기록하고 validation 데이터에도 잘 일반화됨. 이는 깊이가 증가함에 따라 정확도 향상을 쉽게 얻을 수 있음을 보여줌.
- **극단적인 깊이에서의 성능 향상 (Bottleneck 구조)**
  연산 복잡도를 조절하는 병목 아키텍처를 도입하여 50, 101, 152-layer ResNet을 구성함. 깊이가 152층으로 늘어나도 퇴화 문제 없이 34-layer 모델 대비 정확도가 크게 향상됨을 입증함.
- **152-layer ResNet**은 단일 모델 기준 top-5 validation error 4.49%를 달성하여 기존의 모든 앙상블 결과를 뛰어넘음. 6개 모델의 앙상블로 ImageNet test set에서 3.57%의 error를 기록하며 ILSVRC 2015 분류 부문 1위를 차지함.
- **초거대 깊이 탐구 (CIFAR-10)**
  CIFAR-10 데이터셋에서 1202-layer 네트워크를 학습시킨 결과, 최적화의 어려움 없이 0.1% 미만의 training error를 달성 (단, 작은 데이터셋 특성상 110-layer 모델 대비 약간의 과적합은 발생)

5. 결론 (배운점)

의의, 한계

무작정 layer를 쌓을 때 발생하는 degradation 문제를 단순한 덧셈 연산인 residual learning과 shortcut connection으로 해결하여, parameter 증가나 기존 solver의 수정 없이 매우 깊은 deep network 훈련을 가능하게 했지만, CIFAR-10 데이터셋의 1202-layer 모델 실험처럼 초거대 모델에서는 강력한 regularization 없이는 overfitting이 발생한다는 한계가 있음.

개인적 감상

단순한 수식과 연산량을 조절하는 bottleneck 구조의 설계가 인상적이었음

무조건 복잡한 시스템을 고안하기보다 알고리즘의 구조적 단순화를 통해 컴퓨팅 한계를 극복하는 직관적인 문제 해결 방식에서 연구라는 것 자체에 어려움과 막막함을 느꼈던 사람으로서 큰 인사이트가 됨