2. Auto-Encoding Variational Bayes

1. Introduction
    논문이 다루는 분야
    해당 task에서 기존 연구 한계점
    논문의 contributions
2. Related Work
3. 제안 방법론
3. 제안 방법론
    Main Idea
    Contribution
4. 실험 및 결과
    Dataset
    Baseline
    결과
5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

- Continuous latent variables를 가지는 Directed probabilistic models에서의 효율적인 근사 추론 및 학습
- 특히 대규모 데이터셋 환경에서 Posterior distribution을 계산하기 어려운 경우를 주요 대상으로 함.

해당 task에서 기존 연구 한계점

- **사후 확률 계산의 난해함 :** 비선형 은닉층을 가진 신경망 등 복잡한 모델에서는 Marginal likelihood와 True posterior의 적분 계산이 구조적으로 불가능함.
- **기존 근사 추론법의 한계:**
    - Mean-field Variational Bayes: 근사하려는 분포의 기댓값을 해석적으로 (Analytically) 계산할 수 있어야만 적용 가능하므로, 일반적인 비선형 모델에는 사

용이 불가함.

  - MCMC (Markov Chain Monte Carlo): 샘플링 기반 방식이라 대규모 데이터셋에서는 수렴 속도가 너무 느려 실전 적용이 비효율적임.

- **대규모 데이터 처리의 어려움:** 배치 최적화 방식은 큰 데이터셋에서 너무 느리며, 미니배치 기반의 효율적인 학습과 계산 불가능한 사후 확률 문제를 동시에 해결하는 방법론이 부재함.

논문의 contributions

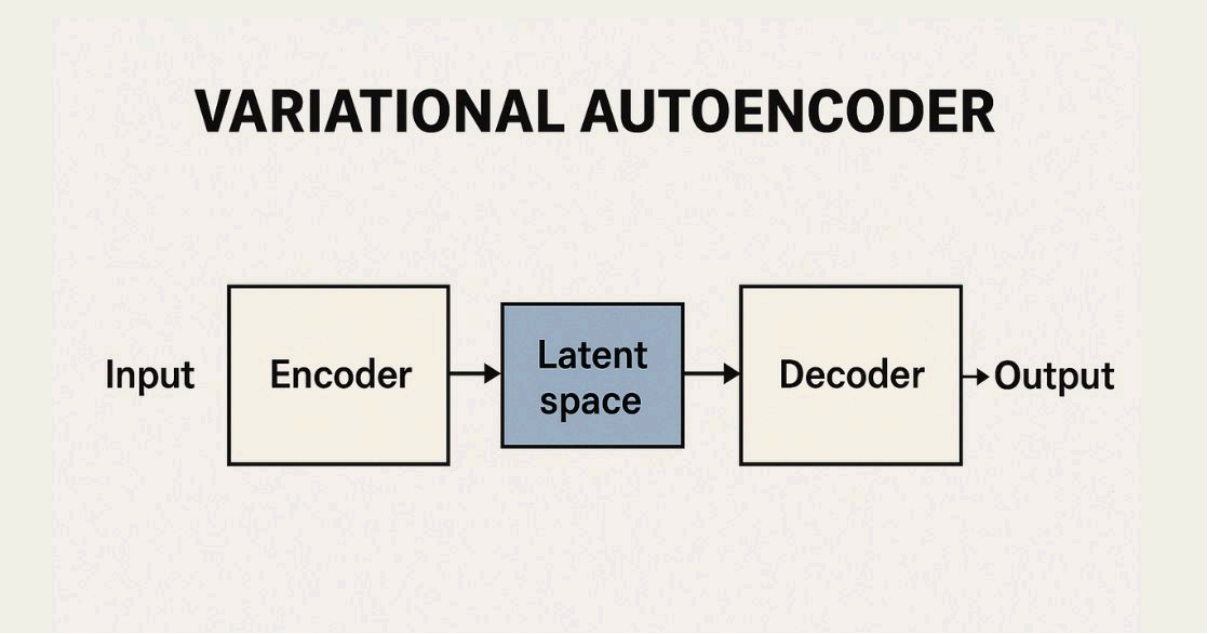

- **SGVB (Stochastic Gradient Variational Bayes) 추정기 제안:** Variational lower bound을 Reparameterization하여, 표준 확률적 경사 하강법(SGD)으로 직접 최적화할 수 있는 실용적인 하한 추정기를 개발함.
- **AEVB (Auto-Encoding Variational Bayes) 알고리즘 제안:** 대규모 독립 동일 분포(i.i.d.) 데이터셋에 대하여, 계산이 불가능한 참인 사후 확률 대신 근사 추론 모델 도입.
- **효율적인 통합 추론/학습 프레임워크 구축:** SGVB 추정기를 사용하여 생성 모델(디코더)과 추론 모델(인코더)의 파라미터를 동시에, 그리고 대규모 데이터셋에서도 매우 효율적으로 최적화할 수 있는 프레임워크를 확립함.

2. Related Work

제안 방법의 차별성

- Wake-sleep 알고리즘과 대비하여, AEVB는 marginal likelihood의 하한이라는 단일 목적 함수를 직접적이고 통합적으로 최적화할 수 있음을 강조함.

- 기존 auto-encoder가 표현 학습을 위해 번거로운 정규화 하이퍼파라미터를 요구했던 것과 달리, SGVB 목적 함수는 변분 하한 수식 자체에 정규화 항(KL divergence)이 내재되어 있어 별도의 튜닝 없이도 유용한 표현 학습이 가능함을 차별점으로 내세움.
- 특정한 조건에 얽매이지 않고, 일반적인 directed probabilistic models 클래스 전체를 학습할 수 있는 매우 범용적인 알고리즘임

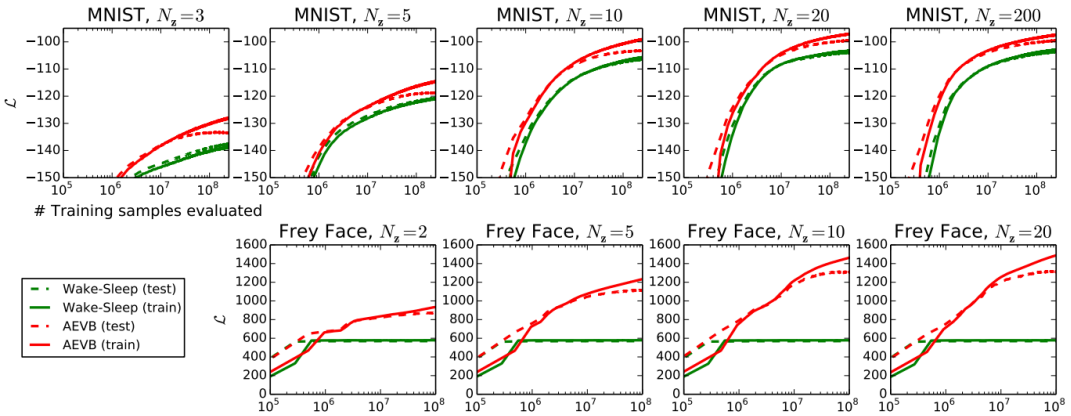

Figure 2: Comparison of our AEVB method to the wake-sleep algorithm, in terms of optimizing the lower bound, for different dimensionality of latent space ($N_{\mathbf{z}}$). Our method converged considerably faster and reached a better solution in all experiments. Interestingly enough, more latent variables does not result in more overfitting, which is explained by the regularizing effect of the lower bound. Vertical axis: the estimated average variational lower bound per datapoint. The estimator variance was small ($<$ 1) and omitted. Horizontal axis: amount of training points evaluated. Computation took around 20-40 minutes per million training samples with a Intel Xeon CPU running at an effective 40 GFLOPS.

3. 제안 방법론

3. 제안 방법론

1) Main Idea

2) Contribution

[📷 시각 자료 추천]

- **알고리즘 캡처:** 논문 4페이지 상단에 있는 **Algorithm 1 (Minibatch version of the Auto-Encoding VB algorithm)** 표를 그대로 캡처해서 넣는 것을 추천함. 제안 방법이 실제 어떻게 미니배치로 구현 가능한지 직관적으로 보여주는 훌륭한 자료임.
- **인터넷 검색 추천:** 구글 이미지 검색에 `Reparameterization trick VAE`라고 검색하여, 기존의 '확률적 노드(Stochastic node)'가 역전파를 막는 그림과, '노이즈 변수 주입(Deterministic node)'을 통해 역전파가 가능해진 구조를 비교하는 직관적인 다이어그램을 찾아 추가하면 원리 설명에 큰 도움이 됨.

Main Idea

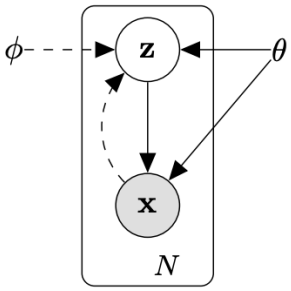

- Variational lower bound 최적화 시 참인 사후 확률을 근사하는 과정에서 발생하는 그래디언트 계산의 높은 Variance 문제를 해결하기 위해 Reparameterization trick을 핵심 아이디어로 제안함.
- 확률적 노드인 잠재 변수 z를 분포에서 직접 샘플링하는 대신, 독립적인 노이즈 변수와 미분 가능한 결정론적 함수의 조합으로 재매개변수화함.
- 이를 통해 역전파(Backpropagation) 과정에서 그래디언트가 샘플링 과정을 통과할 수 있게 만들어, 분산이 낮은 미분 가능한 추정기인 SGVB를 유도함.
- 도출된 SGVB를 기반으로 신경망 형태의 인코더와 디코더를 동시에 최적화하는 AEVB 알고리즘을 제안하여, Introduction에서 목표로 한 대규모 데이터셋에서의 효율적 추론을 달성함.

Algorithm 1 Minibatch version of the Auto-Encoding VB (AEVB) algorithm. Either of the two SGVB estimators in section 2.3 can be used. We use settings $M = 100$ and $L = 1$ in experiments.

$\boldsymbol{\theta}, \boldsymbol{\phi} \leftarrow$ Initialize parameters
repeat
  $\mathbf{X}^M \leftarrow$ Random minibatch of M datapoints (drawn from full dataset)
  $\boldsymbol{\epsilon} \leftarrow$ Random samples from noise distribution $p(\boldsymbol{\epsilon})$
  $\mathbf{g} \leftarrow \nabla_{\boldsymbol{\theta},\boldsymbol{\phi}} \widetilde{\mathcal{L}}^M(\boldsymbol{\theta}, \boldsymbol{\phi}; \mathbf{X}^M, \boldsymbol{\epsilon})$ (Gradients of minibatch estimator (8))
  $\boldsymbol{\theta}, \boldsymbol{\phi} \leftarrow$ Update parameters using gradients $\mathbf{g}$ (e.g. SGD or Adagrad [DHS10])
until convergence of parameters $(\boldsymbol{\theta}, \boldsymbol{\phi})$
return $\boldsymbol{\theta}, \boldsymbol{\phi}$

Contribution

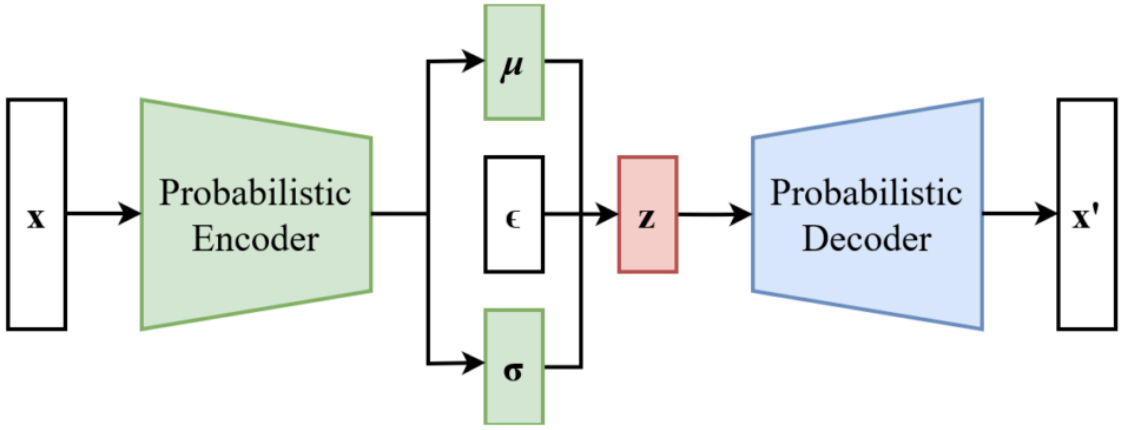

- Reparameterization trick을 통해 연속형 잠재 변수를 갖는 방향성 확률 모델에서 그래디언트 분산을 획기적으로 낮춘 실용적인 하한 추정기(SGVB)를 고안함.
- 베이지안 추론 과정을 딥러닝의 auto-encoder 신경망 구조와 성공적으로 연결하여, 다루기 어려운 사후 확률 분포를 근사하는 새롭고 효율적인 VAE 아키텍처를 정립함.
- 기존 MCMC와 같이 데이터 포인트마다 값비싼 반복 샘플링을 수행해야 했던 방식에서 벗어나, 표준 SGD를 이용한 미니배치 최적화를 가능하게 하여 대규모 데이터셋에 대한 놀라운 확장성을 입증함.

4. 실험 및 결과

대규모 데이터셋에서의 효율적인 approximate inference와 학습이 가능하다는 장점을 검증하기 위해, 기존 알고리즘들과 variational lower bound 및 estimated marginal likelihood 최적화 성능을 직접 비교하는 실험 수행.

Dataset

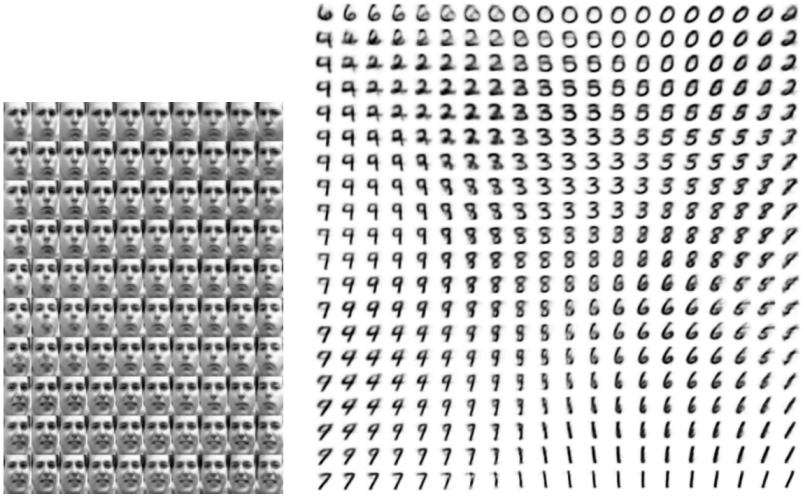

(a) Learned Frey Face manifold (b) Learned MNIST manifold

- MNIST
- Frey Face

Baseline

- Wake-sleep 알고리즘
- Monte Carlo EM (MCEM)

결과

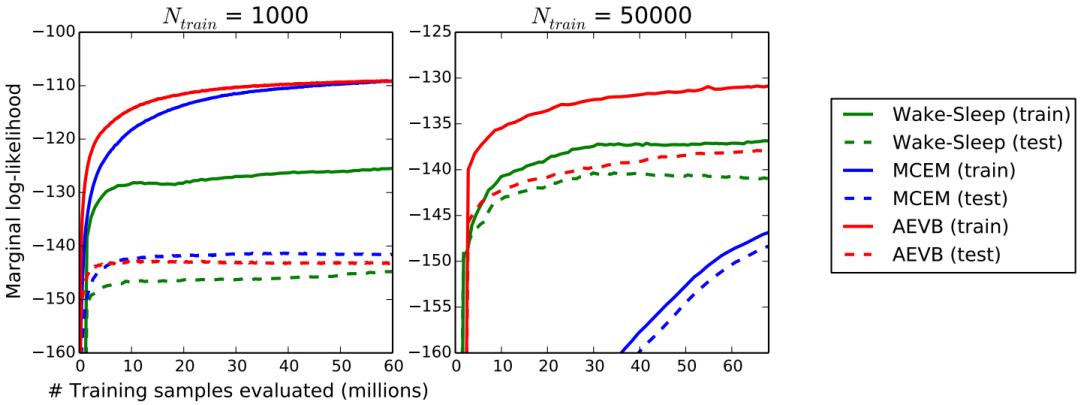

Figure 3: Comparison of AEVB to the wake-sleep algorithm and Monte Carlo EM, in terms of the estimated marginal likelihood, for a different number of training points. Monte Carlo EM is not an on-line algorithm, and (unlike AEVB and the wake-sleep method) can't be applied efficiently for the full MNIST dataset.

- **Variational lower bound 최적화 성능:** 다양한 차원의 latent space에서 AEVB가 Wake-sleep 알고리즘보다 훨씬 빠르게 수렴하며 더 높은 lower bound 값에 도달함

을 입증함.

- **Overfitting 방지:** Latent variables의 개수가 불필요하게 많아지더라도 variational bound의 내재적인 정규화 효과 덕분에 overfitting이 발생하지 않음을 확인함.
- **Marginal likelihood 추정 성능:** MCEM 및 Wake-sleep과의 marginal log-likelihood 비교 실험 결과, AEVB가 학습 및 테스트 셋 모두에서 뛰어난 성능과 빠른 수렴 속도를 보임. 특히 MCEM은 전체 데이터셋에 효율적으로 적용할 수 없는 방식인 반면, AEVB는 미니배치 학습으로 대규모 데이터를 완벽히 처리함.
- **데이터 시각화:** 학습된 encoder를 사용하여 고차원 이미지 데이터를 2D latent manifold로 성공적으로 투영하고, 매끄러운 이미지 생성이 가능함을 증명함.

5. 결론 (배운점)

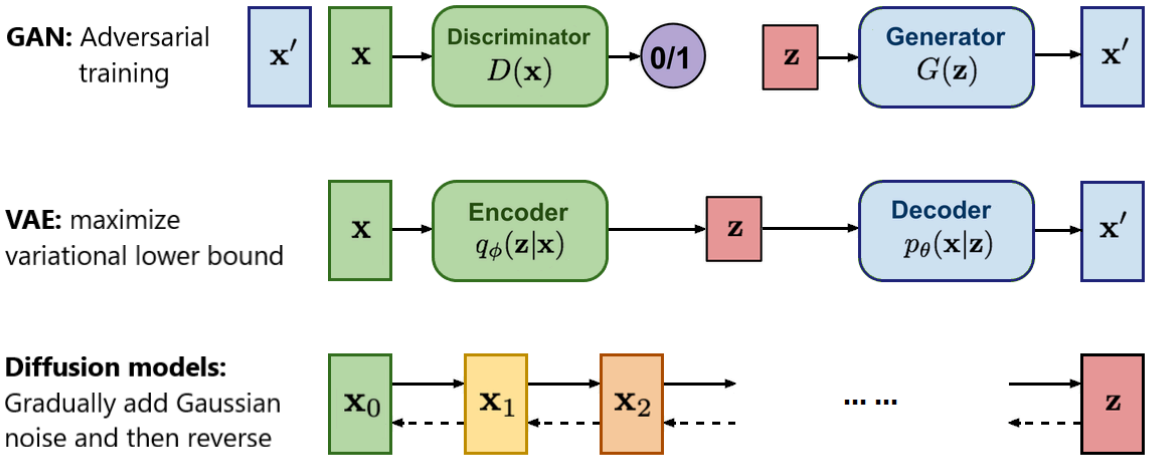

- **의의:** 복잡한 확률 모델에서 계산이 불가능했던 posterior 추론 문제를 reparameterization trick을 통해 미분 가능한 형태로 바꾼 혁신적인 연구임. 이를 딥러닝의 auto-encoder 구조와 성공적으로 결합함으로써, 대규모 데이터셋에서도 SGD를 이용한 미니배치 학습을 가능하게 하여 딥러닝 생성 모델의 새로운 패러다임과 기초를 확립함.
- **한계점:** 본 논문 자체에서는 주로 얕은 구조의 다층 퍼셉트론(MLP) 위주로 실험이 진행되었음. 깊은 신경망을 활용한 계층적 생성 구조나 시계열 데이터(time-series) 처리를 위한 확장 등은 향후 과제로 남겨두었다는 점에서 초기 모델로서의 구조적 한계가 존재
- **배운 점:** 수학적 이론을 실제 코드로 구현 가능한 효율적인 알고리즘으로 연결하는 능력이 얼마나 중요한지 깊이 깨달음. 특히 MCMC 같은 무거운 연산 대신 미니배치 처리가 가능하도록 수식을 재구성하여 컴퓨팅 효율성을 극대화한 점이 인상깊었음.