3주차 예습과제

📍Auto-Encoding Variational Bayes (VAE)

📝 교재 개념정리

1. Introduction
    논문이 다루는 분야
    해당 task에서 기존 연구 한계점
    논문의 contributions
2. Related Work
3. 제안 방법론
    Main Idea
    Contribution
4. 실험 및 결과
    Dataset
    Baseline
    결과
5. 결론 (배운점)

1. Introduction

💡 논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

- 연속적인 잠재 변수(latent variables)나 매개변수(parameters)의 사후 분포(posterior distributions)를 계산하기 까다로운(intractable) 유향 확률 모델에서, 어떻게 효율적인 근사 추론과 학습을 수행할 수 있을까?

해당 task에서 기존 연구 한계점

- 복잡한 확률 모델에서 사후 분포(intractable posterior)를 계산하는 것의 어려움
- 변분 베이즈(Variational Baysian, VB) 접근법이라는 해결책
    - 계산하기 힘든 사후 분포에 대한 근사치를 최적화하는 방식

- mean-field VB 방식도 근사 사후 분포에 대한 기댓값의 해석적 해를 요구

  → 일반적인 경우에는 계산이 불가하다는 한계

- MCMC의 경우 데이터 포인트마다 수천 번의 샘플링이 필요하여 대규모 데이터셋에 부적합

논문의 contributions

- **SGVB(Stochastic Gradient Variational Bayes) 추정량**
  - 변분 하한(variational lower bound)의 **재매개변수화(reparameterization)**를 통해
    미분 가능한 단순 불편 추정량으로 변환, 복잡한 확률 문제를 미분 가능한 함수 형태로 변경

    → 확률적 경사 하강법(stochastic gradient ascent)을 통한 모델 최적화 가능해짐

- **AEVB(Auto-Encoding VB) 알고리즘**
  - 데이터를 잠재 변수로 바꿔주는 인식 모델(Recognition Model)을 만듦
  - 인식 모델($q_\phi(z|x)$)을 통해 단순한 조상 샘플링(ancestral sampling)만으로도 매우 효율적인 근사 사후 추론이 가능

    → 각 데이터 포인트마다 비용이 많이 드는 반복적 추론 기법(MCMC 등) 없이 단일 통과(One-pass)만으로 z를 추론, 모델 매개변수를 효율적으로 학습할 수 있게 됨

  - 근사 사후 추론 모델은 인식, 노이즈 제거(denoising), 표현 학습(representation) 및 시각화 등 다양한 작업에 활용

- **이 인식 모델(인코더)과 생성 모델(디코더)을 신경망으로 구성하여 딥러닝과 확률 모델을 통합 한 것이 '변분 오토인코더(Variational Auto-Encoder, VAE)'**

2. Related Work

💡 Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- 기존 변분 추론과의 비교
  - 전통적인 VB (Variational Bayes):

        - 기존의 변분 추론 방식은 대부분 평균장(Mean-field) 가정을 사용하며, 각 매개변수에 대해 복잡한 기댓값을 계산해야 함

          → 모델이 조금만 복잡해져도 수학적으로 풀기 어려운(Intractable) 문제
    - SGVB 추정량은 재매개변수화(Reparameterization)를 통해 거의 모든 미분 가능한 모델에 일반화 가능
- 웨이크-슬립 알고리즘 (Wake-Sleep Algorithm)
    - 인식 모델(Recognition model)을 사용하여 사후 분포를 근사한다는 공통점
    - Wake-Sleep 알고리즘은 '두 단계'로 나누어 학습해야 하며(Wake 단계와 Sleep 단계), 수학적으로 단일한 목적 함수(Objective function)를 최적화하지 않음
    - AEVB는 하나의 하한(Lower bound) 수식을 동시에 최적화해 더 효율적임
- 몬테카를로 및 기울기 추정 관련 연구
    - 확률적 기울기를 구하기 위해 샘플링을 활용하는 다양한 기법들이 논의됨
        - 기존의 스코어 함수(Score function) 추정량은 분산이 매우 커서 제어가 어려움
    - 재매개변수화 기법은 분산을 획기적으로 낮추어 안정적인 학습을 가능하게 함

3. 제안 방법론

💡 Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

2.1 Problem scenario

- 연속 잠재 변수가 있는 다양한 형태의 확률 모델에 사용 가능
    - 데이터 별 잠재 변수가 있는 독립 동일 분포(i.i.d.) 데이터셋
    - 전역 매개변수에 대해서는 최대 우도(Maximum Likelihood) 또는 최대 사후 확률(MAP) 추론을 수행
    - 잠재 변수에 대해서는 변분 추론(variational inference)을 수행
    - 확장 가능성: 고정된 데이터뿐 아니라 실시간으로 들어오는 스트리밍 데이터에도 적용 가능

- 문제 상황

📌

- 데이터 생성 과정
  - 모든 데이터(x) 뒤에는 눈에 보이지 않는 잠재 원인(z)이 있다고 가정
  - N개의 독립 동일 분포(i.i.d.) 샘플로 구성된 데이터셋 $X = \{x^{(i)}\}_{i=1}^{N}$
  - 관측되지 않은 연속 확률 변수 z를 포함하는 어떤 무작위 과정에 의해 생성
  1. 사전 분포(prior) $p_{\theta^*}(z)$로부터 값 $z^{(i)}$가 생성
  2. 조건부 분포(likelihood) $p_{\theta^*}(x|z)$로부터 값 $x^{(i)}$가 생성

1. **계산 불가능성 (Intractability)**
   - z를 고려해서 x가 나올 확률을 계산하려면 모든 가능한 z에 대해 적분을 해야 하는데, 신경망처럼 복잡한 모델에서는 이 적분이 불가능
2. **큰 데이터셋**
   - 데이터가 너무 많아 배치 최적화(batch optimization) 비용이 너무 큼
   - 기존의 방식(MCMC 등)은 데이터 하나하나마다 수천 번씩 샘플링을 해야 해서 대규모 데이터에는 부적합

- 목표
  1. 매개변수 θ에 대한 효율적인 근사 ML 또는 MAP 추정(→생성)
     - 매개변수 자체가 분석 대상일 수도 있고, 이를 통해 실제 데이터와 유사한 인공 데이터를 생성하는 숨겨진 무작위 과정을 모방할 수도 있음
  2. 관측값 x와 매개변수 θ가 주어졌을 때, 잠재 변수 z에 대한 효율적인 근사 사후 추론 (→ 표현)
     - 부호화(coding)나 데이터 표현(representation) 작업에 유용
  3. 변수 x에 대한 효율적인 근사 주변 추론(marginal inference) (→ 복원)
     - x에 대한 사전 확률이 필요한 모든 종류의 추론 작업을 수행 가능

        - 이미지 노이즈 제거(denoising), 인페인팅(inpainting), 초해상도(super-resolution) 등

- **인식 모델(recognition model) $q_\phi(z|x)$ 도입**
    - 기존 방식처럼 수학적으로 복잡하게 계산하는 것이 아닌, **신경망의 매개변수(ϕ)를 최적화**해서 정답($p_\theta(z|x)$)과 최대한 비슷한 가짜 분포를 만드는 모델
    - 생성 모델(θ)과 인식 모델(ϕ)을 따로따로가 아니라 **한꺼번에(jointly) 학습**
- VAE 구조 정의
    - 관측되지 않은 변수 z는 **잠재 표현(latent representation)** 또는 코드(code)로 해석될 수 있음
    - 인식 모델 $q_\phi(z|x)$: 확률적 인코더(probabilistic encoder)
        - 데이터 포인트 x가 주어졌을 때, 해당 x를 생성했을 법한 코드 z의 가능한 값들에 대한 분포 생성 → 데이터(x)를 보고 코드(z)를 추측하는 모델
    - $p_\theta(x|z)$: 확률적 디코더(probabilistic decoder)
        - 코드 z가 주어졌을 때 그에 대응하는 x 값들의 분포를 생성 → 코드(z)를 보고 다시 데이터(x)를 생성하는 모델

2.2 The variational bound (변분 하한)

📌

- 전체 데이터셋의 주변 우도(marginal likelihood)는 개별 데이터 포인트들의 주변 우도의 합 $\log p_\theta(x^{(1)}, \cdots, x^{(N)}) = \sum_{i=1}^{N} \log p_\theta(x^{(i)})$으로 구성

$\Rightarrow \log p_\theta(x^{(i)}) = D_{KL}(q_\phi(z|x^{(i)})||p_\theta(z|x^{(i)})) + \mathcal{L}(\theta, \phi; x^{(i)}) \quad (1)$

- KL 발산은 항상 0 이상
- 우변의 두 번째 항인 $\mathcal{L}(\theta, \phi; x^{(i)})$는 데이터 포인트 i의 주변 우도에 대한 (변분) 하한(lower bound)이라고 불림

$\Rightarrow \log p_\theta(x^{(i)}) \geq \mathcal{L}(\theta, \phi; x^{(i)}) = E_{q_\phi(z|x)}[-\log q_\phi(z|x) + \log p_\theta(x, z)] \quad (2)$

$\Rightarrow \mathcal{L}(\theta, \phi; x^{(i)}) = -D_{KL}(q_\phi(z|x^{(i)})||p_\theta(z)) + E_{q_\phi(z|x^{(i)})}[\log p_\theta(x^{(i)}|z)] \quad (3)$

- 변분 매개변수 ϕ와 생성 매개변수 θ 모두에 대해 이 하한 $\mathcal{L}(\theta, \phi; x^{(i)})$를 미분하고 최적화하고자 함
  - ϕ에 대한 하한의 기울기(gradient)를 구할 때 사용되는 몬테카를로 기울기 추정량은 분산이 매우 커 문제 생김

- 데이터가 나올 확률($\log p_\theta(x)$)을 최대화 하고 싶지만 계산이 불가능(Intractable)

  → 수식 (3)에 나오는 $\mathcal{L}$(하한)을 최대화

  ⇒ KL 발산은 항상 0 이상이므로 **하한을 최대화**하는 것은 **주변 우도(Marginal Likelihood)를 간접적으로 최대화**하는 것과 같음

  - **첫 번째 항 (KL Divergence):** 인코더가 만든 분포(q_ϕ)가 우리가 정한 사전 지식($p_\theta(z)$, 보통 표준정규분포)과 얼마나 닮았는지 측정. 일종의 **정규화 (Regularization)** 역할
  - **두 번째 항 (Reconstruction Error):** 잠재 변수 z로부터 원래 데이터 x를 얼마나 잘 복원했는지를 측정, **복원 오차**

- 기존 방식의 문제점: 높은 분산 (High Variance)
  - 인코더의 파라미터(ϕ)를 업데이트하려면 미분을 해야 하는데, 위에서 언급한 일반적인 방식(Score function estimator)을 쓰면 값이 너무 튀어서(분산이 커서) 학습이 제대로 되지 않는 문제

2.3 The SGVB estimator and AEVB algorithm

- 변분 하한을 최적화하기 위한 구체적인 추정량(estimator)을 제안

📌

- 선택된 근사 사후 분포 $q_\phi(z|x)$를 따르는 확률 변수 $\tilde{z}$를 다음과 같이 재매개변수화 가능
  - 노이즈 변수 ϵ과 미분 가능한 변환 함수 $g_\phi(\epsilon, x)$를 사용하여 표현

$\Rightarrow \tilde{z} = g_\phi(\epsilon, x) \quad \text{with} \quad \epsilon \sim p(\epsilon) \quad (4)$

- $q_\phi(z|x^{(i)})$에 대한 어떤 함수 $f(z)$의 기댓값을 다음과 같이 몬테카를로 추정치로 구성

$\Rightarrow E_{q_\phi(z|x^{(i)})}[f(z)] = E_{p(\epsilon)}[f(g_\phi(\epsilon, x^{(i)}))] \simeq \frac{1}{L}\sum_{l=1}^{L} f(g_\phi(\epsilon^{(l)}, x^{(i)})) \quad \text{where} \quad \epsilon^{(l)} \sim p(\epsilon) \quad (5)$

- 이 기법을 변분 하한(식 2)에 적용하여, 일반적인 **SGVB(Stochastic Gradient Variational Bayes) 추정량** $\tilde{\mathcal{L}}^A(\theta, \phi; x^{(i)}) \simeq \mathcal{L}(\theta, \phi; x^{(i)})$을 도출

$\Rightarrow \tilde{\mathcal{L}}^A(\theta, \phi; x^{(i)}) = \frac{1}{L}\sum_{l=1}^{L} \log p_\theta(x^{(i)}, z^{(i,l)}) - \log q_\phi(z^{(i,l)}|x^{(i)})$
where $z^{(i,l)} = g_\phi(\epsilon^{(i,l)}, x^{(i)})$ and $\epsilon^{(l)} \sim p(\epsilon)$

Algorithm 1 Minibatch version of the Auto-Encoding VB (AEVB) algorithm. Either of the two SGVB estimators in section 2.3 can be used. We use settings $M = 100$ and $L = 1$ in experiments.

$\boldsymbol{\theta}, \boldsymbol{\phi} \leftarrow$ Initialize parameters
repeat
  $\mathbf{X}^M \leftarrow$ Random minibatch of M datapoints (drawn from full dataset)
  $\boldsymbol{\epsilon} \leftarrow$ Random samples from noise distribution $p(\boldsymbol{\epsilon})$
  $\mathbf{g} \leftarrow \nabla_{\boldsymbol{\theta},\boldsymbol{\phi}} \widetilde{\mathcal{L}}^M(\boldsymbol{\theta}, \boldsymbol{\phi}; \mathbf{X}^M, \boldsymbol{\epsilon})$ (Gradients of minibatch estimator (8))
  $\boldsymbol{\theta}, \boldsymbol{\phi} \leftarrow$ Update parameters using gradients $\mathbf{g}$ (e.g. SGD or Adagrad [DHS10])
until convergence of parameters $(\boldsymbol{\theta}, \boldsymbol{\phi})$
return $\boldsymbol{\theta}, \boldsymbol{\phi}$

- 재매개변수화 기법 (Reparameterization Trick)
  - 원래 확률 분포(q_ϕ)에서 직접 샘플링을 하면, 샘플링 과정 자체가 '무작위'이기 때문에 미분이 불가능하여 역전파(Backpropagation)를 쓸 수 X

    → 확률성을 고정된 노이즈(ϵ)로 외부로 빼 해결
    - 기존: $z \sim \text{Normal}(\mu, \sigma)$ (미분 불가)

    - 변경: $z = \mu + \sigma \times \epsilon$ (여기서 $\epsilon \sim \text{Normal}(0, 1)$은 고정된 노이즈)

      → μ와 σ는 일반적인 신경망의 출력값이 되어 미분 가능

- **SGVB 추정량 (Stochastic Gradient Variational Bayes)**
  - 재매개변수화를 통해 유도된 하한의 추정량을 **SGVB 추정량**이라고 함
    - $\tilde{\mathcal{L}}^A$: 모든 항을 샘플링으로 추정
    - $\tilde{\mathcal{L}}^B$: KL 발산 항은 수학적으로 미리 풀어서 계산(Analytic solution)하고, 복원 오차 항만 샘플링으로 계산. (분산이 더 작아 학습이 안정적임)

    $\tilde{\mathcal{L}}^B(\theta, \phi; x^{(i)}) = -D_{KL}(q_\phi(z|x^{(i)})||p_\theta(z)) + \frac{1}{L}\sum_{l=1}^{L} \log p_\theta(x^{(i)}|z^{(i,l)})$
  - 하한의 기댓값을 몬테카를로 샘플링을 통해 근사
  - 미니배치 사용할 경우, 데이터 포인트당 단 하나의 샘플(L=1)만 뽑아도 충분히 효율적으로 학습됨
  - $q_\phi(z|x)$를 최적화하여 값비싼 반복적 추론 없이도 즉각적인 사후 추론이 가능하게 함

2.4 The reparameterization trick

- 확률적 샘플링 과정에서 미분(gradient)이 끊기는 문제를 해결

📌

- $\tilde{z} \sim q_\phi(z|x)$에서 직접 샘플링하는 대신, 결정론적 함수 $g_\phi(\epsilon, x)$를 사용
  $\tilde{z} = g_\phi(\epsilon, x) \quad (\epsilon \sim p(\epsilon))$

- 확률성(stochasticity)을 외부 노이즈 ϵ으로 몰아넣음으로써, 매개변수 ϕ에 대한 역전파(Backpropagation) 통로를 확보
- **가우시안 예시:** $z = \mu + \sigma \odot \epsilon (\epsilon \sim N(0, I))$
  - 역누적분포함수 활용, 가우시안 같은 위치-척도 분포, 합성함수의 경우

Contribution

- 복잡한 변분 하한(ELBO)을 미분 가능한 SGVB 추정량으로 변환하여 확률 모델 학습의 난제를 해결
- 재매개변수화 기법(Reparameterization Trick)을 제안하여 확률적 샘플링 과정에서도 표준적인 역전파가 가능하도록 함

- 이론적 방법론을 신경망에 적용한 Variational Auto-Encoder(VAE)를 통해 대규모 데이터셋에서도 효율적인 생성 및 추론이 가능

---

3. Example: Variational Auto-Encoder

- 인식 모델(인코더) $q_\phi(z|x)$를 신경망으로 구성
  - 잠재 변수 z의 근사 사후 분포를 **대각 공분산 행렬을 가진 다변량 가우시안 분포**로 가정

    $$\log q_\phi(z|x^{(i)}) = \log N(z; \mu^{(i)}, \sigma^{2(i)} I)$$
  - 신경망은 데이터$x^{(i)}$를 입력받아 가우시안 분포의 파라미터인 평균($\mu^{(i)}$)과 표준편차($\sigma^{(i)}$)를 출력
- 재매개변수화와 목적 함수
  - 샘플링: $z^{(i,l)} = \mu^{(i)} + \sigma^{(i)} \odot \epsilon^{(l)} (\epsilon^{(l)} \sim N(0, I))$
  - 손실 함수 (SGVB 추정량 $\tilde{\mathcal{L}}^B$ 사용):
    - 사전 분포 $p_\theta(z)$를 표준 정규 분포 $N(0, I)$라고 가정하면, KL 발산 항은 해석적으로 계산되어 다음과 같은 수식이 됨

      $$-D_{KL}(q_\phi(z|x^{(i)})||p_\theta(z)) = \frac{1}{2}\sum_{j=1}^{J}(1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2)$$
    - 위 KL 항에 복원 오차(Reconstruction Error) 항을 더하여 최종적인 학습 목적 함수를 완성
- 두 가지 생성 모델(디코더)
  1. 베르누이 MLP (Bernoulli MLP):
     - 데이터 x가 이진 데이터(예: MNIST 검은색/흰색)인 경우 사용
     - 디코더의 출력층은 시그모이드(Sigmoid) 활성화 함수를 사용하며, 손실 함수로 교차 엔트로피(Cross-entropy)를 사용
  2. 가우시안 MLP (Gaussian MLP):
     - 데이터 x가 연속적인 값을 가지는 경우 사용합니다.
     - 디코더가 복원된 x의 평균과 분산을 출력하며, 손실 함수로 평균 제곱 오차(MSE)에 분산 항이 추가된 형태

4. 실험 및 결과

💡 Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- 데이터의 특성(이진 vs 연속)에 따른 모델의 범용성을 테스트하기 위해 두 종류의 데이터셋을 사용
- MNIST dataset
  - 28×28 픽셀의 손글씨 숫자 이미지 데이터셋
  - 인코더/디코더 은닉 유닛 500개 사용
- Frey Face dataset
  - 동일 인물의 다양한 얼굴 표정이 담긴 이미지 데이터셋
  - 데이터셋 규모가 작아 과적합 방지를 위해 200개의 은닉 유닛을 사용
  - 연속적인 데이터 특성을 반영하여 가우시안 출력을 가진 디코더를 채택(출력값은 시그모이드 함수를 통해 0~1 사이로 제한)

Baseline

- AEVB(VAE) 알고리즘의 성능을 검증하기 위해 당시 사용되던 주요 학습 방식들과 비교 진행
- Wake-Sleep 알고리즘
  - 인식 모델을 학습시키는 기존의 대표적인 알고리즘
  - VAE와 동일한 인코더 구조를 사용
- MCEM (Monte Carlo EM)
  - 주변 우도(Marginal Likelihood) 비교를 위해 Hybrid Monte Carlo(HMC) 샘플러를 사용하는 전통적인 샘플링 기반 방식
- 실험 환경
  - 최적화: Adagrad를 사용한 확률적 경사 상승법(Stochastic Gradient Ascent)
  - 초기화: $N(0, 0.01)$ 무작위 샘플링
  - 하이퍼파라미터: 미니배치 크기 M=100, 데이터 포인트당 샘플 수 L=1$

결과

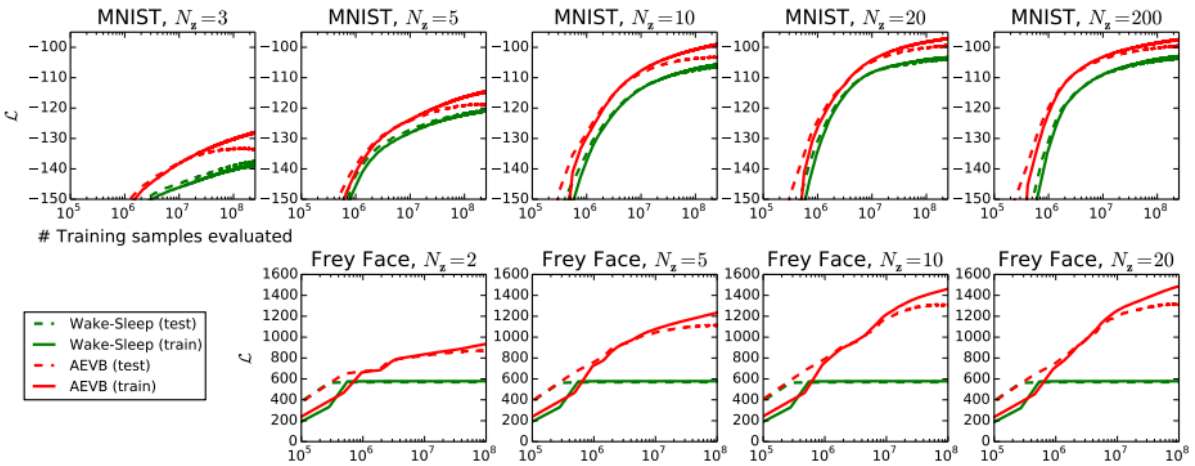

1. **변분 하한 비교 (Likelihood Lower Bound)**
   - 실험의 핵심 지표인 ELBO(Evidence Lower Bound)를 기준으로 AEVB와 Wake-Sleep 알고리즘을 비교
   - 잠재 변수의 차원(M=2, 5, 10, 20)에 상관없이 AEVB가 Wake-Sleep보다 항상 더 높은 하한값을 기록
   - AEVB는 학습 초기 단계에서 매우 가파르게 하한값이 상승하며 최적점에 도달하는 반면, Wake-Sleep은 수렴 속도가 상대적으로 느림
   - 규제 효과(Regularization):
     - VAE는 변분 하한의 KL 발산 항(Regularizer) 덕분에 데이터셋에 비해 잠재 변수의 차원이 과하게 커지더라도 과적합이 발생해 성능이 저하되지 않고 안정적인 학습을 유지

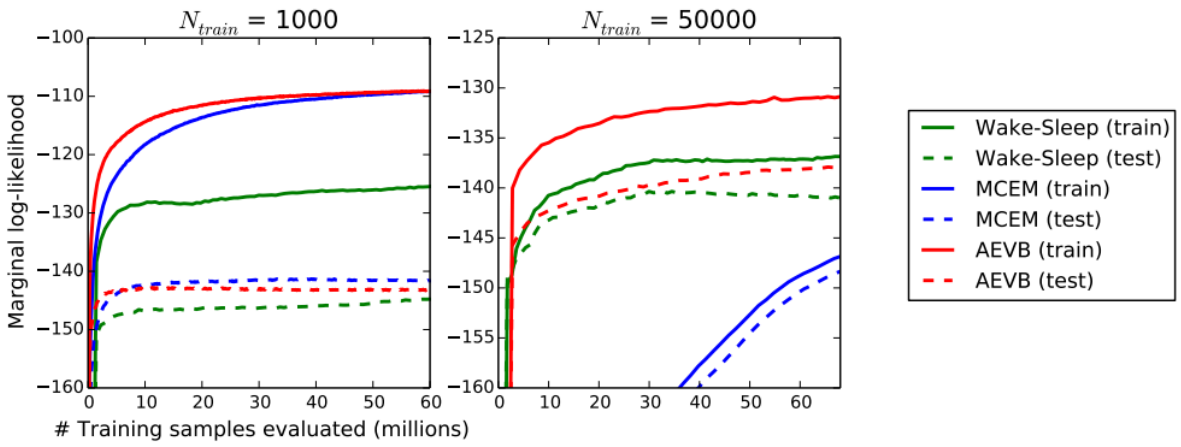

2. 주변 우도 추정 (Marginal Likelihood)

- MCMC(Markov Chain Monte Carlo) 추정량을 사용하여 실제 데이터가 생성될 확률($\log p(x)$)을 측정
- 수렴 효율성:
  - 작은 데이터셋: 세 알고리즘 모두 비슷한 성능에 도달했으나 AEVB가 더 효율적
  - 큰 데이터셋: 데이터 양이 많아질수록 샘플링 기반인 MCEM은 계산 비용이 급증한 반면, AEVB는 미니배치 학습을 통해 가장 빠르고 효율적으로 주변 우도를 근사
- 3차원 이하의 저차원 잠재 공간에서는 AEVB가 매우 신뢰도 높은 추정치를 보임

3. 고차원 데이터 시각화(Visualisation of high-dimensional data)

- 저차원 잠재 공간(예: 2D)을 선택하면, 학습된 인코더(인식 모델)를 사용하여 고차원 데이터를 저차원 매니폴드에 투영 가능

5. 결론 (배운점)

💡 연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- 연속적인 잠재 변수를 가진 모델에서 효율적인 근사 추론을 수행하기 위해 변분 하한(variational lower bound)의 새로운 추정량인 SGVB(Stochastic Gradient VB)를 도입
  - 표준적인 확률적 경사법(stochastic gradient methods)을 사용하여 직관적으로 미분하고 최적화 가능
- 독립 동일 분포(i.i.d.) 데이터셋과 데이터 포인트당 연속 잠재 변수가 있는 경우를 위해, SGVB 추정량을 사용하여 근사 추론 모델을 학습하는 효율적인 알고리즘인 AEVB(Auto-Encoding VB)를 도입
- 기존 MCMC처럼 데이터당 수천 번 샘플링하는 대신, 단 한 번의 샘플링(L=1)과 미니배치 학습만으로도 대규모 데이터셋 학습이 가능
- 학습된 인코더를 통해 복잡한 적분 없이 입력 데이터 x에 대한 잠재 변수 z를 즉각적으로 추론할 수 있게 됨

- 한계점: 연속적인(continuous) 잠재 변수에는 매우 강력하지만, 카테고리 형태와 같은 이산적인(discrete) 변수에는 재매개변수화 기법을 직접 적용하기 어려움

- 향후 과제
  - 인코더와 디코더에 딥러닝 구조(예: 합성곱 신경망, CNN)를 사용한 계층적 생성 아키텍처를 학습하고 AEVB로 공동 훈련하는 것
  - 시계열 모델(동적 베이지안 네트워크)
  - 전역 매개변수(global parameters)에 SGVB를 적용
  - 복잡한 노이즈 분포를 학습하는 데 유용한 잠재 변수가 포함된 지도 학습 모델 등

🧐

- SGVB 추정량 유도 과정이나 부록의 KL 발산 등 수식들이 어려운 부분이 많아 쉽지 않았던 논문이었다.
- 미분이 불가능한 샘플링 과정을 노이즈를 밖으로 빼낸다는 재매개변수화 아이디어로 해결한 점이 인상적이었다.
- 데이터를 단순히 압축하는 것이 아니라, 데이터가 생성되는 원리(확률 분포)를 학습하는 것이 생성 모델의 핵심이다라는 것을 알 수 있었다.

교재 개념정리

🔖<딥러닝 파이토치 교과서>

- 범위 : 13.1. 생성 모델이란 / 13.2. 변형 오토인코더 (p.682~708)

13.1 생성 모델이란

- 생성 모델(generative model)
  - 주어진 데이터를 학습하여 데이터 분포를 따르는 유사한 데이터를 생성하는 모델

13.1.1 생성 모델 개념

- 입력 이미지(x)가 있을 때 그에 따른 정답(y)를 찾는 것: 판별(자) 모델(discriminative model)
  - 이미지를 정확히 분류(구별)하고자 해당 이미지를 대표하는 특성들을 잘 찾는 것을 목표로 함
- 생성(자) 모델
  - 입력 이미지에 대한 데이터 분포 p(x)를 학습하여 새로운 이미지를 생성

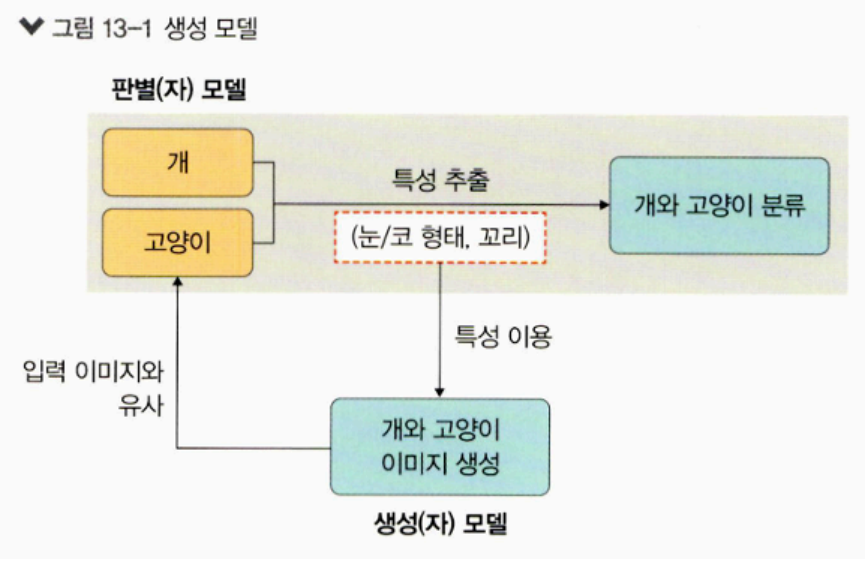

13.1.2 생성 모델의 유형

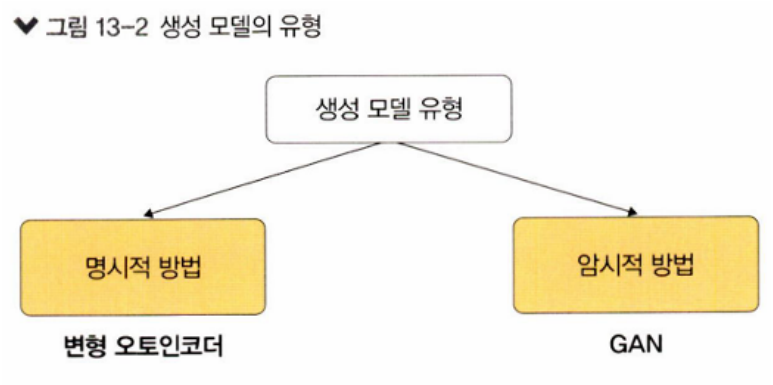

- 명시적 방법(explicit density)
  - 확률 변수 p(x)를 정의해 사용
  - 변형 오토인코더(variational autoencoder)
    - 이미지의 잠재 공간(latent space)에서 샘플링하여 완전히 새로운 이미지나 기존 이미지를 변형하는 방식으로 학습 진행
- 암시적 방법
  - 확률 변수 p(x)에 대한 정의 없이 p(x)를 샘플링하여 사용
    - GAN(Generative Adversarial Network)
      - 생성자와 판별자가 서로 경쟁하면서 가짜 이미지를 진짜 이미지와 최대한 비슷하게 만들도록 학습 진행

13.2 변형 오토인코더

13.2.1 오토인코더란

- 오토인코더
  - 입력을 출력으로 복사하는 신경망
  - 은닉층(병목층)의 노드 수가 입력 값보다 적은 특징
  - 적은 수의 병목층 뉴런으로 데이터를 가장 잘 표현할 수 있는 방법

  1. 인코더
     - 인지 네트워크(recognition network)라고도 하며, 특성에 대한 학습을 수행하는 부분

2. 병목층(은닉층)
    - 모델의 뉴런 개수가 최소인 계층
    - 차원이 가장 낮은 입력 데이터의 압축 표현이 포함됨
3. 디코더
    - 생성 네트워크(generative network)라고도 하며, 병목층에서 압축된 데이터를 원래대로 재구성(reconstruction)하는 역할
    - 최대한 입력에 가까운 출력을 생성하도록 함
4. 손실 재구성
    - 오토인코더는 입력층과 출력층의 뉴런 개수가 동일하다는 것 제외하면 일반적인 다층 퍼셉트론과 구조 동일
    - 압축된 입력을 출력층에서 재구성, 손실 함수는 입력과 출력(인코더와 디코더)의 차이로 계산

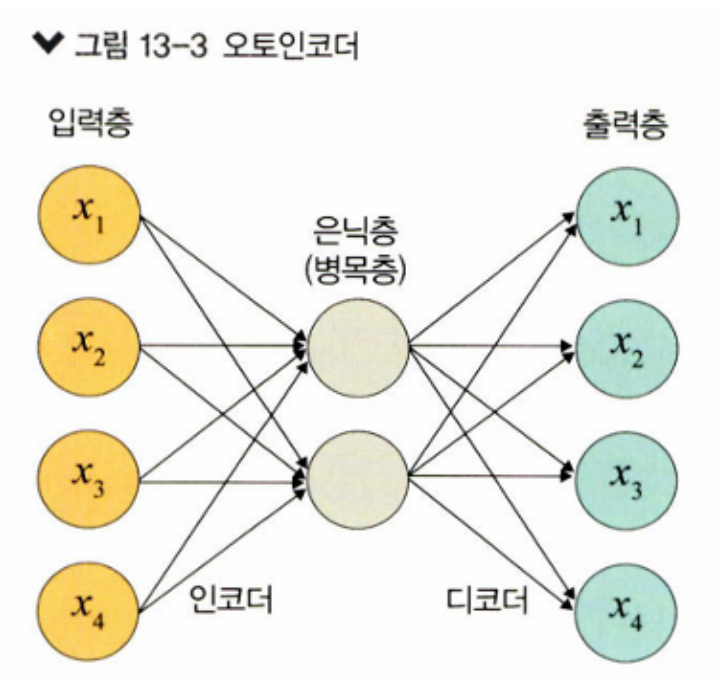

📌

- 입력 x와 출력 y는 같은 차원(R^d)에 존재한다 가정
- 입력 데이터를 인코더에 통과시켜 압축된 잠재 벡터 z값을 얻음
  $z = h(x)$
- 압축된 z 벡터에서 입력 데이터와 크기가 같은 출력 값 계산
  $y = g(z) = g(h(x))$
- 손실 값은 입력 값 x와 디코더를 통과한 y 값의 차이
  $\text{Loss} = \sum_{x \in D} L(x, g(h(x))) = \|x - y\|^2$

⇒ 디코더 네트워크를 통과한 출력 값은 입력 값의 크기와 같아야 함

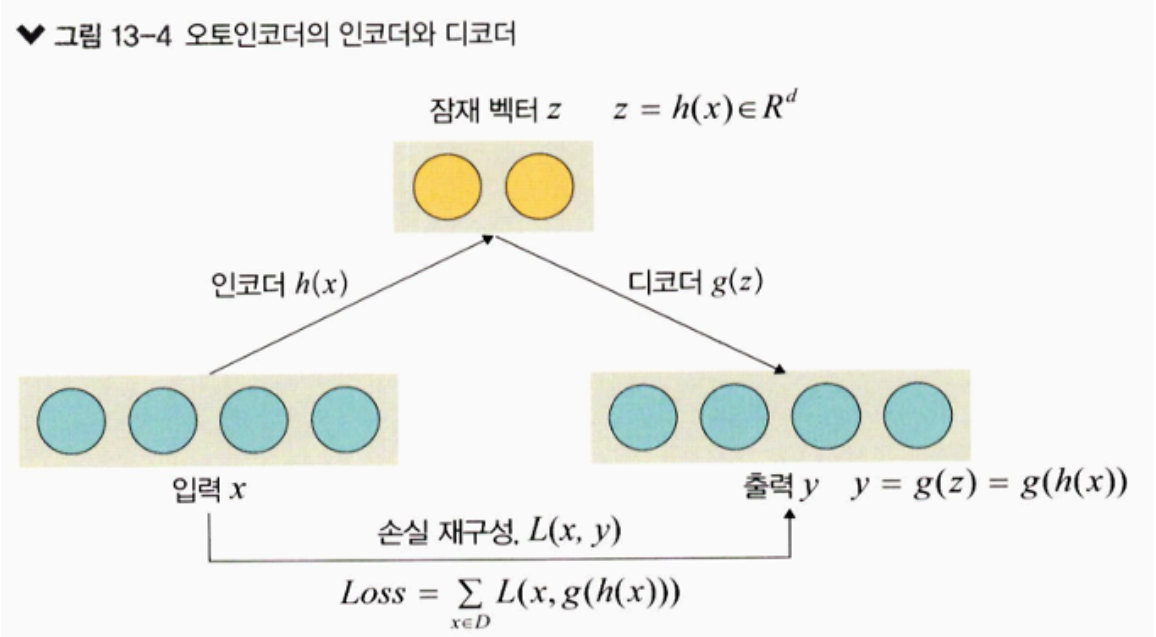

- 오토인코더의 중요성
  1. 데이터 압축
     - 메모리 측면에서의 장점, 오토인코더 이용해 이미지 등의 중요 특성만 압축하면 용량 저하, 품질 상승
  2. 차원의 저주 예방
     - 특성 개수를 줄여 주기 때문에 데이터 차원이 감소하여 차원의 저주 피할 수 있음

3. 특성 추출
    - 비지도 학습으로 자동으로 중요한 특성을 찾아 줌

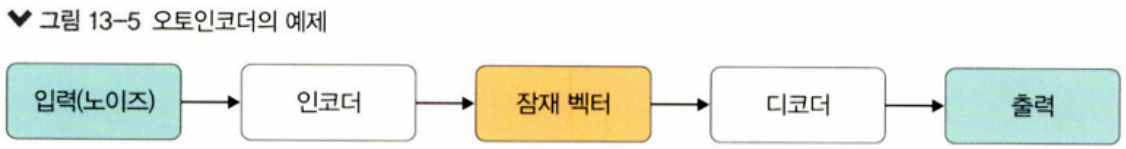

13.2.2 변형 오토인코더

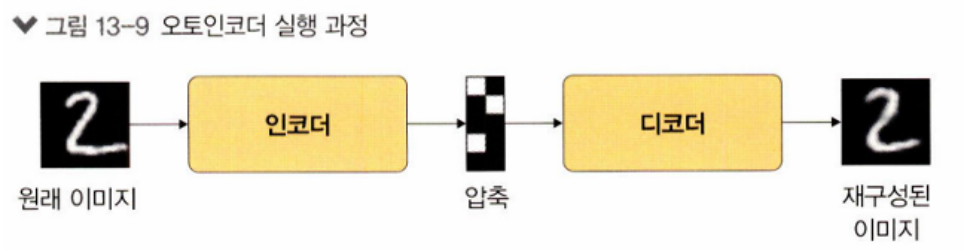

- 오토인코더는 입력 → 인코더 → 압축(차원 축소) → 디코더 → 출력
    - 차원을 줄이는 것이 목표이기 때문에 새롭게 생성된 데이터의 확률 분포에는 관심 X
- 변형 오코인코더
    - 표준편차와 평균을 이용하여 확률 분포를 만들고, 거기서 샘플링하여 디코더를 통과시킨 후 입력 데이터와 조금 다른 새로운 데이터를 만들어 냄
    - 이때 z라는 가우시안 분포를 이용(z는 잠재 벡터(latent vector))
    - 중요한 특성의 파라미터를 담고 있는 z 분포에서 벡터를 랜덤하게 샘플링, 이 분포의 오차를 이용하여 입력 데이터와 유사한 다양한 데이터를 만들어내는 방법

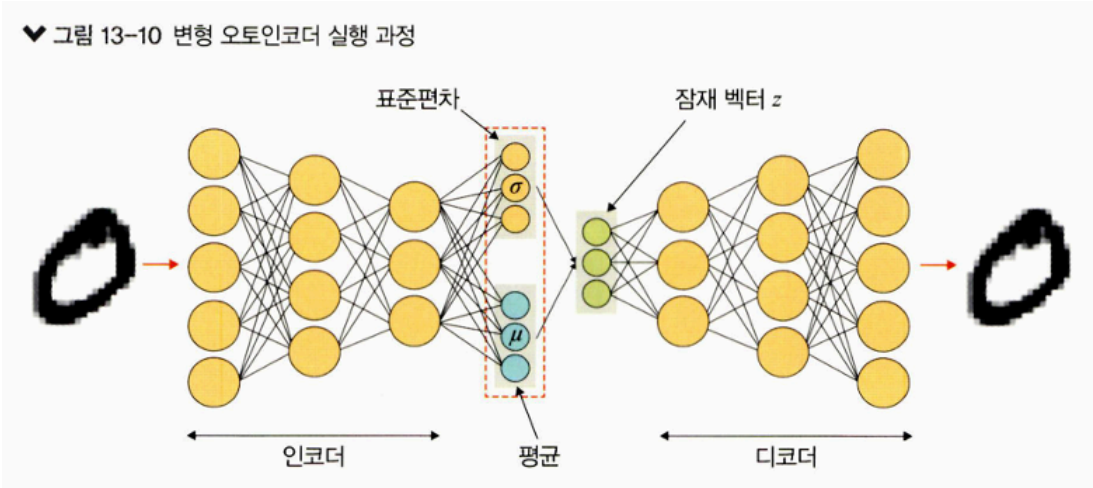

- 오토인코더: 데이터 벡터에 대한 차원을 축소하여 실제 이미지와 동일한 이미지를 출력
  vs. 변형 오토인코더: 데이터가 만들어지는 확률 분포를 찾아 비슷한 데이터를 생성

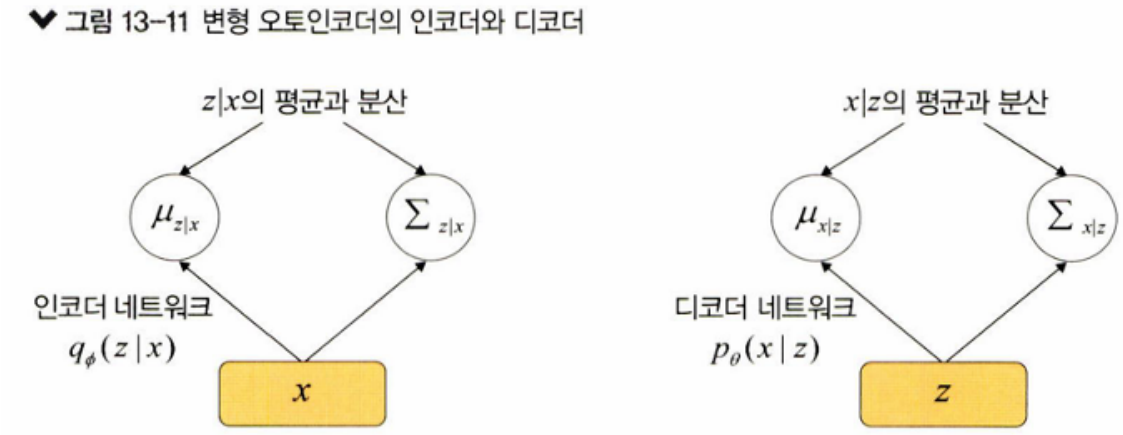

  - $q_\phi(z|x)$: x를 입력받아 잠재 벡터 z와 대응되는 평균과 분산을 구하는 인코더 네트워크
  - $p_\theta(x|z)$: z를 입력받아 x와 대응되는 평균과 분산을 구하는 디코더 네트워크
- 인코더 네트워크

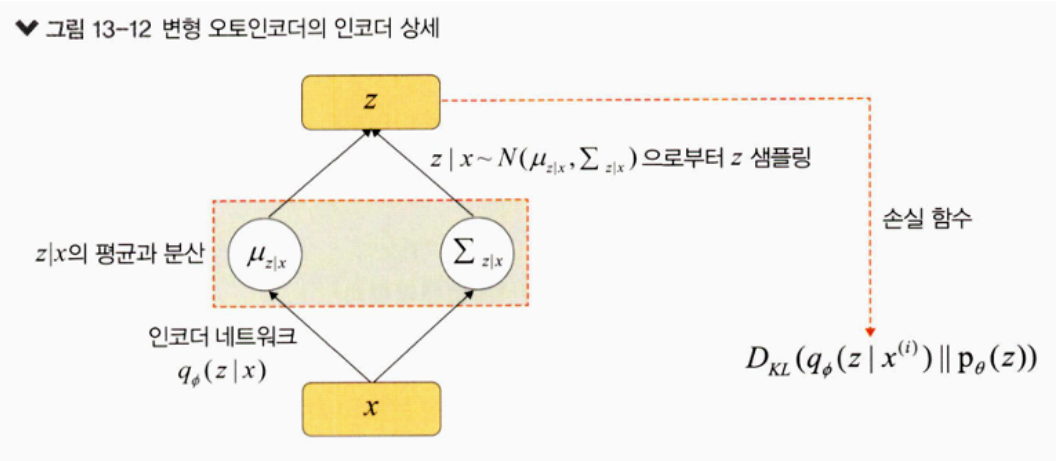

1. 입력 x를 인코더 네트워크 $q_\phi(z|x)$에 보내 ($\mu_{z|x}$, $\sum_{z|x}$)를 출력, 이를 이용해 다음 수식의 D_{KL}에 대한 값을 구함
   $L(x^{(i)}, \theta, \phi) = E_z[\log p_\theta(x^{(i)} \mid z)] - D_{KL}(q_\phi(z \mid x^{(i)}) \| p_\theta(z))$

2. ($\mu_{z|x}$, $\sum_{z|x}$)의 가우시안 분포에서 z를 샘플링
   $z \leftarrow z|x \sim N(\mu_{z|x}, \Sigma_{z|x})$

   → 이렇게 구해진 z는 디코더 네트워크의 입력으로 사용됨

- 디코더 네트워크

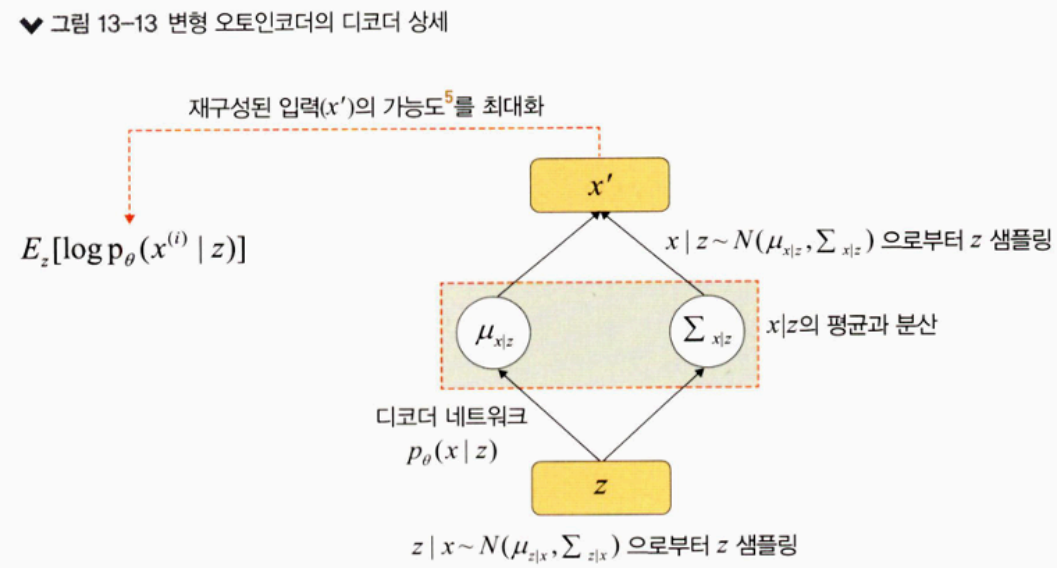

📌

1. 샘플링한 z를 디코더 네트워크 $p_\theta(x|z)$에 보내 ($\mu_{z|x}$, $\sum_{z|x}$)를 출력한 후 이를 이용해 다음 수식의 E_z의 값을 구함
   $L(x^{(i)}, \theta, \phi) = E_z[\log p_\theta(x^{(i)} \mid z)] - D_{KL}(q_\phi(z \mid x^{(i)}) \| p_\theta(z))$
2. ($\mu_{z|x}$, $\sum_{z|x}$)의 가우시안 분포에서 z를 샘플링 한 후 x′를 구함
   $x' \leftarrow x|z \sim N(\mu_{x|z}, \Sigma_{x|z})$
3. 역전파를 이용하여 $L(x^{(i)}, \theta, \phi)$의 값이 높아지는 방향, 즉 가능도(likelihood)가 증가하는 방향으로 기울기를 업데이트

→ 최종적으로 x와 유사한 x′이라는 이미지가 생성됨

$$E_z[\log p_\theta(x^{(i)} \mid z)] - D_{KL}(q_\phi(z \mid x^{(i)}) \| p_\theta(z))$$

- E_z 항은 z가 주어졌을 때 x′를 표현하기 위한 확률밀도 함수, 디코더 네트워크를 나타냄
  - 디코더 네트워크의 가능도가 클수록 θ가 그 데이터를 잘 표현한다 해석

    → E_z 항이 크면 클수록 모델 가능도가 커짐
- D_{KL}항은 x에서 z를 표현하는 확률밀도 함수, 인코더 네트워크와 가우시안 분포가 얼마나 유사한지 나타냄
  - 유사한 정도가 높을수록 KL Divergence는 낮은 값 나타내므로, 인코더 네트워크가 가우시안 분포를 최대한 잘 표현할 수 있도록 가능도가 최대화 됨

    → D_{KL} 항이 작을수록 모델 가능도가 커짐

⇒ E_z 값이 클수록, D_{KL} 값이 작을수록 가짜 데이터를 잘 생성