4. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

1. Introduction
    - 논문이 다루는 분야
    - 해당 task에서 기존 연구 한계점
    - 논문의 contributions
2. Related Work
3. 제안 방법론
    - Main Idea
    - Contribution
4. 실험 및 결과
    - Dataset
    - Baseline
    - 결과
5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

- 대규모의 레이블이 없는 텍스트로부터 언어 모델을 사전 학습(Pre-training)시켜 다양한 자연어 처리 태스크의 성능을 전반적으로 향상시키는 방법론을 다룸.
- 사전 학습된 표현을 하위 태스크에 적용하는 두 가지 주요 전략인 Feature-based 방식과 Fine-tuning 방식 중, 최소한의 파라미터만 추가하여 모델 전체를 업데이트하는 Fine-tuning 방식의 구조적 발전에 집중함.

해당 task에서 기존 연구 한계점

- **단방향성(Unidirectionality)의 제약**
  OpenAI GPT 같은 기존의 주요 Fine-tuning 모델들은 왼쪽에서 오른쪽으로만 텍스트의 흐름을 읽는 단방향 언어 모델 구조를 사용함.

- **문맥 파악의 구조적 한계**
  이러한 단방향성은 문장 전체의 맥락을 종합적으로 보지 못하게 만들어, 양방향의 문맥 통합이 필수적인 질의응답(Question Answering) 같은 토큰 단위 태스크에 적용할 때 치명적인 성능 저하를 일으킴.

- **얕은 양방향성의 한계**
  ELMo와 같은 Feature-based 모델은 양방향 문맥을 고려하긴 하지만, 완전히 깊게 융합된 형태가 아니라 독립적으로 학습된 좌방향 모델과 우방향 모델의 결과를 단순히 얕게 이어 붙인(Shallow concatenation) 형태에 불과함.

논문의 contributions

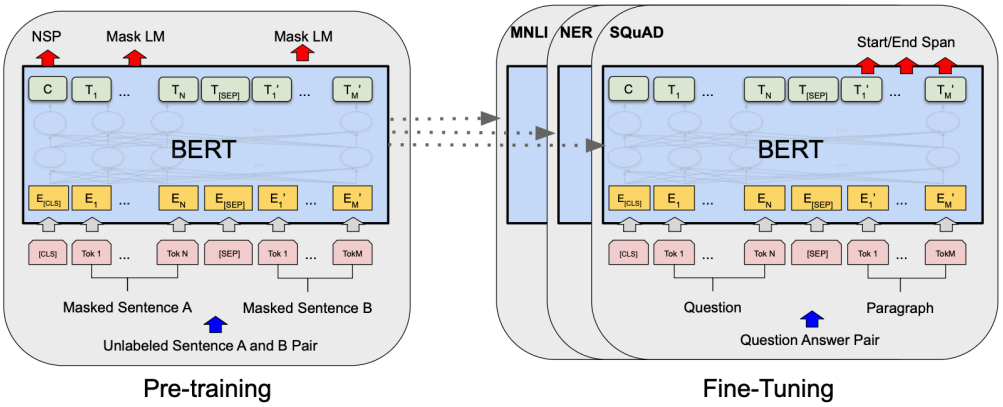

- **Masked Language Model (MLM) 도입**
  입력 텍스트의 일부를 무작위로 가리고 주변 문맥만으로 해당 단어를 예측하게 만드는 MLM 방식을 도입하여, 단방향 제약을 극복하고 텍스트의 좌우 문맥을 완벽하게 융합하는 깊은 양방향(Deep bidirectional) 표현 학습을 최초로 성공시킴.

- **Next Sentence Prediction (NSP) 도입**
  문장 간의 관계를 깊이 이해하기 위해, 두 문장이 실제로 이어지는 문장인지 아닌지를 맞추는 NSP 태스크를 추가로 도입하여 텍스트 쌍에 대한 학습 능력을 강화함.

- **아키텍처의 단순화 및 높은 범용성**
  태스크별로 복잡한 아키텍처를 새로 짤 필요 없이, 사전 학습된 단일 모델에 출력 레이어 하나만 추가하는 단순한 Fine-tuning만으로도 광범위한 문제들을 처리할 수 있음을 증명함.

- **압도적인 SOTA 달성**
  질의응답(SQuAD v1.1, v2.0) 및 자연어 추론(GLUE) 등 11개의 주요 자연어 처리 태스크에서 기존의 모든 모델을 큰 폭으로 따돌리며 State-of-the-art을 달성함.

2. Related Work

1) 기존 연구들에 대한 서술

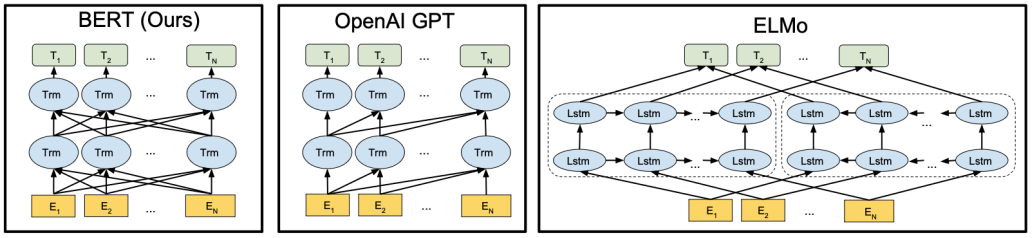

- 단어 임베딩 연구가 현대 자연어 처리 시스템의 필수적인 요소이며, 처음부터 학습하는 것보다 사전 학습된 벡터를 사용하는 것이 성능 향상에 크게 기여했음을 명시함
- **ELMo**와 같이 문맥에 민감한 특징을 추출하는 Feature-based 방식이 주요 벤치마크에서 성과를 냈으나, 이는 독립적으로 학습된 좌향 및 우향 모델의 결과를 단순히 얕게 결합한 형태라고 분석함
- **OpenAI GPT**와 같은 Fine-tuning 방식이 레이블이 없는 텍스트로부터 사전 학습하여 많은 문장 단위 태스크에서 최고 기록을 경신했음을 인정함
- 하지만 기존의 Fine-tuning 모델들이 표준적인 단방향 언어 모델링 구조를 사용하고 있어, 하위 태스크 적용 시 구조적 선택지가 제한된다는 한계를 지적함

2) 제안 방법의 차별성

- ELMo나 GPT와 달리 모든 레이어에서 왼쪽과 오른쪽 문맥을 동시에 결합하여 깊은 양방향(Deep bidirectional) 표현을 학습함을 가장 큰 차별점으로 내세움
- 단방향 제약을 극복하기 위해 클로즈 태스크에서 영감을 얻은 Masked LM 목적 함수를 도입하여, 모델이 자기 자신을 참조하는 문제 없이 양방향 문맥을 융합할 수 있게 함

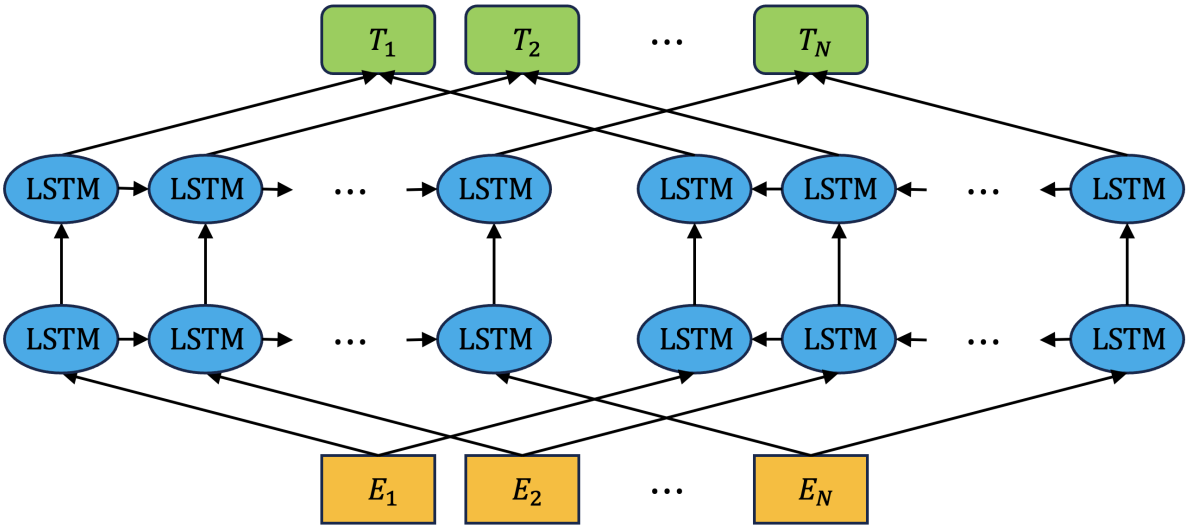

- 특정 태스크를 위해 복잡하고 정교하게 설계된 전용 아키텍처의 필요성을 줄이고, 단일한 사전 학습 모델에 최소한의 레이어만 추가하여 문장 및 토큰 단위의 다양한 태스크를 모두 해결하는 범용성을 입증함
- 기존 연구들이 문장 임베딩만을 전이하거나 특정 특징만을 사용했던 것과 대조적으로, 사전 학습된 모든 파라미터를 초기값으로 사용하여 전체 모델을 미세 조정하는 통합 프레임워크를 확립함

3. 제안 방법론

Main Idea

- **Model Architecture**
  : 범용적으로 쓰이는 Multi-layer bidirectional Transformer encoder 구조를 그대로 사용
- **Input Representation**
  : 하나의 시퀀스 안에 단일 문장 또는 두 문장(예: 질문-답변 쌍)을 모두 담을 수 있도록 설계됨.
- 토큰 임베딩(Token), 세그먼트 임베딩(Segment), 위치 임베딩(Position)의 합
- 시퀀스 첫 시작은 항상 분류용 특수 토큰인 `[CLS]`를 사용하고, 두 문장을 구분할 때는 `[SEP]` 토큰을 사용함.

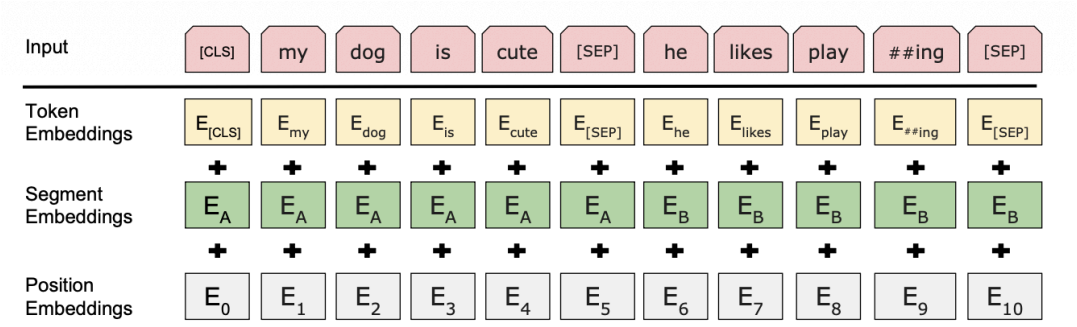

- **사전 학습 태스크 1: Masked LM (MLM)**
  양방향 문맥을 융합하기 위해 입력 토큰의 15%를 무작위로 마스킹하고, 이를 예측하도록 모델을 학습시킴.
  - Pre-training과 Fine-tuning 사이의 환경 불일치(Mismatch)를 줄이기 위해, 선택된 15% 중 80%만 `[MASK]`로 바꾸고, 10%는 무작위 단어로, 나머지 10%는 원래 단어 그대로 유지하는 정교한 전략을 씀.

- **사전 학습 태스크 2: Next Sentence Prediction (NSP)**
  문장 간의 의미적 관계를 학습하기 위해 도입함. 문장 A와 B가 주어졌을 때, 50%는 실제 이어지는 문장(IsNext)으로, 50%는 무작위로 추출된 엉뚱한 문장(NotNext)으로 구성하여 이를 이진 분류로 맞추게 함.

- **Fine-tuning**
  구조 변경 거의 없이, 사전 학습된 모델 파라미터를 그대로 가져와 각 다운스트림 태스크의 목적에 맞게 입출력을 세팅한 후 전체 파라미터를 가볍게 다시 학습시킴.

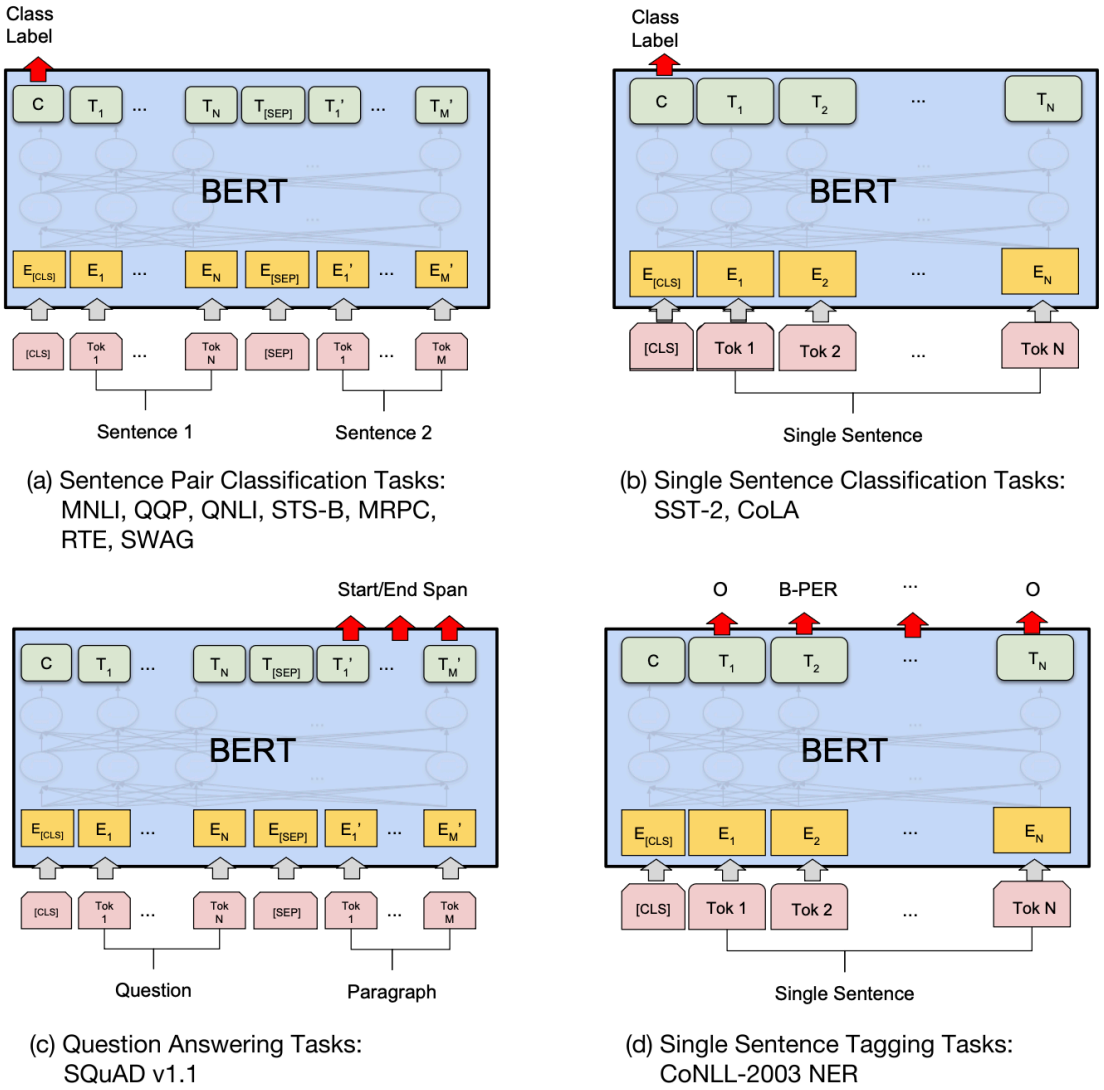

(a) Sentence Pair Classification Tasks: MNLI, QQP, QNLI, STS-B, MRPC, RTE, SWAG

(b) Single Sentence Classification Tasks: SST-2, CoLA

(c) Question Answering Tasks: SQuAD v1.1

(d) Single Sentence Tagging Tasks: CoNLL-2003 NER

Contribution

- 단방향 모델의 한계를 극복하고 양방향 문맥을 통합적으로 고려하는 표현을 학습할 수 있도록 Masked LM 목적 함수를 제안함
- 문장 간의 관계를 파악하는 능력을 향상시키기 위해 Next Sentence Prediction 태스크를 사전 학습 과정에 도입함

- 태스크별 특화 아키텍처를 설계할 필요 없이, 사전 학습된 단일 모델에 출력 레이어 하나만 추가하는 Fine-tuning 방식을 통해 여러 다운스트림 태스크에 적용 가능한 범용성을 입증함
- GLUE, SQuAD 등 11개의 주요 자연어 처리 벤치마크 태스크에서 기존 모델들을 뛰어넘는 SOTA 성능을 달성함

4. 실험 및 결과

Dataset

- **GLUE 벤치마크**
  자연어 추론, 감성 분석, 의미적 유사도 등 9개의 다양한 문장 및 문장 쌍 분류 태스크로 구성된 데이터셋 (MNLI, QQP, QNLI, SST-2, CoLA, STS-B, MRPC, RTE 등)
- **SQuAD v1.1 및 v2.0**
  위키피디아 기반의 대규모 질의응답 데이터셋으로, v2.0은 문서 내에 정답이 존재하지 않는 질문까지 포함하여 난이도를 높임
- **SWAG**
  상식 기반의 문장 완성 추론 능력을 평가하는 대규모 데이터셋

Baseline

- **GLUE:** OpenAI GPT, BiLSTM+ELMo+Attn 등 기존 최고 성능(SOTA) 모델
- **SQuAD:** 리더보드 최상위 앙상블 모델들 및 BiDAF+ELMo 등 출판된 기존 최고 성능 모델
- **SWAG:** ESIM+ELMo, OpenAI GPT 등

결과

- **GLUE**

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	**Average** -
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.8	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	82.3	56.0	75.1
$\text{BERT}_{\text{BASE}}$	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
$\text{BERT}_{\text{LARGE}}$	**86.7/85.9**	**72.1**	**92.7**	**94.9**	**60.5**	**86.5**	**89.3**	**70.1**	**82.1**

- **SQuAD v1.1**
  단일 BERT 모델만으로도 기존 최고 성능의 앙상블 모델을 뛰어넘는 F1 점수를 기록하

였으며, 앙상블 적용 시 93.2 F1 점수로 1.5점의 절대적 성능 향상을 달성함.

- **SQuAD v2.0**
  정답이 없는 까다로운 조건에서도 이전 최고 시스템 대비 5.1점 상승한 83.1 F1 점수를 기록함.

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	-	-	82.3	91.2
#1 Ensemble - nlnet	-	-	86.0	91.7
#2 Ensemble - QANet	-	-	84.5	90.5
Published				
BiDAF+ELMo (Single)	-	85.6	-	85.8
R.M. Reader (Ensemble)	81.2	87.9	82.3	88.5
Ours				
$\text{BERT}_{\text{BASE}}$ (Single)	80.8	88.5	-	-
$\text{BERT}_{\text{LARGE}}$ (Single)	84.1	90.9	-	-
$\text{BERT}_{\text{LARGE}}$ (Ensemble)	85.8	91.8	-	-
$\text{BERT}_{\text{LARGE}}$ (Sgl.+TriviaQA)	**84.2**	**91.1**	**85.1**	**91.8**
$\text{BERT}_{\text{LARGE}}$ (Ens.+TriviaQA)	**86.2**	**92.2**	**87.4**	**93.2**

Table 2: SQuAD 1.1 results. The BERT ensemble is 7x systems which use different pre-training checkpoints and fine-tuning seeds.

System	Dev		Test	
	EM	F1	EM	F1
Top Leaderboard Systems (Dec 10th, 2018)				
Human	86.3	89.0	86.9	89.5
#1 Single - MIR-MRC (F-Net)	-	-	74.8	78.0
#2 Single - nlnet	-	-	74.2	77.1
Published				
unet (Ensemble)	-	-	71.4	74.9
SLQA+ (Single)	-		71.4	74.4
Ours				
$\text{BERT}_{\text{LARGE}}$ (Single)	78.7	81.9	80.0	83.1

Table 3: SQuAD 2.0 results. We exclude entries that use BERT as one of their components.

- **SWAG**
  BERT LARGE가 저자들의 베이스라인 모델을 27.1%, OpenAI GPT를 8.3% 차이로 크게 뛰어넘으며 상식 기반 추론 영역에서도 최고 성능을 달성함.

⇒ 11개의 주요 자연어 처리 벤치마크에서 모두 새로운 최고 성능을 경신함. 태스크별로 아키텍처를 대대적으로 수정할 필요 없이 파라미터 미세 조정만으로도 압도적인 범용성과 성능을 확보한다는 서론의 주장을 완벽하게 입증함.

5. 결론 (배운점)

1) 연구의 의의

- 언어 모델 사전 학습에 깊은 양방향 아키텍처를 성공적으로 도입하여, 문맥을 온전히 파악하지 못하던 기존 단방향 모델들의 근본적인 구조적 한계를 완벽히 극복함
- 복잡한 태스크별 맞춤형 네트워크를 일일이 설계할 필요 없이, 단일 모델의 가벼운 미세 조정만으로 광범위한 자연어 처리 문제에서 압도적인 최고 성능을 낼 수 있는 새로운 표준 패러다임을 확립함

2) 연구의 한계점

- 사전 학습 과정에서는 입력에 마스킹 기호인 `[MASK]` 토큰을 사용하지만, 실제 다운스트림 태스크에 적용할 때는 해당 토큰이 전혀 등장하지 않아 두 단계 간의 환경 불일치

(Mismatch) 문제가 여전히 일부 존재함

- 문장 내 모든 단어를 순서대로 예측하는 기존 언어 모델과 달리, 한 배치 내에서 15%의 마스킹된 일부 토큰에 대해서만 예측을 수행하므로 모델이 수렴하기까지 상대적으로 더 많은 학습 단계와 시간이 요구됨

3) 배운 점

- 인공지능의 성능을 높이기 위해 모델의 레이어를 무작정 깊게 쌓거나 복잡한 수식을 고안하는 것만큼이나, 빈칸 채우기나 다음 문장 맞추기처럼 모델이 데이터의 맥락을 깊게 파악할 수밖에 없도록 유도하는 창의적인 '학습 방법론'의 설계가 매우 중요함을 깨달음
- 자연어 처리 분야의 트렌드가 문제마다 모델을 밑바닥부터 새로 짜는 방식에서, 거대한 범용 모델 하나를 잘 학습시킨 뒤 이를 다양한 곳에 재사용하는 전이 학습 패러다임으로 완전히 넘어왔음을 명확히 체감함

4) 아쉬운 점

- 모델의 성능이 결국 방대한 데이터의 양과 막대한 컴퓨팅 자원(TPU 64개로 4일 연속 학습)에 절대적으로 의존하고 있어, 학부생 수준에서는 이러한 거대 모델을 처음부터 직접 학습시켜보고 실험하기 어렵다는 현실적인 진입 장벽이 크게 느껴짐
- 성능 면에서는 압도적이지만 3억 개가 넘는 파라미터가 정확히 어떤 근거와 맥락으로 단어의 의미를 파악하고 정답을 도출해냈는지, 그 내부 연산 과정을 인간이 직관적으로 해석하기 어려운 전형적인 블랙박스 모델이라는 점이 아쉬움