Improving Language Understanding by Generative Pre-Training

type	예습과제
week	week6

▼ **Terminology**

1. Dense Connectivity : 네트워크 내 모든 층을 후속하는 모든 층과 직접 연결하는 패턴으로, L개 층을 가진 네트워크에서 총 $\frac{L(L+1)}{2}$개의 직접적인 연결을 형성함.

2. Feature Reuse : 이전 층에서 생성된 feature-maps을 다시 학습하지 않고 후속 층의 입력으로 직접 활용하여 파라미터 효율성을 극대화

3. Concatenation : ResNet의 summation 방식과 달리, 이전 층들의 특징 맵을 채널 방향으로 concatenating 방식을 사용하여 정보의 손실 없이 전달

4. Growth Rate : 각 층이 생성하는 특징 맵의 개수를 의미하는 하이퍼파라미터로, 각 레이어가 전체 global state에 얼마나 많은 새로운 정보를 기여할지 조절

5. Collective Knowledge : 특정 블록 내의 모든 레이어가 이전의 모든 특징 맵에 접근할 수 있게 됨으로써 형성되는 네트워크 전반의 공통된 정보 상태

1. Introduction

💡 논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

Generative Pre-Training

- 대규모 Label 미지정 텍스트를 활용한 Generative Pre-training과 특정 Task에 맞춘 Discriminative Fine-tuning을 결합한 Semi-supervised Learning 프레임워크

해당 task에서 기존 연구 한계점

Labeled Data의 부족: 대량의 Unlabeled 데이터는 풍부하나, 특정 Task를 위한 정교한 Labeled 데이터는 매우 희소하여 모델 학습에 한계가 있음

최적의 Objective 및 Transfer 방식 부재: 어떤 Optimization Objectives가 전이에 유용한 표현을 학습하는지 불명확하며, 학습된 표현을 Target Task로 전이하는 효과적인 방법에 대한 합의가 없음

Task-specific 아키텍처 의존: 기존 방식들은 전이 학습 시 모델 구조에 복잡한 수정을 가하거나 정교한 학습 스키마를 요구함

논문의 contributions

Universal Representation 학습: 최소한의 수정만으로 다양한 Task에 적용 가능한 범용적인 표현을 학습함

Transformer 아키텍처 활용: RNN 계열보다 구조적인 메모리를 제공하는 Transformer를 사용하여 텍스트 내 Long-term dependencies을 효과적으로 캡처함

Task-aware Input Transformation: Fine-tuning 시 아키텍처 변경을 최소화하기 위해 입력 데이터를 Traversal-style로 변환하는 방식을 제안함

2. Related Work

💡 Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

기존 연구 서술: 초기 Semi-supervised 방식들이 주로 Word-level이나 Phrase-level의 통계치 및 Embedding 전이에 집중했음을 명시함

제안 방법의 차별성: 단순히 단어 수준 정보를 넘어 문장 수준 이상의 고차원적 Semantics를 캡처하고자 하며, LSTM 기반 모델의 짧은 예측 범위 한계를 Transformer를 통해 극복함

Architecture 효율성: 기존 방식들 이 각 Task마다 새로운 파라미터를 대량으로 추가했던 것과 달리, 최소한의 아키텍처 변화만으로 전이가 가능함을 강조함

3. 제안 방법론

💡 Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

Two-stage Training: 대규모 코퍼스에서의 Unsupervised Pre-training 단계와 특정 데이터셋에서의 Supervised Fine-tuning 단계로 구성됨

Standard Language Modeling: 입력 토큰 시퀀스에 대해 이전 토큰들이 주어졌을 때 다음 토큰의 로그 확률을 최대화하도록 학습함

Task-specific Input Transformations: Classification, Entailment, Similarity 등 서로 다른 Task의 입력을 Delimiter($)를 사용하여 하나의 연속된 시퀀스로 변환하여 처리함

Contribution

Auxiliary Objective: Fine-tuning 시 Language Modeling을 보조 목적 함수로 추가하여 모델의 일반화 성능을 높이고 수렴을 가속화함

Transformer Decoder 구조: 12개의 Layer와 Masked Self-attention을 사용하는 Decoder-only 구조를 채택하여 성능을 최적화함

4. 실험 및 결과

💡 Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

Pre-training: 7,000권 이상의 다양한 장르의 도서가 포함된 BooksCorpus→장거리 문맥학습

Fine-tuning: GLUE 벤치마크, RACE, MultiNLI 등 총 12개의 다양한 NLP 데이터셋

Baseline

ELMo, CoVE: BiLSTM 기반의 사전 학습 모델들

Multi-task BiLSTM: 각 Task별로 최적화된 기존 SOTA 모델들과 성능 비교

결과

SOTA 달성: 테스트한 12개 Task 중 9개에서 기존 성능을 경신하였으며, 특히 Commonsense Reasoning(8.9%↑), QA(5.7%↑) 등에서 큰 폭의 향상

Zero-shot 능력: Supervised Fine-tuning 없이도 Pre-training만으로 다양한 언어적 과제를 수행할 수 있는 능력을 갖추고 있음을 증명

Ablation Study: Transformer 대신 LSTM을 사용하거나 Pre-training을 생략할 경우 성능이 크게 저하됨을 확인하여 각 구성 요소의 중요성을 검증

5. 결론 (배운점)

💡 연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- 의의 : 단일 Task-agnostic 모델이 Generative Pre-training을 통해 충분한 세계 지식을 습득하고 이를 다양한 Task로 성공적으로 전이할 수 있음을 입증
- 인상깊은 점 : 연속된 텍스트 데이터를 활용하여 장거리 의존성 문제를 해결
- 한계 : 소규모 데이터셋에서의 낮은 성능, Pre-training 목적 함수에 대한 탐구 필요

6. Densely Connected Convolution Network Intro review

논문이 다루는 분야

DenseNet: CV의 Visual Object Recognition을 위한 조밀하게 연결된 CNN 아키텍처

해당 task에서 기존 연구 한계점

심층 신경망의 정보 소실 문제: 네트워크가 깊어짐에 따라 입력 정보나 gradient가 많은 층을 통과하며 소실되거나 희석되는 문제가 발생

불필요한 파라미터 중복: 전통적인 feedforward 구조는 이전 층의 정보를 보존하면서도 새로운 상태를 써야 하므로, 학습할 필요가 없는 중복된 feature-maps을 재학습하게 되어 params 수가 상당히 많아짐

기존 대안(ResNet 등)의 결합 방식: ResNet은 skip-connection을 통해 정보 흐름을 개선

하려 했으나, 특징들을 summation 방식으로 결합하여 네트워크 내의 정보 흐름을 방해할 가능성이 있음.

논문의 contributions

DenseNet의 제안

- **Dense Connectivity**: 모든 층을 후속하는 모든 층과 직접 연결하는 방식을 제안하여 네트워크 내 정보 흐름을 극대화

- **Feature Reuse을 통한 효율성**: 이전 층의 특징 맵을 덧셈이 아닌 connection 방식으로 결합하여, 중복된 특징 학습을 방지하고 훨씬 적은 파라미터로도 SOTA

- **경량화된 아키텍처 및 강력한 성능**: 레이어를 매우 좁게(ex : 레이어당 12개 필터) 설계함으로써 파라미터 효율성을 높였으며, CIFAR-10/100, SVHN, ImageNet 등 주요 벤치마크에서 기존 SOTA를 능가하는 성과를 거둠

- **학습 용이성 및 규제 효과**: 각 층이 손실 함수와 원본 입력 신호에 직접 접근할 수 있어 학습이 쉬워지며, 작은 데이터셋에서도 overfitting을 줄이는 규제 효과를 보임.