Densely Connected Convolutional Networks

날짜	2026년 4월 13일
다중 선택	CV

Paper Review

Densely Connected Convolutional Networks

Recent work has shown that convolutional networks can be substantially deeper, more accurate, and efficient to train if they contain shorter connections between layers close to the input and those...

https://arxiv.org/abs/1608.06993

Keyword : Image Classification, Dense Connectivity

1. Introduction

논문이 다루는 분야

Visual Object Recognition

- Image Classification을 중심으로 한 컴퓨터 비전 영역 태스크를 다룸
- CNN이 시각적 객체 인식 분야에서 지배적인 접근법
  - 도입된 지는 20년이 넘었지만, 하드웨어와 네트워크 구조가 최근 개선되며 매우 깊은 CNN 학습이 가능해짐

해당 task에서 기존 연구 한계점

- CNN이 깊어질수록 새로운 문제가 등장 → **Vanishing gradient**
  - 입력 정보나 gradient가 여러 레이어를 통과하면서 희미해지거나 씻겨 나가는 현상이 발생
  - **최근 연구 :** ResNets, Highway Networks (identity connection), Stochastic Depth (학습 중 layer 랜덤 제거), FractalNets (서로 다른 개수의 CNN 블록을 가진 layer를 병렬로 결합)

    → **공통점** : 초기 레이어와 나중 레이어 사이의 짧은 경로를 만드는 것

논문의 contributions

- **DenseNet 핵심 아이디어**

> 레이어 간 최대한의 정보 흐름을 보장하기 위해, **모든 layer를 서로 직접 연결**한다.

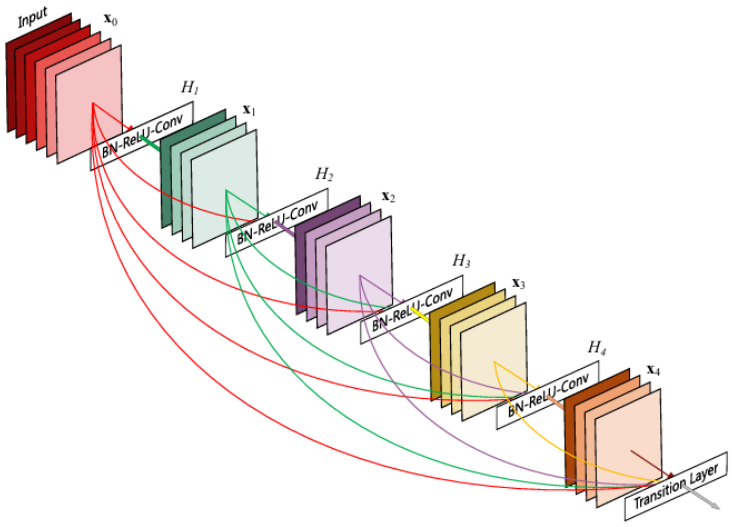

- ResNet과의 차이 : feature를 합산(summation)하는 대신 연결(concatenation)함
- L개의 레이어로 이루어진 신경망의 경우,
  l번째 레이어는 이전 모든 레이어의 feature-map을 입력으로 받아 총 l 개의 입력을 가지며,
  l번째 레이어의 feature-map은 이후 모든 레이어의 입력으로 쓰여 총 $L-l$ 개의 레이어의 입력이 됨

  → 기존의 L개 대신 $\frac{L(L+1)}{2}$**개의 connection**이 생성됨

- **DenseNet의 장점**
  - **적은 파라미터 수**
    기존 feed-forward 방식은 이전 레이어의 상태를 읽고 다음 layer에 전달하는 구조로, 상태를 바꾸는 것뿐만 아니라 정보를 보존하는 것도 중요하다. ResNet은 보존을 위해 identity 방식을 사용하는데, 이때 레이어가 가중치를 가지기 때문에 파라미터 수가 매우 크다.
    반면에, DenseNet은 소수의 feature-map만 collective knowledge에 새로 추가하고 나머지는 그대로 유지하기 때문에 불필요한 featue-map 재학습을 수행하지 않아도 된다.
  - **Gradient를 효과적으로 전달**
    각 레이어가 손실 함수의 gradient와 입력에 직접 접근할 수 있어, 네트워크 전반의 정보와 gradient의 흐름이 개선된다. 이는 implicit deep supervision 효과를 만들어내어 더 깊은 네트워크 구조도 학습하기 쉽게 만든다.
  - **Regularization 효과**
    Dense connection은 regularization 역할을 하여, 학습 데이터셋의 크기가 작은 태스크에서 overfitting을 감소시킨다.
- **성과**
  - CIFAR-10, CIFAR-100, SVHN, ImageNet 4개의 객체 인식 벤치마크에서 더 적은 파라미터로 기존 알고리즘과 비슷한 정확도를 보였으며, 대부분의 벤치마크에서 SOTA를 달성함

2. Related Work

- Cascade structure는 1980년대부터 신경망 분야에서 연구되어 왔는데, fully connected MLP에 cascade를 도입하여 layer-by-layer로 학습하는 방식이었음
- CNN에서 skip-connection을 통해 multi-level feature를 활용하는 것이 다양한 비전 태스크에서 효과적임이 밝혀짐

Depth 관련 모델)

- **Highway Networks** : gating unit이 결합된 shortcut connection으로 100개 이상의 레이어를 가진 신경망을 효과적으로 학습 가능하게 한 최초의 방식 중 하나
- **ResNets** : identity mapping을 bypass path로 사용하는 구조로 image recognition, localization, detection 태스크에서 SOTA 성능을 달성함
- **Stochastic Depth** : 학습 시 ResNet의 레이어를 랜덤으로 제거하는 모델로 1202-layer ResNet을 성공적으로 학습하는 방법으로 제시됨. 모든 레이어가 필요하지 않을 수 있음을 보여주며, DenseNet 연구에도 부분적으로 영감을 줌
- **ResNets with pre-activation** : 1000개 이상의 레이어를 가진 SOTA 모델을 학습하기 용이하도록 함

Width 관련 모델)

- **GoogLeNet** : 다양한 크기의 filter로 생성된 feature-map을 concatenation하는 Inception module을 사용하여 신경망의 너비를 넓힌 모델
- **Variant of ResNets with wide generalized residual blocks**
- **FractalNet**

DenseNet의 차별점)

- 깊이나 너비를 확장해 표현력을 끌어내는 대신에, feature를 재사용하는 구조
- ResNet과 달리 서로 다른 레이어에서 학습한 feature-map을 concat하는 방식을 사용하여 다음 레이어 입력의 다양성을 높이고 효율성을 개선함
- Inception 신경망도 concat 방식을 사용하지만 DenseNet이 더 간단하고 효율적임

그 외 주목할만 한 모델)

- **Network in Network(NIN)** : 복잡한 특징을 추출하기 위해 conv 레이어의 필터에 micro MLP를 포함한 구조
- **Deeply Supervised Network(DSN)** : 내부 레이어에 classifier를 붙여 직접 학습하며, 초기 레이어에서 받는 gradient를 강화
- **Ladder Networks** : autoencoder에 lateral connection을 도입
- **Deeply-Fused Nets(DFNs)** : 서로 다른 base 신경망의 중간 레이어를 결합하여 정보 흐름을 개선

3. 제안 방법론

Method

가정) 단일 이미지 x_0가 L개의 layer로 이루어진 convolutional network를 통과하는 상황을 가정. 각 layer는 비선형 변환 $H_\ell(\cdot)$을 수행하며, 이는 BN, ReLU, Pooling, Conv 등의 복합 함수일 수 있음.

ResNets

- **기존 CNN :** 각 layer의 출력이 다음 layer의 입력으로 전달됨

$$x_\ell = H_\ell(x_{\ell-1})$$

- **ResNet**
  - **Identity function**을 통한 skip-connection 추가
  - 나중 레이어에서 이전 레이어로 직접 gradient를 전달 가능하지만, **합산**하는 방식이 정보 흐름을 방해할 수 있음

$$x_\ell = H_\ell(x_{\ell-1}) + x_{\ell-1}$$

Dense Connectivity

- Connectivity pattern : 각 레이어를 이후에 오는 모든 레이어와 직접 연결
- ℓ 번째 레이어의 입력 :

$$x_\ell = H_\ell([x_0, x_1, \ldots, x_{\ell-1}])$$

여기서 $[x_0, x_1, \ldots, x_{\ell-1}]$는 0번부터 $\ell - 1$번 레이어까지의 feature-map을 **concatenation**한 것

→ 이러한 dense connectivity 때문에 DenseNet이라 함

Composite Function

$H_\ell(\cdot)$은 다음 세 연산의 복합 함수로 정의됨 (pre-activation 방식)

1. **Batch Normalization (BN)**
2. **Rectified Linear Unit (ReLU)**
3. **3×3 Convolution (Conv)**

Pooling Layers

- CNN에서 down-sampling은 필수적이지만, feature-map 크기가 달라지면 concatenation이 불가능함
- **Dense Block :** down-sampling이 용이하도록 신경망을 여러 개의 **Dense Block**으로 분할
- **Transition Layer :** 블록 사이의 레이어를 의미하며 convolution과 pooling을 수행
  - 레이어 구성 : BN → 1×1 Conv → 2×2 Average Pooling

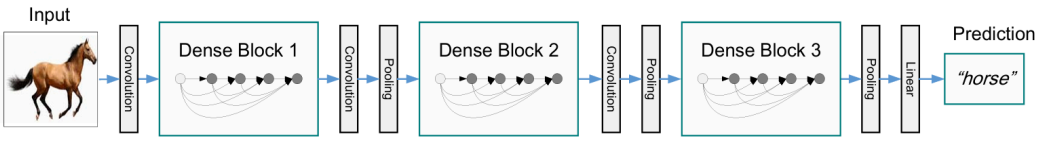

Growth Rate

- H_ℓ 함수가 k개의 feature-map을 출력한다고 할 때, ℓ 번째 레이어의 입력 feature-map 수 :

$$k_0 + k \times (\ell - 1)$$

  - k_0 : 입력 layer의 채널 수

  → 여기서 하이퍼파라미터 k를 **growth rate**라 부름

- DenseNet은 매우 좁은 레이어($k = 12$ 수준)로도 SOTA 성능을 달성함
  - 각 layer가 블록 내 이전 모든 feature-map에 접근하여 collective knowledge를 가지기 때문
  - Growth rate는 각 레이어가 전체 global state에 얼마나 새로운 정보를 기여하는지를 조절

Bottleneck Layers

- 각 레이어의 입력 feature-map 수가 많기 때문에 3×3 Conv 이전에 **1×1 Conv**를 **bottleneck** 레이어로 도입하여 3x3 Conv의 입력 수를 줄이고 계산 효율을 높임
- H_ℓ 구성 : **BN → ReLU → Conv(1×1) → BN → ReLU → Conv(3×3)**
- 1×1 Conv는 $4k$개의 feature-map을 생성하도록 설정

→ Bottleneck layer를 적용한 버전을 **DenseNet-B**라 부름

Compression

- 모델 압축을 위해 transition layer에서 feature-map 수를 줄일 수 있음
- Dense block이 m개의 feature-map을 가지면, transition layer는 $\lfloor \theta m \rfloor$개를 출력 ($0 < \theta \leq 1$: compression factor)

→ $\theta < 1$인 모델을 **DenseNet-C**라 부르며, 논문에서는 $\theta = 0.5$로 설정

→ Bottleneck + Compression 둘 다 사용하는 모델을 **DenseNet-BC**라 부름

4. 실험 및 결과

Dataset

CIFAR

- **CIFAR-10 (C10)** : 32×32 컬러 이미지, 10개 클래스
- **CIFAR-100 (C100)** : 32×32 컬러 이미지, 100개 클래스
- **Train** : 50,000장 (Validation 5,000장 포함) / **Test** : 10,000장
- **데이터 증강** : 해당 데이터셋에서 널리 사용되는 mirroring/shifting 적용
  - 데이터 증강을 적용한 모델에는 "**+**" 표기 (e.g., C10+)
- **전처리** : 채널의 평균과 표준편차로 표준화
- 마지막에는 학습 데이터 50,000장을 모두 사용해서 학습하여 최종 test error 기록

SVHN (Street View House Numbers)

- 32×32 컬러 숫자 이미지
- **Train** : 73,257장 + 추가 531,131장 (Validation 6,000장 포함) / **Test :** 26,032장
- **데이터 증강 :** 없음
- **전처리** : 픽셀값을 255로 나눠 [0, 1]로 정규화
- 학습 과정에서 가장 작은 validation error를 보인 모델을 선택하여 최종 test error 기록

ImageNet

- ILSVRC 2012 classification 데이터셋 : 1,000개 클래스
- **Train** : 120만 장 / **Validation** : 50,000장
- **데이터 증강** : 학습 시 데이터 증강 적용, 테스트 시 224×224로 single-crop 또는 10-crop
- Validation set에 대해 classification error 기록

Training

설정	CIFAR & SVHN	ImageNet
Optimizer	SGD	SGD
Batch size	64	256
Epochs	300 (CIFAR) / 40 (SVHN)	90
초기 Learning rate	0.1	0.1

설정	CIFAR & SVHN	ImageNet
LR decay	전체 epoch의 50%, 75% 시점에 ÷10	epoch 30, 60에 ÷10
Weight decay	10^{-4}	10^{-4}
Momentum	0.9 (Nesterov)	0.9 (Nesterov)
Dropout	0.2 (데이터 증강 없는 경우 처음을 제외한 각 conv layer에 추가)	-

결과

Classification Results on CIFAR and SVHN

Method	Depth	Params	C10	C10+	C100	C100+	SVHN
Network in Network [22]	-	-	10.41	8.81	35.68	-	2.35
All-CNN [32]	-	-	9.08	7.25	-	33.71	-
Deeply Supervised Net [20]	-	-	9.69	7.97	-	34.57	1.92
Highway Network [34]	-	-	-	7.72	-	32.39	-
FractalNet [17]	21	38.6M	10.18	5.22	35.34	23.30	2.01
with Dropout/Drop-path	21	38.6M	7.33	4.60	28.20	23.73	1.87
ResNet [11]	110	1.7M	-	6.61	-	-	-
ResNet (reported by [13])	110	1.7M	13.63	6.41	44.74	27.22	2.01
ResNet with Stochastic Depth [13]	110	1.7M	11.66	5.23	37.80	24.58	1.75
	1202	10.2M	-	4.91	-	-	-
Wide ResNet [42]	16	11.0M	-	4.81	-	22.07	-
	28	36.5M	-	4.17	-	20.50	-
with Dropout	16	2.7M	-	-	-	-	1.64
ResNet (pre-activation) [12]	164	1.7M	11.26*	5.46	35.58*	24.33	-
	1001	10.2M	10.56*	4.62	33.47*	22.71	-
DenseNet ($k = 12$)	40	1.0M	**7.00**	5.24	**27.55**	24.42	1.79
DenseNet ($k = 12$)	100	7.0M	**5.77**	**4.10**	**23.79**	**20.20**	1.67
DenseNet ($k = 24$)	100	27.2M	**5.83**	**3.74**	**23.42**	**19.25**	**1.59**
DenseNet-BC ($k = 12$)	100	0.8M	**5.92**	4.51	**24.15**	22.27	1.76
DenseNet-BC ($k = 24$)	250	15.3M	**5.19**	**3.62**	**19.64**	**17.60**	1.74
DenseNet-BC ($k = 40$)	190	25.6M	-	**3.46**	-	**17.18**	-

Table 2. Error rates(%) on CIFAR and SVHN datasets - 기존 SOTA를 능가한 경우 **boldface**, 전체에서 가장 성능이 좋은 경우 blue

Accuracy

- **DenseNet-BC (L=190, k=40)** : 모든 CIFAR 데이터셋에서 기존 SOTA를 일관되게 능가함
  - **Error rate** : C10+에서 **3.46%**, C100+에서 **17.18%** (Wide ResNet 대비 상당히 낮음)
- C10, C100에서 가장 좋은 결과가 FractalNet 대비 약 **30% 낮은 error**를 기록.
- **DenseNet (L=100, k=24) :** SVHN에서 Wide ResNet의 최고 기록을 넘어섬
- **DenseNet-BC (L=250, k=24)** : SVHN에서 더 작은 모델들보다 성능이 낮았는데, 이는 상대적으로 쉬운 태스크에 너무 깊은 신경망이 과적합을 일으킨 것으로 보임

Capacity

- Bottleneck/Compression 없이 L과 k가 증가할수록 성능이 일관되게 향상됨
  - C10+에서 파라미터가 **1.0M** → **7.0M** → **27.2M**으로 증가할수록 error가 **5.24%** → **4.10%** → **3.74%**로 감소함 (C100+에서도 유사하게 나타남)

→ DenseNet이 더 크고 깊은 모델의 표현력을 잘 활용하며, overfitting이나 최적화 어려움이 없음을 의미

Parameter Efficiency

- **DenseNet-BC**가 특히 파라미터 효율이 높음

- 250-layer 모델이 **15.3M 파라미터**만으로 30M+ 파라미터를 가진 FractalNet, Wide ResNet을 능가
- **DenseNet-BC (L=100, k=12, 0.8M 파라미터)**가 1001-layer pre-activation ResNet (10.2M 파라미터)과 유사한 성능 달성 → **90% 적은 파라미터**로 동등한 성능

Overfitting

- 파라미터 효율의 부가 효과로 **overfitting에 덜 취약함**
- 데이터 증강 없는 경우, DenseNet에서 개선 효과가 특히 뚜렷함
  - C10 : **7.33%** → **5.19%** (약 **29%** 상대적 감소)
  - C100: **28.20%** → **19.64%** (약 **30%** 상대적 감소)
- Overfitting 가능성
  - C10에서 k=12 → k=24로 파라미터를 4배 늘렸을 때 error가 5.77% → 5.83%로 소폭 증가
  - DenseNet-BC의 bottleneck과 compression layer가 이러한 overfitting 경향을 억제하는 효과적인 방법으로 보임

Classification Results on ImageNet

- DenseNet-BC를 다양한 깊이와 growth rate로 실험하고 SOTA ResNet과 비교
- 공정한 비교를 위해 전처리나 최적화 세팅 없이, 공개된 ResNet Torch 구현 방법을 그대로 사용하고 모델만 DenseNet-BC로 교체

Model	top-1	top-5
DenseNet-121	25.02 / 23.61	7.71 / 6.66
DenseNet-169	23.80 / 22.08	6.85 / 5.92
DenseNet-201	22.58 / 21.46	6.34 / 5.54
DenseNet-264	22.15 / 20.80	6.12 / 5.29

Table 3. The top-1 and top-5 error rates on the ImageNet validation set

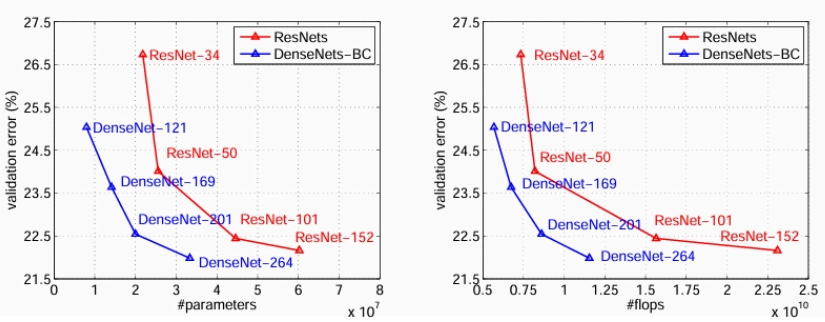

Figure 3. Comparison of the DenseNets and ResNets top-1 error rates on the ImageNet validation dataset as a function of learned parameters (left) and FLOPs during test-time (right)

- DenseNet이 더 적은 파라미터와 계산량으로 동등한 성능을 기록함
  - **Parameters : DenseNet-201 (20M 파라미터) ≈ ResNet-101 (40M+ 파라미터)**
  - **FLOPs :** ResNet-50과 동일한 계산량의 DenseNet이 2배 더 많은 계산량을 요구하는 ResNet-101 수준의 성능 발휘
- 실험에서 사용된 하이퍼파라미터가 ResNet에 최적화된 것이므로, DenseNet 전용 하이퍼파라미터 튜닝 시 추가 성능 향상 가능성 있음

5. 결론

- **DenseNet 제안** : 같은 feature-map 크기를 가진 모든 layer를 직접 연결하는 Dense Convolutional Network를 제안
  - 수백 개의 레이어까지 확장 가능하며, 파라미터 수가 증가해도 성능 하락이나 overfitting 같은 최적화 어려움이 없음
  - 다른 모델에 비해 더 적은 파라미터와 계산량으로 SOTA를 달성
  - Identity mapping, deep supervision, diversified depth의 특성을 자연스럽게 통합하여, feature 재사용이 가능하고 더 작지만 정확한 모델을 생성함
- **Future work :** Convolutional feature 기반의 다양한 컴퓨터 비전 태스크에서 특징 추출에 DenseNet 활용 계획

Improving Language Understanding by Generative Pre-Training

날짜	2026년 4월 13일
다중 선택	NLP

Paper Review

cdn.openai.com
https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf

Keyword : Natural Language Understanding, Generative Pre-Training

1. Introduction

논문이 다루는 분야

Natural Language Understanding (NLU)

- Textual entailment, question answering, semantic similarity, document classification 등 다양한 자연어 이해 태스크를 다룸
- Unlabeled large text corpora는 많지만, 이러한 과제를 학습하기 위한 labeled 데이터는 부족함

해당 task에서 기존 연구 한계점

- NLP에서 지도 학습에 대한 의존도를 완화하기 위해서는 **raw text로부터 효과적으로 학습하는 능력**이 중요함
  - 대부분의 딥러닝 모델은 대량의 manually labeled 데이터를 필요로 하는데, 이는 annotated resource가 부족한 많은 도메인에서의 적용성을 제한함
  - Unlabeled 데이터를 활용할 수 있는 모델은 시간과 비용이 드는 annotation 수집에 대안이 됨
  - 지도 학습 데이터가 충분한 경우에도, 비지도 방식으로 좋은 representation을 학습하면 성능을 크게 향상시킬 수 있음
- Unlabeled text에서 단어 수준 이상의 정보를 활용하는 것은 두 가지 이유로 어려움

  문제점 1) 어떤 최적화 목표가 transfer에 유용한 text representation을 학습하는 데 가장 효과적인지 불분명함
  - Language modeling, machine translation, discourse coherence 등 다양한 목표가 연구되어 왔지만, 태스크마다 서로 다른 방법이 더 좋은 결과를 보임

  문제점 2) 학습된 representation을 target task에 transfer하는 가장 효과적인 방법에 대한 합의가 없음
  - 기존에는 task-specific한 모델 구조 변경, 복잡한 학습 방식 사용, 보조 학습 목표 추가 등의 기법들이 사용되었는데, 이러한 불확실성이 자연어 처리를 위한 효과적인 semi-supervised learning 방식 개발을 어렵게 만들어 왔음

논문의 contributions

- **GPT-1 핵심 아이디어**

  > Unsupervised pre-training과 supervised fine-tuning을 결합한 semi-supervised 방식으로, 다양한 자연어 이해 태스크에 최소한의 수정만으로 transfer 가능한 universal representation을 학습한다.

- **학습 절차**

  1단계 - Unsupervised pre-training : 대규모 unlabeled 데이터에서 language modeling 목표로 신경망의 초기 파라미터를 학습함

  2단계 - Supervised fine-tuning : pre-training된 파라미터를 각 target task에 맞는 목표와 labeled 데이터로 fine-tuning

- **모델 구조 : Transformer**
  - RNN 계열 모델 대비 long-term dependency를 처리하기 위한 더 구조화된 메모리를 제공하여, 다양한 태스크에서 robust한 transfer 성능을 보임
  - Fine-tuning 시 **task-specific input adaptation**을 활용하여, 사전 학습 구조를 최소한으로 변경하고도 효과적으로 fine-tuning 가능

- **성과**
  - Natural language inference, Question answering, Semantic similarity, Text classification 4가지 유형의 NLU 태스크에서 평가
  - Task-agnostic한 단일 모델이 각 태스크에 특화된 구조를 가진 discriminative 모델을 능가하며, 총 12개 태스크 중 9개에서 SOTA 달성
    - Commonsense reasoning (Stories Cloze Test) : **+8.9%**
    - Question answering (RACE) : **+5.7%**
    - Textual entailment (MultiNLI) : **+1.5%**
    - GLUE multi-task benchmark : **+5.5%**
  - Pre-trained 모델의 zero-shot 동작 분석을 통해, 모델이 downstream task에 유용한 언어 지식을 습득함을 확인