6주차 예습과제

📍 Improving Language Understanding by Generative Pre-Training
- 1. Introduction
  - 논문이 다루는 분야
  - 해당 task에서 기존 연구 한계점
  - 논문의 contributions
- 2. Related Work
- 3. 제안 방법론
  - Main Idea
  - Contribution
- 4. 실험 및 결과
  - Dataset
  - Baseline
  - 결과
- 5. 결론 (배운점)

📍 Densely Connected Convolutional Networks
- 1. Introduction
  - 논문이 다루는 분야
  - 해당 task에서 기존 연구 한계점
  - 논문의 contributions

📍 Improving Language Understanding by Generative Pre-Training

1. Introduction

논문이 다루는 분야

자연어 처리에서 raw text로부터 효과적으로 학습하는 능력

- 지도 학습에 대한 의존성 완화에 중요
- 레이블이 지정된 데이터의 부족 → 레이블이 없는 데이터: 사전 훈련된 단어 임베딩의 사용

해당 task에서 기존 연구 한계점

레이블이 없는 텍스트에서 단어 수준 이상의 정보를 활용하는 것의 어려움

1. 전이에 유용한 텍스트 표현을 학습하는 데 가장 효과적인 최적화 목표가 불분명
2. 학습된 표현을 대상 작업으로 전이하는 가장 효과적인 방법 불분명

논문의 contributions

본 논문에서는 **비지도 사전 학습과 지도 미세 조정을 결합**해 **언어 이해 태스크를 위한 준지도 학습 접근 방식**을 탐구

- 광범위한 태스크에 적은 조정으로 전이되는 보편적인 표현을 학습하는 것이 목표

1. 비주석 데이터에 대한 언어 모델링 목표를 사용하여 신경망 모델의 초기 매개변수 학습
2. 해당 지도 목표를 사용해 매개변수를 대상 태크스에 맞게 조정

- 모델 아키텍처로는 Transformer 사용
  - 장기 의존성 텍스트를 처리하기 위한 더 구조화된 메모리 제공
  - 다양한 태스크에 걸친 견고한 전이 성능
- 전이 중에, 구조화된 텍스트 입력을 토큰의 단일 연속 시퀀스로 처리하는 순회 스타일 접근 방식에서 파생된 태스크별 입력 적응 활용
  - 사전 학습된 모델의 아키텍처에 최소한의 변경으로 효과적으로 미세 조정 가능

- 자연어 추론, 질의 응답, 의미론적 유사성, 텍스트 분류의 네 가지 유형의 언어 이해 태스크 평가
  - 각 태스크에 대해 특별히 제작된 아키텍처를 사용하는 판별 학습 모델보다 우수
  - 상식 추론(Stories Clozs Test)에서 8.9%, 질의 응답(RACE)에서 5.7%, 텍스트 함의(MultiNLI)에서 1.5%, GLUE 다중 태스크 벤치마크에서 5.5%의 개선 달성
  - 네 가지 다른 설정에서 사전 학습된 모델의 제로샷 동작을 분석하고, 다운스트림 태스크에 유용한 언어 지식 습득함을 입증함

2. Related Work

NLP를 위한 준지도 학습

- 시퀀스 레이블링, 텍스트 분류와 같은 태스크에 대한 응용
- 초기 접근 방식: 비주석 데이터를 사용해 단어 수준, 구문 수준 통계 계산 → 지도 모델에서 특징으로 사용
- 다양한 태스크에서 성능 향상시키기 위해 비주석 말뭉치에서 훈련된 단어 임베딩의 이점 입증

⇒ 주로 단어 수준 정보를 전이하는 반면, 본 논문은 더 높은 수준의 의미론을 포착하는 것을 목표로 함

- 최근 접근 방식: 비주석 데이터에서 단어 수준 의미론 이상을 학습, 활용
- 비주석 말뭉치를 사용하여 훈련할 수 있는 구문 수준, 문장 수준 임베딩은 다양한 대상 태스크에 대한 적합한 벡터 표현으로 텍스트를 인코딩하는 데 사용됨

비지도 사전 학습

- 지도 학습 목표를 수정하는 대신 좋은 초기화 지점을 찾는 것이 목표인 특수한 준지도 학습
- 초기 연구: 이미지 분류, 회귀 태스크
- 이후 사전 학습이 정규화 기법으로 작용, 심층 신경망에서의 더 나은 일반화 가능함을 입증
- 최근 연구: 이미지 분류, 음성 인식, 개체 모호성 해소, 기계 번역과 같은 다양한 태스크에서 심층 신경망 훈련하는 데 사용
- 본 논문과 유사한 연구 - 언어 모델링 목표를 사용하여 신경망을 사전 학습한 후 지도 학습을 통해 대상 태스크에서 미세 조정 → 텍스트 분류 개선

  ⇒ 본 논문은 LSTM 모델 대신 트랜스포머를 사용함으로서 더 긴 범위의 언어 구조 포착 가능, 더 넓은 범위의 태스크에 대한 효과 입증
- 다른 접근 방식들은 사전 훈련된 언어 또는 기계 번역 모델의 은닉 표현을 보조 특징으로 사용하면서 목표 작업에 대한 지도 학습 모델을 훈련 → 각 목표 작업에 대해 많은 양의 새로운 매개변수를 필요로 함

  ⇒ 본 논문은 전이 시 모델 아키텍처에 최소한의 변경만 필요

보조 훈련 목표

- 보조 비지도 훈련 목표를 추가(준지도 학습의 한 형태)
- 초기 연구: 의미 역 레이블링을 개선하기 위해 품사 태깅, 청킹, 개체명 인식, 언어 모델링과 같은 다양한 보조 NLP 작업 사용
- 최근 연구: 목표 작업의 목표에 보조 언어 모델링 목표를 추가하여 시퀀스 레이블링 작업에서 성능 향상 입증

  ⇒ 본 논문에서도 보조 목표를 사용하지만, 비지도 사현 훈련은 이미 목표 작업과 관련된 여어 언어적 측면을 학습함

3. 제안 방법론

Main Idea

1. 대규모 텍스트 코퍼스에서 고용량 언어 모델 학습
2. 레이블이 지정된 데이터를 사용하여 모델을 판별 작업에 맞추는 미세 조정 수행

비지도 사전 훈련

- 비지도 코퍼스 토큰 U가 주어졌을 때, 다음 likelihood를 최대화 하기 위해 표준 언어 모델링 목표를 사용

$$L_1(\mathcal{U}) = \sum_i \log P(u_i|u_{i-k}, \ldots, u_{i-1}; \Theta)$$

  - k: 컨텍스트 창의 크기
  - 조건부 확률 P는 매개변수 Θ를 가진 신경망을 사용해 모델링
  - 매개변수는 확률적 경사 하강법을 사용해 학습
- 언어 모델로는 multi-layer Transformer decoder를 사용
  - 입력 컨텍스트 토큰에 대한 멀티 헤드 셀프 어텐션 연산을 적용 후, 위치별 feed-forward 레이어를 거쳐 대상 토큰에 대한 출력 분포를 생성

$$\begin{aligned} h_0 &= UW_e + W_p \\ h_l &= \texttt{transformer_block}(h_{l-1}) \forall i \in [1, n] \\ P(u) &= \texttt{softmax}(h_n W_e^T) \end{aligned}$$

  - $U = (u_{-k}, \ldots, u_{-1})$: 토큰의 컨텍스트 벡터
  - n: 레이어 수, W_e: 토큰 임베딩 행렬, W_p: 위치 임베딩 행렬

지도 미세 조정

- 모델을 훈련한 후, 매개변수를 지도 목표 작업에 맞춤
  - 각 인스턴스가 입력 토큰 시퀀스 $x_1, \ldots, x_m$과 레이블 y로 구성된 레이블 데이터셋 C를 가정

- 입력은 사전 훈련된 모델을 통해 전달되어 최종 트랜스포머 블록의 activation h_m^l을 얻고, 이는 y을 예측하기 위해 매개변수 W_y를 가진 추가 선형 출력 레이어로 전달됨

$$P(y|x^1, \ldots, x^m) = \texttt{softmax}(h_l^m W_y).$$

- 이를 통해 다음 목표를 최대화

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y|x^1, \ldots, x^m).$$

- 미세 조정에 언어 모델링을 보조 목표로 포함하는 것은 지도 학습 모델의 일반화를 개선, 수렴을 가속화함으로써 학습에 도움이 됨
  - 다음 목표를 최적화(with weight λ)

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C})$$

- 미세 조정 중에 요구하는 유일한 추가 매개변수는 W_y와 구분자 토큰에 대한 임베딩

태스크별 입력 변환

- 일부 작업의 경우 모델을 직접 미세 조정 가능
  - 질의 응답, 텍스트 함의와 같은 특정 작업들은 순서가 있는 문장 쌍, 또는 문서, 질의, 답변의 삼중항과 같은 구조화된 입력을 가짐
  - 사전 훈련된 모델은 텍스트의 연속적인 시퀀스에 대해 훈련되었기 때문에 이러한 작업에 적용하기 위해서는 약간의 수정이 필요
- 순회 방식(traversal-stlye) 접근 방식을 사용하여, 구조화된 입력을 사전 훈련 모델이 처리할 수 있는 순서가 있는 시퀀스로 변환
  - 이러한 입력 변환을 통해 작업 전반에 걸쳐 아키텍처에 광범위한 변경 가하는 것을 피할 수 있음
  - 모든 변환에는 무작위로 초기화된 시작 및 끝 토큰(<s>, <e>)을 추가하는 것 포함

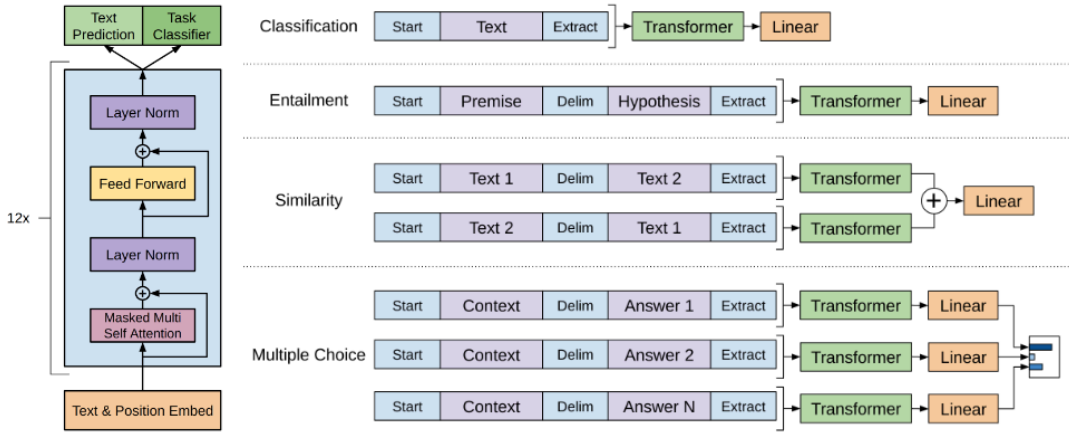

Figure 1: **(left)** Transformer architecture and training objectives used in this work. **(right)** Input transformations for fine-tuning on different tasks. We convert all structured inputs into token sequences to be processed by our pre-trained model, followed by a linear+softmax layer.

- 텍스트 함의 태스크
  - 전제 p와 가설 h 토큰 시퀀스를 구분 토큰($)을 사이에 두고 연결
- 유사도 태스크
  - 비교되는 두 문장 간에 내재된 순서가 없음
  - 따라서 입력 시퀀스를 구분 토큰을 포함한 두 가지 가능한 문장 순서로 구성하도록 수정
  - 각 문장을 독립적으로 처리해 두 개의 시퀀스 표현 h_m과 l을 생성 후, 요소별로 더해 선형 출력 계층에 전달
- 질의 응답 및 상식 추론 태스크
  - 문맥 문서 z, 질의 q, 가능한 답변들의 집합 $\{a_k\}$가 주어짐
  - 문맥 문서와 질의를 각 가능한 답변과 연결하고, 가이에 구분 토큰을 추가해 [z; q; $; a_k;]를 얻음
  - 각 시퀀스는 모델로 독립적으로 처리된 후, 소프트맥스를 통해 정규화되어 가능한 답변들에 대한 출력 분포를 생성함

Contribution

1. **생성적 사전 학습(Generative Pre-training)과 판별적 미세 조정(Discriminative Fine-tuning)을 결합한 프레임워크:**
   - 대규모의 레이블 없는 텍스트 코퍼스로 언어 모델을 먼저 사전 학습(pre-training)하고, 이후 각 특정 다운스트림 작업에 대해 판별적(discriminative)으로 미세 조정(fine-tuning)하는 2단계 학습 절차를 제안

- 레이블이 부족한 NLP 작업에서 성능을 크게 향상시킬 수 있음을 입증

2. **범용적(Task-Agnostic) 모델 및 효과적인 전이 학습(Transfer Learning):**
    - 하나의 범용적인 모델 구조를 사전 학습한 후, 최소한의 아키텍처 변경만으로 다양한 NLP 작업에 적용할 수 있음을 보여줌
    - 사전 학습된 모델이 습득한 언어적 지식과 표현이 다양한 다운스트림 작업으로 효과적으로 전이될 수 있음
3. **Transformer 아키텍처의 활용 및 장기 의존성 포착:**
    - Transformer의 셀프 어텐션 메커니즘을 통해 순환 신경망(RNN)과 같은 이전 모델보다 장기 의존성(long-term dependencies)을 더 잘 처리할 수 있으며, 이는 다양한 작업에서 강력한 전이 성능으로 이어짐
4. **작업 인식적인 입력 변환(Task-aware Input Transformations):**
    - 문장 쌍(예: NLI, 유사도)이나 문서-질문-답변(예: QA)과 같이 구조화된 입력을 사전 학습된 모델이 처리할 수 있는 연속적인 토큰 시퀀스로 변환하는 새로운 방법을 개발
    - 모델 아키텍처를 작업별로 크게 수정할 필요 없이 효과적인 미세 조정이 가능

4. 실험 및 결과

Dataset

- 비지도 사전 학습 (Unsupervised Pre-training)
    - BooksCorpus 데이터셋을 사용하여 언어 모델을 학습
    - 7,000개 이상의 출판되지 않은 다양한 장르의 책을 포함
    - 장문의 연속적인 텍스트를 학습하여 장기 의존성을 파악하는 데 유용
- 지도 미세 조정 (Supervised Fine-tuning) 작업 및 데이터셋
    - 자연어 추론 (Natural Language Inference, NLI): SNLI, MultiNLI, Question NLI, RTE, SciTail
    - 질문 답변 (Question Answering): RACE , Story Cloze
    - 의미 유사성 (Semantic Similarity): MSR Paraphrase Corpus (MRPC), Quora Question Pairs (QQP), STS Benchmark (STS-B)
    - 텍스트 분류 (Classification): Corpus of Linguistic Acceptability (CoLA), Stanford Sentiment Treebank (SST-2)

    - 이 중 일부는 GLUE 다중 작업 벤치마크의 일부로 사용됨

Baseline

- 자연어 추론
    - ESIM + ELMo (앙상블)
    - CAFE (앙상블)
    - Stochastic Answer Network (SAN) (앙상블)
    - CAFE (단일 모델)
    - GenSenMulti-task BiLSTM + Attention
- 질문 답변 및 상식 추론
    - LSGSEM
    - Hidden Coherence Model
    - Dynamic Fusion Net (9-way 앙상블)
    - BiAttention MRU (9-way 앙상블)
- 의미 유사성 및 분류
    - Sparse byte mLSTM
    - TF-KLD
    - ECNU (혼합 앙상블)
    - Single-task BiLSTM + ELMo + Attention
    - Multi-task BiLSTM + ELMo + Attention
- 모델 아키텍처 비교 (Ablation Studies)
    - Transformer 없이 사전 학습: 오직 지도 학습만으로 Transformer 모델을 학습시킨 경우
    - LSTM 사용: Transformer 대신 단일 레이어 LSTM을 사용한 경우
    - 보조 LM(Auxiliary LM) 목적 함수 미사용: 미세 조정 시 보조 언어 모델 목적 함수(L1)를 제외한 경우

결과

- 종합 성능:

    - 평가된 12개 작업 중 9개에서 state-of-the-art 달성
    - 여러 작업에서 앙상블 모델을 능가하는 성능을 보임
- 주요 작업별 성능:
    - 상식 추론에서 8.9%, 질문 답변(RACE)에서 5.7%, 텍스트 함의(MultiNLI)에서 1.5%의 성능 향상
    - GLUE 벤치마크: 72.8점으로 이전 최고 점수(68.9점) 대비 크게 향상
    - 자연어 추론 (NLI): 4개 중 5개 데이터셋에서 이전 최고 기록을 크게 능가했으며, MNLI에서 1.5%, SciTail에서 5%, QNLI에서 5.8%의 향상을 기록
    - 의미 유사성: STS-B에서 1%, QQP에서 4.2%의 성능 향상을 보이며 2개의 데이터셋에서 최고 성능을 달성
    - 분류 (CoLA): 45.4점으로 이전 최고 기록(35.0점) 대비 큰 폭의 향상을 보임
- 모델 및 학습 방식 분석 (Ablation Studies & Analysis):
    - 사전 학습 없이 Transformer를 직접 지도 학습한 모델은 모든 작업에서 성능이 크게 하락하여, 사전 학습이 필수적임을 보여줌 (평균 14.8%p 감소)
    - 동일한 프레임워크에서 Transformer를 LSTM으로 대체했을 때 평균 5.6점의 성능 하락
    - 미세 조정 시 보조 LM 목적 함수를 사용하면 NLI 및 QQP 작업에서 성능이 향상되는 경향을 보였으나, 작은 데이터셋에서는 그 효과가 덜함
    - 사전 학습된 모델의 더 많은 계층을 전이할수록 MultiNLI와 RACE 같은 작업에서 성능이 향상되었으며, 이는 각 계층이 유용한 기능을 학습했음을 보여줌
    - Z사전 학습된 모델이 지도 미세 조정 없이도 다양한 작업 관련 기능을 학습했음을 보여주었으며, Transformer의 귀납적 편향이 LSTM보다 안정적인 zero-shot 성능에 기여함

5. 결론 (배운점)

- **NLP 성능 향상의 새로운 패러다임 제시:** 대규모 레이블 없는 텍스트를 이용한 생성적 사전 학습(Generative Pre-training)과 특정 작업에 대한 판별적 미세 조정(Discriminative Fine-tuning)을 결합하는 2단계 학습 프레임워크통해 레이블이 부족한 NLP 작업에서 성능을 크게 끌어올릴 수 있음을 보여주며 기존의 지도 학습 중심 접근 방식에 대한 강력한 대안을 제시
- **범용 모델 구축 가능성 입증:** 하나의 범용적인(task-agnostic) 모델을 사전 학습하여, 최소한의 아키텍처 수정으로도 다양한 NLP 태스크에 효과적으로 적용할 수 있음을 보

여줌 → 모델 개발 및 적용의 효율성

- **Transformer 아키텍처의 NLU 적용 성공:** Transformer 아키텍처가 기계 번역을 넘어 자연어 이해(NLU) 작업에서도 강력한 성능을 발휘하며, 특히 장기 의존성(long-term dependencies)을 효과적으로 포착하는 데 기여함을 입증
- **사전 학습된 언어 모델의 잠재력 확인:** 사전 학습이 단순한 특징 추출(feature extraction)을 넘어, 모델이 추론, 상식, 문법성 등 고수준의 언어적 지식을 학습할 수 있음을 보여줌
- 이후 대규모 언어 모델(LLM) 연구의 중요한 기반이 된 논문

- **한계점**
  - 대규모 데이터셋으로 Transformer 모델을 사전 학습하는 데 상당한 계산 자원과 시간이 소요될 수 있음
  - 사용된 BooksCorpus는 특정 도메인(출판되지 않은 책)에 편중될 수 있으며, 이는 학습된 지식이 다른 도메인으로 전이될 때 영향을 줄 수 있음
  - 일부 작은 규모의 데이터셋(예: RTE)에서는 모델의 성능이 이전 최고 기록에 미치지 못하는 경우도 관찰됨 → 대규모 사전 학습 효과가 작은 데이터셋에서는 희석될 수 있음

🧐

- 레이블 데이터 부족이라는 NLP의 난제를 대규모 비지도 학습과 효율적인 미세 조정을 결합해 해결한 것이 인상적이었다.
- 단순히 특정 데이터셋(BooksCorpus)에 국한되지 않고, 더욱 포괄적이고 다양한 도메인의 데이터를 학습에 활용한다면 실제 응용 분야에서의 성능이 크게 향상될 것이라는 점을 통해, 이 모델 아키텍처와 접근 방식이 가진 잠재력을 느낄 수 있었다.

📍 Densely Connected Convolutional Networks

1. Introduction

논문이 다루는 분야

합성곱 신경망

- 시각 객체 인식 분야에서 지배적인 머신러닝 접근 방식
- 최근들어 깊은 CNN의 training 가능해짐
  - LeNet5: 5개 층 → VGG: 19개 층 → Highway Networks, ResNets: 100개 층 이상

해당 task에서 기존 연구 한계점

CNN이 점점 깊어짐에 따라 발생하는 문제점

- gradient vanishing
  - 입력에 대한 정보나 기울기가 많은 층을 통과하면서, 네트워크의 끝에 도달할 때는 사라지거나 희석될 수 있음
  - ResNet등의 다양한 접근 방식에서는 초기 층에서 후기 층으로 가는 짧은 경로를 생성함으로 이를 극복

논문의 contributions

본 논문에서는 이러한 인사이트를 단순한 연결 패턴으로 집약하는 아키텍처 제안

- 네트워크 내의 계층 간 최대 정보 흐름을 보장하기 위해 모든 계층을 서로 직접 연결
- 순방향(feed-forward) 특성을 유지하기 위해 각 레이어는 모두 이전 레이어로부터 추가적인 입력을 받고 자신의 특징 맵을 모든 후속 계층으로 전달

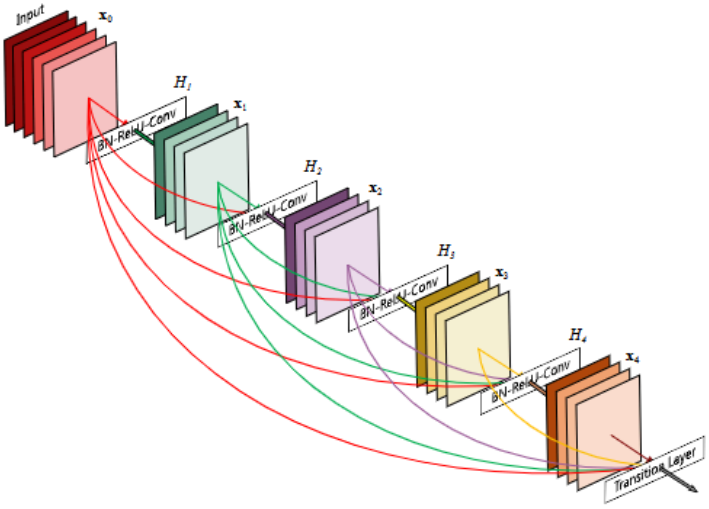

Figure 1: A 5-layer dense block with a growth rate of $k = 4$. Each layer takes all preceding feature-maps as input.

- ResNet과 달리 레이어로 전달되기 전에 합계를 통해 특징 결합 X, **특징을 연결(concatenating)하여 결합**
  - l번째 레이어는 모든 이전 합성곱 블록의 특징 맵으로 구성된 l개의 입력 가짐
  - 자신의 특징 맵은 모든 $L-l$개의 후속 레이어로 전달됨
  - L개의 레이어 네트워크에서 $\frac{L(L+1)}{2}$개의 연결 (기존 구조는 L개의 연결)

- 중복된 특징 맵을 다시 학습할 필요가 없기 때문에 기존 합성곱 신경망보다 더 적은 파라미터를 요구
  - 기존 순방향 구조는 각 레이어가 이전 레이어의 출력을 직접 받아 다음 레이어로 전달하는 방식
  - 이 과정에서 각 레이어는 입력받은 정보를 변형하고, 필요하지 않다고 판단되는 정보를 버리거나 희석시킬 수 있음
  - DenseNet은 각 레이어가 자신보다 이전의 모든 레이어로부터 나온 특징 맵들을 모두 입력으로 받음 → 네트워크 초반에 학습된 특징 맵을 중간이나 후반 레이어에서도 직접 접근하여 재사용될 수 있음

    ⇒ 특정 특징을 다시 학습할 필요 없이 기존의 특징 활용 가능, 모델이 불필요한 정보를 다시 학습하는 데 드는 파라미터 수 줄일 수 있음
- 정보와 기울기의 흐름이 개선되어 훈련이 용이
  - 각 레이어는 손실 함수로부터의 기울기와 원본 입력 신호에 직접 접근 가능 → implicit deep supervision으로 이어져 더 깊은 신경망 아키텍처의 훈련을 도움
  - 밀집된 연결은 정규화 효과를 가짐 → 작은 훈련 데이터셋에서 과적합을 줄임

- DenseNet을 네 개의 벤치마트 데이터셋(CIFAR-10, CIFAR-100, SVHN, ImageNet)에서 평가
  - 비슷한 정확도의 기존 알고리즘보다 훨씬 적은 파라미터 요구하는 경향
  - 대부분의 벤치마크 태스크에서 SOTA를 능가하는 결과