

You Only Look Once: Unified, Real-Time Object Detection

≡ type

▼ Terminology

Inductive bias : the set of underlying assumptions a machine learning model uses to predict outputs for unseen data

Regression : Predicting continuous numerical values (e.g. bounding box coordinates) directly as output, rather than discrete class labels.

Region Proposal : A pre-processing step that generates candidate regions likely to contain objects before classification is applied.

Deformable Parts Models (DPM) : An object detection model that represents objects as a combination of a root filter and several part filters, using a sliding window approach across the image.

Contextual Reasoning : The ability to use global image information to inform predictions, rather than looking at local regions in isolation.

SVM Score : A confidence score produced by a Support Vector Machine classifier, used in R-CNN to determine the class of each proposed region after CNN feature extraction.

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

object detection을 regression 문제로 재정의 → 이미지 전체를 한 번만 보고 bounding box 좌표+class 확률을 동시에 예측하는 unified 모델

해당 task에서 기존 연구 한계점

기존 방법(DPM, R-CNN 계열)은 classifier를 detection에 재활용하는 구조 → 파이프라인이 복잡하고 각 단계를 따로 학습해야함 : 느리고 최적화 어려움

- DPM : sliding window로 classifier를 이미지 전체에 반복 적용
- R-CNN : region proposal → feature 추출 → SVM 분류 → bounding box 보정
다단계 구조 & 이미지당 40초 소요

논문의 contributions

- 단일 CNN으로 bounding box+class 확률을 한 번에 예측 → end-to-end 학습 가능
- base model 45fps, Fast YOLO 155fps → real-time detection 달성
- 이미지 전체를 보고 예측 → background false positive가 Fast R-CNN 대비 절반 이하
- natural image로 학습하고 artwork에서 테스트해도 성능 유지 → 높은 일반화 능력

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- DPM : sliding window 방식, static feature 사용, pipeline 분리 → YOLO는 이를 단일 CNN으로 통합
- R-CNN : Selective Search로 region proposal 생성 후 각 단계 독립 학습 → 복잡하고 느림
- Fast/Faster R-CNN : R-CNN의 속도 개선 시도했지만 real-time엔 여전히 부족 (Faster R-CNN VGG-16 기준 7fps)
- OverFeat : localization 최적화에 초점, global context 못 봄 → post-processing 많이 필요
- MultiBox : bounding box 예측하는 CNN이지만 완전한 detection system이 아님, 추가 분류 단계 필요

⇒ YOLO의 차별성 : 기존의 연구들은 모두 파이프라인의 일부 → YOLO는 파이프라인 자체를 없애고 단일 네트워크로 detection 전체를 처리

- localization error와 classification error를 같은 비중으로 처리하는 문제 → $\lambda_{coord}=5, \lambda_{noobj}=0.5$ 로 보정
- 큰 box와 작은 box의 오차를 동일하게 처리하는 문제 → w, h에 제곱근 적용
- 각 grid cell당 하나의 predictor만 responsible하게 지정 which is IOU 가장 높은

Train method

- ImageNet으로 pretrain(1-20 conv layer), 추후 detection용으로 전환
- lr scheduling
- dropout rate=0.5
- data augmentation : random scaling, translation, HSV 조정

Contribution

- detection을 regression으로 재정의 → 단일 네트워크, end-to-end 학습
- 이미지 전체를 보기 때문에 contextual information 자연스럽게 인코딩
- 구조가 단순해서 새로운 domain에 일반화 잘 됨

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- PASCAL VOC 2007
- VOC 2012

Baseline

Real-Time Detectors	Train
100Hz DPM [31]	2007
30Hz DPM [31]	2007
Fast YOLO	2007+2012
YOLO	2007+2012
Less Than Real-Time	
Fastest DPM [38]	2007
R-CNN Minus R [20]	2007
Fast R-CNN [14]	2007+2012
Faster R-CNN VGG-16[28]	2007+2012
Faster R-CNN ZF [28]	2007+2012
YOLO VGG-16	2007+2012

결과

- Real-time 성능 : Fast YOLO 155fps/52.7mAP, YOLO 45fps/63.4mAP → 기존 real-time detector 대비 mAP 2배 이상
- Error analysis (VOC 2007) : YOLO는 localization error가 주된 약점 (19.0%) / Fast R-CNN은 background error가 주된 약점 (13.6%)
- Fast R-CNN + YOLO 조합 : YOLO로 background detection 걸러내기 → mAP 71.8% → 75.0%로 향상 (+3.2%) / 다른 Fast R-CNN 양상블은 +0.3~0.6%에 그침
- VOC 2012 : YOLO 57.9mAP, Fast R-CNN+YOLO 70.7mAP (리더보드 4위)
- Generalizability : Picasso/People-Art dataset에서 R-CNN은 AP가 급락, YOLO는 유지 → artwork에서도 강건함

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- object detection을 regression으로 바라본다는 발상이 인상적&pipeline을 없어서 속도와 단순함을 동시에 get ㄱㄴ
- Fast R-CNN과의 조합 → 각자의 약점을 상호보완하는게 인상적

한계

- 각 grid cell에서 하나의 class만 예측하면 작은 물체가 밀집한 경우 어떻게 되나.. like troops of sardines
- Sum-squared error의 제곱근으로의 완화 : 근데 작은 박스에서의 오차와 큰 박스에서의 오차가 박스의 크기차이가 점점 커질수록 탐지에 대한 성공 여부가 매우 달라질텐데 → 박스 크기 대비 상대적인 오차를 loss로 표현 못하는듯 ⇒ YOLO의 후의 version을 살펴보는게 좋을 것 같다.

다른 논문 Intro

[IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE]

논문이 다루는 분야

ViT : standard Transformer를 이미지에 직접적으로 적용 with 적은 변형 : 이미지를 patches로 나눠 선형 임베딩 seq에 전달 acts like tokens in NLP.

기존 연구의 한계점

cv에서도 NLP의 성공에서의 영감으로 'CNN like 구조+self att' 형태의 활용으로 현대 hw의 accelerator에서 효과적으로 조정된 최신의 모델이 없음. → 아직도 ResNet이 SOTA.

논문의 contribution

조건 : 충분한 scale에서 pre-trained되고 적은 datapoint task로 옮겨졌을 때 image recognition에서 SOTA