



6. You Only Look Once: Unified, Real-Time Object Detection

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

Contribution

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

1. Introduction


논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

1. Introduction

논문이 다루는 분야



- 컴퓨터 비전 내 Object Detection 분야
- 이미지 전체를 단 한 번만 훑는 방식으로 Bounding Box와 Class Probability를 동시에 예측하는 통합 모델 연구

해당 task에서 기존 연구 한계점

- **분류기 기반 검출의 비효율성**
기존 방식(DPM, R-CNN 등)은 분류기를 이미지의 여러 위치와 스케일에 적용하는 복잡한 파이프라인을 사용하여 속도가 매우 느림
- **최적화의 어려움**
각 구성 요소(영역 제안, 분류, 후처리 등)를 개별적으로 학습시켜야 하므로 전체 시스템을 하나로 통합하여 최적화하기가 구조적으로 불가능함
- **좁은 시야에 따른 배경 오인식**
슬라이딩 윈도우 방식은 특정 영역만 보기 때문에 이미지의 전체 맥락을 파악하지 못하며, 이로 인해 아무것도 없는 배경을 객체로 잘못 인식하는 'False Positive' 오류가 빈번함

논문의 contributions

- **단일 회귀 문제로의 재정의**
객체 검출을 복잡한 분류 단계가 아닌, 픽셀에서 경계 상자 좌표와 클래스 점수를 바로 도출하는 단일 Regression Problem으로 정립함
- **독보적인 실시간 처리 속도**
기본 모델은 초당 45프레임(FPS), 경량화된 Fast YOLO 모델은 초당 155프레임을 기록하여 실시간 동영상 처리가 가능한 수준의 성능을 구현함
- **Global Context 이해**
학습 및 추론 시 이미지 전체를 확인하므로 배경 영역에 대한 오류를 기존 방식(Fast R-CNN 등) 대비 절반 이하로 줄임
- **강력한 일반화 성능**
자연 환경 이미지뿐만 아니라 예술 작품이나 회화 등 새로운 도메인의 데이터에 대해서도 기존 방식들보다 훨씬 뛰어난 범용성을 입증함
- **통합 End-to-End 학습**
하나의 신경망이 전체 검출 파이프라인을 대체하여 모델을 직접 최적화하고 속도와 정확도 사이의 균형을 효과적으로 조절할 수 있게 함

2. Related Work


1) 서론에서 언급한 기존 연구들에 대해 어떻게 서술하는가

- **DPM:**
슬라이딩 윈도우 방식을 사용하며 특징 추출, 영역 분류, 경계 상자 예측 등의 구성 요소가 개별적으로 분리된 복잡한 파이프라인 구조라고 분석함
- **R-CNN:**
영역 제안 방식을 사용하여 정확도는 높였으나, 잠재적 상자 추출, 특징 학습, SVM 분류, 경계 상자 회귀 등이 독립적으로 수행되어 학습과 추론 속도가 매우 느리다는 점을 지적함
- **OverFeat:**
신경망을 활용해 국지화와 검출을 통합하려 시도했으나 여전히 슬라이딩 윈도우 방식을 유지하며, 전역적인 맥락을 고려하지 못하는 구조적 한계가 있음을 기술함
- **MultiBox:**
합성곱 신경망으로 경계 상자를 예측하는 기법을 제안했으나, 일반적인 객체 검출 시스템으로서의 완성도보다는 단일 구성 요소 기술에 머물러 있다고 평가함


2) 제안 방법의 차별성을 어떻게 표현하고 있는가

- **통합 네트워크 설계:**
기존의 복잡한 검출 파이프라인을 단일 신경망으로 통합하여 특징 추출부터 경계 상자 예측까지 한 번에 수행하는 구조적 단순함을 강조함
- **End-to-End 최적화:**
각 단계를 별도로 훈련해야 했던 기존 연구들과 달리, 전체 시스템을 검출 성능 지표에 직접 맞춰 한꺼번에 최적화할 수 있음을 차별점으로 내세움
- **압도적인 실시간성:**
R-CNN처럼 이미지 한 장당 수십 초가 소요되는 방식과 대조적으로, 초당 45프레임 이상의 속도를 유지하면서도 기존의 실시간 검출기들보다 월등한 정확도를 제공함
- **전역적 추론 능력:**
특정 영역의 특징에만 집중하는 기존 방식과 달리 이미지 전체의 정보를 활용하므로, 배경 이미지를 객체로 오인하는 오류를 획기적으로 줄임


예시) $S = 4, B = 2, C = 20$



Resized image 를
4x4 grid 로 분할




Grid cell 마다 bbox 2개씩 예측



3. 제안 방법론


Main Idea



- Object detection을 여러 단계의 파이프라인이 아닌 단일 Regression 문제로 재구성하여 하나의 Neural network로 통합함
- 입력 이미지를 $S \times S$ Grid로 분할하고, 각 Grid cell이 Bounding box 위치, Confidence score, Class probability를 동시에 예측하도록 설계함
- Convolutional layer를 통해 이미지 특징을 추출하고, Fully connected layer를 거쳐 최종 예측값인 $S \times S \times (B \times 5 + C)$ Tensor를 산출함

- 별도의 Region proposal 단계 없이 이미지 전체를 단 한 번의 Forward pass로 훑어 실시간 탐지를 구현함

Contribution



- '통합된 단일 아키텍처'와 '전역적 추론' 개념을 $S \times S$ 기반의 구체적인 알고리즘으로 구현
- 제안 방법의 이점
 - **실시간성 확보**
복잡한 단계별 처리를 배제하고 단일 네트워크 연산으로 단순화하여 초당 45프레임 이상의 고속 처리가 가능한 기술적 토대를 마련함
 - **배경 오류 억제**
네트워크의 마지막 계층이 이미지 전체의 특징을 참조하므로, 특정 윈도우 영역만 볼 때 발생하는 False Positive 문제를 구조적으로 개선함
- 24개의 Convolutional layer와 2개의 Fully connected layer로 이루어진 상세한 Network design을 명시하여 실제 모델 설계가 가능하도록 작성됨
- PASCAL VOC 데이터셋 기준 $S=7, B=2, C=20$ 등의 설정값과 최종 출력 Tensor의 구체적인 규격을 제시하여 재현 가능성을 보장함
- **Loss Function 정의:** Localization 오차와 Classification 오차를 통합하고 가중치를 통해 학습의 안정성을 높인 전용 Loss function 수식을 제공함

loss function:

$$\begin{aligned}
& \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\
& + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\
& + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\
& + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\
& + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \quad (3)
\end{aligned}$$

4. 실험 및 결과

Dataset

- **PASCAL VOC 2007 & 2012:**
객체 검출 성능(mAP) 및 속도(FPS) 측정을 위한 메인 데이터셋
- **Picasso Dataset & People-Art Dataset:**
실생활 이미지가 아닌 예술 작품(회화 등)에서의 일반화 능력을 평가하기 위한 전이 학습 데이터셋

Baseline

- **Real-Time 시스템:**
GPU 환경의 DPM(Fast/Deformable) 등 기존의 실시간 검출 모델
- **State-of-the-art 시스템:**
당시 최고 정확도를 가졌던 Fast R-CNN 및 R-CNN 계열 모델


결과

Real-Time Detectors	Train	mAP	FPS
100Hz DPM [31]	2007	16.0	100
30Hz DPM [31]	2007	26.1	30
Fast YOLO	2007+2012	52.7	155
YOLO	2007+2012	63.4	45
Less Than Real-Time			
Fastest DPM [38]	2007	30.4	15
R-CNN Minus R [20]	2007	53.5	6
Fast R-CNN [14]	2007+2012	70.0	0.5
Faster R-CNN VGG-16[28]	2007+2012	73.2	7
Faster R-CNN ZF [28]	2007+2012	62.1	18
YOLO VGG-16	2007+2012	66.4	21

- **실시간 검출 성능:**

YOLO는 45 FPS를 유지하며 PASCAL VOC에서 63.4 mAP를 기록, 기존 실시간 검출기들보다 2배 이상 높은 정확도 달성

- Fast YOLO는 155 FPS라는 경이로운 속도로 실시간 처리에 최적화된 성능 입증




- **오류 유형 분석:**

Fast R-CNN 대비 Localization error는 다소 높으나, 배경을 객체로 착각하는 Background error는 Fast R-CNN(13.6%)의 약 1/3 수준인 4.75%로 현저히 낮음

- **모델 결합 효과:**

Fast R-CNN의 결과에 YOLO의 예측을 보완적으로 결합했을 때, 배경 오탐지가 제거되면서 Fast R-CNN 단독 성능보다 mAP가 약 3.2% 향상됨



(a) Picasso Dataset precision-recall curves.

	VOC 2007 AP	Picasso AP	Picasso Best F_1	People-Art AP
YOLO	59.2	53.3	0.590	45
R-CNN	54.2	10.4	0.226	26
DPM	43.2	37.8	0.458	32
Poselets [2]	36.5	17.8	0.271	
D&T [4]	-	1.9	0.051	

(b) Quantitative results on the VOC 2007, Picasso, and People-Art Datasets. The Picasso Dataset evaluates on both AP and best F_1 score.

Figure 5: Generalization results on Picasso and People-Art datasets.

- **일반화 능력 검증:**

Picasso 및 People-Art 데이터셋 실험 결과, 자연 이미지로만 학습했음에도 불구하고 그림이나 예술 작품 속 객체를 검출하는 능력이 다른 어떤 모델보다 뛰어남을 확인


5. 결론 (배운점)

1) 연구의 의의 및 한계점

- **의의**

- 객체 검출을 여러 단계의 복잡한 파이프라인에서 단일 신경망 기반의 Regression 문제로 혁신적으로 재정의하여, End-to-End 학습과 실시간 처리(45~155 FPS)를 최초로 동시 구현함
- 특정 윈도우 영역만 추출하는 것이 아니라 이미지 전체의 맥락을 파악하는 Global reasoning을 통해 배경 False Positive를 획기적으로 줄이고, 예술 작품 등 새로운 도메인에 대한 뛰어난 일반화성을 입증함

- **한계점**



- 훈련 데이터에서 학습하지 못한 새롭거나 비정상적인 가로세로 비율을 가진 객체에 대해서는 예측의 정확도가 떨어짐
- Loss function이 큰 상자와 작은 상자의 오차를 동일하게 취급하여, 작은 객체에서의 미세한 위치 오차가 전체 성능에 큰 악영향을 미치는 부정확한 Localization 문제

2) 좋았던/아쉬웠던 점

• 좋았던 점:

기존의 R-CNN 계열처럼 무겁고 쪼개진 파이프라인을 고집하지 않고 문제를 단일 회귀로 치환하여 추론 속도와 연산 효율성을 극대화한 시스템 최적화 관점의 아키텍처 설계가 인상적임

• 아쉬웠던 점:


작은 객체나 겹친 객체에 대한 검출 정확도를 다소 희생하여, 정밀한 위치 파악이 필수적인 도메인에서는 이 초기 모델을 그대로 적용할 수 없다는 점이 아쉬움

AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT

SCALE

1. Introduction

논문이 다루는 분야



- 자연어 처리(NLP) 분야의 표준으로 자리 잡은 Transformer 아키텍처를 컴퓨터 비전 (이미지 인식) 태스크에 직접 적용하는 방법론
- 기존의 합성곱 신경망(CNN)에 의존하지 않고, 이미지를 여러 개의 Patch 시퀀스로 나누어 순수 트랜스포머 모델만으로 이미지 분류를 수행하는 구조 연구

해당 task에서 기존 연구 한계점

- 트랜스포머의 Attention 메커니즘을 비전 분야에 적용하려는 여러 시도가 있었으나, 픽셀 단위의 어텐션 연산은 이미지 크기에 대해 Quadratic 비용이 발생하여 실제 해상도로의 스케일업이 어려움
- 이러한 연산 한계 때문에 어텐션은 주로 기존 CNN 구조에 보조적으로 결합되거나, CNN의 전체적인 뼈대는 유지한 채 일부 구성 요소만 대체하는 제한적인 방식으로만 사용됨
- 결과적으로 대규모 이미지 인식 분야에서는 고전적인 ResNet과 같은 CNN 기반 아키텍처가 여전히 압도적인 표준으로 남아 있었음

논문의 contributions

- 이미지 인식에서 CNN에 대한 의존이 전혀 필요하지 않음을 최초로 입증함
- 이미지를 16x16 크기의 패치 시퀀스로 분할한 뒤 순수 트랜스포머 모델에 직접 입력하는 Vision Transformer(ViT) 구조를 제안함
- 트랜스포머는 CNN이 기본적으로 가지는 Locality나 Translation equivariance 같은 귀납적 편향이 부족하여 중간 규모의 데이터셋에서는 성능이 비교적 낮음
- 하지만 ImageNet-21k, JFT-300M 등 대규모 데이터셋으로 Pre-training할 경우, 대규모 학습이 이러한 귀납적 편향의 부족을 압도적으로 극복할 수 있음을 증명함
- 충분한 규모의 사전 학습 후 Transfer learning을 수행했을 때, 기존의 최고 성능 CNN(State-of-the-art) 모델들과 비교해 훨씬 적은 연산 자원으로도 우수하거나 동등한 정확도를 달성함

