

AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

📅 날짜	2026년 5월 4일
☰ 다중 선택	CV

Paper Review

An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale

While the Transformer architecture has become the de-facto standard for natural language processing tasks, its applications to computer vision remain limited. In vision, attention is either...

✖ <https://arxiv.org/abs/2010.11929>



Keyword : Image Classification, Vision Transformer

1. Introduction

논문이 다루는 분야

Image Recognition with Transformer

- Image Classification을 중심으로 한 컴퓨터 비전 영역 태스크를 다룸
- NLP에서 표준이 된 Transformer 구조를 이미지에 직접 적용하여, CNN 중심의 기존 접근법을 대체하고자 함
- 대규모 데이터셋으로 pre-training 후 downstream task에 transfer하는 방식

해당 task에서 기존 연구 한계점

- **NLP 분야 현황** - Self-attention을 기반으로 한 **Transformer** 구조가 자주 쓰임
 - 대규모 corpus에서 pre-training + 소규모 task-specific dataset에서 fine-tuning하는 방식이 주류
 - Transformer의 연산 효율성과 확장성 덕분에, 100B가 넘는 파라미터를 가진 모델도 학습 가능해지면서 성능도 계속해서 향상됨
- **CV 분야 현황** - CNN(ResNet 등)이 여전히 지배적
 - CNN에 self-attention을 결합하거나, convolution을 완전히 대체하려는 시도가 있었지만, 아직 하드웨어 가속기에서 효율적으로 확장되진 못함
 - 대규모의 이미지 인식 태스크에서는 기존 ResNet 같은 구조가 여전히 SOTA

논문의 contributions

- **ViT의 Contributions** - 표준 Transformer를 이미지에 직접 적용
 - 이미지를 패치로 분할하고, 패치의 linear embedding 시퀀스를 Transformer 입력으로 사용
 - 이미지 패치를 NLP의 토큰(단어)처럼 취급

ViT를 효과적으로 학습하기 위한 **데이터 크기**

- **중간 규모 데이터셋**

ImageNet 같이 대규모가 아닌 데이터셋에서 ViT를 학습했을 때, 비슷한 크기의 ResNet보다 낮은 정확도를 보임. 이러한 결과에서, Transformer는 CNN에 내재된 translation equivariance와 locality라는 inductive bias가 없기 때문에 충분한 학습 데이터가 없으면 일반화하기 어려움을 예상할 수 있음.

- **대규모 데이터셋**

14M-300M개의 대규모 데이터셋으로 학습하면, inductive bias를 뛰어넘을 수 있음. ViT를 충분한 크기의 데이터셋에서 사전 학습 후, 그보다 적은 데이터로 전이 학습해서 좋은 성과를 이룸.

- **성과** - ImageNet-21k 데이터셋이나 in-house JFT-300M 데이터셋에서 사전 학습한 결과, 여러 이미지 인식 벤치마크에서 SOTA 달성

2. Related Work

Transformer in NLP

- Vaswani et al. (2017))가 machine translation을 위한 **transformer**구조를 제안한 이후, NLP의 많은 태스크에서 SOTA 모델로 자리잡음
- 대형 Transformer 기반 모델을 대규모 corpora로 pre-training + 특정 태스크로 fine-tuning하는 방식
ex) **BERT**(denoising self-supervised pre-training), **GPT**(language modeling as pre-training)

Self-attention in Vision

- 이미지에 self-attention을 단순 적용하면, 각 픽셀을 다른 모든 픽셀과 연산해야 함
→ 연산 비용이 $O(n^2)$ 으로 현실적이지 않음
- **기존 해결 방안**
 - Local attention : 각 query 픽셀의 주변 픽셀에만 local self-attention 적용
→ Local multi-head self-attention block으로 convolution을 완전 대체
 - Sparse Transformers : Global self-attention에 근사 기법 사용
 - Block attention : 다양한 크기의 블록 단위로 attention 적용
 - Axial attention : 개별 축에 대해서만 attention 수행→ 많은 구조들이 유망한 결과를 냈지만, 하드웨어 가속기에서 효율적으로 구현하기는 어려움
- **ViT와 가장 유사한 기존 연구** - 입력에서 2x2 패치를 추출하고 full self-attention 적용하는 연구
 - ViT의 차별점
 1. 대규모 pre-training으로 Vanilla Transformer가 SOTA CNN과 경쟁 가능함을 입증
 2. 기존 연구는 저해상도 이미지만 처리 가능하나, ViT는 중간 해상도 이미지도 처리 가능
- **CNN + Self-attention** - Feature map 증강이나 CNN 출력 후처리에 self-attention을 적용하는 방식이 이미지 분류부터 text-vision 태스크까지 다양한 태스크에서 활용됨
- **Image GPT (iGPT)**
 - 이미지 해상도와 색공간을 축소한 후 Transformer 적용
 - 비지도 학습으로 생성 모델 학습 후, fine-tuning하여 ImageNet에서 최대 정확도 72% 달성

Data scale


- 표준 ImageNet보다 대규모 데이터셋을 활용한 이미지 인식 연구가 증가하는 추세
- 기존 연구에서는 CNN의 성능이 데이터셋 크기에 따라 어떻게 변하는지, ImageNet-21k나 JFT-300M 같은 대규모 데이터셋에서의 CNN transfer learning에 대한 탐구가 이뤄짐

- ViT도 동일한 대규모 데이터셋을 사용하나, ResNet 대신 **Transformer**를 학습

3. 제안 방법론

Main Idea

모델 설계는 원래의 Transformer 구조를 최대한 그대로 따름 → NLP Transformer의 확장 구조와 효율적 구현을 거의 그대로 사용 가능



Vision Transformer (ViT)

• 입력

- 표준 Transformer는 1D 토큰 시퀀스를 입력으로 받으므로 2D 이미지를 변환해야 함

2D 이미지 → Flattened 2D 패치 시퀀스

$$x \in R^{H \times W \times C} \rightarrow x_p \in R^{N \times (P^2 \cdot C)}$$

- (H, W) : 원본 이미지 크기
- C : 이미지의 채널 수
- (P, P) : 각 패치 크기
- $N = HW/P^2$: 패치 개수

- Flatten된 각 패치를 학습 가능한 linear projection을 이용해 D 차원 잠재 벡터로 매핑 → **Patch Embedding**

• [class] 토큰

- BERT의 [class] 토큰과 유사하게, 학습 가능한 embedding을 패치 시퀀스 앞에 추가 ($z_0^0 = x_{class}$)
- Transformer encoder 출력에서 이 토큰의 state (z_L^0)가 이미지 표현 y 로 사용됨
- Classification head

- Pre-training 시 : 1개의 hidden layer를 가진 MLP
- Fine-tuning 시 : single linear layer

• Position Embedding

- 위치 정보 보존을 위해 patch embedding에 position embedding을 더함
- 학습 가능한 1D position embedding 사용 (더 발전된 2D-aware 방식을 사용해도 유의미한 성능 향상이 없었음)

• Transformer Encoder

- MSA(Multi-headed Self-Attention)와 MLP 블록을 교대로 구성
- 매 블록 앞에 LN(LayerNorm) 적용
- 매 블록 뒤에 residual connection 적용
- MLP → 2개의 layer + GELU

$$\begin{aligned}
 z_0 &= [x_{class}; x_p^1 E; x_p^2 E; \dots; x_p^N E] + E_{pos} \\
 z'_\ell &= \text{MSA}(\text{LN}(z_{\ell-1})) + z_{\ell-1} \\
 z_\ell &= \text{MLP}(\text{LN}(z'_\ell)) + z'_\ell \\
 y &= \text{LN}(z_L^0) \\
 (E &\in R^{P^2 \cdot C \times D}, E_{pos} \in R^{(N+1) \times D}, \ell = 1 \dots L)
 \end{aligned}$$

Inductive Bias

- ViT는 CNN에 비해 이미지 특화 inductive bias가 훨씬 적음
- **CNN** : locality, 2D neighborhood structure, translation equivariance가 모든 레이어에 내장됨
- **ViT** : MLP만 local + translationally equivariant, self-attention은 global
 - 2D neighborhood structure는 이미지를 패치로 자를 때와 fine-tuning 시 다른 해상도의 이미지를 위해 position embedding을 조정할 때만 부분적으로 사용
 - Position embedding은 초기화 시 2D 위치 정보를 전혀 갖지 않으며, 패치 간 공간적 관계를 처음부터 학습해야 함

Hybrid Architecture

- 이미지 패치 대신 **CNN feature map**에서 입력 시퀀스를 추출하여 패치 임베딩 E 를 적용
- CNN feature map의 공간 차원을 flatten하고 Transformer 차원으로 projection
- 특수하게 패치 크기가 1x1인 경우는 feature map의 각 픽셀을 패치로 하여 Transformer 차원으로 projecting하여 입력 시퀀스를 얻음을 의미

Fine-tuning and Higher Resolution

- 대규모 데이터셋에서 pre-training → 더 작은 downstream task에 fine-tuning하는 방식
- Fine-tuning 시 pre-trained prediction head를 제거하고, zero-initialized $D \times K$ feedforward layer를 추가 (K : downstream 클래스 수)
- **고해상도 fine-tuning**
 - Fine-tuning 시 pre-training보다 높은 해상도를 사용하면 성능이 향상되는 경우가 많음
 - 패치 크기는 동일하게 유지 → 시퀀스 길이 증가
 - Pre-trained position embedding이 더 이상 의미가 없을 수 있음
→ 원본 이미지에서의 위치에 따라 2D interpolation 수행
 - 해상도 조정과 패치 추출이 ViT에서 2D 이미지 구조의 inductive bias가 수동으로 주입되는 유일한 지점

4. 실험 및 결과

Dataset

데이터셋	클래스 수	이미지 수	용도
ImageNet	1k	1.3M	Pre-training
ImageNet-21k	21k	14M	Pre-training

데이터셋	클래스 수	이미지 수	용도
JFT-300M	18k	303M	Pre-training

- 위 데이터셋으로 pre-training한 모델을 여러 벤치마크 태스크로 transfer
- 19개의 VTAB 태스크에서 평가

Baseline

Model Variants

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

- "Base", "Large" 모델은 BERT의 구성을 기반으로 하며, "Huge" 모델 추가
 - 표기법 : ViT-L/16 = Large 모델 + 16×16 패치
- 패치 크기가 작을수록 시퀀스가 길어져 연산 비용 증가
- **Baseline CNN**
 - ResNet (BiT) : BatchNorm을 GroupNorm으로 대체, standardized convolutions 사용
- **Hybrid**
 - 중간 feature map을 ViT에 입력하는 방식으로 패치 크기는 1 픽셀
 - 시퀀스 길이를 다르게 실험하기 위해 두 가지 방식을 사용
 - (i) ResNet50의 stage 4 출력을 사용
 - (ii) Stage 4를 제거하고 같은 개수의 레이어를 stage 3에 배치한 다음, stage 3의 확장된 출력을 사용 → 시퀀스 길이가 4배 길어지고 ViT 연산 비용도 증가

Training 세팅

• Pre-training

설정	값
Optimizer	Adam ($\beta_1=0.9$, $\beta_2=0.999$)
Batch size	4,096
Weight decay	0.1
LR scheduler	Linear warmup + decay

• Fine-tuning

설정	값
Optimizer	SGD with momentum
Batch size	512

- ImageNet은 고해상도로 fine-tuning : **ViT-L/16** → 512, **ViT-H/14** → 518

Metrics

- **Fine-tuning accuracy** : 해당 데이터셋에 fine-tuning한 후의 성능
- **Few-shot accuracy** : 모델을 고정해놓고, 일부 학습 이미지의 표현을 $\{-1, 1\}^K$ 타겟 벡터로 매핑하는 regularized least-squares regression을 해결 → closed-form으로 정확한 해를 구할 수 있음
- 주로 fine-tuning 성능에 초점을 두되, fine-tuning 비용이 클 때 빠른 평가를 위해 few-shot accuracy를 사용

결과

가장 큰 모델인 ViT-H/14와 ViT-L/16을 기존 SOTA CNN과 비교

- **비교 대상**

- **Big Transfer (BiT)** : 대규모 ResNet으로 supervised transfer learning한 모델
- **Noisy Student** : 대규모 EfficientNet을 라벨이 제거된 ImageNet과 JFT-200M으로 semi-supervised learning한 모델

- **실험 결과**

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet ReaL	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

- ViT-L/16 (JFT-300M)이 BiT-L을 모든 task에서 능가하면서 훨씬 적은 계산 자원 소모
- ViT-H/14가 더 어려운 데이터셋(ImageNet, CIFAR-100, VTAB)보다 성능이 개선됨
- ViT-L/16 (ImageNet-21k)도 더 적은 자원으로 대부분의 데이터셋에서 좋은 성능을 보임 → TPUv3 8코어로 약 30일 학습

5. 결론

- **ViT 제안** : **Transformer**를 이미지 인식에 직접 적용

- 초기 패치 추출 단계를 제외하면 이미지 특화 inductive bias를 도입하지 않음
- 이미지를 패치 시퀀스로 해석하고, NLP에서 사용되는 표준 Transformer encoder로 처리
- 이러한 단순하지만 확장 가능한 전략이 **대규모 pre-training**과 결합해 놀라운 성능을 보임

- **성과**

- 많은 이미지 분류 데이터셋에서 SOTA 달성 또는 동등한 성능
- 기존 모델 대비 상대적으로 적은 pre-training 비용

- **Challenges**

- Detection, segmentation 등 다른 비전 태스크에 ViT 적용
- Self-supervised pre-training 방법의 추가 탐색 (supervised와의 격차가 여전히 존재)
- ViT의 추가 확장 → 성능 향상 가능성