

Week10 발표 자료 요약본

Efficient Memory Management for Large Language Model Serving with PagedAttention

연구 배경 및 서빙 병목 현상 분석

- 분야 및 목표

LLM Serving 시스템에서 효율적인 메모리 관리를 통해 Throughput을 높이는 것을 목표로 함.

- 경제적 배경

- LLM request 처리 비용은 기존 키워드 대비 10배 이상 비쌈.
- Throughput 향상을 통한 요청당 비용(cost per request) 감소가 핵심 과제

- 메모리 병목

- autoregressive 생성 구조로 인해 workload가 memory-bound이며, 이로 인해 throughput이 제한됨.
- NVIDIA A100 40GB 기준으로 KV Cache가 메모리의 30% 이상을 차지함.

- 기존 시스템의 비효율성 (단편화 문제)

- 기존 시스템(Orca, FasterTransformer)은 KV 캐시를 연속된 메모리에 저장하여 낭비가 발생함.
- 요청의 최대 길이를 기준으로 메모리를 미리 할당(Pre-allocation)하여 **내부 단편화**가 발생함.
- 할당자 문제로 인한 **외부 단편화** 및 요청 종료 시까지 자원을 점유하는 **예약 (Reservation)** 문제로 인해 실제 유효 사용률은 20.4%~38.2% 수준임.

PagedAttention 메커니즘

- 가상 메모리 개념 차용

- OS의 virtual memory와 paging에서 영감을 얻어 KV 캐시를 고정 크기의 'KV 블록'으로 분할함.
- **동적 할당 및 매핑**
 - **Block Table**을 통해 논리적 블록을 비연속적인 물리적 블록에 매핑하며, 필요할 때만 물리 블록을 동적으로 할당함
- **낭비 최소화**
 - 모든 블록이 동일 크기이므로 외부 단편화가 제거되며, 온데만드 할당을 통해 내부 단편화를 완화함.
- **KV 캐시 공유**
 - 병렬 샘플링(Parallel Sampling)등에서 동일 프롬프트의 KV 블록을 공유하며, **Copy-on-write** 방식을 사용하여 메모리 효율을 극대화함.

시스템 구현 및 실험 결과

- **처리량 향상**
 - FasterTransformer 및 Orca 대비 **2~4배의 throughput 향상**을 기록함 (모델 정확도 변화 없음).
- **실험 설정**
 - OPT-13B, 66B, 175B 모델과 ShareGPT, Alpaca 데이터셋을 사용하여 검증함.
- **블록 크기 최적화**
 - 실험 결과 **블록 크기 16**이 GPU 효율성과 단편화 최소화의 균형점으로 확인되어 기본값으로 설정됨.
- **선점(Preemption) 전략**

- GPU 메모리 부족 시 **스와핑(Swapping)** 또는 재계산(Recomputation)을 통해 요청을 복구함.

Adam: A Method for Stochastic Optimization

연구 배경 및 옵티마이저의 진화

- **목적 함수의 성격**
 - 딥러닝 손실 함수는 미니배치와 Dropout 등으로 인해 매 스텝 그래디언트가 달라지는 **확률적(Stochastic)** 성격을 가짐.
- **기존 방식의 한계**
 - **SGD** : 빠르지만 방향과 스텝이 불안정함.
 - **2차 미분 기반**: Hessian 역행렬 계산 비용($O(d^2 \sim d^3)$)이 커서 대규모 파라미터에는 비현실적임.
- **Adam의 정의**
 - Adaptive Moment Estimation의 약자로, 구현이 간단하고 연산 효율적이며 메모리 요구량이 거의 없는 알고리즘임

기술적 상세 메커니즘

- **두 모멘트의 결합**
 - 방향 정보를 가진 1차 모멘트(Momentum)와 스텝 사이즈 정보를 가진 2차 모멘트(RMSProp)를 통합함.
- **편향 보정 (Bias Correction)**
 - 모멘트를 0으로 초기화할 때 발생하는 초기 스텝의 편향을 제거하여 학습 초기 안정성을 확보함.
- **SNR (신호 대 잡음비) 기반 업데이트**

- 그래디언트가 일관되면(SNR 높음) 큰 스텝을, 잡음이 크면(SNR 낮음) 작은 스텝을 밟도록 자동 조절됨.

- **효율적 구현**

- 나눗셈 횟수를 줄인 효율적 수식을 통해 대규모 모델에서의 실행 속도를 높였으며, 주요 프레임워크(PyTorch, TensorFlow)가 이를 채택함.

실험적 입증 및 학계 영향력

- **광범위한 벤치마크 검증**

- MNIST 이미지 분류, IMDB 텍스트 감성 분석, CIFAR-10 CNN 학습 등에서 타 옵티마이저 대비 일관되게 빠른 수렴 속도를 입증함.

- **AdaMax 변형 제안**

- L2 norm 대신 L^∞ norm(max norm)을 사용하여 수치적 안정성을 높인 변형 알고리즘을 제시함.

- **사실상의 표준 (De facto Standard)**

- BERT, GPT, ResNet, GAN 등 최신 딥러닝 모델의 표준 옵티마이저로 자리 잡음.

- **영향력**

- 딥러닝 역사상 가장 많이 인용된 논문 중 하나로, 120,000건 이상의 인용 횟수를 기록함.