

Week10_발표자료_리뷰

vLLM

1. 연구 배경 및 분야

- LLM 서비스의 처리량을 높이기 위해 KV Cache 메모리를 효율적으로 관리하는 방안을 모색함.
- LLM request 처리 비용이 기존 키워드 검색 대비하여 매우 비싸므로, 요청마다 발생하는 비용 절감이 핵심

2. 기존 시스템의 한계점

(1) Memory 단편화

기존 시스템은 KV 캐시를 연속적인 메모리에 저장

Internal Fragmentation

- 최대 길이 기준으로 메모리 미리 할당
- 실제 출력 길이는 대부분 더 짧음
- 사용되지 않는 공간 낭비 발생

External Fragmentation

- 요청마다 다른 크기 메모리 예약
- 메모리 공간이 조각화됨

(2) Memory Sharing 불가능

- Beam search, parallel sampling에서는 KV cache 공유 가능
- 하지만 기존 방식은 sequence별 독립 메모리 사용
- 동일 prompt가 중복 저장됨

결과

- 실제 KV cache 활용률은 약 20~38% 수준

3. Method: PagedAttention

OS의 가상 메모리, 페이징 개념을 적용한 아이디어이다.

OS 개념	PagedAttention
Page	KV Block
Process	Request
Virtual Memory	Logical Block
Physical Memory	Physical Block

동작 방식

- KV cache를 고정 크기 block으로 분할
- Logical block ↔ Physical block 매핑
- Non-contiguous memory 저장 가능

효과

- Internal fragmentation 감소
- External fragmentation 제거
- Block 단위 memory sharing 가능
- 필요한 만큼만 동적 할당 가능

4. 캐시 메모리 Manager

- block이 가득 찰 때만 새 block 할당
- 요청 종료 시 즉시 메모리 반환
- 요청당 낭비 메모리는 마지막 block 하나 이내

5~6: 다양한 디코딩 방식과 스케줄링 방식 적용 가능하다.

실험 결과

- FasterTransformer, Orca 대비 → 최대 2~4배 throughput 향상
- 긴 sequence일수록 효과 큼
- 복잡한 decoding일수록 개선 폭 증가
- 모델 정확도 변화 없음

Adam

1. 연구 배경 - 목적 함수의 특징

- 딥러닝의 loss function은 stochastic(확률적)이므로 샘플링마다 그래디언트가 달라짐
→ 효율적이고 노이즈에 robust한 1차 optimizer가 필요함
- Momentum과 RMSProp을 통합한 옵티마이저인 Adam을 본 논문에서 제시함

2. Related Work

- AdaGrad: 가중치 업데이트 횟수에 반비례하게 학습률을 조절함
- RMSProp: 학습률 소실 문제를 EMA로 해결
- Adam의 차별성: 방향과 step size를 동시에 조절한다.

3. Algorithm

알고리즘 구현 과정

1. 그래디언트 계산: $g_t = \nabla_{\theta} f_t(\theta; t - 1)$
2. 모멘트 갱신: $m_t = \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t, v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2)(g_t^2)$
3. 편향 보정: $\hat{m}_t = m_t / (1 - \beta_1^t), \hat{v}_t = v_t / (1 - \beta_2^t)$
4. 파라미터 업데이트

$$\theta_t = \theta_{t-1} - \alpha \cdot \frac{\hat{m}_t}{(\sqrt{\hat{v}_t} + \epsilon)}$$

편향 보정의 필요성

- 0 초기화 시, 추정치가 0쪽으로 편향되는 문제가 있기 때문에 보정으로 초기 스텝의 학습률 폭주를 막아 시작부터 안정적으로 수렴하게 한다.
 - 보정 전: 실제 값의 10%만 반영 → 편향
 - 보정 후: 100% 실제 그래디언트 회복 → 안정적 학습

유효학습률&SNR 해석 ≈ Signal-to-Noise Ratio

- 핵심 통찰: $\frac{\hat{m}_t}{\sqrt{\hat{v}_t}} \approx$ 신호 대 잡음비(Signal-to-Noise Ratio, SNR)

- SNR이 크면 → gradient가 일관되어 큰 스텝
- SNR이 작으면 → 노이즈가 커서 작은 스텝
- 자동으로 learning rate 조절하고, 별도 scheduling 필요성이 감소

Step Size 상한 존재

- 업데이트 크기가 제한되어 학습 발산을 방지
- α 가 trust region 역할 수행

실험 결과

실험	환경 / 목적	결과
MNIST	Multi-class Logistic Regression 환경에서 optimizer 비교	Adam은 SGD와 비슷하거나 더 빠르게 수렴하며, AdaGrad보다 우수한 성능
IMDB Sparse Feature	Sparse feature(희소 단어) 환경 테스트	Adam은 sparse 환경에서도 안정적으로 동작하며 SGD보다 빠르게 수렴
MLP	다층 신경망 학습 성능 비교	Adam이 가장 빠르게 training cost 감소, 2차 방법(SFO)보다도 효율적
CNN (CIFAR-10) — 단기 학습	초기 epoch에서의 수렴 속도 비교	Adam이 초기 학습 단계에서 가장 빠르게 cost 감소
CNN (CIFAR-10) — 장기 학습	장기 학습 안정성 비교	AdaGrad는 학습률 감소로 정체되지만 Adam은 안정적으로 수렴 유지