



Adam : A Method for Stochastic Optimization

1. Introduction

이 논문이 다루는 분야

- 📁 딥러닝 최적화 알고리즘 (Optimization Algorithms for Deep Learning)
- 💡 대규모 데이터셋과 고차원 파라미터를 가진 확률적 목적 함수(Stochastic objective functions)의 최적화

해당 task에서 기존 연구 한계

- 🔥 **SGD (Stochastic Gradient Descent)**: 모든 파라미터에 동일한 학습률을 적용하여 수렴 속도가 매우 느리고, 지역 최솟값(Local Minimum)에 갇히기 쉬움.
- 🔥 **AdaGrad**: 희소한 기울기 문제에는 강하지만, 학습이 진행될수록 학습률이 너무 작아져 결국 학습이 조기에 멈춰버리는 현상이 발생함.
- 🔥 **RMSProp**: 비정상적인 목적 함수(Non-stationary objectives) 문제에 대응하여 학습률을 조절하지만, 가던 방향을 유지하려는 '모멘텀(Momentum)'의 이점을 충분히 활용하지 못함.

논문의 contributions

- ✅ **Adaptive Moment Estimation (Adam)**: 1차 모멘트(기울기의 평균, 방향성)와 2차 모멘트(기울기 제곱의 평균, 보폭 조절)를 결합하여 각 파라미터마다 최적화된 학습률을 제공함.
- ✅ **Bias Correction (편향 보정)**: 학습 초기 단계에서 모멘트 추정치가 0으로 편향되는 수학적 문제를 해결하여, 학습 초반부의 안정성을 비약적으로 향상시킴.
- ✅ **실무적 효율성 증명**: 계산 비용이 매우 낮고 메모리 요구량이 적으며, 하이퍼파라미터 튜닝이 거의 필요 없는 직관적인 설정값을 제안함.

✓ **이론적/실증적 검증:** 온라인 볼록 최적화 프레임워크를 통해 이론적 수렴성을 증명하고, 다양한 딥러닝 모델에서 기존 알고리즘보다 뛰어난 성능을 보임을 입증함.

2. Related Work

vs RMSProp

- **모멘트 추정 방식:** RMSProp은 가끔 스케일링된 기울기에 모멘텀을 적용하지만, Adam은 기울기의 1차 및 2차 모멘트 이동 평균을 직접 추정하여 업데이트에 활용.
- **편향 보정(Bias-correction) 유무:** RMSProp에는 Adam의 핵심 장치인 편향 보정이 없음.
- **학습 안정성:** 편향 보정이 없으면 β_2 가 1에 가까울 때(희소 기울기 처리 시 필요) 초기 단계에서 매우 큰 보폭이 발생하여 학습이 발산.

vs AdaGrad

- **희소 기울기 대응:** AdaGrad는 희소한 기울기 환경에서 잘 작동하며, Adam은 특정 조건하에서 이와 유사한 성능을 냄.
- **특수 케이스로서의 Adam:** $\beta_1 = 0$ 이고 β_2 가 1에 무한히 가까워지는 상황에서, Adam은 사실상 AdaGrad의 변형된 형태와 수식적으로 일치.
- **보정의 필수성:** AdaGrad와의 직접적인 대응 관계 역시 편향 보정 항이 존재할 때만 수학적으로 성립하며, 보정이 없다면 초기 업데이트가 무한히 커지는 오류가 발생.

vs 기타 기법 및 구조적 특징

- **메모리 효율성:** SFO와 같은 준 뉴턴 방법은 메모리 요구량이 데이터셋 분할 수에 비례하여 크지만, Adam은 훨씬 적은 메모리만 사용.
- **기하학적 적응:** Adam은 데이터의 기하학적 구조에 적응하는 프리컨디셔너를 사용하며, 이는 대각 피셔 정보 행렬(Diagonal Fisher Information Matrix)의 역행렬 제곱근을 근사하는 것과 유사.
- **곡률 추정:** vSGD, AdaDelta 등 1차 정보를 통해 곡률을 추정하여 보폭을 설정하는 기존 방식들과 궤를 같이함.

3. Method

Algorithm



Adam 알고리즘의 동작 원리

- 1 기울기(g_t) 계산 : 현재 타임스텝에서의 확률적 목적 함수에 대한 기울기 구함
- 2 1차 모멘트 업데이트(m_t) : 과거 기울기의 지수 이동 평균을 구하여 이동할 방향(관성)을 결정
 - ✓ β_1 파라미터 사용
- 3 2차 모멘트 업데이트(v_t) : 기울기 제곱(g_t^2)의 지수 이동 평균을 구하여 파라미터별 변동성(보폭 조절)을 확인
 - ✓ β_2 파라미터 사용
- 4 편향 보정(Bias Correction): m_t 와 v_t 는 초기값 0에서 시작하므로 학습 초기에 0으로 편향되는 경향 존재, 이를 수학적으로 보정하여 $\hat{m}_t, \hat{v}_t$ 를 도출



업데이트 규칙의 특징

: 기울기(g)에 특정 상수(c)를 곱하여 스케일을 키워도, 수식 상에서 이 영향이 상쇄되어 최종 업데이트 양은 변하지 않음.

- 스케일 불변성(Scale Invariance)

기울기의 불확실성(노이즈)이 커지면 SNR이 작아져서 업데이트 보폭이 자동으로 줄어드는데, 이는 일종의 '**자동 어닐링(Automatic annealing)**' 효과를 제공한다.

$$\hat{m}_t / \sqrt{\hat{v}_t} \text{를 } SNR \text{로 정의}$$

- SNR 제어

➡ 기울기 정보가 불충분한 지점 너머로 과도하게 업데이트 되지 않게 함.
: 이 메커니즘은 현재 파라미터 값 주변에 '신뢰 영역(Trust region)'을 설정하는 것과 유사한 효과를 줌.

- 신뢰 구간 형성

➡ 이는 복잡한 지형에서도 학습이 발산하지 않고 안정적으로 진행되도록 함.
: 파라미터 공간에서 취해지는 실제 단계 크기(Δ_t)는 대략적으로 학습률 설정값인 α 에 의해 제한됨.



권장 하이퍼 파라미터 설정

- α (Step size): 0.001
- β_1 (1st moment decay): 0.9
- β_2 (2nd moment decay): 0.999
- ϵ (Stability constant): 10^{-8}

Initialization Bias Correction

: 모멘트(m_t, v_t)를 0으로 초기화할 때 발생하는 통계적 오차를 수학적으로 교정하는 단계



초기 편향의 발생 원인

- 초기화 문제

: 알고리즘 시작 시 모멘트 벡터를 0으로 설정하기 때문에, 특히 학습 초기 단계에서 추정치가 실제 값보다 0에 가깝게 작게 나타나는 편향 발생

- 감쇠율의 영향

: 지수 이동 평균의 감쇠율(β_1, β_2)이 클수록(1에 가까울수록) 과거의 0 초기값의 영향력이 오래 남아 편향이 더 심해짐



편향 보정의 수학적 유도

: 지수 이동 평균을 이전 타임스텝의 모든 기울기 제공의 합으로 전개

$$v_t = (1 - \beta_2) \sum_{i=1}^t \beta_2^{t-i} g_i^2$$

✚ 기대값($E[v_t]$)을 취하여 실제 2차 모멘트($E[g_t^2]$)와의 관계를 분석하면 다음과 같은 보정 계수가 나타남

$$E[v_t] = E[g_t^2] \cdot (1 - \beta_2^t) + \zeta$$



최종 보정 수식

- 1차 모멘트 보정: $\hat{m}_t = m_t / (1 - \beta_1^t)$
- 2차 모멘트 보정: $\hat{v}_t = v_t / (1 - \beta_2^t)$

Convergence Analysis



후회 한계 (Regret Bound) 분석

- **정의:** 전체 타임스텝 T 동안 모델이 예측한 값과 실제 최적 파라미터 사이의 차이 누적액을 $R(T)$ 라고 정의
- **수렴 속도:** Adam의 누적 후회 $R(T)$ 는 $O(\sqrt{T})$ 의 상한선을 가짐



핵심 공식

$$\frac{R(T)}{T} = O\left(\frac{1}{\sqrt{T}}\right)$$

: 타임스텝 T 가 무한대로 갈수록 평균 후회값이 0에 수렴함을 의미하며, 결과적으로 **임의의 볼록 함수(Convex function) 환경에서 완벽하게 수렴함**을 수학적으로 보장



이론적 강점

- **희소 데이터 효율성**

: 데이터의 특징이 희소(Sparse)한 경우, Adam의 적응적 특성 덕분에 비적응적 방법보다 훨씬 작은 오차 범위를 유지하며 빠르게 수렴함.

- **최적성**

: 증명된 $O(\sqrt{T})$ 의 수렴 속도는 일반적인 온라인 볼록 최적화 문제에서 이론적으로 도달 가능한 최상급 수치와 동일함.

4. 실험 및 결과

Dataset

- **MNIST**: 손글씨 숫자 이미지 데이터셋
- **IMDB Movie Reviews**: 영화 리뷰 텍스트 데이터 (희소 특징 처리 능력 검증)

Baseline

- 1 **Gradient Descent 기반 모델**: SGD, Nesterov Momentum
- 2 **Adaptive Learning Rate 모델**: AdaGrad, RMSProp
- 3 **기타 고차원 최적화 모델**: SFO (Sum-of-Functions Optimizer)

결과

1 Logistic Regression (MNIST / IMDB)




Figure 1: Logistic regression training negative log likelihood on MNIST images and IMDB movie reviews with 10,000 bag-of-words (BoW) feature vectors.

- **결과**: Adam은 SGD와 유사한 수렴 속도를 보이며, 두 방식 모두 AdaGrad보다 빠르게 수렴함
- **특징**: 희소 특징을 가진 IMDB 데이터에서도 AdaGrad와 대등한 효율성을 입증함

2 Multi-layer Neural Networks




Figure 2: Training of multilayer neural networks on MNIST images. (a) Neural networks using dropout stochastic regularization. (b) Neural networks with deterministic cost function. We compare with the sum-of-functions (SFO) optimizer (Sohl-Dickstein et al., 2014)

- **결과:** 드롭아웃 노이즈 환경에서 다른 확률적 1차 방법들보다 우수한 성능 달성
- **수치:** SFO 모델 대비 약 5~10배 빠른 연산 및 수렴 속도 기록

3 Convolutional Neural Networks (CNN)




Figure 3: Convolutional neural networks training cost. (left) Training cost for the first three epochs. (right) Training cost over 45 epochs. CIFAR-10 with c64-c64-c128-1000 architecture.

- **결과:** 학습 초기 단계에서 가장 빠른 진척을 보이며, 최종 비용 함수 값도 가장 낮게 도달함
- **특징:** 레이어별로 수동 튜닝 없이도 최적의 학습률 스케일을 자동 조절함

4 Bias-Correction Term (VAE)




Figure 4: Effect of bias-correction terms (red line) versus no bias correction terms (green line) after 10 epochs (left) and 100 epochs (right) on the loss (y-axes) when learning a Variational Auto-Encoder (VAE) (Kingma & Welling, 2013), for different settings of stepsize α (x-axes) and hyper-parameters β_1 and β_2 .

- **결과:** β_2 가 1에 가까운 조건에서 편향 보정 항이 없을 경우 학습이 매우 불안정해짐
- **특징:** 보정 항을 적용한 Adam은 하이퍼파라미터 설정에 관계없이 안정적인 성능을 보임

5. Conclusion

1 알고리즘의 정체성

- **Adam**은 구현이 간단하고 계산 효율성이 매우 뛰어난 1차 경사 기반 최적화 알고리즘
- 이 방법은 대규모 데이터셋이나 고차원 파라미터 공간을 가진 머신러닝 문제를 해결하는 데 최적화

2 기존 모델의 장점 통합

- **AdaGrad**의 희소 기울기(Sparse gradients) 처리 능력과 **RMSProp**의 비정상적 목적 함수(Non-stationary objectives) 대응 능력을 성공적으로 결합함.
- 결과적으로 다양한 형태의 확률적 목적 함수에 대해 매우 견고한(Robust) 성능을 보여줌.

3 성능 및 신뢰도 검증

- 볼록 문제(Convex problems)에 대한 이론적 수렴 속도 분석을 수행하였으며, 실험을 통해 이를 실증적으로 확인함.
- 실제 실험 결과, 다양한 **비볼록(Non-convex)** 최적화 문제에서도 타 알고리즘 대비 뛰어난 성능을 보임을 입증함.

Efficient Memory Management for Large Language Model Serving with PagedAttention

1. Introduction

1차 기울기 기반의 효율적인 확률적 최적화를 위해 방향(Momentum)과 보폭(RMSProp)의 장점을 결합한 알고리즘

이 논문이 다루는 분야

- **확률적 목적 함수 최적화:** 고차원 파라미터 공간을 가진 확률적 목적 함수를 최적화하는 분야
- **1차 미분 기반 방법:** 계산 효율성을 위해 고차 미분 정보가 아닌 1차 미분(Gradient) 정보만을 활용하는 최적화 기법

해당 Task에서 기존 연구의 한계

- **고차 최적화의 부적합성:** 파라미터 공간이 고차원인 경우, 고차 최적화 방법(Higher-order methods)은 연산 비용 등의 이유로 적합하지 않음.
- **기존 적응적 방법의 파편화:** AdaGrad는 희소 기울기(Sparse gradients)에 강하고 RMSProp은 비정상적 설정(Non-stationary settings)에 강하지만, 두 장점을 완벽히 통합한 효율적인 알고리즘이 필요

논문의 주요 Contribution

- **적응적 모멘트 추정(Adam):** 기울기의 1차 및 2차 모멘트 추정치를 바탕으로 각 파라미터마다 개별적인 적응적 학습률을 계산하는 방법을 제안
- **편향 보정(Bias Correction):** 모멘트 추정치가 초기에 0으로 편향되는 수학적 한계를 극복하기 위해 초기화 편향 보정 기술을 도입
- **이론적 및 실증적 검증:** 온라인 볼록 프로그래밍에서의 수렴성을 이론적으로 분석하고, 다양한 모델과 데이터셋에서 기존 기법보다 우수한 성능을 보임을 입증

