



Denoising Diffusion Probabilistic Models

# Citation Count	20000
🕒 Difficulty	Advanced
🏛️ Institution	Academic
≡ Keyword	DDPM, Diffusion Model, Generative Model, Score Matching, Langevin Dynamics, VAE, Image Synthesis
≡ Research Area	Generative Model / Image Synthesis
# Year	2020



이 논문은 **확산 확률 모델(Diffusion Probabilistic Models)** 을 이용해 고품질 이미지 생성을 달성한 연구입니다. 핵심 아이디어는 데이터에 점진적으로 노이즈를 추가하는 **순방향 과정(forward process)** 을 반전시키는 **역방향 과정(reverse process)** 을 학습함으로써, 순수 가우시안 노이즈로부터 데이터를 생성하는 것입니다. 논문은 diffusion model과 **denoising score matching + Langevin dynamics** 사이의 새로운 연결을 발견하고, 이를 바탕으로 단순화된 학습 목적 함수를 제안하여 CIFAR10에서 FID 3.17이라는 당시 최고 성능을 달성합니다.

1. Introduction

논문이 다루는 분야

이 논문이 다루는 핵심 분야는 **딥 생성 모델(Deep Generative Model)**, 특히 **이미지 합성(Image Synthesis)**입니다.

구체적으로는 **비평형 열역학(nonequilibrium thermodynamics)** 에서 영감을 받은 잠재 변수 모델(latent variable model)의 일종인 **확산 확률 모델(Diffusion Probabilistic Models)** 을 다룹니다.

직관적으로 이해하기: 사진을 조금씩 흐릿하게 만들다 보면 결국 완전한 노이즈가 됩니다. Diffusion model은 이 과정을 **역방향으로 학습**합니다. 즉, 노이즈에서 시작해 조금씩 노이즈를 제거하여 원본 이미지를 복원하도록 학습합니다.

- **Forward process (순방향):** 데이터 x_0 에 T 스텝에 걸쳐 점진적으로 가우시안 노이즈를 추가 $\rightarrow x_T \sim \mathcal{N}(0, I)$
- **Reverse process (역방향):** x_T 에서 시작해 T 스텝에 걸쳐 노이즈를 제거 $\rightarrow x_0$ (새로운 데이터 샘플)
- **학습 목표:** 역방향 과정의 각 조건부 분포 $p_\theta(x_{t-1}|x_t)$ 를 신경망으로 근사

해당 task에서 기존 연구 한계점



"왜 기존 생성 모델들은 한계가 있었는가?"

다양한 생성 모델들이 각기 다른 trade-off를 가지고 있었습니다.

기존 생성 모델 분류와 각각의 한계:

1. GAN (Generative Adversarial Networks)

장점: 고품질 샘플 생성 가능. 단점: **학습 불안정성**, mode collapse 문제, 다양성 부족. 또한 likelihood 평가가 불가능합니다.

2. VAE (Variational Autoencoders)

장점: 학습이 안정적이고 tractable likelihood를 가짐. 단점: **샘플 품질이 GAN에 비해 낮으며**, posterior의 근사 오차로 인한 한계가 있습니다.

3. Normalizing Flows

장점: 정확한 likelihood 계산 가능. 단점: **아키텍처 제약(가역적 변환 필수)** 이 크고, 일반적으로 학습이 어렵습니다.

4. Score Matching + Langevin Dynamics (NCSN)

장점: 유망한 샘플 품질. 단점: **샘플링 과정이 불안정할 수 있으며**, 샘플러를 학습 후에 별도로 설계해야 합니다. 분포 이동(distribution shift) 문제 발생.

5. 기존 Diffusion Probabilistic Models [Sohl-Dickstein et al., 2015]

이미 이론적 기반이 있었으나, **고품질 샘플 생성 능력이 입증되지 않았습니다**. DDPM은 이 모델이 실제로 GAN 수준의 고품질 샘플을 생성할 수 있음을 처음으로 보입니다.

논문의 contributions

이 논문의 핵심 기여는 세 가지입니다.

기여 1: Diffusion model과 denoising score matching의 동치(equivalence) 발견

특정 파라미터화(ϵ -prediction)를 사용하면 diffusion model의 변분 하한(variational bound) 학습이 다중 노이즈 스케일에서의 denoising score matching과 동치임을 수학적으로 증명합니다. 이것이 논문의 가장 핵심적인 이론적 기여입니다.

기여 2: 단순화된 학습 목적 함수 제안 (L_{simple})

$L_{simple}(\theta) = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon, t)\|^2]$ 이라는 단순한 MSE 목적 함수가 복잡한 변분 하한보다 오히려 샘플 품질이 더 좋음을 발견합니다.

기여 3: 당시 최고 수준의 이미지 합성 성능 달성

CIFAR10에서 FID 3.17, Inception Score 9.46 을 달성하여, 조건부 모델을 포함한 대부분의 기존 모델을 능가합니다. 또한 progressive lossy compression과의 흥미로운 연결을 발견합니다.

2. Related Work



이 논문은 diffusion model을 중심으로 VAE, Normalizing Flows, GAN, Score Matching, Langevin Dynamics, 그리고 Autoregressive Model과의 관계를 분석합니다.

Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가

1. Flows / VAEs와의 비교

Flows [Dinh et al., 2014; Kingma & Dhariwal, 2018] 및 VAEs [Kingma & Welling, 2013]: Diffusion model이 이들과 구조적으로 유사해 보이지만, 결정적인 차이가 있습니다. Diffusion model은 **근사 사후분포 (approximate posterior) q 에 학습 파라미터가 없으며**, 최상위 잠재 변수 x_T 가 데이터 x_0 와의 상호 정보량 (mutual information)이 거의 0에 가깝도록 설계됩니다.

2. Score Matching + Annealed Langevin Dynamics [Song & Ermon, 2019; 2020]

NCSN / NCSNv2: ϵ -prediction 파라미터화를 통해 diffusion model이 이 방법과 연결됩니다. 그러나 DDPM은 중요한 차이점이 있습니다:

- U-Net + Self-attention 아키텍처 사용 (NCSN: RefineNet + dilated convolution)
- Forward process에서 데이터를 $\sqrt{1 - \beta_t}$ 배 축소하여 **분산이 커지지 않도록 함** (NCSN은 이 스케일링 없음)
- Forward process가 신호를 완전히 파괴하여 $q(x_T|x_0) \approx \mathcal{N}(0, I)$ 보장 $\rightarrow$ 사전분포-사후분포 불일치 방지
- 샘플러를 변분 추론으로 직접 학습 (NCSN은 학습 후 수작업 설정)

제안 방법의 차별성을 어떻게 표현하고 있는가

[Figure 2] — 본 논문에서 고려하는 방향성 그래픽 모델. x_T 에서 $p_\theta(x_{t-1}|x_t)$ 와 x_0 에서 x_T 방향의 순방향 과정 $q(x_t|x_{t-1})$.




Figure 2: The directed graphical model considered in this work.

비교 대상	likelihood 평가	샘플 품질	학습 안정성	주요 한계
DDPM	변분 하한 (near-lossless)	매우 높음 (FID 3.17)	높음	샘플링 속도 (T=1000 스텝)
GAN (BigGAN)	불가	높음 (FID 14.73)	낮음	학습 불안정, mode collapse
Flow (Glow)	정확	중간	높음	아키텍처 제약 (가역 변환)
NCSN [Song & Ermon]	불가 (AIS 추정)	높음 (FID 25.32)	중간	샘플러 수작업 설계

3. 제안 방법론

Main Idea




DDPM의 핵심 아이디어는 "데이터에 노이즈를 추가하는 과정을 뒤집으면 노이즈에서 데이터를 생성할 수 있다"는 것입니다.

단, 역방향 과정을 직접 모델링하는 것은 intractable하므로, 신경망이 각 스텝에서 추가된 노이즈 ϵ 를 예측하도록 학습합니다.

이 ϵ -prediction이 denoising score matching과 동치임을 발견하여, 단순한 MSE 손실로도 최고 성능을 달성합니다.

DDPM의 전체 프레임워크:



순방향(q : 노이즈 추가)과 역방향(p_θ : 노이즈 제거)의 Markov chain 구조.

Method 핵심 구성

1) 순방향 과정 (Forward Process / Diffusion Process)

순방향 과정은 학습 파라미터가 없는 고정된 Markov chain입니다:

$$q(x_{1:T}|x_0) := \prod_{t=1}^T q(x_t|x_{t-1}), \quad q(x_t|x_{t-1}) := \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t\mathbf{I})$$

분산 스케줄(variance schedule): $\beta_1, \dots, \beta_T$ 를 선형으로 증가 ($\beta_1 = 10^{-4}$ 에서 $\beta_T = 0.02$).

핵심 성질 — 임의의 타임스텝 t 에서 직접 샘플링 가능 (closed form):

$$\alpha_t := 1 - \beta_t, \bar{\alpha}_t := \prod_{s=1}^t \alpha_s \text{로 정의하면:}$$

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

즉, $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \epsilon \sim \mathcal{N}(0, \mathbf{I})$ 로 중간 스텝을 바로 샘플링할 수 있습니다. 이것이 효율적 학습을 가능하게 하는 핵심입니다.

$\bar{\alpha}_T \approx 0$ 이 되도록 설계하여 $q(x_T|x_0) \approx \mathcal{N}(0, \mathbf{I})$ 가 됩니다.

2) 역방향 과정 (Reverse Process)

역방향 과정은 학습할 파라미터 θ 를 가진 Markov chain입니다:

$$p_\theta(x_{0:T}) := p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t), \quad p_\theta(x_{t-1}|x_t) := \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

$p(x_T) = \mathcal{N}(x_T; \mathbf{0}, \mathbf{I})$ 에서 시작합니다.

분산 Σ_θ 설정: 학습하지 않고 시간에 따른 상수로 고정합니다. $\sigma_t^2 = \beta_t$ 또는 $\sigma_t^2 = \tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t} \beta_t$ 두 가지 선택이 비슷한 성능을 냅니다.

평균 μ_θ 의 파라미터화 (가장 중요한 부분):

순방향 사후분포 $q(x_{t-1}|x_t, x_0)$ 를 tractable하게 계산할 수 있습니다 (x_0 에 조건부):

$$q(x_{t-1}|x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t\mathbf{I})$$

$$\tilde{\mu}_t(x_t, x_0) := \frac{\sqrt{\bar{\alpha}_{t-1}\beta_t}}{1-\bar{\alpha}_t} x_0 + \frac{\sqrt{\bar{\alpha}_t(1-\bar{\alpha}_{t-1})}}{1-\bar{\alpha}_t} x_t$$

여기서 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$ 를 이용해 x_0 를 x_t 와 ϵ 으로 표현하면:

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right)$$

즉, 신경망 ϵ_θ 가 추가된 노이즈 ϵ 를 예측하도록 파라미터화합니다.

3) 학습 목적 함수

변분 하한 (Variational Lower Bound) 을 KL divergence 항으로 분해하면:

$$L = \underbrace{D_{KL}(q(x_T|x_0)||p(x_T))}_{L_T(\text{const})} + \sum_{t>1} \underbrace{D_{KL}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t))}_{L_{t-1}} + \underbrace{(-\log p_\theta(x_0|x_1))}_{L_0}$$

L_T 는 학습 파라미터가 없으므로 상수. 각 L_{t-1} 항은 두 가우시안 분포 간의 KL divergence이므로 closed form 으로 계산됩니다:

$$L_{t-1} = \mathbb{E}_{x_0, \epsilon} \left[\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1-\bar{\alpha}_t)} \|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2 \right] + C$$

단순화된 목적 함수 L_{simple} (가중치 제거):

$$L_{simple}(\theta) := \mathbb{E}_{x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2]$$

t 가 작은(노이즈가 적은) 스텝의 손실 가중치를 줄임으로써 모델이 **어려운 노이즈 제거 태스크(큰 t)에 집중**하게 합니다. 실험적으로 L_{simple} 이 전체 변분 하한보다 **샘플 품질이 더 좋음**을 발견합니다.

4) 훈련 및 샘플링 알고리즘

Algorithm 1 Training

- 1: **repeat**
 - 2: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$
 - 3: $t \sim \text{Uniform}(\{1, \dots, T\})$
 - 4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 5: Take gradient descent step on
 $\nabla_\theta \|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2$
 - 6: **until** converged
-

Algorithm 1 Training (요약):

1. $x_0 \sim q(x_0)$ 데이터 샘플링
2. $t \sim \text{Uniform}(\{1, \dots, T\})$ 타임스텝 랜덤 선택
3. $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 노이즈 샘플링
4. $\nabla_\theta \|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2$ 에 대한 그래디언트 하강

Algorithm 2 Sampling

- 1: $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - 2: **for** $t = T, \dots, 1$ **do**
 - 3: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if $t > 1$, else $\mathbf{z} = \mathbf{0}$
 - 4: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$
 - 5: **end for**
 - 6: **return** $\mathbf{x}_0$
-

Algorithm 2 Sampling (요약):

1. $x_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 에서 시작

2. $t = T, T - 1, \dots, 1$ 순서로 반복:

- $z \sim \mathcal{N}(0, \mathbf{I})$ ($t > 1$ 이면), 아니면 $z = 0$
- $x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z$

3. x_0 반환

이 샘플링 절차는 ϵ_θ 를 데이터 밀도의 학습된 기울기(learned gradient)로 갖는 Langevin dynamics와 유사합니다.

5) 모델 아키텍처

역방향 과정을 나타내기 위해 PixelCNN++ 기반의 U-Net 구조를 사용합니다:

구성 요소	상세
기본 구조	U-Net (Wide ResNet 기반, PixelCNN++ 백본)
정규화	Weight Normalization → Group Normalization 으로 교체 (구현 단순화)
시간 조건화	Transformer sinusoidal position embedding을 각 ResBlock에 추가
Self-attention	16×16 feature map 해상도에서만 적용
파라미터 공유	모든 타임스텝 t에서 파라미터 공유
CIFAR10 모델 크기	35.7M 파라미터
LSUN/CelebA-HQ 모델 크기	114M 파라미터 (대형: 256M)

4. 실험 및 결과

Dataset

데이터셋	해상도	설명	학습 스텝
CIFAR10	32×32	10개 클래스, 60k 이미지. 비조건부(unconditional) 생성	800k
CelebA-HQ	256×256	고해상도 얼굴 데이터셋	500k
LSUN Bedroom	256×256	침실 이미지	2.4M
LSUN Church	256×256	교회 이미지	1.2M
LSUN Cat	256×256	고양이 이미지	1.8M

공통 실험 설정:

- $T = 1000$ (모든 실험에서 고정)
- Linear β schedule: $\beta_1 = 10^{-4} \rightarrow \beta_T = 0.02$
- 옵티마이저: Adam ($\text{lr} = 2 \times 10^{-4}$, 32×32), ($\text{lr} = 2 \times 10^{-5}$, 256×256)
- 배치 크기: 128 (CIFAR10), 64 (고해상도)
- EMA decay: 0.9999
- 학습 하드웨어: TPU v3-8 ($\approx$ V100 8개)

Baseline

모델	유형	CIFAR10 IS	CIFAR10 FID
EBM [Du & Mordatch]	에너지 기반	6.78	38.2
NCSN [Song & Ermon, 2019]	Score matching	8.87±0.12	25.32
NCSNv2 [Song & Ermon, 2020]	Score matching	-	31.75
SNGAN	GAN	8.22±0.05	21.7
BigGAN (조건부)	GAN	9.22	14.73
StyleGAN2+ADA (조건부)	GAN	10.06	2.67
Gated PixelCNN	Autoregressive	4.60	65.93
Diffusion (original) [Sohl-Dickstein]	Diffusion	-	-

결과

실험 1: CIFAR10 샘플 품질 (Table 1)

Table 1: CIFAR10 results. NLL measured in bits/dim.

Model	IS	FID	NLL Test (Train)
Conditional			
EBM [11]	8.30	37.9	
JEM [17]	8.76	38.4	
BigGAN [3]	9.22	14.73	
StyleGAN2 + ADA (v1) [29]	10.06	2.67	
Unconditional			
Diffusion (original) [53]			≤ 5.40
Gated PixelCNN [59]	4.60	65.93	3.03 (2.90)
Sparse Transformer [7]			2.80
PixelIQN [43]	5.29	49.46	
EBM [11]	6.78	38.2	
NCSNv2 [56]		31.75	
NCSN [55]	8.87±0.12	25.32	
SNGAN [39]	8.22±0.05	21.7	
SNGAN-DDLS [4]	9.09±0.10	15.42	
StyleGAN2 + ADA (v1) [29]	9.74 ± 0.05	3.26	
Ours (L , fixed isotropic Σ)	7.67±0.13	13.51	≤ 3.70 (3.69)
Ours (L_{simple})	9.46±0.11	3.17	≤ 3.75 (3.72)

CIFAR10 Inception Score, FID, NLL 비교표.

핵심 관찰:

- L_{simple} 으로 학습한 모델이 FID **3.17** 달성 → 비조건부 모델 중 당시 최고 수준
- 완전한 변분 하한(L)으로 학습하면 **NLL은 더 좋지만 샘플 품질은 낮음**
- 단순화된 목적 함수가 샘플 품질 면에서 더 우수

실험 2: 역방향 과정 파라미터화 소거 실험 (Table 2)

Table 2: Unconditional CIFAR10 reverse process parameterization and training objective ablation. Blank entries were unstable to train and generated poor samples with out-of-range scores.

Objective	IS	FID
$\tilde{\mu}$ prediction (baseline)		
L , learned diagonal Σ	7.28 ± 0.10	23.69
L , fixed isotropic Σ	8.06 ± 0.09	13.22
$\ \tilde{\mu} - \tilde{\mu}_\theta\ ^2$	-	-
ϵ prediction (ours)		
L , learned diagonal Σ	-	-
L , fixed isotropic Σ	7.67 ± 0.13	13.51
$\ \tilde{\epsilon} - \epsilon_\theta\ ^2 (L_{\text{simple}})$	9.46 ± 0.11	3.17

파라미터화 방식(μ 예측 vs. ϵ 예측) 및 학습 목적 함수 조합별 CIFAR10 성능.

분석:

- 역방향 분산 학습 (learned diagonal Σ): 오히려 학습 불안정 및 성능 저하 → 분산을 고정 상수로 두는 것이 더 안정적
- $\tilde{\mu}$ 예측 vs. ϵ 예측: 변분 하한으로 학습 시 비슷하지만, L_{simple} 사용 시 ϵ 예측이 압도적으로 우수
- L_{simple} 의 핵심: 작은 t(쉬운 노이즈 제거)의 가중치를 낮춰 모델이 어려운 큰 t 스텝에 집중

실험 3: LSUN 256×256 샘플 품질

Table 3: FID scores for LSUN 256×256 datasets

Model	LSUN Bedroom	LSUN Church	LSUN Cat
ProgressiveGAN [27]	8.34	6.42	37.52
StyleGAN [28]	2.65	4.21*	8.53*
StyleGAN2 [30]	-	3.86	6.93
Ours (L_{simple})	6.36	7.89	19.75
Ours (L_{simple} , large)	4.90	-	-

LSUN Church 샘플 (FID=7.89).

Table 4: Unconditional CIFAR10 test set rate-distortion values (accompanies Fig. 5)

Reverse process time ($T - t + 1$)	Rate (bits/dim)	Distortion (RMSE $[0, 255]$)
1000	1.77581	0.95136
900	0.11994	12.02277
800	0.05415	18.47482
700	0.02866	24.43656
600	0.01507	30.80948
500	0.00716	38.03236
400	0.00282	46.12765
300	0.00081	54.18826
200	0.00013	60.97170
100	0.00000	67.60125

LSUN Bedroom 샘플 (FID=4.90).

ProgressiveGAN과 유사하거나 더 나은 품질 달성. StyleGAN2에는 미치지 못하지만, 비조건부 likelihood 기반 모델 중에서는 당시 최고 수준.

실험 4: Progressive Coding 및 Rate-Distortion




Figure 5: Unconditional CIFAR10 test set rate-distortion vs. time. Distortion is measured in root mean squared error on a $[0, 255]$ scale. See Table 4 for details.

CIFAR10 테스트셋 rate-distortion vs. 시간. 역방향 스텝 수($T-t$)에 따른 distortion(RMSE)과 rate(bits/dim), 그리고 rate-distortion 곡선.

주요 발견:

- 총 lossless codelength: rate(1.78 bits/dim) + distortion(1.97 bits/dim) = 3.75 bits/dim
- 코드길이의 절반 이상이 지각 불가능한 세부 정보(imperceptible details)를 기술하는 데 사용됨
- 이는 diffusion model이 lossy compression에서 우수한 귀납적 편향(inductive bias)을 가짐을 시사

실험 5: Progressive Generation 및 Interpolation



Figure 6: Unconditional CIFAR10 progressive generation ($\hat{x}_0$ over time, from left to right). Extended samples and sample quality metrics over time in the appendix (Figs. 10 and 14).

CIFAR10 progressive generation. 역방향 과정 진행에 따라 대규모 특징이 먼저, 세부 정보가 나중에 나타남.



Figure 7: When conditioned on the same latent, CelebA-HQ 256×256 samples share high-level attributes. Bottom-right quadrants are x_t , and other quadrants are samples from $p_\theta(x_0|x_t)$.

동일한 잠재 변수 x_t 에서 조건부 샘플링. t 가 클수록 대규모 속성만 공유.



Figure 8: Interpolations of CelebA-HQ 256x256 images with 500 timesteps of diffusion.

CelebA-HQ 256x256 이미지 잠재 공간 보간(interpolation). pose, skin tone, hairstyle, expression 등이 자연스럽게 변환됨.

보간 결과 분석: 소스 이미지 x_0, x'_0 를 500 타임스텝으로 노이즈화(x_t, x'_t)한 뒤 선형 보간하여 역방향 과정으로 복원합니다. t 가 클수록 더 거친(coarser) 보간이 이루어집니다.

5. Ablation Studies (소거 실험)

NCSN과의 아키텍처/설계 차이 분석 (Appendix C)

항목	DDPM (본 논문)	NCSN
아키텍처	U-Net + Self-attention (16x16)	RefineNet + dilated convolution
시간 조건화	모든 레이어에 sinusoidal embedding 추가	정규화 레이어에만 (v1) 또는 출력에만 (v2)
분산 폭발 방지	Forward step에서 $\sqrt{1 - \beta_t}$ 배 축소	스케일링 없음
신호 파괴	$D_{KL}(q(x_T x_0) \mathcal{N}(0, I)) \approx 0$ 보장	신호가 완전히 파괴되지 않을 수 있음
샘플러 학습	변분 추론으로 직접 학습	학습 후 수작업으로 계수 설정

이 네 가지 설계 차이가 NCSN 대비 **안정적인 샘플링**과 높은 품질을 가능하게 합니다.

β_t 스케줄 및 하이퍼파라미터 선택

하이퍼파라미터	선택값	선택 근거
β 스케줄	Linear ($10^{-4} \rightarrow 0.02$)	상수/선형/2차 중 선형이 최적
T	1000	기존 연구와 비교 위해 스윙 없이 고정
Dropout (CIFAR10)	0.1	{0.1, 0.2, 0.3, 0.4} 중 최적
학습률	2×10^{-4} (32×32), 2×10^{-5} (256×256)	고해상도에서 큰 lr 불안정
배치 크기	128 (32×32), 64 (256×256)	메모리 제약

6. 결론

이 논문의 가장 큰 의의는 "**Diffusion probabilistic model이 GAN에 필적하는 고품질 이미지를 생성할 수 있으며, 이는 denoising score matching + Langevin dynamics와 수학적으로 동치인 단순한 노이즈 예측 목적 함수를 통해 달성될 수 있다**"는 것을 설득력 있게 증명한 것입니다.

DDPM 이후 생성 AI의 패러다임이 완전히 바뀌었습니다.

Stable Diffusion, DALL-E 2/3, Imagen, Midjourney의 핵심 기반이 바로 이 논문입니다.

이 논문이 발견한 **ϵ -prediction + L_{simple}** 이라는 단순한 레시피가 현재 모든 텍스트-이미지 생성 모델의 표준이 되었습니다.

Diffusion model의 핵심 연결관계 요약:

- Diffusion model ↔ **변분 추론 (Variational Inference)**: ELBO 최적화로 학습
- Diffusion model ↔ **Denoising Score Matching**: ϵ -prediction이 score matching과 동치
- Diffusion model ↔ **Langevin Dynamics**: 역방향 샘플링 = annealed Langevin dynamics
- Diffusion model ↔ **Autoregressive Model**: Gaussian diffusion은 generalized bit ordering을 가진 autoregressive model로 해석 가능
- Diffusion model ↔ **Progressive Lossy Compression**: rate-distortion 관점에서 해석 가능

7. 느낀점

좋았던 점

복잡한 변분 하한보다 단순한 MSE 목적함수가 오히려 더 좋은 샘플 품질을 만든다는 점이 흥미로웠습니다. 또한 autoregressive decoding, lossy compression, Langevin dynamics 등 다양한 분야와의 연결성을 설명하며 diffusion model의 확장 가능성을 보여준 부분도 인상 깊게 느껴졌습니다. 특히 progressive lossy compression 관점에서 diffusion을 해석한 부분은 기존 생성 모델 논문과 다른 창의적인 시각이라고 생각했습니다. 더불어 ablation study에서는 파라미터화 방식, 분산 설정, 목적 함수까지 체계적으로 비교하여 각 설계 선택이 왜 필요한지 논리적으로 이해할 수 있었다는 점도 좋았습니다.

아쉬웠던 점

가장 큰 한계는 샘플링 속도로, T=1000 단계의 순차적 신경망 평가가 필요하기 때문에 GAN 계열에 비해 생성 속도가 매우 느렸습니다. 또한 likelihood 기반 모델임에도 log-likelihood 성능이 기존 PixelCNN 계열보다 낮다는 점도 아쉬웠습니다. 논문에서는 사람이 인식하지 못하는 정보까지 코드 길이에 포함되기 때문이라고 설명하지만, 여전히 모델이 어떤 정보를 충분히 포착하지 못하는지에 대한 의문은 남았습니다. 더불어 완전한 비조건부 생성만 다루기 때문에 텍스트 조건 이미지 생성처럼 실제 활용도가 높은 conditional generation 방향에 대한 논의가 부

족했고, 픽셀 공간에서 직접 확산을 수행하는 구조 특성상 고해상도 이미지 생성 시 메모리와 계산 비용이 매우 크다는 점 역시 실용적 측면에서는 한계로 느껴졌습니다.



Distributed Representations of Words and Phrases and their Compositionality

# Citation Count	40000
📌 Difficulty	Intermediate
📌 Institution	Google
≡ Keyword	Word2Vec, Skip-gram, Negative Sampling, Subsampling, Phrase Vector, Word Embedding, Compositionality
≡ Research Area	NLP / Word Representation
# Year	2013



이 논문은 Mikolov et al. (2013)의 Skip-gram 모델을 세 가지 방향으로 확장한 연구입니다.

Negative Sampling(NEG), **빈도 단어 서브샘플링(Subsampling)**, 그리고 **구(Phrase) 단위 표현 학습**을 도입하여 벡터의 품질과 학습 속도를 동시에 향상시킵니다. 특히, 단어 벡터의 단순 덧셈이 의미있는 합성(compositionality)을 가능하게 함을 실험적으로 보이며, " $\text{vec}(\text{Russia}) + \text{vec}(\text{river}) \approx \text{vec}(\text{Volga River})$ "와 같은 선형 구조가 Skip-gram 표현에 내재되어 있음을 입증합니다.

1. Introduction

논문이 다루는 분야

이 논문이 다루는 핵심 분야는 **자연어처리(NLP)에서의 분산 단어 표현(Distributed Word Representations) 학습**입니다.

구체적으로는 대규모 비레이블 텍스트로부터 단어와 구(phrase)의 **고품질 벡터 표현**을 효율적으로 학습하는 방법을 다룹니다. 이 표현들은 의미적·문법적 규칙성을 선형 구조로 인코딩합니다. 비슷한 문맥에서 등장하는 단어들은 비슷한 벡터를 갖게 됩니다. Skip-gram은 중심 단어로 주변 단어들을 예측하도록 학습하면서, 자연스럽게 의미와 문법 정보가 벡터 공간에 인코딩됩니다.

- **기존 Skip-gram [Mikolov et al., 2013]**: 대규모 텍스트에서 하루에 1000억 단어를 학습 가능한 효율적인 모델. 학습된 벡터는 $\text{vec}(\text{"Madrid"}) - \text{vec}(\text{"Spain"}) + \text{vec}(\text{"France"}) \approx \text{vec}(\text{"Paris"})$ 와 같은 선형 유추(analogy) 가능.
- **본 논문의 확장**: 세 가지 기술적 개선(Negative Sampling, Subsampling, Phrase 학습)으로 벡터 품질과 속도를 동시에 향상.

해당 task에서 기존 연구 한계점



"왜 기존 Skip-gram 모델은 한계가 있었는가?"

학습 효율성과 구(phrase) 표현 두 측면에서 근본적인 한계가 있었습니다.

한계 1: Hierarchical Softmax의 비효율성

기존 Skip-gram은 출력 확률 $p(w_O|w_I)$ 를 계산할 때 전체 어휘($W = 10^5 \sim 10^7$)를 대상으로 softmax를 계산합니다. 이를 완화하기 위해 **Hierarchical Softmax** (이진 Huffman 트리 기반)를 사용했지만, 여전히 $\log_2(W)$ 개의 노드를 평가해야 하며 **빈도 단어에 대한 표현 품질이 낮은 문제**가 있습니다.

한계 2: 빈번한 단어(Frequent Words)의 정보량 부족

"the", "in", "a"와 같이 수억 번 등장하는 단어들은 문맥 정보를 거의 제공하지 않습니다. 예를 들어 "France"와 "Paris"의 공출현은 유용하지만, "France"와 "the"의 공출현은 거의 무의미합니다. 그런데도 빈도 단어들이 학습을 지배하여 **희귀 단어의 표현 품질이 저하**됩니다.

한계 3: 단어 단위 표현의 관용구 표현 불가

단어 벡터는 본질적으로 단어 순서에 무감각하고, **관용구(idiomatic phrases)를 표현할 수 없습니다**. "Boston Globe"는 신문사이지만 "Boston"과 "Globe"의 의미를 단순 조합해서는 얻을 수 없습니다. 마찬가지로 "Air Canada"는 "Canada"와 "Air"의 합성으로 이해할 수 없습니다.

논문의 contributions

이 논문의 핵심 기여는 세 가지입니다.

기여 1: Negative Sampling (NEG)

Noise Contrastive Estimation(NCE)를 단순화한 Negative Sampling을 제안합니다. 각 positive sample에 대해 k 개의 noise sample을 사용하여 이진 분류(logistic regression) 문제로 변환합니다. Hierarchical Softmax보다 빠르고, 특히 빈도 단어의 표현이 더 좋아집니다.

기여 2: 빈도 단어 서브샘플링 (Subsampling of Frequent Words)

각 단어를 $P(w_i) = 1 - \sqrt{t/f(w_i)}$ 의 확률로 학습 데이터에서 제거합니다. 학습 속도를 2~10배 향상시키고, 빈도 임계값 $t=10^{-5}$ 사용 시 희귀 단어의 표현 정확도도 크게 향상됩니다.

기여 3: 구(Phrase) 벡터 학습 및 가산 합성(Additive Compositionality)

데이터 기반 구 탐지(score 함수)로 수백만 개의 구를 단일 토큰으로 취급하여 학습하고, 구 유추 태스크에서 72% 정확도를 달성합니다. 또한 $\text{vec}(\text{"Russia"}) + \text{vec}(\text{"river"}) \approx \text{vec}(\text{"Volga River"})$ 와 같은 벡터 덧셈의 가산적 합성 현상을 발견하고 이론적으로 설명합니다.