

Distributed Representations of Words and Phrases and their Compositionality

≡ type

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

단어와 phrase를 고품질의 distributed vector representations으로 학습하는 것 → 단어 간 syntactic/semantic 관계를 벡터 공간에서 포착

해당 task에서 기존 연구 한계점

기존 Skip-gram 모델의 두 가지 문제:

- **softmax 계산 비용** : vocabulary 크기 W 에 비례하는 계산량 → W 가 $10^5 \sim 10^7$ 에 달해 비현실적
- **단어 표현의 한계** : 단어 순서 무시 + 관용적 표현(idiomatic phrases) 표현 불가 → "Canada"와 "Air"의 의미를 단순 조합해서 "Air Canada"를 표현하는 게 불가능

논문의 contributions

- Subsampling of frequent words → 학습 속도 2x~10x 향상 + 빈도 낮은 단어의 표현 정확도 향상
- Negative Sampling (NEG) → hierarchical softmax보다 단순하고 빠른 학습 방법 제안
- Phrase 표현 학습 → 단어 단위를 넘어 수백만 개의 phrase를 단일 토큰으로 처리하는 방법 제안
- Additive Compositionality → 벡터 덧셈만으로 의미 있는 결과 도출 가능성을 발견

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- **기존 Skip-gram 모델 (Mikolov et al. 2013):** 원래 dense matrix multiplication 없이 효율적 학습 가능하지만 softmax 계산이 bottleneck → 이 논문에서 NEG와 subsampling으로 개선
- **Hierarchical Softmax (Morin and Bengio, Mnih and Hinton):** W개 output node 대신 $\log_2(W)$ 개만 평가 → 계산 효율 개선 / binary Huffman tree 사용 시 빈도 높은 단어에 짧은 코드 부여 → 빠른 학습 가능 / 하지만 subsampling 없이는 NEG보다 성능 낮음
- **Noise Contrastive Estimation (NCE, Gutmann and Hyvarinen):** 좋은 모델은 data와 noise를 logistic regression으로 구별할 수 있어야 한다는 아이디어 / NCE는 softmax log probability를 근사적으로 최대화하는 것을 목표로 하지만 noise distribution의 numerical probability까지 필요 → NEG는 sample만 사용하도록 단순화
- **Recursive Autoencoders (Socher et al.):** phrase의 의미를 word vector 조합으로 표현하려는 시도 → 이 논문의 phrase vector 방식과 상호 보완적

⇒ 기존 방법들은 softmax 계산의 복잡도 문제를 완전히 해결하지 못하거나, phrase를 개별 단어의 단순 조합으로만 처리함 → 이 논문은 NEG + subsampling + phrase tokenization을 조합하여 속도와 품질을 동시에 개선

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

Skip-gram 기본 구조

- 중심 단어 w_t 가 주어졌을 때 주변 단어들을 예측하도록 학습 → average log probability 최대화 (Eq. 1)

- 기본 formulation은 softmax로 $p(w_O|w_I)$ 정의 (Eq. 2) → vocabulary 크기 W 에 비례하는 계산 비용 → 비현실적

Hierarchical Softmax

- W 개 output node → $\log_2(W)$ 개만 평가하도록 binary tree 구조 활용 → binary Huffman tree 사용 시 빈도 높은 단어에 짧은 코드 부여, 각 단어 w 는 root에서 leaf까지의 경로로 표현 (Eq. 3)

Negative Sampling (NEG)

NCE를 단순화한 방법 → target word w_O 를 noise distribution $P_n(w)$ 에서 뽑은 k 개의 negative sample과 구별하도록 학습 (Eq. 4)

- small dataset: $k = 5 \sim 20$ / large dataset: $k = 2 \sim 5$
- noise distribution: unigram distribution $U(w)$ 의 $3/4$ 제곱 → $U(w)^{3/4}/Z$ → unigram, uniform distribution보다 모든 task에서 우수
- NCE와의 차이: NCE는 sample + numerical probability of noise distribution 모두 필요 / NEG는 sample만 사용

Subsampling of Frequent Words

- "the", "in", "a" 같은 고빈도 단어는 정보량이 적고, vector representation도 수백만 번 학습 후엔 거의 변하지 않음 → 각 단어 w_i 를 확률 $P(w_i)$ 로 학습에서 제외 (Eq. 5) / threshold $t = 10^{-5}$ 기준으로 빈도가 t 보다 큰 단어를 적극적으로 subsampling

Phrase 표현 학습

- 단어 쌍의 unigram·bigram count 기반 score 계산 (Eq. 6) → score가 threshold 이상인 bigram을 phrase로 처리 / discounting coefficient δ 로 저빈도 단어로만 구성된 phrase 형성 방지 / training data를 decreasing threshold로 2~4회 반복 → 더 긴 phrase 형성 가능

Contribution

- NEG: 기존 hierarchical softmax보다 단순하고 빠르며 고빈도 단어에 더 정확한 벡터 학습
- Subsampling: 학습 속도 수배 향상 + low frequency한 단어 표현 정확도 크게 향상
- Phrase 학습: 수백만 개의 phrase를 단일 토큰으로 처리 → Skip-gram 모델의 표현력 대폭 확장
- Additive Compositionality: $\text{vec}(\text{"Russia"}) + \text{vec}(\text{"river"}) \approx \text{vec}(\text{"Volga River"})$ → 단순 벡터 덧셈이 AND function처럼 작동 (두 context distribution의 product와 관련)

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- 학습 데이터: Google 내부 뉴스 기사 데이터 (1B words), vocabulary 크기 692K (5회 미만 등장 단어 제외)
- Phrase 실험: 동일 뉴스 데이터로 phrase 기반 corpus 구성 / 최대 정확도 실험은 약 33B words 사용

Baseline

- Hierarchical Softmax (HS-Huffman)
- Noise Contrastive Estimation (NCE-5)
- Negative Sampling (NEG-5, NEG-15)

결과

단어 analogy task (Table 1, 300차원, 1B words):

- subsampling 없이: NEG-15가 총 61%로 최고 / HS-Huffman이 47%로 최저
- subsampling ($t=10^{-5}$) 적용 시: 학습 시간 대폭 단축 (NEG-5: 38분 → 14분) + semantic 정확도 크게 향상
- NEG-15 + subsampling: syntactic 61%, semantic 61%, 총 61% → 가장 균형 잡힌 성능
- HS-Huffman + subsampling: semantic 40% → 59%로 큰 폭 향상 → subsampling이 semantic 표현에 특히 효과적

Phrase analogy task (Table 3, 300차원):

- subsampling 없이: NEG-15 27%로 최고
- subsampling 적용 시: HS-Huffman이 47%로 최고 → phrase task에서는 HS + subsampling 조합이 가장 우수
- NEG-15 + subsampling: 42%
- 학습 데이터 33B words + HS + 1000차원 + 전체 문장 context 사용 시 최고 72% 달성

기존 모델과의 비교 (Table 6):

- Collobert (50d, 2달 학습), Turian (200d, 수 주), Mnih (100d, 7일) 대비 Skip-Phrase (1000d, 1일)가 압도적으로 우수한 nearest neighbour 품질
- 30B words 학습에도 불구하고 학습 시간은 기존 모델의 일부에 불과

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- Subsampling이 단순한 아이디어임에도 속도와 정확도를 동시에 잡는다는 점이 흥미로움 → 특히 semantic 표현에서 효과가 두드러짐
- NEG의 단순함 : NCE에서 numerical probability를 제거하고 sample만 사용하도록 단순화했는데 오히려 성능이 더 굿

한계

- word 순서를 여전히 무시 → 어순이 중요한 언어나 문장 수준의 의미 파악에는 한계 O

다른 논문 Intro

[Denoising Diffusion Probabilistic Models]

논문이 다루는 분야

Diffusion Probabilistic Models를 활용한 고품질 샘플 생성 → parameterized Markov chain을 variational inference로 학습하여 데이터 분포와 일치하는 샘플을 생성

동작 방식:

- **Forward process:** 데이터에 Gaussian noise를 점진적으로 추가 → signal이 완전히 파괴될 때까지
- **Reverse process:** 이 noise 추가 과정을 역방향으로 학습 → 샘플링 시 conditional Gaussian으로 설정 가능 → 단순한 neural network parameterization으로 구현 가능

기존 연구의 한계점

- GAN, autoregressive models, flows, VAE 등 다양한 생성 모델들이 이미 고품질 샘플 생성을 달성
- Energy-based model과 score matching도 GAN에 필적하는 이미지 생성 가능
- Diffusion model은 정의하기 쉽고 학습도 효율적이지만 → 고품질 샘플을 생성할 수 있다는 것이 아직 입증되지 않음

논문의 contribution

- **고품질 샘플 생성 입증** → diffusion model이 다른 생성 모델의 published result보다 뛰어난 샘플을 생성할 수 있음을 처음으로 보임
- **새로운 parameterization 발견 및 equivalence 입증** → 특정 parameterization 하에서 diffusion model이 학습 시 multiple noise level에서의 denoising score matching, 샘플링 시 annealed Langevin dynamics와 동치임을 발견 → 이를 primary contribution으로 강조
- **lossless codelength 분석** → 모델의 log likelihood가 다른 likelihood-based 모델 대비 경쟁력 없음을 인정하면서, 그 원인이 사람이 인지하기 어려운 image detail을 표현하는 데 대부분의 codelength가 소모되기 때문임을 분석
- **Progressive decoding 관점 제시** → diffusion model의 샘플링 과정이 autoregressive decoding과 유사한 progressive decoding의 일종임을 보이며, 기존 autoregressive model보다 훨씬 일반화된 bit ordering을 따름을 설명