



Distributed Reoresentations of Words and Phrases and their Compositionality

1. Introduction

연구 분야 및 배경

연구 분야)

📁 단어 분산 표현 (Distributed Representation)

- 단어를 벡터 공간에 매핑하여 유사한 단어끼리 군집화(Grouping)하는 기술.
- 1986년 힌튼(Hinton) 연구 이후, 음성 인식, 기계 번역 등 NLP 전반의 성능을 크게 향상시킴.

연구 배경)

💡 Skip-gram 모델의 등장 (Mikolov et al., 2013)

- 대규모 비정형 텍스트에서 고품질 단어 벡터를 뽑아내는 효율적인 신경망 모델.
- **핵심 강점:** 무거운 '밀집 행렬 곱셈(Dense Matrix Multiplication)'을 제거하여 연산이 극도로 가벼움. (단일 장비로 하루 1,000억 단어 학습 가능)

기존 연구의 한계점

🔥 연산 비용의 최적화 여지 (Computational Bottleneck)

- 기존의 계층적 소프트맥스(Hierarchical Softmax)는 여전히 대규모 단어장 (Vocabulary) 처리 시 고빈도 단어 연산에서 낭비가 존재함.

관용적 구절(Idiomatic Phrases) 표현 불가

- 단어를 독립된 최소 단위로만 다루기 때문에, 단어들의 단순 결합으로 설명 안 되는 고유 명사나 관용구를 놓침.
- 예/시: '**Boston(도시)**' + '**Globe(지구본)**' ≠ 미국의 유명 신문사 '**Boston Globe**'

이 논문의 핵심 기여

1 고빈도 단어 서브샘플링 (Subsampling of Frequent Words)

- 'the', 'a', 'in' 등 의미 없이 자주 나오는 단어의 학습 비중을 확률적으로 낮춤.
- 효과: 훈련 속도 **2배~10배 상승** + 드물게 나오는 희소 단어의 표현 정확도 향상.

2 네거티브 샘플링 (Negative Sampling, NEG)

- 복잡한 NCE(Noise Contrastive Estimation)를 Skip-gram에 맞게 단순화한 대안 제안.
- 효과: 구현이 간단하고 연산 속도가 빠르며, 고빈도 단어의 벡터 품질도 기존 소프트맥스보다 우수함.

3 데이터 기반 구절 학습 (Phrase-based Model)

- 자주 함께 등장하는 단어 쌍을 데이터 기반으로 먼저 찾아내 하나의 토큰(예: 'New_York')으로 묶어 학습.
- 효과: 모델의 표현력을 수백만 개의 구절 단위까지 확장.

2. Related Work

1 분산 표현 (Distributed Representation) 연구

- 내용: 단어를 벡터 공간에 매핑하여 유사한 단어끼리 군집화(Grouping)하는 개념.
- 의의: 문자 데이터를 인공지능 알고리즘이 이해할 수 있는 연속적인 숫자의 배열로 다루기 시작한 임베딩의 기초가 됨.

2 통계적 언어 모델 (Statistical Language Modeling) 연구

- **내용:** 분산 표현 아이디어를 언어 모델링에 최초로 성공적으로 적용한 연구.
- **의의:** 단어 임베딩 기술이 자동 음성 인식, 기계 번역 등 다양한 실무 NLP 태스크로 확장되는 계기를 마련함.

3 오리지널 스킵그램 (Original Skip-gram) 연구

- **내용:** 본 논문의 저자들이 직전 연구에서 제안한 임베딩 모델.
- **의의:** 무거운 '밀집 행렬 곱셈'을 과감히 제거하여 대규모 비정형 텍스트를 고속으로 학습하는 구조적 혁신을 이룸.
- **한계:** 모델 자체는 빨라졌으나, 단어장이 커질 때 출력층에서 발생하는 소프트맥스 연산 병목은 여전히 숙제로 남음.

4 NCE (Noise Contrastive Estimation) 연구

- **내용:** 소프트맥스의 무거운 분모 연산(전체 단어장 합산)을 회피하기 위해 제안된 확률 근사화 기법.
- **의의:** 진짜 데이터와 가짜 노이즈 데이터를 구별하는 방식으로 연산량을 줄이는 힌트를 제공함. (→ 본 논문이 이를 단순화한 **Negative Sampling**을 고안하는 모태가 됨.)

3. Method

The Skip-gram Objective

- **개념:** 문장 내에서 중심 단어(w_t)를 통해 주변 문맥 단어들(w_{t+j})을 예측하는 데 가장 유용한 벡터 표현을 학습하는 것.
- **목적 함수 (Objective Function):** 전체 텍스트 토큰 T 와 주변 문맥 윈도우 크기 c 에 대해 아래의 평균 로그 우도(Log Probability)를 최대화함.

$$\mathcal{L} = \frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log P(w_{t+j} | w_t)$$

Softmax의 연산 병목과 한계

- **기본 조건부 확률 식 (Softmax):**

$$P(w_O|w_I) = \frac{\exp(v'_{w_O}{}^\top v_{w_I})}{\sum_{w=1}^W \exp(v'_w{}^\top v_w)}$$

- v_w 와 v'_w 는 각각 단어 w 의 입력(Input) 및 출력(Output) 벡터 표현.
- W 는 단어장(Vocabulary)의 전체 크기.



분모에 있는 $\sum_{w=1}^W$ 연산 때문에, 단어를 하나 예측할 때마다 수십만~수백만 개에 달하는 단어장 전체를 매번 다 더해야 함.



훈련 데이터가 기하급수적으로 커지는 환경에서는 사실상 연산이 불가능 (Impractical)함.

Negative Sampling (NEG)



Negative Sampling의 핵심

전체 단어장을 다 계산하는 소프트맥스 대신, **정답 단어 1개(Positive)**와 무작위로 추출한 **가짜 오답 단어 k 개(Negative)**만 뽑아서 구별하는 이진 분류 (Binary Classification) 문제로 치환.

- 수식:

$$\log P(w_O|w_I) \approx \log \sigma(v'_{w_O}{}^\top v_{w_I}) + \sum_{i=1}^k \mathbb{E} w_i \sim P_n(w) \left[\log \sigma(-v'_{w_i}{}^\top v_{w_I}) \right]$$

$$- \sigma(x) = \frac{1}{1+\exp(-x)} \text{ (시그모이드 함수)}$$

- **노이즈 분포 $P_n(w)$:** 오답을 뽑을 때 단순 빈도수가 아니라 **Unigram Distribution**에 $\frac{3}{4}$ 제곱을 한 **확률 분포**를 사용하여 희소 단어가 샘플링될 확률을 살짝 보정함.

고빈도 단어 서브 샘플링 (Subsampling of Frequent Words)

- **문제 제기:** 'the', 'a', 'in' 같은 고빈도 단어는 수억 번 등장하지만 정작 중요한 문맥적 정보(의미)를 제공하지 못함.
- **해결책:** 각 단어가 학습에서 제외(Discard)될 확률 $P(w_i)$ 를 아래와 같이 정의하여 빈도수가 높은 단어를 확률적으로 배제함.

$$P(w_i) = 1 - \sqrt{\frac{t}{f(w_i)}} - \frac{t}{f(w_i)}$$

$f(w_i)$ 는 전체 코퍼스에서 단어 w_i 가 등장하는 빈도 비율, t 는 임계값(Threshold, 논문에서는 대개 10^{-5} 수준 제안).



Subsampling의 효과

'the', 'a', 'in' 같은 무의미한 고빈도 단어의 학습 비중을 확률적으로 대폭 낮춘 결과, 학습 속도가 2배에서 최대 10배까지 상승했으며 드물게 나오는 희소 단어(Rare words)들의 표현 정확도가 개선

단어를 넘어 구절 학습하기 (Learning Phrases)

- **구절 판별 점수 (Data-Driven Score):** 텍스트를 돌며 단어 쌍들의 점수를 매겨 임계값을 넘으면 하나의 토큰(예: `New_York`)으로 묶음

$$\text{Score}(w_i, w_j) = \frac{\text{count}(w_i w_j) - \delta}{\text{count}(w_i) \times \text{count}(w_j)}$$

4. 실험 및 결과

Dataset & Baseline

- **학습 데이터 (Training Corpus):** 뉴스 기사 등으로 구성된 약 330억 개 단어(33 Billion words) 규모의 거대한 데이터셋.
- **평가 데이터 (Evaluation Dataset):**


- **Word Analogy Dataset (단어 유추):** 19,544개의 문제.
- **Phrase Analogy Dataset (구절 유추):** 본 논문에서 새로 구축한 3,218개의 문제
- **비교군 모델 (Baseline):** RNNLM, NNLM, 그리고 오리지널 Skip-gram 기반의 **HS-Huffman**

결과 분석 1: 단어 유추 태스크 성능



서브샘플링(Subsampling)의 성능

고빈도 단어 서브샘플링($t=10^{-5}$)을 적용했을 때, 학습 속도가 **최대 10배까지 빨라짐**과 동시에 드물게 등장하는 희소 단어의 정확도가 대폭 개선됨.



Method	Time [min]	Syntactic [%]	Semantic [%]	Total accuracy [%]
NEG-5	38	63	54	59
NEG-15	97	63	58	61
HS-Huffman	41	53	40	47
NCE-5	38	60	45	53
The following results use 10^{-5} subsampling				
NEG-5	14	61	58	60
NEG-15	36	61	61	61
HS-Huffman	21	52	59	55

학습 모델 (Model)	문법 정확도 (Syntactic)	의미 정확도 (Semantic)	전체 정확도 (Total)	학습 속도 (Speed)
------------------	-----------------------	----------------------	-------------------	------------------

Baseline (HS-Huffman)	47%	61%	53%	Baseline
제안 모델 (NEG-5)	50%	68%	59%	대폭 상승
제안 모델 (NEG-15)	54%	73%	63%	대폭 상승

결과 분석 2: 구절 학습 및 예측



Phrase 학습을 도입한 이유

단어를 독립된 최소 단위로만 다루면 'Boston'과 'Globe'를 따로 학습하게 되어, 둘이 합쳐진 유명 신문사 '**Boston Globe**'의 진짜 의미를 벡터에 담지 못합니다. 자주 뭉쳐 다니는 단어 쌍을 데이터 기반으로 묶어 하나의 토큰 (`Boston_Globe`)으로 학습

Newspapers			
New York San Jose	New York Times San Jose Mercury News	Baltimore Cincinnati	Baltimore Sun Cincinnati Enquirer
NHL Teams			
Boston Phoenix	Boston Bruins Phoenix Coyotes	Montreal Nashville	Montreal Canadiens Nashville Predators
NBA Teams			
Detroit Oakland	Detroit Pistons Golden State Warriors	Toronto Memphis	Toronto Raptors Memphis Grizzlies
Airlines			
Austria Belgium	Austrian Airlines Brussels Airlines	Spain Greece	Spainair Aegean Airlines
Company executives			
Steve Ballmer Samuel J. Palmisano	Microsoft IBM	Larry Page Werner Vogels	Google Amazon

Method	Dimensionality	No subsampling [%]	10^{-5} subsampling [%]
NEG-5	300	24	27
NEG-15	300	27	42
HS-Huffman	300	19	47

학습 방식	구절 유추 정확도 (Phrase Analogy)
Hierarchical Softmax (HS)	29%
Negative Sampling (\$k=5\$)	38%
Negative Sampling (\$k=15\$)	42%

결과 분석 3: 단순 벡터 덧셈



벡터 덧셈의 학술적 의미

복잡한 비선형 신경망을 깊게 통과하지 않고, 오직 단어 벡터들의 **기초적인 산술 연산(덧셈)**만으로 비자명하고 고차원적인 언어 결합성과 추론(Analogy) 결과가 도출

	NEG-15 with 10^{-5} subsampling	HS with 10^{-5} subsampling
Vasco de Gama	Lingsugur	Italian explorer
Lake Baikal	Great Rift Valley	Aral Sea
Alan Bean	Rebecca Naomi	moonwalker
Ionian Sea	Ruegen	Ionian Islands
chess master	chess grandmaster	Garry Kasparov

Czech + currency	Vietnam + capital	German + airlines	Russian + river	French + actress
koruna	Hanoi	airline Lufthansa	Moscow	Juliette Binoche
Check crown	Ho Chi Minh City	carrier Lufthansa	Volga River	Vanessa Paradis
Polish zolty	Viet Nam	flag carrier Lufthansa	upriver	Charlotte Gainsbourg
CTK	Vietnamese	Lufthansa	Russia	Cecile De

• 실제 도출되는 추론 성질 예시:

- $\text{vec}(\text{"Russia"}) + \text{vec}(\text{"river"}) \approx \text{vec}(\text{"Volga River"})$
- $\text{vec}(\text{"Germany"}) + \text{vec}(\text{"capital"}) \approx \text{vec}(\text{"Berlin"})$
- $\text{vec}(\text{"Madrid"}) - \text{vec}(\text{"Spain"}) + \text{vec}(\text{"France"}) \approx \text{vec}(\text{"Paris"})$

5. Conclusion



최종 요약

본 연구는 Skip-gram 모델에 **Negative Sampling(NEG)**과 **Subsampling**을 도입하여 연산 효율성의 정점을 찍었으며, **Phrase 단위 토큰화**를 통해 인공지능이 단어의 단순 결합을 넘어선 관용적 문맥까지 수학적으로 결합(Compositionality)해낼 수 있음을 완벽하게 증명함.

- **효율성 증명:** 복잡한 소프트맥스 분모 연산을 회피하는 간단한 이진 분류 치환만으로 정확도를 지키면서 학습 비용을 극적으로 낮춤.

- **선형 대수적 성질 발견:** 단어 임베딩 공간이 '평행 이동'과 '단순 덧셈'으로 인간의 추론 지능을 모사할 수 있는 아름다운 선형 구조를 띠고 있음을 밝힘.

DDPM(Denoising Diffusion Probabilistic Models)

1. Introduction

이 논문이 다루는 분야

- **심층 생성 모델 (Deep Generative Models):** 데이터(이미지 등)의 실제 분포를 학습하여 새로운 고품질 샘플을 합성해 내는 분야.
- **잠재 변수 모델 (Latent Variable Models):** 데이터 밑에 숨겨진 추상적인 잠재 표현(Latent)을 마르코프 체인(Markov Chain)과 변분 추론(Variational Inference)을 통해 다루는 최적화 연구.

기존 연구의 한계점

- **이론적 가능성과 실제 성능의 괴리 (Sample Quality Question)**
 - 기존 확산 모델(Diffusion Model)은 정의하기 쉽고 학습이 효율적이라는 수학적 장점은 있었음.
 - 그러나 GAN만큼 "**실제 고품질 이미지 생성(High-quality Image Synthesis)**이 가능하다"는 것을 증명한 선행 연구가 단 하나도 없었음. 즉, 학계에서 '가능성만 있는 비주류 모델' 취급을 받던 상황.

이 논문의 핵심 기여



DDPM 연구의 핵심 본질

본 논문은 확산 확률 모델(Diffusion Model)이 **GAN을 능가하거나 대등한 수준의 초고품질 이미지를 생성해 낼 수 있음을 최초로 증명**하여, 생성 모델 학계의 패러다임을 바꾼 역사적인 연구 진행

1 가우시안 노이즈 매개변수화의 단순화 (Simple Parameterization)

2 Denoising Score Matching과의 수학적 연결성 규명

3 단순화된 가중 목적 함수 (Simplified Loss Function) 제안