

Denoising Diffusion Probabilistic Models

날짜	2026년 5월 18일
태그	Generative

Paper Review

Denoising Diffusion Probabilistic Models

We present high quality image synthesis results using diffusion probabilistic models, a class of latent variable models inspired by considerations from nonequilibrium thermodynamics. Our best...

 <https://arxiv.org/abs/2006.11239>



Keyword : Image Synthesis, Diffusion Model, Denoising Score Matching

1. Introduction

논문이 다루는 분야

Image Synthesis with Deep Generative Model

- 다양한 데이터 양식에서 고품질 샘플을 합성하는 deep generative model 분야를 다룸
- 기존의 deep generative model(GAN, autoregressive model, flow, VAE)이 고품질 이미지 및 오디오 샘플을 합성해 왔으며, energy-based model과 score matching도 GAN만큼 이미지를 생성하는 수준에 도달함
- 논문은 deep generative model 중에서 **diffusion probabilistic model("diffusion model")**을 다룸
 - **Diffusion model**은 variational inference를 통해 학습되는 parameterized Markov chain으로, 유한 시간 내에 실제 데이터와 일치하는 샘플을 생성
 - 이 chain은 **diffusion process**를 역전시키도록 학습
 - diffusion process : 데이터에 점진적으로 노이즈를 추가해 신호가 완전히 소멸되는 방향으로 작동하는 Markov chain

해당 task에서 기존 연구 한계점

- **Diffusion probabilistic model**은 정의하기 간단하고 학습이 효율적이거나, 고품질 샘플을 생성할 수 있다는 것이 입증되지 않았음

논문의 contributions

- **DDPM**
 - Diffusion model이 **고품질 샘플 생성이 가능함**을 입증하고, 때로는 다른 유형의 생성 모델보다 더 성능이 좋음을 보임
 - Diffusion model의 특정 parameterization이 다중 노이즈 레벨에서의 denoising score matching(학습 시)과 annealed Langevin dynamics(샘플링 시)와 동등함을 보임
 - 이 parameterization에서 최고의 샘플 품질을 달성
 - Log likelihood 한계 : 다른 likelihood 기반 모델 대비 경쟁력 있는 log likelihood를 갖지 못함
 - Lossless codelength의 비효율성 : 모델의 lossless codelength 대부분이 인지할 수 없는 이미지 디테일을 설명하는데 소비됨
 - 이 현상을 lossy compression의 관점에서 분석하고, diffusion model의 샘플링 과정이 autoregressive decoding을 일반화한 progressive decoding의 한 형태임을 보임
- **성과**
 - CIFAR10에서 Inception score 9.46, **SOTA FID score 3.17** 달성

- 256×256 LSUN에서 ProgressiveGAN과 유사한 샘플 품질 달성

2. Related Work

- **Flow, VAE와의 차이** : diffusion model은 유사해 보이지만, forward process q 에 학습 가능한 파라미터가 없고 top-level latent x_T 가 데이터 x_0 와 거의 상호 정보가 없도록 설계됨
- **Denoising score matching과의 연결**
 - ϵ -prediction parameterization이 여러 노이즈 레벨에서의 denoising score matching 및 annealed Langevin dynamics와의 연결을 확립
 - 다만, diffusion model은 straightforward한 log likelihood 평가가 가능하며, variational inference를 통해 Langevin dynamics sampler를 명시적으로 학습
- **기타 관련 연구**
 - **Markov chain 학습의 다른 방법들** : infusion training, variational walkback, generative stochastic networks 등
 - **Energy-based model과의 관계** : score matching과 energy-based modeling의 연결을 통해 energy-based model 관련 연구도 함축
 - **Rate-distortion curve** : annealed importance sampling에서 distortion penalty에 따라 계산하는 방식과 유사
 - **Progressive decoding** : convolutional DRAW 등에서도 확인 가능하며, autoregressive model의 subscale ordering이나 sampling strategy의 더 일반적인 설계로 이어질 수 있음

3. 제안 방법론

Main Idea

Background

Diffusion model은 데이터에 점진적으로 노이즈를 추가하는 forward process를 역전시키는 reverse process를 학습하는 **latent variable model**

- **Diffusion model의 정의**
 - Latent variable model : $p_\theta(\mathbf{x}_0) := \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}$
 - Latent $\mathbf{x}_1, \dots, \mathbf{x}_T$ 는 데이터 $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 와 같은 차원
- **Reverse Process (생성 과정)**
 - Joint distribution $p_\theta(\mathbf{x}_{0:T}) : p(\mathbf{x}_T) = \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$ 에서 시작하는 학습된 Gaussian transition의 Markov chain

$$p_\theta(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$$

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t))$$

⇒ Gaussian 노이즈 $\mathbf{x}_T$ 에서 시작하여, 각 스텝마다 학습된 평균 $\boldsymbol{\mu}_\theta$ 와 분산 $\boldsymbol{\Sigma}_\theta$ 를 가진 Gaussian에서 샘플링하여 한 단계씩 노이즈를 제거하는 과정을 반복하여 최종적으로 데이터 $\mathbf{x}_0$ 를 생성

- **Forward Process (확산 과정)**
 - Approximate posterior $q(\mathbf{x}_{1:T} | \mathbf{x}_0)$: variance schedule $\beta_1, \dots, \beta_T$ 에 따라 데이터에 점진적으로 Gaussian noise를 추가하는 Markov chain

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})$$

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

⇒ 데이터 $\mathbf{x}_0$ 에서 시작하여, 각 step마다 이전 데이터를 $\sqrt{1 - \beta_t}$ 로 스케일링하고 분산 β_t 만큼의 Gaussian 노이즈를 추가

- **Closed-form sampling**

- $\alpha_t := 1 - \beta_t$, $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$ 로 정의하면, 임의의 timestep t 에서 직접 샘플링 가능

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

- **Variational bound**

- 학습은 negative log likelihood의 variational bound를 최적화하여 수행

$$E[-\log p_\theta(x_0)] \leq E_q[-\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)}] =: L$$

- L 을 KL divergence 형태로 다시 쓰면 variance reduction을 통해 추가적인 개선을 얻을 수 있음

$$L = \underbrace{D_{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T))}_{L_T} + \sum_{t>1} \underbrace{D_{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \| p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t))}_{L_{t-1}} - \underbrace{\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}_{L_0}$$

$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 는 $\mathbf{x}_0$ 를 조건으로 하면 tractable

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I})$$

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t$$

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$$

→ 모든 KL divergence가 Gaussian 간의 비교이므로 높은 분산의 Monte Carlo 추정 대신 Rao-Blackwellized closed-form 표현으로 계산 가능

Diffusion models and denoising autoencoders

Diffusion model은 제한된 종류의 latent variable model처럼 보일 수 있지만, 구현에서 많은 자유도를 허용함. Forward process의 **variance** β_t , **모델 구조**, **reverse process의 Gaussian 분포 parameterization**을 선택해야 함. 이를 위해 diffusion model과 denoising score matching 사이의 새로운 명시적 연결을 확립하고, 이를 통해 simplified weighted variational bound objective를 도출함.

Forward Process and L_T

- Forward process의 variance β_t 는 학습하지 않고 **상수로 고정**
→ Approximate posterior q 에 학습 가능한 파라미터가 없으므로 L_T 는 학습 중 상수(무시 가능)

Reverse Process and $L_{1:T-1}$

- **분산 설정**: $\Sigma_\theta(\mathbf{x}_t, t) = \sigma_t^2 \mathbf{I}$ 로 학습하지 않는 시간 의존 상수 설정
 - $\sigma_t^2 = \beta_t$ 와 $\sigma_t^2 = \tilde{\beta}_t$ 둘 다 실험적으로 유사한 성능을 보임
- **평균 $\boldsymbol{\mu}_\theta$ 의 parameterization**
 - $p_\theta(x_{t-1} | x_t) = N(x_{t-1}; \boldsymbol{\mu}_\theta(x_t, t), \sigma_t^2 \mathbf{I})$ 로 설정하면, L_{t-1} 은 다음과 같이 쓸 수 있음

$$L_{t-1} = \mathbb{E}_q \left[\frac{1}{2\sigma_t^2} \|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\|^2 \right] + C$$

- C : θ 에 의존하지 않는 상수
- 가장 직접적인 parameterization은 $\boldsymbol{\mu}_\theta$ 가 forward process posterior mean $\tilde{\boldsymbol{\mu}}_t$ 를 예측하는 것

- **ε-prediction reparameterization**

- $\mathbf{x}_t(\mathbf{x}_0, \epsilon) = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$ ($\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$)으로 reparameterize하고, forward process posterior formula를 적용하면,

$$L_{t-1} - C = \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left\| \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t(\mathbf{x}_0, \epsilon) - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right) - \boldsymbol{\mu}_\theta(\mathbf{x}_t(\mathbf{x}_0, \epsilon), t) \right\|^2 \right]$$

x_t 는 모델에 입력으로 제공되므로 다음과 같이 parameterize 가능

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right)$$

- $\epsilon_\theta : x_t$ 로부터 ϵ 을 예측하도록 의도된 function approximator
- **Sampling** : $\mathbf{x}_{t-1} \sim p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 는 다음을 계산하는 것에 해당

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

- 전체 sampling 절차는 ϵ_θ 를 학습된 data density의 gradient로 사용하는 Langevin dynamics와 유사
- **Denosing score matching과의 연결** : 위의 ε-prediction parameterization에서 L_{t-1} 은 다음과 같이 단순화

$$\mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)} \left\| \epsilon - \epsilon_\theta(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2 \right]$$

- t 로 인덱싱된 여러 노이즈 스케일에서의 denoising score matching과 유사
- 이는 Langevin-like reverse process의 variational bound의 한 항과 구조적으로 동일
- 노이즈를 잘 예측하도록 학습하는 것(denoising score matching)과 reverse process의 sampling 과정을 학습하는 것(variational inference)이 수학적으로 동등

- **Parameterization 요약**

- Reverse process mean μ_θ 를 학습시키는 방법
 - i. $\tilde{\mu}_t$ 를 직접 예측하도록 학습
 - ii. parameterization을 변경하여 ϵ 을 예측하도록 학습
 (x_0 를 예측하는 것도 가능하나, 초기 실험에서 샘플 품질이 떨어짐)
- ε-prediction parameterization은 Langevin dynamics와 유사하며, diffusion model의 variational bound를 denoising score matching과 유사한 objective로 단순화함

Data scaling, reverse process decoder, and L_0

- 이미지 데이터는 $\{0, 1, \dots, 255\}$ 의 정수를 $[-1, 1]$ 로 선형 스케일링
 - 신경망 reverse process가 standard normal prior $p(x_T)$ 에서 시작하여 일관되게 스케일링된 입력에 대해 작동하도록 보장
- Discrete log likelihood를 얻기 위해, reverse process의 마지막 항을 Gaussian $\mathcal{N}(\mathbf{x}_0; \boldsymbol{\mu}_\theta(\mathbf{x}_1, 1), \sigma_1^2 \mathbf{I})$ 에서 유도된 독립적 discrete decoder로 설정

$$p_\theta(\mathbf{x}_0 | \mathbf{x}_1) = \prod_{i=1}^D \int_{\delta_-(x_0^i)}^{\delta_+(x_0^i)} \mathcal{N}(x; \mu_\theta^i(\mathbf{x}_1, 1), \sigma_1^2) dx$$

$$\delta_+(x) = \begin{cases} \infty & \text{if } x = 1 \\ x + \frac{1}{255} & \text{if } x < 1 \end{cases} \quad \delta_-(x) = \begin{cases} -\infty & \text{if } x = -1 \\ x - \frac{1}{255} & \text{if } x > -1 \end{cases}$$

⇒ Reverse process의 마지막 단계에서 모델이 출력한 연속 Gaussian 분포를, 실제 이산 픽셀값에 대한 확률로 변환하는 과정

- D : 데이터의 dimensionality, i : 하나의 좌표를 추출하는 인덱스
- VAE decoder나 autoregressive model에서 사용되는 discretized continuous distribution과 유사
- 이를 통해 데이터에 노이즈를 추가하거나 Jacobian을 포함하지 않고도 discrete data의 lossless codelength가 됨

Simplified training objective

- Variational bound는 미분 가능하고 학습에 바로 사용할 수 있으나, 샘플 품질 향상을 위해(그리고 구현의 단순화를 위해) 다음의 **simplified objective** 사용

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left\| \epsilon - \epsilon_{\theta}(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \epsilon, t) \right\|^2 \right]$$

⇒ Denoising score matching loss에서 시간 의존 가중치를 제거하고 실제 노이즈와 예측 노이즈의 MSE만 남긴 것

- t 는 1과 T 사이에서 균일하게 샘플링
 - $t = 1$ 인 경우 : L_0 에 대응하며, discrete decoder의 적분을 Gaussian 확률 밀도 함수 × bin width로 근사한 것에 해당 (σ_1^2 과 edge effect 무시)
 - $t > 1$ 인 경우 : denoising score matching loss의 unweighted 버전으로, NCSN denoising score matching model에서 사용된 loss weighting과 유사 (L_T 는 forward process variance β_t 가 고정이므로 나타나지 않음)
 - **가중치 제거 효과**
 - 원래 variational bound의 가중치를 제거한 형태로, 작은 t 에 해당하는 loss term을 down-weight하여 신경망이 더 어려운 denoising task(큰 t)에 집중하도록 함
- True variational bound로 학습하면 더 나은 codelength를, simplified objective로 학습하면 더 나은 샘플 품질을 달성

4. 실험 및 결과

실험 설정


- **Diffusion step** : $T = 1000$ (기존 연구와 동일한 평가 횟수)
- **Forward process variance** : $\beta_1 = 10^{-4}$ 에서 $\beta_T = 0.02$ 까지 **선형적으로 증가**
 - 데이터가 $[-1, 1]$ 로 스케일링되었으므로 상대적으로 작은 값으로 설정하여, reverse와 forward process가 거의 동일한 함수 형태를 유지하면서 x_T 의 signal-to-noise ratio를 최대한 작게 유지 ($L_T \approx 10^{-5}$ bits/dim)
- **신경망 구조** : PixelCNN++와 유사한 U-Net backbone
 - Group normalization 사용
 - 시간 정보 t 는 Transformer sinusoidal position embedding으로 네트워크에 전달
 - 16×16 feature map 해상도에서 self-attention 사용
- **CIFAR10 모델** : 35.7M 파라미터, **LSUN/CelebA-HQ 모델** : 114M 파라미터

Sample quality

CIFAR10에서의 Inception score, FID score, negative log likelihood를 기존 모델들과 비교

Table 1: CIFAR10 results. NLL measured in bits/dim.

Model	IS	FID	NLL Test (Train)
Conditional			
EBM [11]	8.30	37.9	
JEM [17]	8.76	38.4	
BigGAN [3]	9.22	14.73	
StyleGAN2 + ADA (v1) [29]	10.06	2.67	
Unconditional			
Diffusion (original) [53]			≤ 5.40
Gated PixelCNN [59]	4.60	65.93	3.03 (2.90)
Sparse Transformer [7]			2.80
PixellQN [43]	5.29	49.46	
EBM [11]	6.78	38.2	
NCSNv2 [56]		31.75	
NCSN [55]	8.87 ± 0.12	25.32	
SNGAN [39]	8.22 ± 0.05	21.7	
SNGAN-DDLS [4]	9.09 ± 0.10	15.42	
StyleGAN2 + ADA (v1) [29]	9.74 ± 0.05	3.26	
Ours (L , fixed isotropic Σ)	7.67 ± 0.13	13.51	≤ 3.70 (3.69)
Ours (L_{simple})	9.46 ± 0.11	3.17	≤ 3.75 (3.72)

Figure 1: Generated samples on CelebA-HQ 256 $\times$ 256 (left) and unconditional CIFAR10 (right)

- DDPM이 **FID 3.17**로 대부분의 기존 모델보다 우수한 샘플 품질 달성
- FID를 test set 기준으로 계산해도 **5.24**로, 여전히 기존 training set FID보다 우수
- True variational bound로 학습하면 더 나은 codelength를, simplified objective로 학습하면 더 나은 샘플 품질을 보임

Reverse process parameterization and training objective ablation

Reverse process의 parameterization 방식($\tilde{\mu}$ prediction vs ϵ prediction)과 training objective(true variational bound vs simplified objective)의 조합이 샘플 품질에 미치는 영향을 비교

Table 2: Unconditional CIFAR10 reverse process parameterization and training objective ablation. Blank entries were unstable to train and generated poor samples with out-of-range scores.

Objective	IS	FID
$\tilde{\mu}$ prediction (baseline)		
L , learned diagonal Σ	7.28 ± 0.10	23.69
L , fixed isotropic Σ	8.06 ± 0.09	13.22
$\ \tilde{\mu} - \tilde{\mu}_\theta\ ^2$	–	–
ϵ prediction (ours)		
L , learned diagonal Σ	–	–
L , fixed isotropic Σ	7.67 ± 0.13	13.51
$\ \tilde{\epsilon} - \epsilon_\theta\ ^2$ (L_{simple})	9.46 ± 0.11	3.17

- $\tilde{\mu}$ prediction (baseline) : true variational bound로 학습할 때만 잘 작동, unweighted MSE(simplified objective와 유사)로는 불안정하고 품질이 나쁜 샘플 생성
- 학습 가능한 diagonal Σ_θ 도입 시, 학습 불안정 및 고정 분산 대비 샘플 품질 저하
- ϵ prediction (제안 방법) : variational bound + fixed variance에서는 $\tilde{\mu}$ prediction과 비슷한 성능, simplified objective에서는 훨씬 우수 (IS 9.46, FID 3.17)

Progressive coding

CIFAR10 모델의 codelength를 분석하고, diffusion model의 압축 특성을 rate-distortion 관점에서 탐구

- Train/test 간 codelength 차이가 최대 0.03 bits/dim으로, 다른 likelihood 기반 모델과 비슷
→ overfitting X
- Lossless codelength는 다른 likelihood 기반 모델 대비 경쟁력이 떨어지지만, 샘플 품질은 우수
→ Diffusion model이 우수한 lossy compressor로서의 inductive bias를 가짐
- 최고 품질 샘플을 가진 CIFAR10 모델 : rate 1.78 bits/dim, distortion 1.97 bits/dim (RMSE 0.95 / [0, 255])
→ lossless codelength의 절반 이상이 인지할 수 없는 distortion을 설명

Progressive lossy compression

Variational bound의 형태를 반영한 progressive lossy code를 도입하여 rate-distortion 동작을 추가 분석




Figure 5: Unconditional CIFAR10 test set rate-distortion vs. time. Distortion is measured in root mean squared error on a [0, 255] scale. See Table 4 for details.

- 시간에 따른 rate-distortion plot에서, rate가 낮은 영역에서 distortion이 급격히 감소 → 대부분의 bit가 인지할 수 없는 distortion에 할당됨

Progressive generation

Random bits로부터 progressive decomposition을 수행하는 progressive unconditional generation




Figure 6: Unconditional CIFAR10 progressive generation ($\hat{x}_0$ over time, from left to right). Extended samples and sample quality metrics over time in the appendix (Figs. 10 and 14).

- Reverse process 진행에 따라 $\hat{x}_0$ 를 예측하면, 대규모 이미지 특징이 먼저, 세부 사항이 나중에 나타남
- 동일한 latent $\mathbf{x}_t$ 에서 조건부 샘플을 생성하면, t 가 작을 때 세부 사항만 다르고, t 가 클 때 대규모 특징만 보존됨 → conceptual compression의 힌트

Connection to autoregressive decoding

- Gaussian diffusion model을 일반화된 bit ordering을 가진 autoregressive model의 일종으로 해석할 수 있음을 보임
 - 특수한 경우(forward process를 좌표별 masking으로 설정)에서 diffusion model 학습이 autoregressive model 학습과 정확히 동일해짐

- Gaussian diffusion 장점
 - Gaussian noise가 masking noise보다 이미지에 더 자연스러워 더 효과적인 inductive bias를 제공할 수 있음
 - Diffusion 길이가 데이터 차원에 제한되지 않아 빠른 샘플링을 위해 짧게, 모델 표현력을 위해 길게 조절 가능

Interpolation

Latent space에서의 이미지 보간이 가능한지 실험




Figure 8: Interpolations of CelebA-HQ 256x256 images with 500 timesteps of diffusion.

- Source 이미지 $\mathbf{x}_0, \mathbf{x}'_0$ 를 q 를 stochastic encoder로 사용하여 latent space에서 선형 보간
 - 서로 다른 λ 값에 대해 노이즈를 고정하여 $\mathbf{x}_t$ 와 $\mathbf{x}'_t$ 가 동일하게 유지되도록 함

$$\mathbf{x}_t, \mathbf{x}'_t \sim q(\mathbf{x}_t | \mathbf{x}_0)$$

$$\bar{\mathbf{x}}_t = (1 - \lambda)\mathbf{x}_t + \lambda\mathbf{x}'_t$$

- 결과
 - 고품질 reconstruction과, 포즈·피부색·헤어스타일·표정·배경 등의 속성이 부드럽게 변화하는 보간 생성 (안경 제외)
 - 큰 t 일수록 더 거친(coarser) 보간, $t = 1000$ 에서는 novel sample

5. 결론

- Diffusion model을 사용하여 고품질 이미지 샘플을 생성할 수 있음을 입증
- Diffusion model과 다음 분야들 사이의 연결을 발견
 - Variational inference를 통한 Markov chain 학습
 - Denoising score matching 및 annealed Langevin dynamics (energy-based model로의 확장 포함)
 - Autoregressive model
 - Progressive lossy compression
- Diffusion model이 이미지 데이터에 대해 우수한 inductive bias를 가지고 있으므로, 다른 데이터 양식이나 다른 유형의 생성 모델 및 머신러닝 시스템의 구성 요소로서의 활용을 기대

Distributed Representations of Words and Phrases and their Compositionality

날짜 2026년 5월 18일

태그 NLP

Paper Review

Distributed Representations of Words and Phrases and their Compositionality

The recently introduced continuous Skip-gram model is an efficient method for learning high-quality distributed vector representations that capture a large number of precise syntactic and semantic...

<https://arxiv.org/abs/1310.4546>



Keyword : Word Embedding, Skip-gram, Negative Sampling, Phrase Representation

1. Introduction

논문이 다루는 분야

Word Representation (Distributed Word Vectors)

- 벡터 공간에서의 단어의 distributed representation은 유사한 단어를 그룹화하여 NLP 태스크에서 학습 알고리즘의 성능을 향상시키는 데 기여
- Word representation의 최초 사용은 1986년 Rumelhart, Hinton, Williams로 거슬러 올라가며, 이후 통계적 언어 모델링, 자동 음성 인식, 기계 번역 등 다양한 NLP 태스크에 성공적으로 적용됨
- 최근 Mikolov et al.이 대규모 비정형 텍스트 데이터로부터 고품질 단어 벡터 표현을 효율적으로 학습하는 **Skip-gram 모델**을 제안
 - 기존 신경망 구조와 달리 dense matrix multiplication이 필요 없어 학습이 매우 효율적 (단일 머신에서 하루에 1000억 단어 이상 학습 가능)
 - 학습된 벡터가 많은 언어적 규칙성과 패턴을 명시적으로 인코딩하며, 이러한 패턴이 선형 변환으로 표현 가능
 - 예시 : $\text{vec}(\text{"Madrid"}) - \text{vec}(\text{"Spain"}) + \text{vec}(\text{"France"}) \approx \text{vec}(\text{"Paris"})$

해당 task에서 기존 연구 한계점

- 기존 Skip-gram 모델은 학습 시 **hierarchical softmax**를 사용했으나, 더 빠른 학습과 빈도 높은 단어에 대한 더 나은 표현이 필요
 - **Word representation의 근본적 한계** : 개별 단어의 조합이 아닌 관용적 표현을 표현할 수 없음
 - 예시 : "Boston Globe"는 신문 이름이지, "Boston"과 "Globe"의 의미를 자연스럽게 조합한 것이 아님
- 단어 벡터 대신 **구(phrase) 전체를 벡터로 표현**해야 Skip-gram 모델의 표현력이 높아짐

논문의 contributions

- **Skip-gram 모델의 여러 확장을 제안**
 - **Subsampling of frequent words** : 학습 중 빈도 높은 단어를 서브샘플링하여 약 2~10배의 속도 향상, 빈도 낮은 단어의 표현 정확도 개선
 - **Negative Sampling (NEG)** : Noise Contrastive Estimation(NCE)의 단순화된 변형으로, 기존의 hierarchical softmax 대비 더 빠른 학습과 빈도 높은 단어에 대한 더 나은 벡터 표현

- **Phrase representation** : data-driven 방식으로 구를 식별한 후, 구를 하나의 토큰으로 취급하여 학습 → 단어 기반에서 구 기반 모델로 확장
 - 구 벡터의 품질 평가를 위해 단어와 구를 모두 포함하는 **analogical reasoning test set** 개발
 - 예시 : "Montreal" : "Montreal Canadiens" :: "Toronto" : "Toronto Maple Leafs"
 - **Compositionality 발견**
 - 단순한 벡터 덧셈으로 의미 있는 결과를 생성할 수 있음
 - 예시 : $\text{vec}(\text{"Russia"}) + \text{vec}(\text{"river"}) \approx \text{vec}(\text{"Volga River"})$, $\text{vec}(\text{"Germany"}) + \text{vec}(\text{"capital"}) \approx \text{vec}(\text{"Berlin"})$
- 기본적인 수학 연산만으로 non-obvious 수준의 언어 이해가 가능함을 시사