



# Distributed Representations of Words and Phrases and their Compositionality

## 1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

## 2. Method

## 3. Experiments

## 4. 결론 (배운점)


## 1. Introduction

### 논문이 다루는 분야

- 벡터 공간에서 단어의 분산 표현
  - nlp task에서 비슷한 단어를 그룹화해 학습 알고리즘의 성능 향상 도움
- 1986 Rumelhart, Hinton, Williams의 단어 표현 초기 사용 연구
  - 이후 통계적 언어 모델링에 성공적으로 적용
  - 후속연구로 자동 음성 인식 및 기계 번역, 광범위 NLP 작업

### 해당 task에서 기존 연구 한계점

- Skip-gram 모델
  - 대량의 비정형 텍스트 데이터로부터 단어의 고품질 벡터 표현을 학습
  - dense matrix multiplication을 포함하지 않아 효율적 학습



- 신경망을 사용하여 계산된 단어 표현은 학습된 벡터가 많은 언어적 규칙성과 패턴을 명시적으로 인코딩 → 선형 변환으로 표현 가능
  - $\text{vec}(\text{"Madrid"}) - \text{vec}(\text{"Spain"}) + \text{vec}(\text{"France"})$ 의 결과는  $\text{vec}(\text{"Paris"})$ 에 가장 가까움

## 논문의 contributions

- 원본 Skip-gram 모델의 여러 확장 제시
  - 훈련 중 frequent word의 하위 샘플링이 속도 향상 가져오고, less frequent word의 표현 정확도를 향상
  - Skip-gram 훈련을 위한 Noise Contrastive Estimation(NCE)의 단순화된 변형 제시
    - 노이즈 대조 추정치는 이전 연구에서 사용된 더 복잡한 계층적 소프트맥스보다 더 빠른 훈련, frequent word에 대한 더 나은 벡터 표현 가능
- 개별 단어의 조합이 아닌 관용구를 표현하는 능력의 한계
  - "Boston Globe"는 신문이므로 "Boston"과 "Globe" 의미의 조합이 X
  - 전체 구문을 나타내는 구문 벡터를 사용하면 표현력이 풍부해짐
- 단어 기반에서 구문 기반 모델로의 확장
  - 데이터 기반 접근 방식으로 많은 수의 구문 식별 → 구문을 개별 토큰으로 취급
  - 구문 벡터의 품질을 평가하기 위해 단어와 구문을 모두 포함하는 유추 추론 작업으로 구성된 테스트 세트 개발
- 단순 벡터 덧셈의 의미있는 결과 생성

- 단어 벡터 표현에 대한 기본적인 수학 연산을 사용해 non-obvious한 수준의 언어 이해를 얻을 수 있음

## 2. Method

### Skip-gram model

- 목표: 문장이나 문서에서 주변 단어를 예측하는 데 유용한 단어 표현 찾기
- 훈련 단어 시퀀스  $w_1, w_2, w_3, \dots, w_T$ 가 주어졌을 때 평균 로그 확률을 최대화하는 것


$$\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j} | w_t)$$

- $c$ =훈련 컨텍스트의 크기(중심 단어  $w_t$ 의 함수일 수 있음)
- $c$ 가 클수록 훈련 예제 많아져 정확도 ↑, 훈련 시간 ↑
- 기본 Skip-gram 공식

- 소프트맥스 함수 사용해  $p(w_{t+j} | w_t)$  정의

$$p(w_O | w_I) = \frac{\exp(v'_w w_O^\top v_{w_I})}{\sum_{w=1}^W \exp(v'_w w^\top v_{w_I})}$$

- $v_w, v'_w = w$ 의 입력 및 출력 벡터 표현,  $W$ =어휘 집합의 단어 수
- $\nabla \log p(w_O | w_I)$ 의 계산 비용이  $W$ 에 비례하기 때문에 비현실적



### Hierarchical Softmax

- 계층적 소프트맥스: 전체 소프트맥스의 계산 효율적 근사
  - 확률 분포를 얻기 위해 약  $\log_2(W)$ 개의 노드만 평가하면 된다는 장점
  - W개의 단어를 앞으로 하는 출력 레이어의 이진 트리 표현을 사용
    - 각 노드에 대해 자식 노드의 상대적 확률을 명시적으로 표현 → 단어에 확률을 부여하는 random walk를 정의
- 
- 각 단어 w는 트리의 루트에서 적절한 경로 통해 도달 가능
  - $n(w, j)$ =루트에서 w까지의 경로 상의 j번째 노드,  $L(w)$ =이 경로의 길이 ( $n(w, 1) = root, n(w, L(w)) = w$ )
  - 임의의 내부 노드 n에 대해  $ch(n)$ =n의 임의로 고정된 자식
  - $[[x]]$ =x가 참이면 1, 거짓이면 -1
- 계층적 소프트맥스는 다음과 같이  $p(w_O|w_I)$  정의
 
$$p(w|w_I) = \prod_{j=1}^{L(w)-1} \sigma \left( [[n(w, j+1) = ch(n(w, j))]] \cdot v' n(w, j)^\top v w_I \right)$$
    - $\sum_{w=1}^W p(w|w_I) = 1$ 임을 확인할 수 있음
      - $\log p(w_O|w_I)$  및  $\nabla \log p(w_O|w_I)$ 의 계산 비용이  $L(w_O)$ 에 비례하고, 평균적으로  $\log W$ 보다 크지 않음 의미
    - Skip-gram의 표준 소프트맥스 공식과는 달리 계층적 소프트맥스 공식은 각 단어 w에 대해 하나의 표현  $v_w$ 와 이진 트리의 모든 내부 노드 n에 대해 하나의 표현  $v'_n$ 을 가짐
  - 이렇게 계층적 소프트맥스에서 사용되는 트리 구조는 성능에 상당한 영향 줌
    - binary Huffman tree 사용 → frequent word에 짧은 코드 할당해 빠른 훈련 가능

## Negative Sampling

- 노이즈 대조 추정(NCE)가 계층적 소프트맥스의 대안으로 소개됨
- Noise Contrastive Estimation(NCE)
  - 좋은 모델이 logistic regression 통해 노이즈로부터 데이터를 구별할 수 있어야 한다 가정
- Skip-gram 모델은 고품질 벡터 표현을 학습하는 것에 집중하므로, 벡터 표현의 품질이 유지되는 한 NCE를 단순할 수 있음

- 목적 함수 네거티브 샘플링(NEG) 정의

$$\log \sigma(v'_{w_O} v_{w_I}) + \sum_{i=1}^k \mathbb{E}_{w_i \sim P_n(w)} [\log \sigma(-v' w_i v_{w_I})]$$

- Skip-gram 목적함수의 모든  $\log P(w_O | w_I)$ 항을 대체하는 데 사용
- 로지스틱 회귀를 사용해 노이즈 분포  $P_n(w)$ 로부터의 샘플로부터 타겟 단어  $w_O$ 를 구분
- 각 데이터 샘플에 대해 k개의 네거티브 샘플이 존재
- NEG와 NCE의 차이점
  - NCE는 샘플과 노이즈 분포의 수치적 확률 모두를 필요로 하지만 네거티브 샘플링은 샘플만 사용
  - NCE는 소프트맥스의 로그 확률을 근사적으로 최대화하지만 이 속성은 본 논문에서의 적용에는 중요 X
- NCE와 NEG 모두 노이즈 분포  $P_n(w)$ 를 자유 매개변수로 가짐

## Subsampling of Frequent Words

- "in", "the", "a"와 같은 frequent word는 매우 큰 말뭉치에서 수억 번 나타날 수 있으나 희귀한 단어보다 정보의 가치가 적은 경우 많음
- 또한 frequent word의 벡터 표현은 수백만 개의 예제에 대해 훈련한 후에도 크게 변하지 않음
- 희귀 단어와 빈번한 단어 간의 불균형을 상쇄하기 위해 서브샘플링 접근 방식 사용
  - 훈련 세트의 각 단어  $w_i$ 는 아래 공식에서 계산된 확률로 폐기됨
 
$$P(w_i) = 1 - \sqrt{\frac{t}{f(w_i)}}$$
    - $f(w_i)$ =단어  $w_i$ 의 빈도,  $t$ =threshold(일반적으로 약  $10^{-5}$ )
  - 빈도의 순위를 유지하면서 임계값  $t$ 보다 높은 빈도의 단어를 서브샘플링
  - 학습 가속화, 희귀 단어의 학습된 벡터 정확도를 향상시킴

## 3. Experiments

### Empirical results

- 계층적 소프트맥스, 노이즈 대조 추정, 네거티브 샘플링 및 훈련 단어의 서브샘플링을 평가
- 유추 추론 작업 사용
  - "Germany" : "Berlin" :: "France" : ? 와 같은 유추로 구성됨
  - 벡터  $x$ 를 찾아  $\text{vec}(x)$ 가 코사인 거리에 따라  $\text{vec}(\text{"Berlin"}) - \text{vec}(\text{"Germany"}) + \text{vec}(\text{"France"})$ 에 가장 가까워지도록 하는 방식으로 해결
    - $x = \text{"Paris"}$ 인 경우 올바르게 답변된 것으로 판단
  - 구문적 유추, 의미적 유추로 나뉨
- Skip-gram 모델 훈련 위해 다양한 뉴스 기사로 구성된 대규모 데이터셋(10억 단어 분량의 내부 Google 데이터셋) 사용
  - 5회 미만으로 발생한 모든 단어 어휘에서 제거 → 총 692K 어휘 크기

| Method                                          | Time [min] | Syntactic [%] | Semantic [%] | Total accuracy [%] |
|-------------------------------------------------|------------|---------------|--------------|--------------------|
| NEG-5                                           | 38         | 63            | 54           | 59                 |
| NEG-15                                          | 97         | 63            | 58           | <b>61</b>          |
| HS-Huffman                                      | 41         | 53            | 40           | 47                 |
| NCE-5                                           | 38         | 60            | 45           | 53                 |
| The following results use $10^{-5}$ subsampling |            |               |              |                    |
| NEG-5                                           | 14         | 61            | 58           | 60                 |
| NEG-15                                          | 36         | 61            | 61           | <b>61</b>          |
| HS-Huffman                                      | 21         | 52            | 59           | 55                 |

- 유추 추론 작업에서 네거티브 샘플링이 계층적 소프트맥스, 노이즈 대조 추정보다 우수
- 빈번한 단어의 서브샘플링은 훈련 속도 향상, 단어 표현 더 정확하게 만듦
- 또한 선형적 특성 지닌 Skip-gram 모델 뿐 아니라 비선형 모델에서도 학습 과정에서 단어 간의 관계를 포착하는 데 있어서는 결국 선형적인 구조가 중요하거나 유리하게 작용한다는 것을 시사 → 단어의 의미와 관계를 잘 나타내기 위해서는 벡터 표현 자체가 선형적인 규칙성을 갖도록 학습되는 것이 중요하다

## Learning Phrases

- 구문에 대한 벡터 표현 학습 위해 먼저 함께 자주 나타나고 다른 맥락에서는 드물게 나타나는 단어를 찾음
- 어휘 크기를 크게 늘리지 않고도 많은 구를 형성할 수 있음

- 유니그램 및 바이그램 빈도에 기반해 구가 형성되는 간단한 데이터 기반 접근 방식을 사용

$$\text{score}(w_i, w_j) = \frac{\text{count}(w_i w_j) - \delta}{\text{count}(w_i) \times \text{count}(w_j)}.$$

- $\delta$  = discounting coefficient, 매우 흔한 단어로 구성된 너무 많은 구의 형성 방지
- 선택된 임계값보다 높은 점수 가진 바이그램은 구로 사용됨

| Newspapers                           |                                          |                             |                                           |
|--------------------------------------|------------------------------------------|-----------------------------|-------------------------------------------|
| New York<br>San Jose                 | New York Times<br>San Jose Mercury News  | Baltimore<br>Cincinnati     | Baltimore Sun<br>Cincinnati Enquirer      |
| NHL Teams                            |                                          |                             |                                           |
| Boston<br>Phoenix                    | Boston Bruins<br>Phoenix Coyotes         | Montreal<br>Nashville       | Montreal Canadiens<br>Nashville Predators |
| NBA Teams                            |                                          |                             |                                           |
| Detroit<br>Oakland                   | Detroit Pistons<br>Golden State Warriors | Toronto<br>Memphis          | Toronto Raptors<br>Memphis Grizzlies      |
| Airlines                             |                                          |                             |                                           |
| Austria<br>Belgium                   | Austrian Airlines<br>Brussels Airlines   | Spain<br>Greece             | Spainair<br>Aegean Airlines               |
| Company executives                   |                                          |                             |                                           |
| Steve Ballmer<br>Samuel J. Palmisano | Microsoft<br>IBM                         | Larry Page<br>Werner Vogels | Google<br>Amazon                          |

- 구를 포함하는 새로운 유추 추론 작업을 사용해 구 표현의 품질 평가

## • 구 Skip-gram 결과

| Method     | Dimensionality | No subsampling [%] | $10^{-5}$ subsampling [%] |
|------------|----------------|--------------------|---------------------------|
| NEG-5      | 300            | 24                 | 27                        |
| NEG-15     | 300            | 27                 | 42                        |
| HS-Huffman | 300            | 19                 | 47                        |

- 네거티브 샘플링은  $k=15$  사용시 더 나은 성능 달성
  - 계층적 소프트맥스는 빈번한 단어를 다운샘플링했을때 가장 좋은 성능
- ⇒ 하위 샘플링이 더 빠른 훈련으로 이어질 수 있고, 정확도 향상시킬 수 있음
- 훈련 데이터의 양 늘렸을 때 72%, 줄였을 때 66% 정확도
- ⇒ 대량의 훈련 데이터가 중요

|               | NEG-15 with $10^{-5}$ subsampling | HS with $10^{-5}$ subsampling |
|---------------|-----------------------------------|-------------------------------|
| Vasco de Gama | Lingsugur                         | Italian explorer              |
| Lake Baikal   | Great Rift Valley                 | Aral Sea                      |
| Alan Bean     | Rebecca Naomi                     | moonwalker                    |
| Ionian Sea    | Ruegen                            | Ionian Islands                |
| chess master  | chess grandmaster                 | Garry Kasparov                |

- 다른 모델들이 학습한 표현이 얼마나 다른지에 대해 알아보기 위해 다양한 모델 사용해 빈도가 낮은 구문의 nearest neighborhood 조사
  - 계층적 소프트맥스와 서브샘플링 사용하는 모델이 구문의 최적 표현을 학습

### Additive Compositionality

- Skip-gram 모델이 학습한 단어 및 구문 표현은 벡터 연산을 통해 정밀한 유추 추론을 가능하게 하는 선형 구조 나타냄
- Skip-gram 표현은 벡터 표현의 요소별 덧셈을 통해 단어들을 의미 있게 결합할 수 있게 하는 또 다른 종류의 선형 구조를 나타냄

| Czech + currency | Vietnam + capital | German + airlines      | Russian + river | French + actress     |
|------------------|-------------------|------------------------|-----------------|----------------------|
| koruna           | Hanoi             | airline Lufthansa      | Moscow          | Juliette Binoche     |
| Check crown      | Ho Chi Minh City  | carrier Lufthansa      | Volga River     | Vanessa Paradis      |
| Polish zolty     | Viet Nam          | flag carrier Lufthansa | upriver         | Charlotte Gainsbourg |
| CTK              | Vietnamese        | Lufthansa              | Russia          | Cecile De            |

- 벡터의 additive property
  - 단어 벡터는 소프트맥스 비선형 함수의 입력과 선형 관계
  - 단어 벡터는 문장에서 주변 단어 예측하도록 훈련됨 → 벡터는 단어가 나타나는 문맥의 분포를 나타내는 것
  - 이 값들이 출력층에서 계산된 확률에 로그적으로 관련되어 있으므로 두 단어 벡터의 합은 두 문맥 분포의 곱과 관련 있음
    - 곱은 여기서 AND 함수 역할 — 두 단어 벡터 모두에 의해 높은 확률인 언어는 높은 확률, 다른 단어들은 낮은 확률 가질 것
    - “Volga River”가 “Russia”와 “River”라는 단어와 함께 같은 문장에 자주 나타난다면 두 단어 벡터의 합은 “Volga River”의 벡터와 가까운 특징 벡터 결과로 낼 것

### Comparison to Published Word Representation

| Model<br>(training time)      | Redmond                                          | Havel                                                       | ninjutsu                               | graffiti                           | capitulate                                  |
|-------------------------------|--------------------------------------------------|-------------------------------------------------------------|----------------------------------------|------------------------------------|---------------------------------------------|
| Collobert (50d)<br>(2 months) | conyers<br>lubbock<br>keene                      | plauen<br>dzerzhinsky<br>osterreich                         | reiki<br>kohona<br>karate              | cheesecake<br>gossip<br>dioramas   | abdicate<br>accede<br>rearm                 |
| Turian (200d)<br>(few weeks)  | McCarthy<br>Alston<br>Cousins                    | Jewell<br>Arzu<br>Ovitz                                     | -<br>-<br>-                            | gunfire<br>emotion<br>impunity     | -<br>-<br>-                                 |
| Mnih (100d)<br>(7 days)       | Podhurst<br>Harlang<br>Agarwal                   | Pontiff<br>Pinochet<br>Rodionov                             | -<br>-<br>-                            | anaesthetics<br>monkeys<br>Jews    | Mavericks<br>planning<br>hesitated          |
| Skip-Phrase<br>(1000d, 1 day) | Redmond Wash.<br>Redmond Washington<br>Microsoft | Vaclav Havel<br>president Vaclav Havel<br>Velvet Revolution | ninja<br>martial arts<br>swordsmanship | spray paint<br>grafitti<br>taggers | capitulation<br>capitulated<br>capitulating |

- 단어 유추 과제에서 기존 모델들과의 단어 표현 평가 비교
  - Skip-gram 모델이 압도적인 성능으로 최고 달성
- 학습된 벡터 품질의 차이에 대해 알기 위해 빈도가 낮은 단어의 최근접 이웃 제시해 비교
  - 대규모 코퍼스에서 훈련된 큰 Skip-gram 모델이 학습된 표현의 품질 면에서 다른 모델보다 우수
    - 약 300억개의 단어로 훈련되었기 때문, 이 Skip-gram 모델의 훈련 데이터셋은 훨씬 크지만 훈련 시간은 이전 모델 구조에 필요한 시간 복잡도의 극히 일부

## 4. 결론 (배운점)

### Contribution

- Skip-gram 모델을 사용해 단어와 구의 분산 표현 훈련 방법 제시
  - 이러한 표현이 정확한 유추 추론을 가능하게 하는 선형 구조 나타냄 입증
  - 이 논문에서 소개한 기법들은 continuous bag-of-words 모델 훈련에도 사용 가능
- 효율적인 모델 아키텍처로 이전 모델들보다 몇 배 더 큰 규모의 데이터로 모델 성공적으로 훈련
  - 희귀 개체에 대해 학습된 단어 및 구 표현의 품질에서 큰 향상 가져옴
  - 모델 아키텍처의 선택, 벡터의 크기, 서브 샘플링 비율, 훈련 창 크기가 성능에 중요한 영향 미침
- 빈번한 단어의 서브샘플링이 훈련 속도를 높이고 드물게 사용되는 단어의 표현을 개선한다는 것 발견
- 네거티브 샘플링 알고리즘 제시 — 빈번한 단어에 대해 정확한 표현 학습하는 훈련 방법

- 단어 벡터가 단순한 벡터 덧셈을 사용해 의미 있게 결합됨, 구를 단일 토큰으로 단순히 표현  
⇒ 최소한의 계산 복잡도로 긴 텍스트 조각 표현 가능
- 기존의 재귀적 행렬-벡터 연산을 사용해 구를 표현하는 접근 방식과 상호보완적



- 단어 벡터 공간에서 선형적인 연산(덧셈, 뺄셈)만으로도 복잡한 의미 관계(유추, 구성성)를 탐색할 수 있다는 점이 흥미로웠다.
- 구문을 학습하기 위해 구문을 하나의 토큰으로 취급하는 방식을 사용하기 때문에 구문의 내부 의미 구조를 직접적으로 모델링하는 것은 아니라는 점이 아쉬웠다.



# Denoising Diffusion Probabilistic Models

## 1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

## 1. Introduction

### 논문이 다루는 분야

- 딥 생성 모델
  - 최근 다양한 양식의 데이터에서 고품질 샘플 보여줌
  - GAN, autoregressive model, flows, VAE — 이미지와 오디오 샘플 합성, 에너지 기반 모델링 및 점수 매칭 분야의 발전으로 GAN과 비교할 만한 이미지 생성

### 해당 task에서 기존 연구 한계점

- 확산 모델
  - 유한한 시간 후에 데이터와 일치하는 샘플을 생성하기 위해 변분 추론(variational inference)으로 학습된 매개변수화된 Markov chain
  - 체인의 전이는 확산 과정을 역으로 학습
    - 확산 과정은 샘플링의 반대방향으로 데이터에 점진적으로 노이즈를 추가하여 신호가 파괴될 때까지 진행되는 Markov chain
    - 확산이 소량의 가우시안 노이즈로 구성될 때, 샘플링 체인 전환을 조건부 가우시안으로 설정, 간단한 신경망 파라미터화를 가능하게 함
- 확산모델은 고품질 샘플을 생성할 수 있다는 사실 입증 X

### 논문의 contributions

- 확산 확률 모델(diffusion probabilistic models)의 발전 제시

- 이 논문에서는 확산 모델이 실제로 고품질 샘플을 생성할 수 있으며, 때로는 다른 유형의 생성 모델의 결과보다 더 나은 성능 보인다는 것 보여줌
- 확산 모델의 특정 매개변수화가 학습 중 다중 노이즈 레벨에서의 denoising score matching 및 샘플링 중 annealed Langevin dynamics과의 동등성 드러낸다는 사실 보여줌
  - 이 매개변수화를 이용해 최고의 샘플 품질 결과 얻음
- 이 모델은 다른 확률 기반 모델에 비해 경쟁력 있는 log likelihood 갖지 않음
  - 모델의 무손실 코딩 길이(lossless codelengths)의 대다수가 감지할 수 없는 이미지 세부 사항을 설명하는 데 소비됨
  - 손실 압축(lossy compression)의 관점으로 이 현상에 대한 분석 제시
  - 확산 모델의 샘플링 절차가 autoregressive 모델로 일반적으로 가능한 것을 크게 일반화하는 비트 순서를 따른 것과 유사한 비트 순서를 따라 progressive decoding의 한 유형임을 보여줌