

# Swin Transformer: Hierarchical Vision Transformer using Shifted Windows

≡ type

## 1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가  
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

### 논문이 다루는 분야

Transformer를 NLP가 아닌 computer vision의 **general-purpose backbone**으로 확장하는 것 → image classification, object detection, semantic segmentation 등 다양한 vision task에 범용적으로 적용 가능한 구조 제안

### 해당 task에서 기존 연구 한계점

Transformer를 vision에 적용할 때 근본적인 문제

1. **Scale 문제** : NLP의 word token은 고정된 크기인데 visual entity는 scale이 다양함  
→ 기존 ViT처럼 fixed scale token을 쓰면 object detection 같은 task에 부적합
2. **해상도 문제** : 이미지의 pixel 해상도는 text보다 훨씬 높음 → global self-attention은 token 수에 대해 **quadratic complexity** → 고해상도 이미지에서 semantic segmentation 같은 dense prediction task에 적용 불가능

### 논문의 contributions

- **Hierarchical feature map 구조** → 작은 patch에서 시작해서 deeper layer로 갈수록 neighboring patch를 merge → FPN, U-Net 같은 dense prediction 기법과 자연스럽게 호환
- **Shifted Window based Self-Attention** → self-attention을 non-overlapping local window 내에서만 계산 → **image size에 대해 linear complexity** 달성 + 연속된 layer에서 window를 shift하여 cross-window connection 확보

- 광범위한 task에서 SOTA 달성 → ImageNet-1K top-1 87.3%, COCO test-dev 58.7 box AP / 51.1 mask AP (+2.7/+2.6 over previous SOTA), ADE20K 53.5 mIoU (+3.2 over previous SOTA)
- All-MLP architecture에도 적용 가능 → hierarchical design + shifted window 방식이 Transformer 구조 외에도 범용적으로 유효함을 입증

## 2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가  
제안 방법의 차별성을 어떻게 표현하고 있는가

- **CNN and variants** : AlexNet부터 VGG, ResNet, DenseNet, EfficientNet까지 vision backbone의 표준이었음 → depthwise convolution, deformable convolution 같은 개별 layer 개선도 이어졌지만 Transformer 기반 unified modeling의 가능성을 열기엔 한계
- **Self-attention based backbone** : ResNet의 spatial convolution layer 일부를 self-attention으로 교체한 시도 → local window 내에서 self-attention 계산으로 accuracy/FLOPs는 비슷하지만 **costly memory access로 실제 latency가 conv 대비 훨씬 큼** → Swin은 sliding window 대신 layer 간 window를 shift하는 방식으로 hardware 효율 개선
- **Self-attention/Transformer to complement CNNs** : CNN backbone에 self-attention이나 Transformer를 보완적으로 추가하는 연구들 / encoder-decoder Transformer를 object detection, instance segmentation에 적용 → Swin은 이런 연구들과 상호 보완적이며 basic visual feature extraction에 집중
- **ViT and follow-ups** : ViT는 non-overlapping medium-sized patch에 Transformer를 직접 적용 → image classification에서 좋은 speed-accuracy tradeoff / 하지만 **single resolution feature map + quadratic complexity** → dense vision task나 고해상도 입력에 부적합 / DeiT는 ImageNet-1K만으로 ViT를 효과적으로 학습하는 training strategy 제안 / 일부 concurrent work은 ViT를 dense task에 적용하려 했지만 deconvolution으로 hierarchical feature를 억지로 만들어야 해서 성능이 낮음

⇒ 논문의 차별성 : 기존 ViT 계열은 single resolution + quadratic complexity → dense prediction task에 구조적으로 부적합 / Swin은 hierarchical feature map + linear complexity를 동시에 달성 + shifted window로 cross-window connection까지 확보 → general-purpose backbone으로서의 조건을 모두 충족

### 3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가  
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가  
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

#### Main Idea

##### 1. Overall Architecture

입력 이미지를  $4 \times 4$  non-overlapping patch로 분할 → 각 patch를 token으로 취급  
(feature dim =  $4 \times 4 \times 3 = 48$ ) → Linear Embedding으로 dimension C로 projection  
4개의 Stage로 구성:

- Stage 1:  $H/4 \times W/4$  token, dimension C
- Stage 2~4: Patch Merging으로  $2 \times 2$  neighboring patch를 concat → 해상도  $2 \times$  감소, dimension  $2 \times$  증가
- 최종적으로  $H/4, H/8, H/16, H/32$  의 **hierarchical feature map** 생성 → VGG, ResNet과 동일한 해상도 구성 → 기존 방법의 backbone을 그대로 교체 가능

##### 2. Shifted Window based Self-Attention

기존 global self-attention의 quadratic complexity 문제 해결:

- **W-MSA (Window Multi-head Self-Attention):** 이미지를  $M \times M$  (default  $M=7$ ) non-overlapping window로 분할 후 각 window 내에서만 self-attention 계산
  - $\Omega(\text{MSA}) = 4hwC^2 + 2(hw)^2C \rightarrow$  patch 수에 quadratic
  - $\Omega(\text{W-MSA}) = 4hwC^2 + 2M^2hwC \rightarrow M$  고정 시 **image size에 linear**
- **SW-MSA (Shifted Window MSA):** window-based self-attention은 window 간 연결이 없어 modeling power 제한 → 연속된 layer에서 window partition을  $(\lfloor M/2 \rfloor, \lfloor M/2 \rfloor)$  pixel shift → 이전 layer의 window 경계를 crossing하는 새로운 window 형성 → cross-window connection 달성
- **Efficient batch computation:** shift 후 window 수 증가 문제 → cyclic shift (top-left 방향으로 이동) + masking mechanism으로 window 수를 regular partitioning과 동일하게 유지 → latency overhead 최소화

- **Relative position bias:** attention 계산 시 각 head에 relative position bias B 추가 →  $\text{Attention}(Q, K, V) = \text{SoftMax}(QK^T/\sqrt{d} + B)V$  / absolute position embedding 대비 image classification, object detection, semantic segmentation 모두에서 성능 향상 / absolute position embedding 추가 시 오히려 dense task에서 성능 하락

### 3. Architecture Variants

- Swin-T: C=96, layers={2,2,6,2} → ResNet-50 수준 complexity
- Swin-S: C=96, layers={2,2,18,2} → ResNet-101 수준
- Swin-B: C=128, layers={2,2,18,2} → ViT-B/DeiT-B 수준
- Swin-L: C=192, layers={2,2,18,2} → Swin-B의 2× complexity

## Contribution

- Hierarchical feature map + linear complexity를 동시에 달성한 최초의 Transformer backbone
- Shifted window로 cross-window connection을 효율적으로 구현 → sliding window 대비 4.1×(Swin-T 기준) 빠른 속도, 유사한 modeling power
- Relative position bias가 absolute position embedding보다 일관되게 우수 → 특히 dense prediction task에서
- Hierarchical design + shifted window가 Transformer 외 all-MLP 구조에도 범용적으로 적용 가능성을 입증

## 4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

## Dataset

- ImageNet-1K (1.28M training images, 50K val, 1000 classes)
- ImageNet-22K (14.2M images, 22K classes) — pre-training용
- COCO 2017 (118K train, 5K val, 20K test-dev) — object detection & instance segmentation
- ADE20K (25K images, 150 semantic categories) — semantic segmentation

## Baseline

- Transformer 계열: ViT, DeiT
- ConvNet 계열: ResNet, ResNeXt, RegNet, EfficientNet
- Segmentation: SETR, DeiT+deconvolution, ResNeSt 기반 DeepLabV3+

## 결과

### ImageNet-1K Image Classification (Table 1):

- Swin-T (81.3%) vs DeiT-S (79.8%) → **+1.5%**, 유사한 complexity
- Swin-B (83.3%) vs DeiT-B (81.8%) → **+1.5%**, 유사한 complexity
- RegNet, EfficientNet 대비 slightly better speed-accuracy tradeoff
- ImageNet-22K pre-training: Swin-B **86.4%** (ViT-B 84.0% 대비 +2.4%, 유사한 throughput), Swin-L **87.3%**

### COCO Object Detection & Instance Segmentation (Table 2):

- Swin-T vs ResNet-50 (Cascade Mask R-CNN): **+3.4~4.2 box AP** 향상
- Swin-B vs ResNeXt-101-64×4d: **+3.6 box AP, +3.3 mask AP** (유사한 model size, FLOPs, latency)
- System-level SOTA: Swin-L (HTC++) **58.7 box AP, 51.1 mask AP** → Copy-paste 대비 +2.7 box AP, DetectoRS 대비 +2.6 mask AP
- DeiT-S 대비 Swin-T: **+2.5 box AP, +2.3 mask AP** + 더 빠른 inference (15.3 FPS vs 10.4 FPS)

### ADE20K Semantic Segmentation (Table 3):

- Swin-S vs DeiT-S: **+5.3 mIoU** (유사한 computation cost)
- Swin-L (ImageNet-22K pretrain): **53.5 mIoU** → SETR 대비 **+3.2 mIoU** (더 작은 model size)

### Ablation (Table 4):

- Shifted window 제거 시: ImageNet -1.1%, COCO -2.8 box AP/-2.2 mask AP, ADE20K -2.8 mIoU → shifted window의 효과 명확
- Relative position bias vs no position: +1.2% (ImageNet), +1.3 box AP (COCO), +2.3 mIoU (ADE20K)
- Absolute position embedding 추가 시: ImageNet +0.4%지만 COCO -0.2 box AP, ADE20K -0.6 mIoU → dense task에서 오히려 해로움

## 5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

### 의의

- ViT의 한계였던 single resolution, quadratic complexity를 한 번에 해결하고 CNN backbone을 완전히 대체할 수 있는 구조를 만들었다는 것 → vision과 language의 unified modeling 가능성을 열었다는 의의
- Relative position bias가 absolute position embedding보다 일관되게 낫다는 실험 결과 → translation invariance의 중요성을 dense task에서 다시 확인한 점이 흥미로움

### 한계

- Window size M이 고정된  $7 \times 7$  → 다양한 scale의 물체를 하나의 window 내에서 처리하기 어려울 수 있음. 특히 window보다 훨씬 큰 물체는 여러 window에 걸쳐 있어 정보가 분산될 수 있지 않을까...?

## 다른 논문 Intro

### [GAN : Generative Adversarial Networks]

### 논문이 다루는 분야

자연 이미지, 음성, 자연어 같은 AI 데이터의 확률 분포를 학습하는 **deep generative model** → 기존 deep learning의 성공은 주로 discriminative model(입력 → class label 매핑)에 집중되어 있었고, generative model은 상대적으로 발전이 더뎠음

### 해당 task에서 기존 연구 한계점

기존 deep generative model의 두 가지 문제:

1. **Maximum likelihood estimation** 과정에서 intractable한 확률 계산 근사의 어려움
2. **Piecewise linear unit(ReLU 등)의 장점을 generative context에서 활용하기 어려움** → discriminative model에서는 잘 작동하는 backpropagation + dropout + piecewise linear unit 조합을 generative model에 그대로 적용하기 어려웠음

### 논문의 contributions

위 두 문제를 모두 회피하는 새로운 생성 모델 학습 방식 제안 → **Adversarial Nets Framework**

- **Generative model (위조지폐범):** 가짜 샘플을 생성해서 discriminator를 속이려 함
- **Discriminative model (경찰):** 샘플이 실제 데이터 분포에서 왔는지, 모델 분포에서 왔는지 구별하려 함
- 두 모델이 경쟁하면서 함께 학습 → 위조품이 진품과 구별 불가능한 수준에 도달할 때까지

특히 이 논문에서 다루는 special case인 **adversarial nets:**

- Generator: random noise → MLP 통과 → 샘플 생성
- Discriminator: MLP 구조
- **backpropagation + dropout만으로 두 모델을 동시에 학습 가능** → approximate inference나 Markov chain 불필요