



Generative Adversarial Nets

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

Contribution

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

Swin Transformer: Hierarchical Vision Transformer using Shifted Windows

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

1. Introduction

논문이 다루는 분야

- 인공지능 응용 분야에서 접하는 자연 이미지, 음성 파형, 자연어 기호 등의 데이터가 가지는 확률 분포를 표현하는 생성 모델 추정 프레임워크 연구
- 두 개의 신경망(생성 모델과 판별 모델)을 Adversarial process를 통해 동시에 훈련시키는 새로운 딥러닝 방법론

해당 task에서 기존 연구 한계점

- 기존 딥러닝은 고차원의 풍부한 감각 입력을 클래스 레이블로 매핑하는 판별 모델에서는 큰 성공을 거두었으나, 생성 모델에서는 그 성과가 제한적이었음
- 기존 생성 모델들은 Maximum likelihood estimation이나 관련 전략에서 발생하는 확률적 연산이 다루기 매우 까다로운 구조적 한계를 가짐

- 또한, 기존 모델들은 딥러닝에서 큰 성공을 거둔 조각 선형 단위의 이점을 생성 모델의 맥락에서 효과적으로 활용하는 데 어려움을 겪음

논문의 contributions

- 데이터 분포를 포착하는 생성 모델(G)과 샘플이 G가 아닌 실제 훈련 데이터에서 나왔을 확률을 추정하는 판별 모델(D)을 동시에 훈련하는 적대적 신경망 프레임워크를 제안함
- 이 훈련 과정은 두 플레이어 간의 최소최대 게임과 일치하며, G와 D가 임의의 함수 공간에 있을 때 G가 훈련 데이터 분포를 완벽히 복원하고 D가 모든 곳에서 1/2가 되는 고유한 해가 존재함을 이론적으로 입증함
- G와 D가 다층 퍼셉트론으로 정의될 경우, 복잡한 마르코프 체인이나 근사 추론 네트워크 없이 오직 순전파와 역전파 알고리즘만으로 전체 시스템을 훈련하고 새로운 샘플을 생성할 수 있음을 증명함

2. Related Work

1) Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가

- **Directed graphical models**
잠재 변수를 가지는 전통적인 대안 모델들(Deep belief networks, Deep Boltzmann machines 등)은 확률적 계산이 다루기 매우 까다로워 근사 추론이 필수적이라는 한계를 서술함
- **Boltzmann machines**
MCMC(Markov Chain Monte Carlo)와 같은 샘플링 방식에 크게 의존하여 연산 비용이 높고 훈련이 매우 어렵다고 지적함
- **Score matching 및 NCE (Noise-Contrastive Estimation)**
데이터의 확률 밀도 자체를 학습하려 하지만, 여전히 다루기 힘든 정규화 상수를 처리해야 하는 근본적인 어려움이 존재한다고 설명함
- **오토인코더 계열**
VAE(Variational Autoencoder) 등은 근사치 최적화를 사용하므로, 복잡한 데이터 분포를 완벽하게 모사하는 데 구조적인 한계가 있음을 간접적으로 시사함

2) 제안 방법의 차별성을 어떻게 표현하고 있는가

- **마르코프 체인(Markov chains) 완전 배제:** 훈련(Training)과 생성(Generation)의 모든 과정에서 MCMC 연산이나 복잡한 샘플링 기법이 전혀 필요 없음을 가장 큰 구조적 차별점으로 강조함
- **근사 추론의 불필요:** 판별 모델과 생성 모델 모두 오직 순전파와 역전파, Dropout만으로 훈련될 수 있는 극강의 단순성을 내세움

- **간접적인 분포 업데이트:** G가 데이터의 확률 분포를 명시적으로 계산하거나 모델링하지 않고, D를 속이는 과정(Gradients from D)을 통해서만 간접적으로 업데이트됨으로써 기존의 다루기 힘든 확률 연산을 완전히 우회했음을 어필함
- **Piecewise linear units의 적극적 활용:** G와 D 모두 다층 퍼셉트론으로 구성되어, 기존 생성 모델에서는 활용하기 어려웠던 ReLU(Rectified Linear Unit) 등의 강력한 비선형 활성화 함수를 마음껏 사용하여 표현력을 극대화할 수 있음을 강조함

3. 제안 방법론

Main Idea

- 생성 모델(Generator, G)과 판별 모델(Discriminator, D)을 모두 Multilayer Perceptron으로 구성하여 데이터 공간을 학습하는 적대적 체계를 구축함
- 무작위 노이즈 분포 $p_z(z)$ 로부터 샘플링된 변수를 실제 데이터 공간으로 매핑하는 함수 $G(z; \theta_g)$ 를 정립함
- 입력 샘플 x 가 생성된 가짜 분포 p_g 가 아닌 실제 데이터 분포 p_{data} 에서 나왔을 확률을 단일 스칼라값으로 도출하는 함수 $D(x; \theta_d)$ 를 정의함
- 가치 함수(Value Function) $V(D, G)$ 에 대해 D는 진짜와 가짜를 완벽히 구별하도록 극대화(Maximization)하고, G는 D의 오답률을 높이도록 극소화(Minimization)하는 Minimax Game 목적 함수를 설계함

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))].$$

Contribution

- **서론과의 정합성 유지**
서론에서 예고한 'Markov chain이나 복잡한 추론 네트워크 없이 복격적인 순전파(Forward)와 역전파(Backpropagation)만으로 생성 모델 학습이 가능하다'는 개념이 구체적인 아키텍처 매핑을 통해 일관되게 전개됨
- **이점 검증의 기술적 근거 확보**
학습 초기 단계에서 G가 겪는 수렴 정체 문제를 해결할 수 있는 수식 변환 기법과 목적 함수의 재정의 근거를 논리적으로 명확히 규명함
- **구현 가능한 알고리즘 명시**
전체 학습 메커니즘을 담은 상세한 의사코드(Algorithm 1)를 통해 D를 k단계 학습시키

는 동안 G를 1단계 학습시키는 미니배치(Minibatch) 기반의 반복 루프 형식을 구체적으로 제시함

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k , is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

for k steps **do**

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Sample minibatch of m examples $\{x^{(1)}, \dots, x^{(m)}\}$ from data generating distribution $p_{\text{data}}(x)$.
- Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(x^{(i)}) + \log (1 - D(G(z^{(i)}))) \right].$$

end for

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log (1 - D(G(z^{(i)}))).$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

- **표준 최적화 도구와의 호환성:** 다층 퍼셉트론 구조 내에서 표준적인 Gradient 기반 최적화 기법을 곧바로 적용할 수 있도록 End-to-End 파이프라인의 실무적 사양을 명확히 제공함

4. 실험 및 결과


Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

- 마르코프 체인(Markov chains)이나 복잡한 근사 추론 없이, 오직 순전파와 역전파만으로 모델 훈련과 샘플 생성이 가능하다는 서론의 주장을 실제 이미지 생성 결과를 통해 증명함
- 기존 생성 모델(MCMC 기반)들이 주로 겪는 흐릿한 이미지 생성 한계를 극복하고, ReLU와 같은 조각 선형 단위(Piecewise linear units)를 활용하여 훨씬 선명한 이미지를 만들어내는 질적 우수성을 입증함

Dataset

- **MNIST:** 0부터 9까지의 수기 숫자 이미지 데이터셋


- **TFD (Toronto Face Database):** 사람의 다양한 표정과 얼굴 구조를 담은 이미지 데이터셋
- **CIFAR-10:** 10개 클래스로 구성된 자연물 및 인공물 컬러 사물 이미지 데이터셋




a)



b)



c)



d)

Baseline

- **DBN (Deep Belief Networks):** 전통적인 생성 모델의 대표적인 심층 신뢰 신경망
- **Stacked CAE (Contractive Auto-Encoders):** 데이터의 잠재 표현을 학습하는 오토인코더 계열
- **GMM (Gaussian Mixture Models) 및 GSN (Generative Stochastic Networks):** 기존 확률적 생성 모델과 마르코프 체인 기반 모델들

결과

- **정량적 평가:**
Gaussian Parzen window 기법을 사용하여 테스트 데이터의 로그 우도(Log-likelihood)를 추정한 결과, 제안한 Adversarial nets가 기존 베이스라인 모델들과 비교해 동등하거나 더 우수한 데이터 분포 추정 성능을 달성함

- **훈련 데이터 압기 방지:**

생성된 가짜 이미지가 단순히 기존 훈련 데이터를 복사한 것이 아님을 입증하기 위해, 생성된 이미지와 가장 비슷한 실제 훈련 세트의 이미지를 나란히 비교하여 모델이 새로운 이미지를 성공적으로 창조해 냈음을 시각적으로 증명함

- **잠재 공간의 의미론적 연속성 :**

무작위 노이즈가 존재하는 잠재 공간(z 공간)의 두 점 사이를 선형 보간(Linear interpolation)했을 때, 생성되는 이미지가 부드럽고 자연스럽게 변환되는 모습을 확인시켜 모델이 데이터의 의미적 구조를 훌륭하게 학습했음을 입증함

Model	MNIST	TFD
DBN [3]	138 $\pm$ 2	1909 $\pm$ 66
Stacked CAE [3]	121 $\pm$ 1.6	2110 $\pm$ 50
Deep GSN [6]	214 $\pm$ 1.1	1890 $\pm$ 29
Adversarial nets	225 $\pm$ 2	2057 $\pm$ 26



5. 결론 (배운점)

1) 연구의 의의 및 한계점


- **연구의 의의:**

- 기존 생성 모델들의 고질적인 문제였던 복잡한 확률적 연산이나 마르코프 체인 (Markov chains) 알고리즘을 완전히 배제하고, 오직 순전파와 역전파만으로 학습 가능한 적대적 학습(Adversarial process) 프레임워크를 최초로 정립함
- 데이터 분포를 직접 수식으로 모델링하지 않고 두 모델 간의 Minimax game이라는 게임 이론적 접근법을 도입하여, 생성 모델 연구의 새로운 패러다임을 제시함

- **연구의 한계점:**

- 생성 모델(G)의 확률 밀도 함수가 명시적으로 존재하지 않아 데이터 분포를 정량적으로 직접 계산하거나 평가하기 어렵고, 실험에서 사용한 Parzen window 방식 역시 고차원 데이터에서 오차가 클 수 있다는 한계가 있음

- 학습 과정에서 생성 모델(G)과 판별 모델(D) 간의 균형을 맞추기가 매우 까다로우며, 수렴 과정에 대한 이론적 증명(Nash equilibrium)과 달리 실제 구현 시에는 학습이 불안정해지거나 최적화 과정에서 부작용이 발생할 위험이 상존함



2) 배운점

전통적인 머신러닝의 유도 추정 방식에서 벗어나, 두 신경망이 서로 적대적으로 경쟁하며 발전하도록 설계한 최소최대 게임 메커니즘이 무척 새롭고 강렬하게 다가왔습니다. 알고리즘 자체가 마르코프 체인 같은 무거운 연산 없이 순수하게 역전파만으로 최적화되도록 파이프라인을 단순화한 점이 엔지니어링 관점에서 매우 영리한 설계라고 느껴졌습니다.


다만 이론적인 완전 수렴성 증명과 달리, 실제 학습 시 두 네트워크의 균형을 정밀하게 제어해야 하고 그래디언트 소실을 막기 위해 목적 함수를 중간에 변환해 주어야 하는 등 구현 환경에서의 최적화 제약이 까다롭다는 점은 아쉬우면서도 도전적인 과제로 보였습니다.

이번 학습을 통해 일차원적 최적화를 넘어, 시스템의 구조적 관계성과 패러다임의 전환이 복잡한 문제를 얼마나 명쾌하게 해결할 수 있는지 배울 수 있었고, 앞으로 대규모 모델이나 복잡한 아키텍처를 다룰 때 구조적 효율성을 극대화하는 방향으로 시야를 넓혀야겠다고 다짐하게 되었습니다.

Swin Transformer: Hierarchical Vision Transformer using Shifted Windows

1. Introduction

논문이 다루는 분야



- Transformer 아키텍처를 Computer Vision 전반의 보편적인 Backbone 네트워크로 확장하는 분야
- Image Classification뿐만 아니라 고해상도 입력이 필요한 Object Detection, Semantic Segmentation 등 다양한 Dense Prediction 태스크를 일괄적으로 처리할 수 있는 범용 신경망 구조 연구

해당 task에서 기존 연구 한계점

- **Scale의 큰 가변성:**
NLP의 텍스트 토큰과 달리, 이미지 속 시각적 요소들은 객체의 거리에 따라 크기 (Scale)가 매우 다양하여 기존 ViT의 고정된 패치 크기로는 이를 유연하게 포착하기 어려움
- **해상도 증가에 따른 연산량 폭발:**
기존 ViT의 Global Self-Attention은 패치 수(해상도)의 제곱에 비례하는 $O(N^2)$ 의 Computational Complexity를 가짐. 이로 인해 고해상도 입력이 필수적인 Dense Prediction 태스크에 적용할 때 극심한 메모리 병목과 연산 효율성 저하가 발생함

논문의 contributions

- **Hierarchical Feature Map 설계:**
레이어가 깊어질수록 주변 패치들을 병합하는 방식을 통해 CNN의 Feature Pyramid 구조를 Transformer에 구현함으로써, 다양한 크기의 객체를 효과적으로 포착하고 다른 비전 태스크 모델들과의 결합을 용이하게 함

- **Shifted Window 기반 Local Self-Attention 도입:**

전체 이미지가 아닌 서로 겹치지 않는 국소적인 창(Local Window) 내부에서만 Self-Attention을 수행하도록 제한하여, 이미지 크기에 선형적으로 비례하는 $O(N)$ 의 Computational Complexity를 달성함

- **Shifted Windowing Mechanism 제안:**

연속된 레이어 간에 Window 분할 위치를 대각선 방향으로 이동시키는 단순하면서도 효과적인 방식을 통해, Local 연산의 효율성을 유지하면서도 분할된 Window 간의 정보 교류(Cross-window Connection)를 성공적으로 유도함

- **실전적 SOTA 성능 및 효율성 입증:**

대규모 컴퓨터 비전 벤치마크인 ImageNet-1K, COCO, ADE20K 등에서 기존의 최상위권 CNN(RegNet, ResNeXt) 및 Transformer 모델들을 제치고, 성능과 연산 자원 최적화 측면 모두에서 압도적인 우위를 증명함

