

BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension

≡ type

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야

텍스트를 임의로 corrupting한 뒤 원본 텍스트를 복원하는 방식으로 sequence-to-sequence 모델을 사전학습하는 것 → NLG, 번역, 이해 등 광범위한 downstream task에 범용적으로 적용 가능한 denoising autoencoder 제안

해당 task에서 기존 연구 한계점

기존 masked language model 기반 방법들의 두 가지 문제:

1. **적용 가능한 task의 제한** : BERT처럼 bidirectional encoder만 사용하면 generation task에 부적합하고, GPT처럼 left-to-right decoder만 쓰면 양방향 문맥을 학습하지 못함 → 하나의 모델이 생성과 이해 task를 동시에 잘 하기 어려움
2. **noising 방식의 고정성** : 기존 방법들은 특정 noising 방식(token masking 등)에 맞춰 설계됨 → 다양한 형태의 corruption을 유연하게 적용하기 어려움

논문의 contributions

- **Bidirectional Encoder + Autoregressive Decoder 결합** → BERT의 양방향 문맥 이해 능력과 GPT의 생성 능력을 하나의 모델에서 통합

- **유연한 noising function 지원** → token masking, deletion, text infilling, sentence permutation, document rotation 등 다양한 corruption 방식 적용 가능
→ 길이 변화까지 허용하는 방식이 가능
- **Text infilling + Sentence permutation이 최적** → 여러 noising 방식 중 이 조합이 가장 consistently 좋은 성능을 보임을 실험으로 검증
- **다양한 task에서 SOTA 달성** → XSum에서 prior SOTA 대비 6 ROUGE 향상, ConvAI2, ELI5, WMT RO-EN(+1.1 BLEU) 등에서 state-of-the-art 기록, GLUE/SQuAD에서도 RoBERTa와 comparable한 성능

2. Related Work



Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가
제안 방법의 차별성을 어떻게 표현하고 있는가

- **GPT (Radford et al., 2018):** left-to-right Transformer LM → generation task에는 유리하지만 leftward context만 참조 가능 → bidirectional interaction 학습 불가
- **BERT (Devlin et al., 2019):** masked language modelling 도입 → 양방향 문맥 학습 가능 / 하지만 예측이 독립적으로 이루어져 generation task에 직접 사용하기 어려움
- **UniLM (Dong et al., 2019):** BERT를 여러 종류의 self-attention mask 조합으로 fine-tuning → 생성/이해 task 모두 가능하지만 예측이 conditionally independent → BART는 autoregressive하게 예측하므로 이 점에서 차별화
- **MASS (Song et al., 2019):** 연속된 span을 masking하고 sequence-to-sequence로 복원 → BART와 가장 유사한 방식이지만 encoder와 decoder에 disjoint한 token set을 넣는 구조 → discriminative task에 덜 효과적
- **XLNet (Yang et al., 2019):** permuted order로 masked token을 autoregressive하게 예측 → 양방향 문맥을 활용하되 생성도 가능하게 함 / 하지만 BART는 decoder가 pre-training 때부터 left-to-right로 동작해서 generation setting과의 mismatch가 없음

⇒ 기존 방법들은 생성 또는 이해 중 하나에 특화되어 있거나, noising 방식이 고정되어 있음 → BART는 임의의 noising function을 허용하는 denoising autoencoder 구조로 두 가지 모두를 잘 하는 범용 pre-training 방식을 제안

3. 제안 방법론



Introduction에서 언급된 내용과 동일하게 작성되어 있는가
Introduction에서 언급한 제안 방법이 가지는 장점에 대한 근거가 있는가
제안 방법에 대한 설명이 구현 가능하도록 작성되어 있는가

Main Idea

BART 기본 구조

Corrupted document → Bidirectional Encoder → Autoregressive Decoder → 원본 문서 복원

- **Encoder:** corrupted text를 양방향으로 인코딩 (BERT처럼)
- **Decoder:** 원본 문서를 left-to-right로 생성 (GPT처럼)
- Pre-training 목표: decoder output과 원본 문서 간의 cross-entropy (negative log likelihood) 최소화

아키텍처는 Vaswani et al. (2017)의 standard seq2seq Transformer 기반 → ReLU → GeLU로 변경, 파라미터 $N(0, 0.02)$ 으로 초기화. Base 모델은 encoder/decoder 각 6 layers, Large는 각 12 layers. BERT 대비 약 10% 더 많은 파라미터 (decoder의 cross-attention layer 때문)

실험한 Noising 방식들

Noising 방식	설명
Token Masking	BERT처럼 random token을 [MASK]로 교체
Token Deletion	Random token 삭제 → 어느 위치가 빠졌는지 모델이 직접 판단해야 함
Text Infilling	Poisson distribution($\lambda=3$)에서 span 길이 샘플링 → span 전체를 단 하나의 [MASK]로 교체 → 몇 개의 token이 빠졌는지도 학습
Sentence Permutation	문서를 문장 단위로 쪼개서 random 순서로 섞음
Document Rotation	Random token을 시작점으로 문서를 rotation → 문서의 시작점 파악을 학습

Fine-tuning 방식

- **Sequence Classification:** 동일 input을 encoder/decoder 모두에 입력 → 마지막 decoder token의 hidden state → linear classifier

- **Token Classification (SQuAD):** 전체 문서를 encoder/decoder에 입력 → decoder top hidden state로 각 token 분류
- **Sequence Generation (요약, QA):** encoder에 input, decoder가 autoregressive하게 output 생성
- **Machine Translation:** BART의 encoder embedding layer를 randomly initialized new encoder로 교체 → 외국어를 "noised English"로 매핑하도록 학습 → BART가 이를 복원하는 방식. 2단계 학습: ① BART 대부분 freeze, new encoder + positional embedding + 첫 layer self-attention projection만 학습 → ② 전체 파라미터 소수 iteration fine-tuning

Contribution

- 임의의 noising function을 허용하는 유연한 denoising pre-training 구조 → 특히 text infilling이 "몇 개의 token이 빠졌는지"를 모델이 스스로 추론하게 만든다는 점에 서 기존 span masking 방식과 차별화됨

4. 실험 및 결과



Introduction에서 언급한 제안 방법의 장점을 검증하기 위한 실험이 있는가

Dataset

- **SQuAD 1.1 / 2.0:** extractive QA (Wikipedia paragraphs)
- **MNLI:** bitext classification (entailment)
- **ELI5:** long-form abstractive QA
- **XSum:** highly abstractive news summarization
- **ConvAI2:** dialogue response generation
- **CNN/DailyMail:** extractive-style news summarization
- **WMT16 Romanian-English:** machine translation (back-translation 데이터 포함)
- **GLUE benchmark:** 다양한 discriminative task

Baseline

- BERT, RoBERTa, XLNet, UniLM (discriminative tasks)
- PTGEN, PTGEN+COV, BERTSUMABS, BERTSUMEXTABS (summarization)
- 기타 Seq2Seq + Attention, best published system (ConvAI2)
- Pre-training objective 비교: Language Model, Permuted LM, Masked LM, Multitask Masked LM, Masked Seq2Seq

결과

- Pre-training objective 비교에서 **Text Infilling (+ Sentence Permutation) 조합이 가장 consistently 강한 성능** → Document Rotation과 Sentence Shuffling 단독은 성능이 많이 낮음 → token masking 계열이 핵심임을 확인
- ELI5는 예외 → output이 input에 loosely constrained된 task라 pure language model이 오히려 더 좋음
- GLUE/SQuAD에서 RoBERTa와 comparable → generation 성능 향상이 classification 성능을 희생해서 얻은 게 아님을 확인
- XSum에서 prior SOTA 대비 **약 6 ROUGE 향상** (R1: 38.81 → 45.14)
- CNN/DailyMail에서도 모든 metric에서 SOTA
- ConvAI2에서 Valid F1 20.72 (best system 19.09 대비 향상)
- WMT RO-EN에서 back-translation baseline(36.80) 대비 **+1.17 BLEU (37.96)**

5. 결론 (배운점)



연구의 의의 및 한계점, 본인이 생각하는 좋았던/아쉬웠던 점 (배운점)

- BERT처럼 이해를 잘 하거나 GPT처럼 생성을 잘 하거나 둘 중 하나를 선택해야 했던 기존의 trade-off를 BART가 하나의 구조로 해소했다는게 의의

다른 논문 Intro

[Dropout: A Simple Way to Prevent Neural Networks from Overfitting]

논문이 다루는 분야

깊은 신경망 학습 시 발생하는 **overfitting** 문제를 해결하기 위한 regularization 방법 제안
→ 학습 중 신경망의 unit을 무작위로 drop하는 방식으로 여러 모델의 앙상블 효과를 하나의 모델에서 효율적으로 구현

기존 연구 한계점

1. **Overfitting 문제** : 파라미터 수가 많은 deep neural network는 training data에 쉽게 과적합 → 충분한 데이터가 없으면 일반화 성능이 낮음
2. **앙상블의 비용 문제** : 여러 모델을 학습시켜 예측을 평균내는 앙상블이 overfitting에 효과적이지만 → 큰 네트워크를 여러 개 학습시키는 건 **시간/연산 비용이 너무 큼**

논문의 contribution

- **Dropout이라는 새로운 regularization 기법 제안** → 학습 시 각 unit을 확률 p 로 임의 제거 → 매 학습 step마다 다른 "thinned network"를 학습하는 효과 → 지속적으로 많은 모델의 앙상블을 하나의 네트워크로 근사
- **Test time의 효율적 approximation** → 학습된 weight에 dropout 확률을 곱하는 것만으로 앙상블 예측을 단일 forward pass로 근사 가능
- **다양한 task에서 overfitting 감소 및 성능 향상 입증** → vision, speech, NLP, computational biology 등 여러 도메인에서 당시 SOTA 달성