

BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension

📅 날짜	2026년 6월 1일
🏷️ 태그	NLP

Paper Review

BART: Denoising Sequence-to-Sequence Pre-training for Natural...

We present BART, a denoising autoencoder for pretraining sequence-to-sequence models.

BART is trained by (1) corrupting text with an arbitrary noising function, and (2) learning a model to...

🔗 <https://arxiv.org/abs/1910.13461>



Keyword : Seq2Seq, Denoising Autoencoder, Pre-training

1. Introduction

논문이 다루는 분야

Natural Language Processing - Pre-training for Seq2Seq


- 텍스트 생성, 번역, 이해를 포괄하는 NLP 태스크를 다룸
- Self-supervised pre-training 방식으로 다양한 downstream task에 적용 가능한 범용 모델 연구

해당 task에서 기존 연구 한계점

- 기존 masked language model 계열(BERT 등)은 특정 태스크 유형에 집중되어 범용성이 제한됨
 - BERT : 양방향 인코더 → 생성 태스크에 바로 적용하기 어려움
 - GPT : 단방향(left-to-right) 디코더 → 양방향 문맥을 활용하지 못함
 - 두 모델 모두 단일 구조로 생성과 이해를 동시에 잘 처리하기 어려움
- 최근 연구에서 masked token의 분포(SpanBERT), 예측 순서(XLNet), 대체 문맥(UniLM) 등을 개선했으나, 여전히 특정 태스크 유형에 치중

논문의 contributions

- BART (Bidirectional and Auto-Regressive Transformers) 제안



- 임의의 noising function으로 텍스트를 손상시키고, 원래 텍스트를 복원하도록 학습하는 **denoising autoencoder**
- **양방향 인코더(BERT) + 단방향 auto-regressive 디코더(GPT)**를 결합한 seq2seq 구조
- 표준 Transformer 기반의 NMT 구조를 사용하여, BERT와 GPT 및 여러 pre-training scheme을 일반화(generalize)할 수 있음
- **다양한 noising 방식을 탐색하여 최적 조합 발견**
 - Sentence shuffling + Text infilling (임의 길이의 span을 단일 [MASK]로 대체)의 조합이 가장 효과적
 - 기존 BERT의 word masking과 next sentence prediction을 일반화하여, 전체 문장 길이에 대한 추론과 입력에 대한 더 긴 범위의 변환을 요구
- **성과**
 - 텍스트 생성에 특히 강력 : XSum 요약에서 기존 대비 최대 **6 ROUGE** 향상
 - 기계번역(WMT RO-EN)에서 back-translation 기반 baseline 대비 **1.1 BLEU** 향상
 - RoBERTa와 동등한 학습 자원으로 GLUE, SQuAD에서 비슷한 성능 달성

2. Related Work

- **Early pre-training methods**
 - **GPT** : 단방향(left-to-right) LM → 생성에 적합하나, 양방향 문맥 학습 불가
 - **ELMo** : left-only, right-only 표현을 concat하나, 두 표현 간의 상호작용을 pre-training하지 않음
 - **BERT** : Masked LM 도입 → 좌우 문맥 간 상호작용 학습 가능, 그러나 auto-regressive하지 않아 생성 태스크에서 효과 제한
- **BERT 개선 연구**
 - 더 긴 학습(RoBERTa), 레이어 파라미터 공유(ALBERT), span masking(SpanBERT) 등
- **UniLM** : BERT에 다양한 attention mask를 ensemble하여 생성 및 판별 태스크 모두에 사용 가능
 - 차이점 : UniLM의 예측은 조건부 독립(conditionally independent), BART는 auto-regressive
- **MASS** : 연속된 token span을 마스킹하고 seq2seq 모델로 복원 → BART와 가장 유사한 구조
 - 차이점 : 인코더와 디코더에 disjoint한 token 집합을 입력하여 판별 태스크에서 효과 감소
- **XLNet** : 마스킹된 토큰을 랜덤 순서로 auto-regressive하게 예측
 - 차이점 : BART 디코더는 pre-training 시 left-to-right으로 동작 → 생성 세팅과 일치

3. 제안 방법론

Main Idea

BART = Denoising Autoencoder for Seq2Seq


손상된 문서를 원래 문서로 복원하는 sequence-to-sequence 모델

- 양방향 인코더(over corrupted text) + left-to-right auto-regressive 디코더
- Pre-training 목표 : 원래 문서의 negative log likelihood 최소화
- 극단적인 경우 source의 모든 정보가 손실되면 language model과 동일해짐

Architecture


- 표준 **seq2seq Transformer** 구조 사용
 - ReLU → GeLU 활성화 함수로 변경
 - 파라미터 초기화 : $N(0, 0.02)$
- **Base model** : 인코더 6 레이어 + 디코더 6 레이어
- **Large model** : 인코더 12 레이어 + 디코더 12 레이어
- BERT 구조와의 차이
 1. 디코더의 각 레이어가 인코더 최종 hidden layer에 대해 cross-attention 수행
 2. BERT는 word prediction 전에 추가 feed-forward network를 사용하나, BART는 미사용
- 동일 크기의 BERT 모델 대비 약 10% 많은 파라미터

Pre-training BART



- **Token Masking** : BERT와 동일하게 랜덤 token을 [MASK]로 대체
- **Token Deletion** : 랜덤 token을 입력에서 삭제 → 모델이 어느 위치가 삭제됐는지 판단해야 함
- **Text Infilling** : Poisson 분포($\lambda=3$)에서 샘플링한 길이의 span을 단일 [MASK] token으로 대체
 - 0-length span → [MASK] 삽입에 해당
 - SpanBERT와 유사하나, SpanBERT는 span과 동일한 수의 [MASK]를 사용하는 반면 BART는 단일 [MASK]만 사용
 - 모델이 얼마나 많은 token이 누락됐는지 예측하도록 학습
- **Sentence Permutation** : 문서를 마침표 기준으로 문장 분리 후 랜덤 순서로 셔플
- **Document Rotation** : 랜덤 token을 선택하여 해당 token이 문서 시작이 되도록 회전 → 문서의 시작 위치를 식별하는 태스크

Fine-tuning BART



(a) To use BART for classification problems, the same input is fed into the encoder and decoder, and the representation from the final output is used.

(b) For machine translation, we learn a small additional encoder that replaces the word embeddings in BART. The new encoder can use a disjoint vocabulary.

- **Sequence Classification** : 동일한 입력을 인코더와 디코더에 모두 공급, 최종 디코더 token의 hidden state를 분류기에 입력 (BERT의 [CLS]와 유사하나, token을 끝에 추가)
- **Token Classification** : 전체 문서를 인코더와 디코더에 공급, 디코더 top hidden state를 각 단어의 표현으로 사용
- **Sequence Generation** : auto-regressive 디코더를 직접 fine-tuning (abstractive QA, 요약 등)
- **Machine Translation**
 - BART 전체(인코더 + 디코더)를 사전 학습된 단일 디코더로 활용
 - BART의 인코더 임베딩 레이어를 새로운 randomly initialized 인코더로 교체
 - 새 인코더가 외국어를, BART가 de-noise할 수 있는 영어 표현으로 매핑하도록 end-to-end 학습
 - 학습 2단계
 1. 대부분의 BART 파라미터를 고정하고 새 인코더, BART positional embedding, BART 인코더 첫 레이어의 self-attention projection만 업데이트
 2. 전체 파라미터를 소수의 iteration 동안 학습

4. 실험 및 결과

Comparing Pre-training Objectives

Comparison Objectives

- Base-size 모델(6 encoder + 6 decoder layer, hidden size 768)로 다양한 pre-training 목표를 비교
- 공정한 비교를 위해 학습 데이터, 최적화 파라미터 등을 최대한 통일하되, learning rate와 layer normalisation은 각 목표별로 별도 튜닝
- **비교 대상**
 - **Language Model** : GPT와 동일하게 left-to-right Transformer LM 학습. BART 디코더만 사용 (cross-attention 없음)
 - **Permuted Language Model** : XLNet 기반. 1/6의 token을 샘플링하여 랜덤 순서로 auto-regressive하게 생성
 - **Masked Language Model** : BERT와 동일하게 15%의 token을 [MASK]로 대체하고 독립적으로 원래 token을 예측
 - **Multitask Masked Language Model** : UniLM 방식. Masked LM에 추가 self-attention mask 적용 (1/6 left-to-right, 1/6 right-to-left, 1/3 unmasked, 1/3 처음 50% unmasked + 나머지 left-to-right)
 - **Masked Seq-to-Seq** : MASS에서 영감. 50%의 token을 포함하는 span을 마스킹하고 seq2seq 모델로 예측

Tasks

- **SQuAD** : Wikipedia 단락 기반 extractive QA. 질문과 문맥을 concat하여 인코더에 입력하고 디코더에도 전달. start/end index를 예측하는 classifier 포함
- **MNLI** : 두 문장 간 함의 관계를 분류하는 bitext classification 태스크. 두 문장에 EOS token을 append하여 인코더와 디코더에 입력, EOS token 표현으로 분류
- **ELI5** : 장문의 abstractive QA 데이터셋. 질문과 관련 문서를 concat한 입력에 대해 답변을 생성

- **XSum** : highly abstractive한 뉴스 요약 데이터셋
- **ConvAI2** : 대화 맥락과 persona에 조건부로 응답을 생성하는 dialogue response generation 태스크
- **CNN/DM** : 뉴스 요약 데이터셋. 요약이 원문 문장과 밀접하게 관련됨

Results

Model	SQuAD 1.1 F1	MNLI Acc	ELI5 PPL	XSum PPL	ConvAI2 PPL	CNN/DM PPL
BERT Base (Devlin et al., 2019)	88.5	84.3	-	-	-	-
Masked Language Model	90.0	83.5	24.77	7.87	12.59	7.06
Masked Seq2seq Language Model	87.0	82.1	23.40	6.80	11.43	6.19
Permutated Language Model	76.7	80.1	21.40	7.00	11.51	6.56
Multitask Masked Language Model	89.1	83.7	24.03	7.69	12.23	6.96
	89.2	82.4	23.73	7.50	12.39	6.74
BART Base						
w/ Token Masking	90.4	84.1	25.05	7.08	11.73	6.10
w/ Token Deletion	90.4	84.1	24.61	6.90	11.46	5.87
w/ Text Infilling	90.8	84.0	24.26	6.61	11.05	5.83
w/ Document Rotation	77.2	75.3	53.69	17.14	19.87	10.59
w/ Sentence Shuffling	85.4	81.5	41.87	10.93	16.67	7.89
w/ Text Infilling + Sentence Shuffling	90.8	83.8	24.17	6.62	11.12	5.41

- Pre-training 방법의 효과는 태스크마다 크게 다름
 - 단순 Language Model이 ELI5에서 최고 성능, 그러나 SQuAD에서 최저 성능
- Token masking이 핵심
 - Document rotation이나 sentence permutation만으로는 성능 매우 낮음
 - 성공적인 방법들은 모두 token deletion이나 masking, 또는 self-attention mask를 포함
 - Deletion이 생성 태스크에서 masking보다 우수
- Left-to-right pre-training이 생성 성능 향상에 기여
 - Masked LM과 Permuted LM은 left-to-right auto-regressive LM을 포함하지 않는 유일한 모델이며, 생성에서 상대적으로 성능 낮음
- SQuAD에서는 양방향 인코더가 중요
 - Left-to-right 디코더만으로는 분류 결정에 미래 문맥을 활용할 수 없어 성능 저하
 - 단, BART는 절반의 양방향 레이어만으로 비슷한 성능 달성
- Pre-training 목표만이 유일한 요인은 아님
 - Permuted LM이 XLNet보다 성능이 낮은 이유 중 일부는 relative positional embedding 등의 구조적 차이 때문일 수 있음
- ELI5는 예외적 태스크
 - 출력이 입력에 느슨하게 제약되어 있어 순수 Language Model이 최고 성능을 보이며, BART의 효과가 제한적
- BART(Text Infilling + Sentence Shuffling)가 전 태스크에서 가장 일관적으로 높은 성능 (ELI5 제외)

Large-scale Pre-training Experiments

Experimental Setup

설정	값
Layers	12 encoder + 12 decoder

설정	값
Hidden size	1024
Batch size	8,000
Steps	500,000
Tokenizer	GPT-2와 동일한 BPE
Noising	Text infilling (30% token masking) + Sentence permutation
학습 데이터	뉴스, 책, 이야기, 웹 텍스트 총 160GB (RoBERTa와 동일)
기타	학습 마지막 10%에서 dropout 비활성화

- 위의 실험 결과를 바탕으로 text infilling + sentence permutation 조합을 사용
- Sentence permutation은 CNN/DM 요약에서만 유의미한 추가 이득을 보였으나, 대규모 모델에서는 더 잘 학습할 수 있을 것으로 가정

Discriminative Tasks

- SQuAD와 GLUE 태스크에서 RoBERTa, XLNet 등과 비교
- 가장 직접적인 비교 대상은 동일한 자원으로 학습한 RoBERTa
- 전반적으로 BART는 RoBERTa와 유사한 성능 → 대부분의 태스크에서 소폭 차이만 존재
- BART의 생성 태스크 개선이 분류 성능 희생 없이 이루어졌음을 시사

Generation Tasks

- Fine-tuning 시 label smoothed cross entropy loss 사용 (smoothing parameter = 0.1)
- 생성 시 beam size 5, 중복 trigram 제거, min-len/max-len/length penalty를 validation set에서 튜닝
- **Summarization (CNN/DailyMail, XSum)**

	CNN/DailyMail			XSum		
	R1	R2	RL	R1	R2	RL
Lead-3	40.42	17.62	36.67	16.30	1.60	11.95
PTGEN (See et al., 2017)	36.44	15.66	33.42	29.70	9.21	23.24
PTGEN+COV (See et al., 2017)	39.53	17.28	36.38	28.10	8.02	21.72
UniLM	43.33	20.21	40.51	-	-	-
BERTSUMABS (Liu & Lapata, 2019)	41.72	19.39	38.76	38.76	16.33	31.15
BERTSUMEXTABS (Liu & Lapata, 2019)	42.13	19.60	39.18	38.81	16.50	31.27
BART	44.16	21.28	40.90	45.14	22.27	37.25

- **CNN/DailyMail** : 요약이 원문 문장과 유사하여 추출 모델도 경쟁력 있는 데이터셋이지만, BART가 기존 모든 모델 능가
- **XSum** (highly abstractive) : 추출 모델의 성능이 낮은 데이터셋. BERT를 활용한 기존 SOTA(BERTSUMEXTABS) 대비 모든 ROUGE 지표에서 약 **6.0점 향상**
- **Dialogue (ConvAI2)**

	ConvAI2	
	Valid F1	Valid PPL
Seq2Seq + Attention	16.02	35.07
Best System	19.09	17.51
BART	20.72	11.85

- 이전 맥락과 텍스트로 명시된 persona에 조건부로 응답 생성
- Valid F1 **20.72**, Valid PPL **11.85**로 기존 최고 시스템 능가

- **Abstractive QA (ELI5)**

	ELI5		
	R1	R2	RL
Best Extractive	23.5	3.1	17.5
Language Model	27.8	4.7	23.1
Seq2Seq	28.3	5.1	22.8
Seq2Seq Multitask	28.9	5.4	23.1
BART	30.6	6.2	24.3

- 장문의 자유형 답변을 생성하는 태스크
- ROUGE-L 기준 기존 최고 대비 **1.2점 향상** (R1 30.6, R2 6.2, RL 24.3)
- 답변이 질문에 느슨하게 연결되어 여전히 어려운 데이터셋

Translation

- **실험 설정**

- WMT16 Romanian-English에서 평가, back-translation 데이터로 증강
- 6-layer transformer 소스 인코더를 추가하여 루마니아어 → BART가 de-noise할 수 있는 영어 표현으로 매핑 (Section 3.4의 접근법)
- Beam width 5, length penalty $\alpha=1$

- **결과**

	RO-EN
Baseline	36.80
Fixed BART	36.29
Tuned BART	37.96

- Tuned BART가 강력한 back-translation baseline 대비 **+1.16 BLEU** 향상
- Target language(영어)의 monolingual pre-training만으로 번역 성능 개선
- 예비 실험에서 back-translation 데이터 없이는 효과가 제한적이고 overfitting 경향 → 추가 regularization 기법 탐색 필요

5. 결론

- **BART 제안** : 손상된 문서를 원래 문서로 복원하도록 학습하는 pre-training 접근법
- 판별 태스크에서 RoBERTa와 동등한 성능을 유지하면서, 다양한 텍스트 생성 태스크에서 새로운 SOTA 달성
- **Future work** : pre-training을 위한 새로운 문서 corruption 방법 탐색 (특정 end task에 맞게 조정하는 방향)

Dropout: A Simple Way to Prevent Neural Networks from Overfitting

📅 날짜	2026년 6월 1일
🏷️ 태그	Optimization

Paper Review

jmlr.org

<https://jmlr.org/papers/volume15/srivastava14a/srivastava14a.pdf>

Keyword : Regularization, Overfitting

1. Introduction

논문이 다루는 분야

Neural Network Regularization


- 다수의 비선형 hidden layer를 가진 deep neural network의 overfitting 방지 기법을 다룸
- Vision, speech recognition, document classification, computational biology 등 다양한 도메인의 supervised learning 태스크에 적용

해당 task에서 기존 연구 한계점


- Deep neural network는 매우 강력하지만, 학습 데이터가 제한적일 경우 sampling noise에 의한 복잡한 관계까지 학습하게 되어 **overfitting** 발생
- **기존 overfitting 방지 방법**
 - Validation set 성능이 나빠지기 시작하면 학습을 멈추는 **early stopping**
 - L1, L2 regularization, soft weight sharing 등의 weight penalty 기법
- 이론적으로 가장 좋은 regularization은 모든 가능한 파라미터 설정에 대한 예측의 평균을 내는 것이지만, 이는 계산량이 막대하여 현실적으로 불가능
- **Model combination** (여러 모델의 예측을 결합)은 거의 항상 성능을 향상시키지만, 대규모 신경망에서는 한계가 존재
 - 여러 대규모 신경망을 개별적으로 학습시키고 출력을 평균하는 것은 비용이 매우 높음
 - 모델을 서로 다르게 만들려면 다른 구조를 사용하거나 다른 데이터로 학습해야 하는데, 각 구조에 대한 최적 하이퍼파라미터를 찾는 것이 어렵고 학습 비용도 큼
 - 대규모 신경망은 대량의 데이터가 필요한데, 서로 다른 신경망을 서로 다른 데이터 부분집합으로 학습하기에 충분한 데이터가 없을 수 있음
 - 빠른 응답이 필요한 환경에서 테스트 시 여러 대규모 신경망을 모두 사용하는 것은 불가능

논문의 contributions

- **Dropout 제안** : 학습 중 신경망에서 유닛(hidden + visible)을 랜덤으로 제거하는 기법





(a) Standard Neural Net



(b) After applying dropout.

- 각 유닛은 다른 유닛과 독립적으로 고정 확률 p 로 유지됨 (hidden unit은 보통 $p=0.5$, input unit은 1에 가까운 값이 최적)
- 유닛이 과도하게 **co-adaptation**(상호 의존적 적응)하는 것을 방지
- **지수적으로 많은 thinned network의 효율적 앙상블**
 - n 개의 유닛을 가진 신경망에서 2^n 개의 가능한 thinned network를 샘플링하여 학습하는 효과
 - 각 학습 사례마다 새로운 thinned network가 샘플링되어 학습됨
 - 이 모든 thinned network는 가중치를 공유하므로 총 파라미터 수는 $O(n^2)$ 이하
- **테스트 시 간단한 근사 평균 방법 제시**



- 테스트 시에는 dropout 없이 단일 신경망을 사용하되, 학습된 가중치를 p 만큼 스케일 다운
- 이를 통해 2^n 개의 thinned network를 하나의 신경망으로 결합하여 사용
- 학습 시 기대 출력과 테스트 시 실제 출력이 동일하도록 보장
- **성과**
 - 다른 regularization 방법 대비 overfitting을 크게 줄이고 일반화 성능을 향상
 - Vision, speech recognition, document classification, computational biology 등 다양한 벤치마크에서 SOTA 달성