



Dropout: A Simple Way to Prevent Neural Networks from Overfitting

1. Introduction


논문이 다루는 분야

- 딥 뉴럴 네트워크의 과적합(overfitting) 방지를 위한 정규화 기법
 - 파라미터 수가 많은 대규모 신경망은 강력한 표현력을 갖지만 과적합 문제가 심각
 - 훈련 데이터의 샘플링 노이즈로 인해 학습된 복잡한 관계가 실제 테스트 데이터에서는 성립하지 않는 문제
- 기존 앙상블 방법론의 한계를 극복하는 효율적 모델 조합 기법
 - 여러 모델의 예측을 평균하는 방식이 성능 향상에 효과적이지만, 대규모 네트워크에서 현실적으로 적용 불가


해당 task에서 기존 연구 한계점

- 기존 정규화 방법들의 한계
 - Early stopping, L1/L2 정규화, soft weight sharing — 과적합 방지 효과가 제한적
 - 베이지안 방법론 — 계산 비용이 매우 크고 대규모 네트워크로의 확장이 어려움
- 앙상블 기반 접근의 비현실성
 - 여러 대형 네트워크를 개별 훈련하려면 각각의 최적 하이퍼파라미터 탐색이 필요, 계산 비용이 막대함
 - 서로 다른 구조의 모델을 만들기 위해 다른 아키텍처나 다른 데이터 부분집합으로 훈련해야 하는데 대규모 네트워크는 데이터 분할 어려움
 - 테스트 시 다수의 대형 네트워크를 동시에 사용하는 것은 응답 속도가 중요한 환경에서 사실상 불가능

논문의 contributions





(a) Standard Neural Net



(b) After applying dropout.

- **Dropout**

- 훈련 시 유닛을 랜덤하게 제거하는 간단하고 효과적인 정규화 기법 제안



- 각 유닛을 고정 확률 p 로 독립적으로 유지하고, 나머지는 연결과 함께 임시 제거
 - n 개의 유닛을 가진 네트워크를 2^n 개의 서로 다른 thinned 네트워크의 집합으로 해석하여 지수적으로 많은 모델을 효율적으로 조합하는 효과
- 테스트 시 효율적인 근사 앙상블 방법 제안
 - 훈련된 가중치에 보존 확률 p 를 곱해 스케일을 축소하면, 지수적으로 많은 thinned 네트워크의 예측 평균을 단일 네트워크 한 번의 추론으로 근사 가능
- 생물학적 직관에서 출발한 이론적 동기 제시
 - 성적 생식에서 유전자 간 과도한 공동 적응이 억제되듯, dropout이 은닉 유닛 간 co-adaptation을 방지하여 각 유닛이 독립적으로 유용한 특징을 학습하도록 유도

- 비전, 음성, 텍스트, 전산생물학 등 다양한 도메인에서 state-of-the-art 성능 달성
 - 특정 태스크에 종속되지 않는 범용 정규화 기법임을 실험적으로 입증
 - Dropout이 feed-forward 신경망에 국한되지 않고 Restricted Boltzmann Machine 등 다른 그래프 모델에도 적용 가능함을 제시



BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

1. Introduction


논문이 다루는 분야

- 자연어 처리를 위한 시퀀스-투-시퀀스 사전학습 모델
 - 텍스트 생성, 번역, 독해 등 광범위한 NLP 태스크를 단일 모델로 처리
 - 손상된 텍스트를 원본으로 복원하는 denoising autoencoder 방식의 사전학습
- 기존 BERT, GPT 등의 사전학습 방식을 일반화하는 통합 프레임워크 제안
 - BERT의 양방향 인코더 + GPT의 autoregressive 디코더를 결합한 구조



(a) BERT: Random tokens are replaced with masks, and the document is encoded bidirectionally. Missing tokens are predicted independently, so BERT cannot easily be used for generation.

(b) GPT: Tokens are predicted auto-regressively, meaning GPT can be used for generation. However words can only condition on leftward context, so it cannot learn bidirectional interactions.



(c) BART: Inputs to the encoder need not be aligned with decoder outputs, allowing arbitrary noise transformations. Here, a document has been corrupted by replacing spans of text with mask symbols. The corrupted document (left) is encoded with a bidirectional model, and then the likelihood of the original document (right) is calculated with an autoregressive decoder. For fine-tuning, an uncorrupted document is input to both the encoder and decoder, and we use representations from the final hidden state of the decoder.

해당 task에서 기존 연구 한계점

- BERT (Masked Language Model)
 - 양방향 문맥을 학습하지만, 토큰을 독립적으로 예측하기 때문에 생성 태스크에 직접 적용하기 어려움
 - 마스킹된 토큰들 간의 상호의존성을 모델링하지 못함
- GPT (Auto-Regressive Language Model)
 - 자동회귀 방식으로 생성 태스크에 강점이 있으나, 왼쪽 문맥만 활용 가능
 - 양방향 상호작용을 학습하지 못해 분류 등 이해 태스크에서 한계
- 기존 연구들이 특정 태스크 유형(span prediction, generation 등)에만 최적화
 - 생성과 이해 태스크를 동시에 잘 처리하는 범용 모델의 부재
 - 노이즈 방식이 고정되어 있어 다양한 형태의 텍스트 손상을 실험하기 어려움

논문의 contributions

- 임의의 노이즈 함수를 적용 가능한 유연한 사전학습 프레임워크 제안
 - 텍스트 길이 변경을 포함한 다양한 변환을 자유롭게 적용 가능
 - Token Masking, Token Deletion, Text Infilling, Sentence Permutation, Document Rotation 등 다양한 노이즈 방식 실험
- 최적 노이즈 전략 발견: Text Infilling + Sentence Permutation 조합

- Span 단위의 마스킹으로 모델이 누락된 토큰 수까지 추론하도록 유도
- 생성 및 이해 태스크 모두에서 일관되게 강한 성능
- 기계번역을 위한 새로운 파인튜닝 방식 제안
 - BART 위에 새로운 인코더를 추가하여 외국어를 영어로 번역
 - 강력한 back-translation 베이스라인 대비 1.1 BLEU 향상
- 다양한 생성 태스크에서 새로운 state-of-the-art 달성
 - XSum에서 기존 최고 성능 대비 6 ROUGE 향상
 - 요약, 대화, 추상적 QA 등 여러 생성 태스크에서 동시에 강력한 성능


2. Related Work

- **GPT** (Radford et al., 2018)
 - 왼쪽 문맥만 모델링하는 단방향 언어 모델
 - 일부 태스크에서 양방향 문맥이 없어 성능 제한
- **ELMo** (Peters et al., 2018)
 - 좌향, 우향 표현을 단순 연결하여 사용
 - 두 방향 간의 상호작용을 사전학습 단계에서 직접 학습하지 못함
- **BERT** (Devlin et al., 2019)
 - Masked Language Modeling으로 양방향 문맥 학습
 - 토큰을 독립적으로 예측하는 구조로 인해 생성 태스크 적용이 어려움
- **UniLM** (Dong et al., 2019)
 - 다양한 self-attention 마스크 조합으로 생성 및 이해 태스크 모두 지원
 - 예측이 조건부 독립적으로 이루어진다는 점이 BART의 자동회귀 방식과 차이
- **MASS** (Song et al., 2019)
 - BART와 가장 유사한 구조로, 연속 span을 마스킹하여 seq2seq 학습
 - 인코더와 디코더에 분리된 토큰 집합이 입력되어 판별 태스크에서 약점
- **XLNet** (Yang et al., 2019)
 - 마스킹된 토큰을 순열 순서로 자동회귀 예측하여 양방향 문맥 활용
 - 상대 위치 임베딩, segment 수준 재귀 등 추가 구조적 개선 포함


3. 제안 방법론

Main Idea

- BART = 양방향 인코더 + 자동회귀 디코더 결합의 denoising autoencoder
 - 텍스트를 임의의 방식으로 손상시킨 뒤, 원본 텍스트를 복원하도록 학습
 - 손실 함수: 디코더 출력과 원본 문서 간의 cross-entropy
- 사전학습에서 실험한 노이즈 방식



- **Token Masking**: BERT 방식, 랜덤 토큰을 [MASK]로 대체
 - **Token Deletion**: 랜덤 토큰 삭제, 모델이 누락 위치를 직접 추론
 - **Text Infilling**: Poisson 분포($\lambda=3$)로 span 샘플링 후 단일 [MASK]로 대체, 누락 토큰 수까지 예측 유도
 - **Sentence Permutation**: 문장 단위로 무작위 순서로 섞기
 - **Document Rotation**: 임의의 토큰을 시작점으로 문서 회전
-
- 아키텍처: Transformer seq2seq 구조 기반, ReLU → GeLU 활성화 함수 변경
 - Base 모델: 인코더/디코더 각 6레이어, 히든 사이즈 768
 - Large 모델: 인코더/디코더 각 12레이어, 히든 사이즈 1024
 - 동일 크기 BERT 대비 약 10% 더 많은 파라미터
 - 다양한 파인튜닝 방식 지원



(a) To use BART for classification problems, the same input is fed into the encoder and decoder, and the representation from the final output is used.

(b) For machine translation, we learn a small additional encoder that replaces the word embeddings in BART. The new encoder can use a disjoint vocabulary.

- 시퀀스 분류: 동일 입력을 인코더/디코더에 모두 넣고 마지막 디코더 은닉 상태 활용
- 토큰 분류: 전체 문서를 입력하고 디코더 상위 은닉 상태로 각 토큰 분류
- 시퀀스 생성: 자동회귀 디코더를 통한 직접 생성
- 기계번역: 새로운 랜덤 초기화 인코더 추가, 2단계 학습으로 외국어 → 영어 변환

4. 실험 및 결과

Dataset

- **SQuAD 1.1 / 2.0**: Wikipedia 기반 추출형 QA
- **MNLI**: 문장 쌍 자연어 추론 (함의 관계 분류)
- **ELI5**: 장문 추상적 QA
- **XSum**: 높은 추상성의 뉴스 요약
- **ConvAI2**: 페르소나 기반 대화 응답 생성
- **CNN/DailyMail**: 추출형에 가까운 뉴스 요약
- **WMT16 Romanian-English**: back-translation 데이터 증강 포함 기계번역

Baseline

- Language Model (GPT 유사)
- Permuted Language Model (XLNet 유사)
- Masked Language Model (BERT 유사)
- Multitask Masked Language Model (UniLM 유사)
- Masked Seq-to-Seq (MASS 유사)
- BERT, RoBERTa, XLNet (대규모 실험 비교)

결과

• 사전학습 목표 비교 (Base 모델)

Model	SQuAD 1.1 F1	MNLI Acc	ELI5 PPL	XSum PPL	ConvAI2 PPL	CNN/DM PPL
BERT Base (Devlin et al., 2019)	88.5	84.3	-	-	-	-
Masked Language Model	90.0	83.5	24.77	7.87	12.59	7.06
Masked Seq2seq Language Model	87.0	82.1	23.40	6.80	11.43	6.19
Permuted Language Model	76.7	80.1	21.40	7.00	11.51	6.56
Multitask Masked Language Model	89.1	83.7	24.03	7.69	12.23	6.96
BART Base	89.2	82.4	23.73	7.50	12.39	6.74
w/ Token Masking	90.4	84.1	25.05	7.08	11.73	6.10
w/ Token Deletion	90.4	84.1	24.61	6.90	11.46	5.87
w/ Text Infilling	90.8	84.0	24.26	6.61	11.05	5.83
w/ Document Rotation	77.2	75.3	53.69	17.14	19.87	10.59
w/ Sentence Shuffling	85.4	81.5	41.87	10.93	16.67	7.89
w/ Text Infilling + Sentence Shuffling	90.8	83.8	24.17	6.62	11.12	5.41

- Document Rotation, Sentence Shuffling 단독 사용은 성능 저하가 큼
- Text Infilling이 가장 일관된 강점, Token Deletion이 생성 태스크에서 Masking 보다 우수
- Text Infilling + Sentence Shuffling 조합이 CNN/DM에서 최고 성능

• 판별 태스크 (Large 모델)

	SQuAD 1.1 EM/F1	SQuAD 2.0 EM/F1	MNLI m/mm	SST Acc	QQP Acc	QNLI Acc	STS-B Acc	RTE Acc	MRPC Acc	CoLA Mcc
BERT	84.1/90.9	79.0/81.8	86.6/-	93.2	91.3	92.3	90.0	70.4	88.0	60.6
UniLM	-/-	80.5/83.4	87.0/85.9	94.5	-	92.7	-	70.9	-	61.1
XLNet	89.0/94.5	86.1/88.8	89.8/-	95.6	91.8	93.9	91.8	83.8	89.2	63.6
RoBERTa	88.9/ 94.6	86.5/89.4	90.2/90.2	96.4	92.2	94.7	92.4	86.6	90.9	68.0
BART	88.8/ 94.6	86.1/89.2	89.9/90.1	96.6	92.5	94.9	91.2	87.0	90.4	62.8

- SQuAD, GLUE에서 RoBERTa와 유사한 성능 달성
- 단방향 디코더 레이어에도 불구하고 분류 성능 손실 없음

• 생성 태스크

	CNN/DailyMail			XSum		
	R1	R2	RL	R1	R2	RL
Lead-3	40.42	17.62	36.67	16.30	1.60	11.95
PTGEN (See et al., 2017)	36.44	15.66	33.42	29.70	9.21	23.24
PTGEN+COV (See et al., 2017)	39.53	17.28	36.38	28.10	8.02	21.72
UniLM	43.33	20.21	40.51	-	-	-
BERTSUMABS (Liu & Lapata, 2019)	41.72	19.39	38.76	38.76	16.33	31.15
BERTSUMEXTABS (Liu & Lapata, 2019)	42.13	19.60	39.18	38.81	16.50	31.27
BART	44.16	21.28	40.90	45.14	22.27	37.25

	ConvAI2	
	Valid F1	Valid PPL
Seq2Seq + Attention	16.02	35.07
Best System	19.09	17.51
BART	20.72	11.85

	ELI5		
	R1	R2	RL
Best Extractive	23.5	3.1	17.5
Language Model	27.8	4.7	23.1
Seq2Seq	28.3	5.1	22.8
Seq2Seq Multitask	28.9	5.4	23.1
BART	30.6	6.2	24.3

- XSum: R1 45.14, R2 22.27, RL 37.25로 BERTSUMEXTABS 대비 약 6점 향상
- CNN/DM: 모든 ROUGE 지표에서 기존 최고 성능 초과
- ConvAI2: Valid F1 20.72로 기존 최고 시스템(19.09) 상회
- ELI5: ROUGE-L 기준 1.2점 향상으로 state-of-the-art

• 기계번역

	RO-EN
Baseline	36.80
Fixed BART	36.29
Tuned BART	37.96

- WMT16 RO-EN: back-translation 베이스라인(36.80 BLEU) 대비 Tuned BART 37.96 BLEU 달성

5. 결론 (배운점)

- 의의
 - 생성과 이해 태스크를 하나의 프레임워크로 통합, 범용성 확보
 - 노이징 방식의 유연성을 통해 다양한 사전학습 목표 비교 가능
 - 텍스트 생성 분야에서 이전 연구 대비 높은 성능 향상을 보임
- 한계점
 - ELI5 태스크에서 순수 언어 모델보다 낮은 성능
 - 출력이 입력과 느슨하게 연결된 경우 BART의 denoising 방식이 덜 효과적임
 - 기계번역에서 back-translation 데이터 없이 단독 적용 시 효과 제한적
 - 향후 연구로 태스크별 맞춤형 노이징 방식 탐색이 남겨짐



- BERT의 양방향 인코더와 GPT의 단방향 디코더를 결합하여 BERT의 문맥 이해 능력과 GPT의 생성 능력을 통합한 모델을 만든다는 아이디어가 인상적이었다.
- 다양한 노이징 기법을 시도하고 조합함으로써 유연한 사전학습 방식을 통해 범용적인 모델을 구축하고 성능을 향상시킨 것이 좋았다. 하지만 노이징 방식 조합 실험이 Text Infilling + Sentence Shuffling에 그쳤기 때문에 더 다양한 조합 탐색이 있었다면 좋았을 것 같다.