



# BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension.

## 1. Introduction

### 연구 분야 및 배경

- 연구 분야

#### 시퀀스-투-시퀀스 사전학습 (Denoising Autoencoder for Seq2Seq)

- 텍스트를 임의의 노이즈 함수로 손상(corrupt)시킨 뒤, 원본 텍스트를 복원하도록 시퀀스-투-시퀀스 모델 전체를 사전학습하는 프레임워크.
- 표준 Transformer 기반 신경망 기계번역(NMT) 아키텍처를 사용하며, 단순함에도 불구하고 BERT(양방향 인코더)와 GPT(좌 → 우 디코더)를 일반화한 구조로 볼 수 있음.

- 연구 배경

#### 기존 자기지도학습(Self-supervised) 방식들의 성과와 한계

- BERT 계열(마스킹 언어 모델): 마스킹된 토큰을 복원하는 방식으로 NLU에서 큰 성과. 그러나 예측이 독립적(independent)으로 이루어져 생성 태스크에는 직접 적용이 어려움.
- GPT 계열(언어 모델): 자기회귀적(auto-regressive) 구조로 생성에 강점. 단, 단어가 왼쪽 문맥만 참조하므로 양방향 상호작용을 학습하지 못함.

- 기존 연구들은 특정 유형의 태스크(예: 스패ن 예측, 생성 등)에 집중하여 범용적 적용에 한계가 있었음.

## 기존 연구의 한계점

### 단일 목적 모델의 한계

- 마스킹된 토큰 분포 개선(SpanBERT), 예측 순서 개선(XLNet), 마스킹 토큰 교체 시 사용 가능한 문맥 개선(UniLM) 등 각각 특정 측면만 개선해왔음.
- 생성(Generation)과 이해(Comprehension) 태스크를 동시에 잘 처리하는 범용 사전학습 방식이 없었음.

## 이 논문의 핵심 기여



### BART의 핵심 아이디어

임의의 노이즈 함수로 손상된 텍스트를 입력받아 원본을 복원하는 디노이징 오토 인코더(Denoising Autoencoder)를 Seq2Seq 구조로 구현. BERT의 양방향 인코더와 GPT의 자기회귀 디코더를 하나의 모델에 통합하여 NLU와 NLG 모두를 커버하는 범용 사전학습 프레임워크를 제안.

### 1 유연한 노이즈 적용 (Flexible Noising Schemes)

- 텍스트 길이 변경을 포함한 임의의 변환(transformation)을 원본 텍스트에 적용 가능.
- 효과: 문장 순서 무작위 섞기(Sentence Shuffling)와 스패ンを 단일 마스크 토큰으로 교체하는 새로운 Text Infilling 기법을 조합했을 때 최고 성능 달성.

### 2 다양한 태스크에서 SOTA 달성

- 추상적 대화, 질의응답, 요약 태스크에서 새로운 최고 성능(state-of-the-art) 기록.
- XSum 데이터셋에서 이전 연구 대비 최대 6 ROUGE 성능 향상.
- 기계번역에서 역번역(back-translation) 시스템 대비 1 BLEU 향상.

### 3 판별 태스크에서도 RoBERTa 수준 유지

- GLUE와 SQuAD에서 동등한 학습 자원을 사용한 RoBERTa와 대등한 성능을 달성하여 생성 성능 향상이 이해 성능 손실 없이 이루어짐을 증명.

## 2. Related Work

### 1 언어 모델 (Language Models)

- GPT처럼 왼쪽 문맥만 모델링하는 좌 → 우 Transformer LM. 일부 태스크에는 문제가 됨.
- ELMo는 좌 → 우 및 우 → 좌 표현을 연결하지만, 두 방향 간 상호작용을 사전학습하지 않음.
- GPT-2는 매우 큰 LM이 비지도 멀티태스크 모델로 작동함을 보임.

### 2 마스킹 언어 모델 (Masked Language Models)

- BERT: 마스킹된 언어 모델링을 도입하여 좌우 문맥 단어 간 상호작용 학습 가능. 단, 예측이 자기회귀적이지 않아 생성 태스크 효과 감소.
- SpanBERT: 스패ن 단위 마스킹으로 성능 향상. BART의 Text Infilling 아이디어의 모태.

### 3 UniLM (Unified Language Model)

- 앙상블 마스크(좌 → 우, 우 → 좌, 비마스킹, 혼합)로 BERT를 파인튜닝하여 생성판별 양쪽에 활용 가능.
- BART와의 차이: UniLM의 예측은 조건부 독립(conditionally independent)인 반면, BART 디코더는 자기회귀적(autoregressive). BART는 디코더가 항상 손상되지 않은 문맥(uncorrupted context)으로 학습되어 사전학습-생성 간 불일치가 줄어듦.

### 4 MASS (Masked Sequence-to-Sequence)

- 연속된 토큰 스패ンを 마스킹한 입력을 인코더에, 마스킹된 토큰들을 디코더 출력으로 학습하는 BART와 가장 유사한 모델.
- BART와의 차이: 인코더와 디코더에 서로 다른(disjoint) 토큰 집합이 입력되어 판별 태스크 성능이 낮음.

### 5 XLNet

- 마스킹 토큰을 무작위 순서로 자기회귀적으로 예측하여 좌우 문맥을 모두 참조 가능.
- BART와의 차이: BART 디코더는 사전학습 시 좌 → 우로 동작하여 생성 (generation) 시의 설정과 일치함.

## 3. Method

### BART 아키텍처 (Architecture)



#### 핵심 학습 목표

손상된 문서(Corrupted Document) → 양방향 인코더 → 자기회귀 디코더 → 원본 문서 복원. 사전학습 시 디코더 출력과 원본 문서 간의 음의 로그우도 (Negative Log Likelihood)를 최소화하도록 최적화.

- 인코더

: 양방향(Bidirectional) Transformer 인코더. 손상된 텍스트를 입력받아 전체 문맥을 참조하며 인코딩.

- 디코더

: 좌→우 자기회귀(Auto-regressive) Transformer 디코더. 인코더 최종 은닉층에 대한 크로스-어텐션(cross-attention)을 각 레이어에서 수행. (GPT와 동일한 구조).

- 세부 설정

: ReLU 대신 GeLU 활성화 함수 사용, 파라미터 초기화  $N(0, 0.02)$ . Base 모델: 인코더디코더 각 6레이어(hidden size 768), Large 모델: 각 12레이어(hidden size 1024). 동일 크기 BERT 대비 약 10% 더 많은 파라미터.

### 노이즈 전략 (Noising Strategies)

#### 1 Token Masking

- BERT를 따라 무작위 토큰을 샘플링하여 [MASK] 요소로 교체.

#### 2 Token Deletion

- 무작위 토큰을 입력에서 완전히 삭제. Token Masking과 달리, 모델이 어느 위치에서 토큰이 삭제됐는지도 스스로 판단해야 함.

#### 3 Text Infilling ★ 핵심 기법 (본 논문 제안)

- 포아송 분포( $\lambda=3$ )에서 스패 길이를 샘플링하여 여러 텍스트 스패(span)를 각각 단 하나의 [MASK] 토큰으로 교체. 0-길이 스패는 [MASK] 삽입에 해당.
- SpanBERT에서 착안했으나 차이점: SpanBERT는 스패와 동일한 길이의 [MASK] 시퀀스로 교체하지만, BART는 단 하나의 [MASK]로 교체하여 모델이 스패에서 몇 개의 토큰이 빠졌는지도 예측해야 함.

#### 4 Sentence Permutation

- 문서를 온점(full stop) 기준으로 문장 단위로 분리하고 무작위 순서로 섞음.

#### 5 Document Rotation

- 균일 분포로 무작위 토큰을 선택하고, 그 토큰이 문서의 시작점이 되도록 문서를 회전. 모델이 실제 문서 시작점을 식별하도록 학습.

## 파인튜닝 전략 (Fine-tuning Strategies)

### 📌 시퀀스 분류 (Sequence Classification Tasks)

동일한 입력을 인코더와 디코더 양쪽에 입력. 최종 디코더 토큰의 은닉 상태를 새로운 다중 클래스 선형 분류기에 연결. BERT의 [CLS] 토큰 방식과 유사하나, 토큰을 끝에 추가하여 디코더가 전체 입력의 디코더 상태를 참조 가능.

### 📌 토큰 분류 (Token Classification Tasks)

전체 문서를 인코더디코더에 입력. 디코더 최상위 은닉 상태를 각 단어의 표현으로 사용하여 토큰 분류 수행. (예: SQuAD 답변 끝점 분류)

### 📌 시퀀스 생성 (Sequence Generation Tasks)

자기회귀 디코더를 가지므로 추상적 질의응답요약 등 생성 태스크에 직접 파인튜닝 가능. 인코더 입력 = 입력 시퀀스, 디코더가 자기회귀적으로 출력 생성.

### 📌 기계 번역 (Machine Translation)

BART 인코더의 임베딩 레이어를 새로 무작위 초기화된 인코더로 교체.

2단계 학습: ① 새 인코더·BART 위치 임베딩·BART 인코더 첫 번째 레이어의 self-attention 입력 투영 행렬만 학습, ② 전체 파라미터를 소규모 반복 학습. 새 인코더는 BART 원본과 별도 어휘(vocabulary) 사용 가능

## 4. Experiment - 사전 학습 목표 비교

### 실험 설정



모든 모델은 동일한 크기(Base: 인코더·디코더 각 6레이어, hidden size 768)이며, 도서+위키피디아 데이터로 100만 스텝 학습. 공정한 비교를 위해 학습률과 레이어 정규화 설정만 각 목표에 맞게 조정.

- Language Model (GPT 방식): 좌 → 우 Transformer LM. 크로스-어텐션 없는 BART 디코더에 해당.
- Permuted Language Model (XLNet 방식): 토큰의 1/6을 샘플링하여 무작위 순서로 자기회귀 생성.
- Masked Language Model (BERT 방식): 토큰의 15%를 [MASK]로 교체, 독립적으로 원본 토큰 예측.
- Multitask Masked Language Model (UniLM 방식): 좌 → 우 1/6, 우 → 좌 1/6, 비마스킹 1/3, 혼합 1/3 비율의 self-attention 마스크 앙상블.
- Masked Seq-to-Seq (MASS 방식): 토큰의 50%를 포함하는 스패를 마스킹, Seq2Seq 모델로 마스킹된 토큰 예측.

## 결과

| Model                                  | SQuAD 1.1<br>F1 | MNLI<br>Acc | ELI5<br>PPL  | XSum<br>PPL | ConvAI2<br>PPL | CNN/DM<br>PPL |
|----------------------------------------|-----------------|-------------|--------------|-------------|----------------|---------------|
| BERT Base (Devlin et al., 2019)        | 88.5            | <b>84.3</b> | -            | -           | -              | -             |
| Masked Language Model                  | 90.0            | 83.5        | 24.77        | 7.87        | 12.59          | 7.06          |
| Masked Seq2seq                         | 87.0            | 82.1        | 23.40        | 6.80        | 11.43          | 6.19          |
| Language Model                         | 76.7            | 80.1        | <b>21.40</b> | 7.00        | 11.51          | 6.56          |
| Permuted Language Model                | 89.1            | 83.7        | 24.03        | 7.69        | 12.23          | 6.96          |
| Multitask Masked Language Model        | 89.2            | 82.4        | 23.73        | 7.50        | 12.39          | 6.74          |
| BART Base                              |                 |             |              |             |                |               |
| w/ Token Masking                       | 90.4            | 84.1        | 25.05        | 7.08        | 11.73          | 6.10          |
| w/ Token Deletion                      | 90.4            | 84.1        | 24.61        | 6.90        | 11.46          | 5.87          |
| w/ Text Infilling                      | <b>90.8</b>     | 84.0        | 24.26        | <b>6.61</b> | <b>11.05</b>   | 5.83          |
| w/ Document Rotation                   | 77.2            | 75.3        | 53.69        | 17.14       | 19.87          | 10.59         |
| w/ Sentence Shuffling                  | 85.4            | 81.5        | 41.87        | 10.93       | 16.67          | 7.89          |
| w/ Text Infilling + Sentence Shuffling | <b>90.8</b>     | 83.8        | 24.17        | 6.62        | 11.12          | <b>5.41</b>   |



## 분석 결과

- 토큰 마스킹이 핵심: 문서 회전(Document Rotation)이나 문장 섞기(Sentence Permutation)만 단독 사용 시 성능이 낮음. 성공적인 방법들은 모두 Token Deletion, Masking 또는 self-attention 마스크를 사용함.
- 좌→우 사전학습이 생성 성능 향상: Masked LM과 Permuted LM은 생성 태스크에서 다른 모델들보다 낮은 성능. 이 둘은 사전학습 중 좌→우 자기회귀 LM을 포함하지 않는 유일한 모델들임.
- SQuAD에는 양방향 인코더가 핵심: 순수 좌→우 디코더는 미래 문맥이 분류 결정에 중요한 SQuAD에서 성능이 낮음. BART는 절반의 양방향 레이어만으로도 유사한 성능 달성.
- ELI5 예외: 유일하게 순수 언어 모델이 BART보다 좋은 성능. 출력이 입력에 의해 느슨하게(loosely) 제약받는 태스크에서는 BART가 덜 효과적임.

## 4. Experiment - 대규모 사전학습 실험

### 실험 설정

- RoBERTa와 동일한 규모로 학습: 인코더디코더 각 12레이어, hidden size 1024, 배치 크기 8000, 50만 스텝.
- 학습 데이터: 뉴스, 도서, 스토리, 웹 텍스트로 구성된 160GB 텍스트 (Liu et al., 2019와 동일).
- 토크나이저: GPT-2와 동일한 Byte-Pair Encoding(BPE).
- 노이즈 전략: Section 4 결과를 바탕으로 Text Infilling + Sentence Permutation 조합 사용. 각 문서의 토큰 30% 마스킹, 모든 문장 순서 치환. 학습 마지막 10% 구간에서는 드롭아웃 비활성화.

### 결과

|         | SQuAD 1.1<br>EM/F1 | SQuAD 2.0<br>EM/F1 | MNLI<br>m/mm     | SST<br>Acc  | QQP<br>Acc  | QNLI<br>Acc | STS-B<br>Acc | RTE<br>Acc  | MRPC<br>Acc | CoLA<br>Mcc |
|---------|--------------------|--------------------|------------------|-------------|-------------|-------------|--------------|-------------|-------------|-------------|
| BERT    | 84.1/90.9          | 79.0/81.8          | 86.6/-           | 93.2        | 91.3        | 92.3        | 90.0         | 70.4        | 88.0        | 60.6        |
| UniLM   | -/-                | 80.5/83.4          | 87.0/85.9        | 94.5        | -           | 92.7        | -            | 70.9        | -           | 61.1        |
| XLNet   | <b>89.0/94.5</b>   | 86.1/88.8          | 89.8/-           | 95.6        | 91.8        | 93.9        | 91.8         | 83.8        | 89.2        | 63.6        |
| RoBERTa | 88.9/ <b>94.6</b>  | <b>86.5/89.4</b>   | <b>90.2/90.2</b> | 96.4        | 92.2        | 94.7        | <b>92.4</b>  | 86.6        | <b>90.9</b> | <b>68.0</b> |
| BART    | 88.8/ <b>94.6</b>  | 86.1/89.2          | 89.9/90.1        | <b>96.6</b> | <b>92.5</b> | <b>94.9</b> | 91.2         | <b>87.0</b> | 90.4        | 62.8        |

Table 2: Results for large models on SQuAD and GLUE tasks. BART performs comparably to RoBERTa and XLNet, suggesting that BART's uni-directional decoder layers do not reduce performance on discriminative tasks.



BART는 동일한 학습 자원을 사용한 가장 직접적인 비교 대상인 RoBERTa와 대부분의 태스크에서 유사한 성능을 보임. BART의 단방향 디코더 레이어가 판별 태스크 성능을 낮추지 않음을 시사

|                                    | CNN/DailyMail |              |              | XSum         |              |              |
|------------------------------------|---------------|--------------|--------------|--------------|--------------|--------------|
|                                    | R1            | R2           | RL           | R1           | R2           | RL           |
| Lead-3                             | 40.42         | 17.62        | 36.67        | 16.30        | 1.60         | 11.95        |
| PTGEN (See et al., 2017)           | 36.44         | 15.66        | 33.42        | 29.70        | 9.21         | 23.24        |
| PTGEN+COV (See et al., 2017)       | 39.53         | 17.28        | 36.38        | 28.10        | 8.02         | 21.72        |
| UniLM                              | 43.33         | 20.21        | 40.51        | -            | -            | -            |
| BERTSUMABS (Liu & Lapata, 2019)    | 41.72         | 19.39        | 38.76        | 38.76        | 16.33        | 31.15        |
| BERTSUMEXTABS (Liu & Lapata, 2019) | 42.13         | 19.60        | 39.18        | 38.81        | 16.50        | 31.27        |
| BART                               | <b>44.16</b>  | <b>21.28</b> | <b>40.90</b> | <b>45.14</b> | <b>22.27</b> | <b>37.25</b> |

Table 3: Results on two standard summarization datasets. BART outperforms previous work on summarization on two tasks and all metrics, with gains of roughly 6 points on the more abstractive dataset.

- CNN/DailyMail: 요약이 원문 문장과 가깝게 추출되는 경향. 추출 모델도 경쟁력 있으나, BART가 모든 기존 연구를 능가.
- XSum: 매우 추상적인 요약 데이터셋으로 추출 모델 성능이 낮음. BART는 BERT를 활용한 최고 기존 연구 대비 모든 ROUGE 지표에서 약 6점 향상.

|                     | ConvAI2      |              |
|---------------------|--------------|--------------|
|                     | Valid F1     | Valid PPL    |
| Seq2Seq + Attention | 16.02        | 35.07        |
| Best System         | 19.09        | 17.51        |
| BART                | <b>20.72</b> | <b>11.85</b> |

Table 4: BART outperforms previous work on conversational response generation. Perplexities are renormalized based on official tokenizer for ConvAI2.

- ConvAI2: 이전 컨텍스트와 텍스트 명시된 페르소나(persona)에 조건부로 응답을 생성하는 태스크. 두 자동 지표 모두에서 기존 연구 능가

|                   | ELI5        |            |             |
|-------------------|-------------|------------|-------------|
|                   | R1          | R2         | RL          |
| Best Extractive   | 23.5        | 3.1        | 17.5        |
| Language Model    | 27.8        | 4.7        | 23.1        |
| Seq2Seq           | 28.3        | 5.1        | 22.8        |
| Seq2Seq Multitask | 28.9        | 5.4        | 23.1        |
| BART              | <b>30.6</b> | <b>6.2</b> | <b>24.3</b> |

Table 5: BART achieves state-of-the-art results on the challenging ELI5 abstractive question answering dataset. Comparison models are from Fan et al. (2019).

- ELI5: 장문 자유형 답변 생성 태스크. 이전 최고 연구 대비 ROUGE-L 기준

1.2점 향상. 단, 답변이 질문에 의해 느슨하게 제약되는 어려운 데이터셋.

|            | RO-EN        |
|------------|--------------|
| Baseline   | 36.80        |
| Fixed BART | 36.29        |
| Tuned BART | <b>37.96</b> |

Table 6: The performance (BLEU) of baseline and BART on WMT'16 RO-EN augmented with back-translation data. BART improves over a strong back-translation (BT) baseline by using monolingual English pre-training.

- 강력한 역번역(back-translation) 베이스라인 대비 1 BLEU 향상.
- 단, 역번역 데이터 없이는 효과가 낮고 과적합(overfitting) 경향이 있어 추가적인 정규화 기법 탐색이 필요함을 논문이 명시.

## 5. Conclusion



BART는 손상된 문서를 원본으로 매핑하도록 학습하는 사전학습 방법을 제안. 판별 태스크에서는 RoBERTa와 유사한 성능을 달성하면서, 다양한 텍스트 생성 태스크에서 새로운 SOTA를 기록. 향후 연구 방향으로 특정 최종 태스크에 맞춘 새로운 문서 손상 방법 탐색을 제안.

- **통합 아키텍처의 범용성 증명:** BERT(양방향 인코더) + GPT(자기회귀 디코더) 통합이 NLU·NLG 양쪽에서 효과적임을 대규모 실험으로 입증.
- **Text Infilling의 우수성:** 스패를 단일 [MASK]로 교체하는 새로운 기법이 가장 범용적으로 강력한 노이즈 전략임을 체계적 ablation으로 확인.
- **생성 태스크의 패러다임 전환:** 추상적 요약(XSum +6 ROUGE), 대화 생성(ConvAI2 SOTA), 기계번역(+1.1 BLEU) 등 생성 전 영역에서 사전학습+파인튜닝 패러다임의 강

점을 실증.

# + Dropout: A Simple Way to Prevent Neural Networks from Overfitting

## 1. Introduction

### 연구 분야 및 배경

#### 연구 분야

#### 과적합 방지 정규화 (Regularization for Overfitting)

- 대규모 파라미터를 가진 심층 신경망(Deep Neural Network)은 매우 강력한 머신러닝 시스템이지만, 훈련 데이터에 과적합(Overfitting)되는 심각한 문제를 가짐.
- 기존 해결책: 검증 세트 성능이 나빠지면 학습을 조기 종료(Early Stopping)하거나, L1·L2 정규화, 소프트 가중치 공유(Soft Weight Sharing) 등의 가중치 페널티 적용.

#### 연구 배경

#### 모델 결합(Model Combination)의 딜레마

- 무한한 연산이 있다면 최선의 정규화는 모든 파라미터 설정의 예측을 훈련 데이터에 대한 사후 확률(Posterior Probability)로 가중하여 평균하는 것(베이지안 방식).
- 현실적 대안: 지수적으로 많은 학습된 모델들의 예측을 동일 가중치 기하 평균(Equally-weighted Geometric Mean)으로 근사.
- 문제: 모델 결합은 성능을 거의 항상 향상시키지만, 대형 신경망에서는 별도로 학습된 여러 네트워크의 출력을 평균하는 방식이 연산 비용이 너무 높아 현실적으로 불가능.

### 기존 연구 한계점

#### 다수 모델 학습의 현실적 장벽 (Prohibitive Computational Cost)

- 모델들이 서로 달라야 결합 효과가 극대화되는데, 이를 위해서는 서로 다른 아키텍처 또는 서로 다른 데이터로 학습해야 함.
- 각 아키텍처마다 최적 하이퍼파라미터 탐색이 필요하고, 각 대형 네트워크 학습에는 막대한 연산이 필요. 또한 대형 네트워크는 대량의 훈련 데이터를 요구하는데, 각기 다른 데이터 부분집합으로 학습할 만큼 데이터가 충분하지 않을 수 있음.
- 설령 여러 대형 네트워크를 학습했다하더라도, 빠른 응답이 중요한 테스트 상황에서 모두 사용하는 것은 현실적으로 불가능

## 이 논문의 핵심 기여



### Dropout의 핵심 아이디어

학습 중 신경망에서 유닛(hidden unit 및 visible unit)을 그 연결(connections)과 함께 무작위로 제거(Drop)하는 기법. 각 유닛은 다른 유닛과 독립적으로 고정 확률  $p$ 로 유지(retain)되며,  $p = 0.5$ 가 광범위한 네트워크와 태스크에서 최적에 가까운 것으로 확인됨. 입력 유닛의 경우 최적 유지 확률은 0.5보다 1에 가까운 것이 일반적.

### 1 과적합 방지

- 유닛들이 서로 과도하게 co-adapt(공동 적응)하는 것을 방지. 각 학습 케이스마다 새로운 '얇아진 네트워크(Thinned Network)'를 샘플링하여 학습하므로,  $n$ 개 유닛을 가진 신경망은  $2^n$ 개의 가능한 얇아진 네트워크의 집합으로 볼 수 있음.

### 2 지수적으로 많은 모델의 효율적 결합 근사

- 테스트 시에는 드롭아웃 없이 단일 네트워크를 사용하되, 학습된 가중치를 유지 확률  $p$ 로 스케일 다운( $W_{\text{test}} = pW$ ). 이렇게 하면 모든 얇아진 네트워크의 예측을 평균한 것과 동일한 기댓값 출력을 단일 순전파(forward pass)로 효율적으로 근사.

### 3 광범위한 태스크에서의 성능 향상 입증

- 비전(Vision), 음성 인식(Speech Recognition), 문서 분류(Document Classification), 전산 생물학(Computational Biology) 등 다양한 지도학습 태스크에서 성능 향상을 보이며 다수의 벤치마크에서 최고 성능(State-of-the-Art) 달성.