



StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

Contribution

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

Squeeze-and-Excitation Networks

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

1. Introduction

논문이 다루는 분야

- 단일 이미지 내에서 머리색, 성별, 나이, 표정 등 특정한 속성(Attribute)을 다른 속성으로 자유롭게 변환하는 Multi-domain image-to-image translation 분야
- 조건부 생성 적대 신경망(Conditional GAN)을 기반으로, 입력 이미지와 원하는 타겟 도메인 정보를 함께 제공하여 유연하게 이미지를 합성하고 편집하는 생성 모델 연구

해당 task에서 기존 연구 한계점

- **네트워크 확장의 비효율성**

기존의 교차 도메인(Cross-domain) 모델들은 k 개의 도메인 간 변환을 모두 학습하기 위해 무려 $k(k-1)$ 개의 독립적인 생성기를 훈련해야 하는 극심한 구조적 비효율성을 가짐

- **제한적인 데이터 활용과 품질 저하**


각 생성기가 전체 학습 데이터가 아닌 단 두 개의 도메인 이미지에만 의존하므로, 얼굴의 윤곽이나 형태와 같은 전역적인(Global) 특징을 완벽히 학습하지 못해 최종 생성 이미지의 품질이 저하됨

- **이종 데이터셋 결합 훈련 불가**


각 데이터셋마다 보유한 레이블 정보가 다르기 때문에(예: CelebA는 머리색 속성만, RaFD는 표정 속성만 보유), 서로 다른 데이터셋을 하나로 엮어 다중 도메인을 훈련하는 것이 기존 구조에서는 불가능함

논문의 contributions

(a) Cross-domain models



(b) StarGAN



- **단일 모델 기반 다중 도메인 매핑**

수십 개의 네트워크 대신 단 하나의 생성기(Generator)와 판별기(Discriminator)만으로 다중 도메인 간의 모든 변환 매핑을 성공적으로 학습하는 확장성 높은 아키텍처인 **StarGAN**을 제안함

- **Mask vector 도입**

데이터셋마다 서로 다른 레이블 체계를 통합하기 위해, 모델이 모르는 레이블은 무시하고 명시적으로 주어진 레이블에만 집중하게 만드는 마스크 벡터 기법을 최초로 도입함

- **이종 데이터셋 간 지식 전이 성공**

마스크 벡터를 활용하여 CelebA와 RaFD처럼 다른 레이블을 가진 복수의 데이터셋을 단일 네트워크 내에서 성공적으로 결합 훈련함

- Facial attribute transfer 및 Facial expression synthesis 벤치마크에서, 모든 훈련 데이터를 한 번에 활용하는 StarGAN의 구조적 우위를 바탕으로 기존 베이스라인 모델들을 뛰어넘는 정성적, 정량적 결과를 증명함

2. Related Work

1) Introduction에서 언급한 기존 연구들에 대해 어떻게 서술하는가


- 기존 Image-to-Image Translation 연구 중 pix2pix 모델은 Paired 데이터가 필수적이라는 데이터 수집의 한계를 가진다고 지적함
- 이후 등장한 UNIT, CycleGAN, DiscoGAN 등은 Unpaired 데이터 문제를 해결하여 큰 성과를 거두었음을 서술함
- 하지만 이러한 최신 연구들조차 한 번에 두 개의 도메인 사이의 관계만 학습할 수 있다고 분석함
- 따라서 다중 도메인을 다루기 위해서는 도메인 쌍의 개수만큼 독립적인 모델을 훈련해야 하는 Scalability 한계가 명확하다고 설명함

2) 제안 방법의 차별성을 어떻게 표현하고 있는가

- 수많은 네트워크를 훈련해야 했던 기존 방법들과 달리, 단 하나의 모델만을 사용하여 여러 도메인 간의 관계를 동시에 학습할 수 있음을 가장 큰 구조적 차별성으로 강조함
- 조건부 도메인 정보를 제공함으로써, 복잡한 네트워크의 확장 없이도 타겟 도메인으로 이미지를 유연하게 변환할 수 있는 프레임워크임을 내세움
- Adversarial loss를 기본적으로 활용하여 생성된 이미지가 최대한 실제 사진처럼 보이도록 높은 품질을 확보했음을 명시함


3. 제안 방법론

Main Idea



- 단일 생성기(Generator, G)에 입력 이미지와 원하는 타겟 도메인 레이블을 동시에 입력하여, 하나의 네트워크만으로 유연한 이미지 변환을 수행하도록 설계함
- 학습 최적화를 위해 다음의 3가지 핵심 손실 함수를 결합하여 사용함:
 - **Adversarial Loss:**
생성된 이미지가 실제 사진처럼 현실감 있게 보이도록 판별기(Discriminator, D)를 속이는 데 사용됨.
 - **Domain Classification Loss:**
보조 분류기(Auxiliary classifier)를 도입하여, 생성된 이미지가 사용자가 의도한 타겟 도메인(예: 금발, 웃는 표정)으로 정확히 분류되도록 유도함.
 - **Reconstruction Loss:**
도메인이 변환된 가짜 이미지와 원본 도메인 레이블을 다시 G 넣어 원본 이미지를 복원하게 함으로써, 머리색이나 표정 외에 사람의 고유한 정체성(얼굴형 등)을 유지하게 함.
- 이종 데이터셋(CelebA, RaFD 등)을 하나의 네트워크에서 훈련하기 위해, 각 데이터셋의 레이블 벡터와 특정 데이터셋의 유효성을 알려주는 '마스크 벡터'를 하나로 이어 붙이는 혁신적인 기법을 제안함


Contribution



- 서론에서 목표로 한 '단일 모델을 통한 다중 도메인 매핑' 및 '여러 데이터셋의 통합 훈련'이라는 비전이, 보조 분류기와 마스크 벡터라는 구체적인 알고리즘 설계로 본문에 일관성 있게 구현됨
- 기존 교차 도메인 모델들이 수많은 생성기를 필요로 했던 구조적 비효율성을, 목적 함수의 통합과 조건부 레이블(c) 투입을 통해 어떻게 단일 아키텍처로 우회하고 극복했는지 수학적 근거를 명확히 제시함
- **높은 재현 및 구현 가능성:**
최적화의 안정성을 위해 Wasserstein GAN과 Gradient Penalty를 적용했다는 점을 수식(Eq 8)으로 명시하였으며, 손실 함수의 가중치와 네트워크 아키텍처(2개의 Convolution, 6개의 Residual block 등)를 상세히 기술하여 코드로 바로 구현 가능하도록 친절하게 작성됨

4. 실험 및 결과

Dataset



- **CelebA**: 40개의 Binary attribute를 가진 얼굴 이미지 Dataset으로, 본 실험에서는 Hair color, Gender, Age를 활용해 7개의 Domain을 구성함.
- **RaFD**: 67명의 참가자가 8가지 표정을 짓고 있는 Dataset.

Baseline

- **DIAT**: 두 Domain 간의 Mapping을 학습하며 Identity feature를 보존하도록 정규화하는 모델.
- **CycleGAN**: Cycle consistency loss를 사용하여 두 Domain 간의 Mapping을 학습하는 모델.
- **IcGAN**: Encoder와 cGAN을 결합하여 Latent vector와 Conditional vector를 기반으로 이미지를 합성하는 모델.

결과



Method	Classification error	# of parameters
DIAT	4.10	52.6M $\times$ 7
CycleGAN	5.99	52.6M $\times$ 14
IcGAN	8.07	67.8M $\times$ 1
StarGAN	2.12	53.2M $\times$ 1
Real images	0.45	-

- **Qualitative evaluation:**

StarGAN은 기존 모델들보다 월등히 높은 시각적 품질을 보여주었으며, Input 이미지의 고유한 Identity를 가장 잘 보존함. 이는 Multi-task learning을 통해 여러 Domain의 데이터를 동시에 활용함으로써 강력한 Regularization 효과를 얻었기 때문임.

- **Quantitative evaluation (AMT):**

Amazon Mechanical Turk를 활용한 사용자 평가 결과, Single attribute transfer 및 Multi-attribute transfer 모두에서 StarGAN이 압도적인 1위를 차지함. 특히 복잡한 Multi-attribute transfer에서 타 모델과의 성능 격차가 훨씬 크게 벌어짐을 확인함.

- **Classification error 및 Scalability:**

RaFD에서 ResNet-18 기반 Classifier로 합성된 이미지를 평가한 결과 가장 낮은 에러율(2.12%)을 달성함. 또한 DIAT 대비 7배, CycleGAN 대비 14배 적은 Parameter만으로 모든 변환을 완벽히 학습해 내어 탁월한 Scalability를 입증함.

- **Joint training 효과:**

CelebA와 RaFD를 함께 학습한 StarGAN-JNT가 RaFD만 학습한 StarGAN-SNG보다 CelebA 이미지의 표정 합성에서 훨씬 선명하고 자연스러운 결과를 생성함. 이는 두 Dataset을 함께 활용해 Low-level task의 처리 능력을 크게 향상시켰기 때문임.

5. 결론 (배운점)

1) 연구의 의의 및 한계점

- **연구의 의의:**

- 기존 다중 도메인 변환 모델들이 가지던 치명적인 비효율성(도메인이 늘어날수록 훈련해야 할 모델 개수가 기하급수적으로 증가하는 문제)을 단 하나의 생성기(Generator)로 해결하여, 확장성(Scalability)과 파라미터 메모리 효율성을 극대화한 기념비적인 연구임
- 특정 도메인에 종속된 구조를 탈피하고, '마스크 벡터(Mask Vector)'라는 직관적인 장치를 도입해 서로 다른 레이블 체계를 가진 이종 데이터셋(CelebA, RaFD)을

하나의 파이프라인에서 성공적으로 통합 학습시킨 점이 매우 혁신적임

- **연구의 한계점:**

- 변환하고자 하는 속성 외에 원본 이미지의 배경색이나 질감이 미세하게 왜곡되거나 흐릿해지는 현상이 완벽하게 해결되지는 않았음
- 단일 생성기가 모든 도메인의 매핑을 감당해야 하므로, 처리해야 할 이미지 해상도가 매우 커지거나 융합해야 할 데이터셋의 수가 극단적으로 많아질 경우 모델의 표현력 한계로 인한 품질 저하가 발생할 가능성이 큼

2) 좋았던/아쉬웠던 점

- **좋았던 점:**

데이터셋 통합이라는 까다로운 문제를 풀기 위해 알고리즘의 층을 무작정 복잡하게 짰 것이 아니라, 데이터 입력단에 0과 1로 이루어진 '마스크 벡터'를 이어 붙인다는 단순한 방식이 인상적이었음.

- **아쉬웠던 점:** 논문이 제시하는 아이디어의 뼈대는 명쾌하지만, 실제 GAN 모델의 고질적인 불안정성을 고려할 때 세 가지 손실 함수(적대적, 분류, 재구성 손실) 간의 가중치 밸런스를 맞추는 과정이 매우 까다로울 것으로 예상됨. 학부생 입장에서 한정된 GPU 자원으로 이 모든 다중 도메인 최적화 과정을 직접 바닥부터 튜닝하며 재현해 보기에는 현실적인 리소스 장벽이 다소 높게 느껴짐.

Squeeze-and-Excitation Networks

1. Introduction

논문이 다루는 분야


- Computer Vision 영역에서의 Convolutional Neural Network(CNN) 아키텍처 설계 및 Representation learning
- 네트워크의 표현력을 향상시키기 위해 Channel 간의 상호 의존성 (Interdependencies)을 명시적으로 모델링하는 메커니즘 연구

해당 task에서 기존 연구 한계점

- 기존의 CNN 아키텍처 최적화 연구들은 주로 Spatial dimension 측면에서 Receptive field를 넓히거나 네트워크의 깊이를 더하는 방식(Inception, ResNet 등)에 집중해 옴

- Convolution 연산이 Local spatial connectivity와 Channel-wise dynamics를 한 번에 융합하여 처리하기는 하지만, Channel 간의 관계는 암묵적(Implicit)이며 Local 영역의 수용장에만 국한되어 반영된다는 한계가 존재함
- 즉, 모델이 어떤 Channel의 Feature가 전체 이미지 관점에서 더 유용한 정보인지 파악하고 가중치를 두어 민감도를 조절하는 구조적 시스템이 부족함

논문의 contributions



- Channel 간의 관계를 명시적으로 모델링하여 Feature의 질을 높이는 Squeeze-and-Excitation(SE) block을 새롭게 제안함
- Global information을 압축(Squeeze)하고 이를 바탕으로 각 Channel의 중요도를 재조정(Excitation)하여, 유용한 Feature는 강조하고 덜 중요한 Feature는 억제하는 Feature recalibration 과정을 구현함
- SE block은 Computational cost 증가가 최소화되어 있으면서도, 기존의 표준 아키텍처(VGG, ResNet, Inception 등)에 쉽게 결합될 수 있는 높은 범용성과 실용성을 가짐을 증명함
- SE block을 통합한 SENet 모델을 통해 ILSVRC 2017 분류 대회에서 우승을 차지하며 기존 Baseline을 뛰어넘는 압도적인 성능을 실증함