



Squeeze-and-Excitation Networks

# Citation Count	25000
🕒 Difficulty	Intermediate
🏛️ Institution	Academic
≡ Keyword	SENet, Squeeze-and-Excitation, Channel Attention, Feature Recalibration, ImageNet
≡ Research Area	Computer Vision / CNN Architecture
# Year	2019

1. Introduction

이 논문은 CNN의 **채널 간 상호의존성(channel-wise interdependency)**을 명시적으로 모델링하여 feature representation의 품질을 향상시키는 새로운 구조적 단위, **Squeeze-and-Excitation (SE) block**을 제안합니다.

? "CNN의 합성곱 연산은 공간(spatial) 정보와 채널(channel) 정보를 동시에 처리하는데, 왜 채널 간 관계는 명시적으로 모델링하지 않는가? 채널마다 '얼마나 중요한지'를 동적으로 조정할 수 있다면 어떨까?"

저자들은 기존 CNN이 채널 간 관계를 **암묵적(implicit)**으로만 인코딩한다는 문제를 지적하며, 이를 **전역 정보(global information)**를 활용해 채널별 중요도를 동적으로 재조정(recalibrate)하는 메커니즘으로 해결합니다.

논문이 다루는 분야

이 논문은 **CNN 아키텍처 설계(CNN Architecture Design)** 분야, 특히 **채널 어텐션(channel attention)** 메커니즘을 다룹니다.

- **이미지 분류**: ImageNet, CIFAR-10/100
- **장면 분류(scene classification)**: Places365
- **객체 탐지(object detection)**: COCO
- **모바일 환경 최적화**: MobileNet, ShuffleNet과의 결합

Introduction에서는 Inception 계열 아키텍처의 multi-scale 처리, 공간적 상관관계 모델링 연구들을 언급하면서, 이와 달리 **채널 관계에 집중**한다는 차별점을 명시합니다. 기존 합성곱 연산에서 채널 의존성은 필터 가중치에 **암묵적이고 지역적(implicit and local)**으로만 인코딩되어 있어, 전역 문맥을 활용한 동적 재조정이 불가능했습니다.

해당 task에서 기존 연구 한계점

기존 CNN의 합성곱 연산은 공간과 채널 정보를 지역 수용 영역(local receptive field) 안에서만 함께 처리하므로, 채널 간 전역적(global) 의존성을 명시적으로 모델링하지 못한다.

논문의 contributions

1) SE Block: 채널 어텐션의 일반적 구조 단위 제안

이 논문의 핵심 contribution은 어떤 CNN 아키텍처에도 **플러그인(drop-in replacement)** 형태로 삽입 가능한 **Squeeze-and-Excitation block**을 제안한 것입니다.



Squeeze: 전체 feature map을 공간 차원(H×W)에 걸쳐 압축 → 채널별 전역 통계량 생성

Excitation: 채널별 통계량으로부터 채널 가중치(channel weight)를 학습 → 중요한 채널 강조, 덜 중요한 채널 억제

Scale: 학습된 가중치를 원래 feature map에 채널별 곱셈으로 적용

2) 기존 SOTA 아키텍처 성능 향상

- SE block을 ResNet-50에 추가 → ResNet-101 수준의 성능을 절반의 연산량으로 달성
- VGGNet, Inception, ResNeXt, MobileNet, ShuffleNet 등 다양한 기반 구조에 모두 적용 가능
- ILSVRC 2017 분류 대회 **1위** 달성 (top-5 error 2.251%, 전년 대비 약 25% 상대적 개선)

3) 경량성과 범용성

- ResNet-50 기준 추가 연산량 **+0.26% (GFLOPs)**, 추가 파라미터 **~10%** 수준의 극소 오버헤드
- ImageNet, CIFAR, Places365, COCO 등 다양한 데이터셋·태스크에서 일관된 성능 개선

2. Related Work

저자들은 관련 연구를 크게 세 방향으로 정리합니다.

1) Deeper Architectures

- **VGGNet, Inception:** 네트워크 깊이 증가의 효과 입증
- **Batch Normalization:** 깊은 네트워크 학습 안정화
- **ResNet:** identity skip connection으로 더 깊은 학습 가능
- **Highway Networks:** shortcut connection의 정보 흐름을 gating mechanism으로 조절
- **ResNeXt, DenseNet:** 연결 구조 재설계로 표현력 향상

이 흐름들은 공간 구조 개선에 집중했으며, 채널 간 관계는 상대적으로 덜 탐구됨.

2) Algorithmic Architecture Search

- 진화 알고리즘, 강화학습, 미분가능 탐색(DARTS) 등으로 구조를 자동 설계하는 NAS 계열 연구
- SE block은 이런 탐색 알고리즘의 **원자 단위(atomic building block)**로도 활용 가능함을 언급

3) Attention and Gating Mechanisms

- 시퀀스 학습, 이미지 캡셔닝, 위치 인식 등 다양한 분야의 attention 메커니즘
- **Residual Attention Network (Wang et al.):** trunk-and-mask 구조의 공간적 attention
- **CBAM (Woo et al.):** 공간 + 채널 어텐션 결합 (SE 이후 제안된 연구)

SE block은 이런 attention 연구들과 달리, **경량 gating 메커니즘으로 채널 관계만 집중 모델링**하여 연산 효율성과 성능 개선을 동시에 달성합니다.

3. 제안 방법론

"We propose a mechanism that allows the network to perform feature recalibration, through which it can learn to use global information to selectively emphasise informative features and suppress less useful ones."

Main Idea

전역 평균 풀링으로 채널별 통계량(Squeeze)을 추출하고, 두 개의 FC 레이어로 채널 가중치(Excitation)를 학습하여, feature map을 채널별로 재조정(Scale)한다.

구조 개요

[Figure 1 — SE block 전체 구조 다이어그램]




Fig. 1. A Squeeze-and-Excitation block.

입력 $X \in \mathbb{R}^{H' \times W' \times C'}$ 에 합성곱 변환 F_{tr} 을 적용하면 feature map $U \in \mathbb{R}^{H \times W \times C}$ 가 생성됩니다. SE block은 이 U 에 대해 다음 세 단계를 수행합니다.

Step 1. Squeeze: Global Information Embedding

각 채널의 2D feature map 전체를 하나의 스칼라 값으로 압축합니다. **Global Average Pooling**을 사용합니다.

$$z_c = F_{sq}(u_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j)$$

- 결과: $z \in \mathbb{R}^C$ (채널별 전역 통계량 벡터)
- 이 벡터는 **전체 이미지에 대한 채널별 중요도 신호**를 담고 있음
- 지역 수용 영역의 한계를 극복하고 **전역 문맥 정보**를 모든 레이어에서 활용 가능

Step 2. Excitation: Adaptive Recalibration

Squeeze로 얻은 통계량 z 로부터 채널별 가중치 $s \in \mathbb{R}^C$ 를 학습합니다.

$$s = F_{ex}(z, W) = \sigma(W_2 \cdot \delta(W_1 z))$$

- $W_1 \in \mathbb{R}^{C/r \times C}$: 차원 축소 FC 레이어 (reduction ratio r , 기본값 16)
- δ : ReLU 활성화
- $W_2 \in \mathbb{R}^{C \times C/r}$: 차원 복원 FC 레이어
- σ : Sigmoid 활성화 $\rightarrow$ 0~1 사이의 채널 가중치 출력
- Bottleneck 구조로 **모델 복잡도 제한 + 비선형 채널 상호작용** 학습
- Sigmoid (non-mutually-exclusive) 사용으로 여러 채널이 동시에 강조될 수 있음

Step 3. Scale: Feature Recalibration

$$\tilde{x}_c = F_{scale}(u_c, s_c) = s_c \cdot u_c$$

- 학습된 채널 가중치 s_c 를 해당 채널의 feature map $u_c \in \mathbb{R}^{H \times W}$ 에 스칼라 곱
- 결과: $\tilde{X} \in \mathbb{R}^{H \times W \times C}$ (재조정된 feature map)

다양한 아키텍처로의 적용 (Instantiations)

[Figure 2 — SE-Inception 모듈 구조 비교]




Fig. 2. The schema of the original Inception module (left) and the SE-Inception module (right).

[Figure 3 — SE-ResNet 모듈 구조 비교]




Fig. 3. The schema of the original Residual module (left) and the SE-ResNet module (right).

기반 아키텍처	SE block 위치	SE 버전 이름
VGGNet	각 합성곱 이후 비선형 활성화 뒤	SE-VGG
Inception	Inception 모듈 전체를 Ftr로 사용	SE-Inception
ResNet	Residual branch의 비-항등(non-identity) 분기에 적용, identity branch와의 합산 전	SE-ResNet
ResNeXt	동일 방식	SE-ResNeXt
MobileNet	동일 방식	SE-MobileNet
ShuffleNet	동일 방식	SE-ShuffleNet

[Table 1 — ResNet-50 / SE-ResNet-50 / SE-ResNeXt-50 아키텍처 상세 비교표]

TABLE 1
(Left) ResNet-50 [13]. (Middle) SE-ResNet-50. (Right) SE-ResNeXt-50 with a $32 \times 4d$ template. The shapes and operations with specific parameter settings of a residual building block are listed inside the brackets and the number of stacked blocks in a stage is presented outside. The inner brackets following by fc indicates the output dimension of the two fully connected layers in an SE module.

Output size	ResNet-50	SE-ResNet-50	SE-ResNeXt-50 ($32 \times 4d$)
112 × 112	conv, 7 × 7, 64, stride 2		
56 × 56	max pool, 3 × 3, stride 2		
	$\begin{bmatrix} \text{conv}, 1 \times 1, 64 \\ \text{conv}, 3 \times 3, 64 \\ \text{conv}, 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} \text{conv}, 1 \times 1, 64 \\ \text{conv}, 3 \times 3, 64 \\ \text{conv}, 1 \times 1, 256 \\ fc, [16, 256] \end{bmatrix} \times 3$	$\begin{bmatrix} \text{conv}, 1 \times 1, 128 \\ \text{conv}, 3 \times 3, 128 \\ \text{conv}, 1 \times 1, 256 \\ fc, [16, 256] \end{bmatrix} \begin{matrix} C = 32 \\ \times 3 \end{matrix}$
28 × 28	$\begin{bmatrix} \text{conv}, 1 \times 1, 128 \\ \text{conv}, 3 \times 3, 128 \\ \text{conv}, 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} \text{conv}, 1 \times 1, 128 \\ \text{conv}, 3 \times 3, 128 \\ \text{conv}, 1 \times 1, 512 \\ fc, [32, 512] \end{bmatrix} \times 4$	$\begin{bmatrix} \text{conv}, 1 \times 1, 256 \\ \text{conv}, 3 \times 3, 256 \\ \text{conv}, 1 \times 1, 512 \\ fc, [32, 512] \end{bmatrix} \begin{matrix} C = 32 \\ \times 4 \end{matrix}$
14 × 14	$\begin{bmatrix} \text{conv}, 1 \times 1, 256 \\ \text{conv}, 3 \times 3, 256 \\ \text{conv}, 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} \text{conv}, 1 \times 1, 256 \\ \text{conv}, 3 \times 3, 256 \\ \text{conv}, 1 \times 1, 1024 \\ fc, [64, 1024] \end{bmatrix} \times 6$	$\begin{bmatrix} \text{conv}, 1 \times 1, 512 \\ \text{conv}, 3 \times 3, 512 \\ \text{conv}, 1 \times 1, 1024 \\ fc, [64, 1024] \end{bmatrix} \begin{matrix} C = 32 \\ \times 6 \end{matrix}$
7 × 7	$\begin{bmatrix} \text{conv}, 1 \times 1, 512 \\ \text{conv}, 3 \times 3, 512 \\ \text{conv}, 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} \text{conv}, 1 \times 1, 512 \\ \text{conv}, 3 \times 3, 512 \\ \text{conv}, 1 \times 1, 2048 \\ fc, [128, 2048] \end{bmatrix} \times 3$	$\begin{bmatrix} \text{conv}, 1 \times 1, 1024 \\ \text{conv}, 3 \times 3, 1024 \\ \text{conv}, 1 \times 1, 2048 \\ fc, [128, 2048] \end{bmatrix} \begin{matrix} C = 32 \\ \times 3 \end{matrix}$
1 × 1	global average pool, 1000-d fc , softmax		

각 stage에서 bottleneck block의 구성은 기존과 동일하되, 각 블록 끝에 $fc, [C/r, C]$ 형태의 SE 모듈이 추가됩니다. 예를 들어 56×56 stage (256채널)에서는 $fc, [16, 256]$ 이 추가됩니다.

4. 모델 복잡도 분석

연산량 (GFLOPs)

- ResNet-50: ~3.86 GFLOPs
- SE-ResNet-50 ($r=16$): ~3.87 GFLOPs → **+0.26%** 증가
- SE-ResNet-50의 정확도는 ResNet-50을 크게 능가하며 ResNet-101(~7.58 GFLOPs)에 근접
- 학습 시간: ResNet-50 190ms → SE-ResNet-50 209ms (배치 256, 8× NVIDIA Titan X)
- CPU 추론: 164ms → 167ms (224×224 입력)

파라미터 수

SE block이 추가하는 파라미터 수 공식:

$$\frac{2}{r} \sum_{s=1}^S N_s \cdot C_s^2$$

- r : reduction ratio, S : stage 수, N_s : stage s 의 블록 수, C_s : stage s 의 출력 채널 수
- SE-ResNet-50: ~2.5M 파라미터 추가 (ResNet-50 대비 **~10%** 증가)
- 대부분의 추가 파라미터는 마지막 stage에 집중 (채널 수가 가장 많기 때문)
- 마지막 stage의 SE block 제거 시: 파라미터 증가 **~4%** 수준으로 감소, 성능 손실 <0.1% (top-5 error)

5. 실험 및 결과

5.1 이미지 분류 (ImageNet 2012)

학습 설정

- 데이터: 128만 훈련 / 5만 검증 이미지, 1000 클래스
- 데이터 증강: Random crop (224×224), Horizontal flip, Mean RGB subtraction
- 옵티마이저: Synchronous SGD, momentum 0.9, batch size 1024
- Learning rate: 초기 0.6, 30 epoch마다 ×0.1 decay, 총 100 epochs
- Reduction ratio $r = 16$ (기본값)

[Table 2 — ImageNet validation set에서 SE block 적용 전후 top-1/top-5 error 및 GFLOPs 비교]

모델	top-1 err. (재구현)	top-5 err. (재구현)	GFLOPs	top-1 err. (SENet)	top-5 err. (SENet)	개선 (top-1)
ResNet-50	24.80	7.48	3.86	23.29	6.62	+1.51%
ResNet-101	23.17	6.52	7.58	22.38	6.07	+0.79%
ResNet-152	22.42	6.34	11.30	21.57	5.73	+0.85%
ResNeXt-50	22.11	5.90	4.24	21.10	5.49	+1.01%
ResNeXt-101	21.18	5.57	7.99	20.70	5.01	+0.48%
VGG-16	27.02	8.81	15.47	25.22	7.70	+1.80%
BN-Inception	25.38	7.89	2.03	24.23	7.14	+1.15%
Inception-ResNet-v2	20.37	5.21	11.75	19.80	4.79	+0.57%

핵심 관찰: SE-ResNet-50(6.62% top-5 error)이 ResNet-101(6.52%)에 근접하면서 연산량은 절반 수준(3.87 vs 7.58 GFLOPs). SE-ResNet-101(6.07%)은 더 깊은 ResNet-152(6.34%)를 능가.

[Figure 4 — ResNet-50, ResNet-152, ResNeXt-50, BN-Inception 및 각각의 SE 버전 학습 곡선 비교]




Fig. 4. Training baseline architectures and their SENet counterparts on ImageNet. SENets exhibit improved optimisation characteristics and produce consistent gains in performance which are sustained throughout the training process.

SE 버전이 학습 전 과정에 걸쳐 일관되게 낮은 error를 유지함을 보여줍니다.

[Table 3 — MobileNet / ShuffleNet에 SE block 적용 결과]

모델	top-1 err. (원본)	top-1 err. (SENet)	개선	MFLOPs 증가	Params 증가
MobileNet	28.4	25.3	-3.1%	569 → 572	4.2M → 4.7M
ShuffleNet	32.6	31.0	-1.6%	140 → 142	1.8M → 2.4M

경량 모델에서도 매우 적은 추가 비용으로 큰 성능 향상을 달성합니다.

[CIFAR-100 분류 error (%) 비교]

모델	CIFAR-10 (원본)	CIFAR-10 (SE)	CIFAR-100 (원본)	CIFAR-100 (SE)
ResNet-110	6.37	5.21	26.88	23.85
ResNet-164	5.46	4.39	24.33	21.31
WRN-16-8	4.27	3.88	20.43	19.14
Shake-Shake + Cutout	2.56	2.12	15.85	15.41

ImageNet에 국한되지 않고 모든 기준 모델에서 일관되게 성능이 향상됩니다.

5.2 장면 분류 (Places365-Challenge)

[Table 6 — Places365 validation set top-1/top-5 error 비교]

모델	top-1 err.	top-5 err.
Places-365-CNN	41.07	11.48
ResNet-152 (재구현)	41.15	11.61
SE-ResNet-152	40.37	11.01

SE-ResNet-152가 기존 SOTA인 Places-365-CNN을 능가하며 장면 분류에서도 효과를 입증합니다.

5.3 객체 탐지 (COCO)

[Table 7 — COCO minival set에서 Faster R-CNN 기반 객체 탐지 결과 비교]

모델	AP@IoU=0.5	AP	개선 (AP)
ResNet-50	57.9	38.0	-
SE-ResNet-50	61.0	40.4	+2.4% (rel. +6.3%)
ResNet-101	60.1	39.9	-
SE-ResNet-101	62.7	41.9	+2.0% (rel. +5.0%)

Faster R-CNN의 backbone을 SE-ResNet으로 교체하는 것만으로 객체 탐지 성능도 크게 향상됩니다.

5.4 ILSVRC 2017 분류 대회

SENet-154 아키텍처:

- 64×4d ResNeXt-152를 기반으로 SE block 통합
- 224×224 crop: top-1 error 18.68%, top-5 error 4.47% (당시 최고 성능)
- 320×320 crop: top-1 error 17.28%, top-5 error 3.79%

대회 최종 결과: 소규모 SENet 앙상블로 top-5 error **2.251%** 달성 (전년 우승 2.991% 대비 ~25% 상대적 개선)

6. Ablation Study

6.1 Reduction Ratio r

[Table 10 — SE-ResNet-50에서 reduction ratio r 변화에 따른 성능 및 파라미터 비교]

Ratio r	top-1 err.	top-5 err.	Params
2	22.29	6.00	45.7M
4	22.25	6.09	35.7M
8	22.26	5.99	30.7M
16	22.28	6.03	28.1M
32	22.72	6.20	26.9M
원본 ResNet-50	23.30	6.55	25.6M

- r=16이 정확도와 파라미터 효율성의 최적 균형
- r이 너무 작으면 파라미터가 급증하면서 오히려 성능이 개선되지 않음 (과적합 위험)
- r이 너무 크면 병목이 과도해 표현력 감소

6.2 Squeeze 연산자 비교

[Table 11 — Global Max Pooling vs Global Average Pooling Squeeze 비교]

Squeeze 방식	top-1 err.	top-5 err.
Max Pooling	22.57	6.09
Average Pooling	22.28	6.03

Average pooling이 약간 더 우수하며 전체 통계를 더 잘 대표함. 두 방식 모두 기준 대비 큰 성능 향상을 보여 SE block 성능이 집계 연산 선택에 크게 의존하지 않음.

6.3 Excitation 비선형 함수 비교

[Table 12 — Excitation 연산의 비선형 함수 비교]

Excitation 함수	top-1 err.	top-5 err.
ReLU	23.47	6.98
Tanh	23.00	6.38
Sigmoid	22.28	6.03

- **ReLU**: 성능이 ResNet-50 기준선 이하로 급락 → 채널 가중치가 non-mutually-exclusive 특성(여러 채널이 동시에 강조 가능)을 유지해야 함
- **Tanh**: ReLU보다 낮지만 Sigmoid 미달
- **Sigmoid**: 0~1 범위의 연속적 가중치로 채널 간 비경쟁적(non-exclusive) 강조 가능 → 최적

6.4 Stage별 SE block 삽입 효과

[Table 13 — ResNet-50의 각 stage에 SE block 삽입 효과 비교]

구성	top-1 err.	top-5 err.
ResNet-50 (기준)	23.30	6.55
SE Stage 2만	23.03	6.48
SE Stage 3만	23.04	6.32
SE Stage 4만	22.68	6.22
SE All stages	22.28	6.03

모든 stage에서 SE block이 성능 개선에 기여하며, 각 stage의 효과는 **보완적(complementary)**이어서 합산하면 더 큰 개선을 달성합니다.

6.5 통합 위치(Integration Strategy) 비교

[Figure 5 — SE block 통합 위치 변형 4가지: (a) Standard SE, (b) SE-PRE, (c) SE-POST, (d) SE-Identity]




Fig. 5. SE block integration designs explored in the ablation study.

[Table 14 — 각 통합 전략의 성능 비교]

설계	top-1 err.	top-5 err.	설명
SE (표준)	22.28	6.03	Residual branch에 적용, 합산 전
SE-PRE	22.23	6.00	Residual unit 이전에 삽입
SE-POST	22.78	6.35	Identity branch와 합산 후 (ReLU 이후)
SE-Identity	22.20	6.15	Identity connection에 병렬 배치

- SE, SE-PRE, SE-Identity는 비슷한 성능 → **branch 합산 이전에 적용되는 한 위치에 크게 의존하지 않음**
- SE-POST는 성능 하락 → 합산 이후 적용은 효과 감소

추가로, SE block을 3×3 conv 직후에 삽입하는 SE 3×3 변형 실험(Table 15)에서는 파라미터를 더 줄이면서도 비슷한 성능을 달성 → 효율-성능 트레이드오프 조정 가능성 확인

7. SE Block의 역할 분석

7.1 Squeeze의 효과

[Table 16 — Squeeze 연산 유무 비교: ResNet-50 vs NoSqueeze vs SE]

모델	top-1 err.	top-5 err.	GFLOPs	Params
ResNet-50	23.30	6.55	3.86	25.6M
NoSqueeze (1×1 conv 대체)	22.93	6.39	4.27	28.1M
SE (Global Avg Pool)	22.28	6.03	3.87	28.1M

NoSqueeze 변형(Global Average Pooling을 제거하고 동등 파라미터의 1×1 conv로 대체)은 SE보다 GFLOPs가 오히려 더 늘어나면서도 성능이 낮습니다. 전역 정보(global information)가 SE block 성능의 핵심임을 확인.

7.2 Excitation의 역할: 클래스별 활성화 패턴

[Figure 6 — SE-ResNet-50의 각 stage에서 Excitation 활성화 분포]




Fig. 6. Activations induced by the Excitation operator at different depths in the SE-ResNet-50 on ImageNet. Each set of activations is named according to the following scheme: SE_stageID_blockID. With the exception of the unusual behaviour at SE_5_2, the activations become increasingly class-specific with increasing depth.

[Figure 7 — goldfish/plane 클래스 이미지 인스턴스별 Excitation 활성화 평균 및 표준편차 분포]




Fig. 7. Activations induced by Excitation in the different modules of SE-ResNet-50 on image samples from the goldfish and plane classes of ImageNet. The module is named "SE_stageID_blockID".

세 가지 핵심 관찰:

1. 초기 레이어(SE_2_3): 클래스 간 활성화 분포가 매우 유사 → 초기에는 클래스에 무관한(class-agnostic) 범용 특징 강조
2. 중간·후기 레이어(SE_4_6, SE_5_1): 클래스별로 뚜렷이 다른 채널 선호도 → 점점 클래스별로 특화(class-specific)

3. **최후 stage(SE_5_2, SE_5_3)**: 대부분 활성화가 1에 가까운 포화 상태 → 사실상 identity operation에 가까워짐. 마지막 stage SE block 제거 시 성능 손실이 미미한 이유를 설명

이는 깊이에 따라 SE block의 역할이 '범용 강조'에서 '클래스 특화 재조정'으로 전환됨을 보여주며, 기존 딥러닝의 계층적 표현 학습 이론과 일치합니다.

8. 결론 (배운점)



이 논문의 가장 큰 의의는 '어떤 채널이 얼마나 중요한가'를 동적으로 학습하는 경량 메커니즘을 제안하여, 기존 CNN 아키텍처에 거의 비용 없이 일관된 성능 향상을 가져왔다는 점입니다.

1) 연구의 의의

1. **채널 어텐션 패러다임 확립**: 공간 attention 중심이었던 기존 연구에서 채널 attention의 독자적 가치를 입증
2. **플러그인 모듈의 범용성**: VGG, Inception, ResNet, ResNeXt, MobileNet 등 거의 모든 CNN에 drop-in 적용 가능
3. **효율성**: 성능 대비 극소 오버헤드로 실용적 배포 가능
4. **경쟁 우승**: ILSVRC 2017 1위로 실제 대규모 벤치마크에서의 우수성 검증

2) 논문의 한계점

1. **공간 정보 무시**: Squeeze 단계에서 H×W 공간 구조를 완전히 버림 → 공간적 attention과 결합하면 더 강력할 수 있음 (→ CBAM 등 후속 연구)
2. **FC 레이어의 위치 의존성**: excitation 단계의 FC 레이어는 각 채널 위치를 고정 가정 → 입력 해상도 변화에 취약 가능
3. **마지막 stage 비효율**: 실험에서 마지막 stage SE block은 거의 identity operation처럼 작동 → 불필요한 파라미터 낭비

3) 좋았던 점

1. **직관적 설계**: Squeeze-Excitation이라는 명명과 구조가 개념을 명확하게 전달
2. **철저한 ablation study**: reduction ratio, squeeze/excitation 함수, 삽입 위치, stage별 효과 등 모든 설계 선택의 근거를 실험으로 뒷받침
3. **역할 분석(Section 7)**: 단순 성능 보고에 그치지 않고 SE block이 실제로 어떻게 작동하는지 심층 분석

4) 아쉬웠던 점

1. **공간+채널 어텐션의 시너지 미탐구**: 두 가지를 결합하면 어떨지 이 논문에서는 분석하지 않음
2. **이론적 해석의 한계**: 왜 채널 어텐션이 효과적인지에 대한 이론적 설명 부족
3. **태스크 한정**: 분류, 탐지 위주이며 segmentation 등 다른 비전 태스크에 대한 검증은 미흡

5) 배운점



SE Networks를 통해 배울 수 있는 핵심 인사이트는, "어떤 정보가 중요한지"를 네트워크 스스로 학습하게 하는 **self-attention의 아이디어를 채널 차원에서 극도로 단순하고 효율적으로 구현할 수 있다**는 점입니다. 복잡한 구조 변화 없이 전역 정보를 활용하는 경량 모듈 하나가 다양한 아키텍처와 태스크에서 일관된 성능 향상을 가져온다는 사실은, 좋은 inductive bias의 설계가 얼마나 중요한지를 보여줍니다.

SE block의 아이디어는 이후 **CBAM(공간+채널 attention)**, **ECA-Net(효율적 채널 attention)**, **Transformer의 multi-head attention** 등 현대 딥러닝 아키텍처 설계의 핵심 흐름으로 이어집니다.



SE block과 관련 방법 핵심 비교

항목	SE block	CBAM	Residual Attention	Transformer Self-Attention
Attention 유형	채널 attention	채널 + 공간 attention	공간 attention (trunk-mask)	전체(QKV 기반)
전역 정보 활용	Global Avg Pool	Global Avg/Max Pool	Hourglass module	모든 위치 간 관계
파라미터 오버헤드	매우 낮음 (~10%)	낮음	높음	높음
연산 오버헤드	매우 낮음 (+0.26%)	낮음	높음	매우 높음
적용 용이성	어떤 CNN에도 plug-in	어떤 CNN에도 plug-in	구조 의존적	구조 전환 필요



StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation

# Citation Count	6000
☉ Difficulty	Intermediate
☉ Institution	Academic
≡ Keyword	StarGAN, Multi-Domain, Image-to-Image Translation, Conditional GAN, Cycle Consistency, Mask Vector
≡ Research Area	Generative Model / Image Translation
# Year	2018

1. Introduction

이 논문은 단 하나의 **Generator**와 **Discriminator**만으로 여러 도메인 간 **image-to-image translation**을 동시에 수행할 수 있는 새로운 GAN 프레임워크, **StarGAN**을 제안합니다.

❓ "k개의 도메인 간 변환을 위해 k(k-1)개의 모델을 따로 학습해야 하는 기존 방식, 정말 비효율적이지 않은가? 단 하나의 모델로 모든 도메인을 유연하게 다룰 수는 없을까?"

저자들은 기존 image-to-image translation 모델들이 두 도메인 쌍 간에만 작동한다는 근본적 한계를 지적하며, 이를 하나의 통합 모델로 해결하는 StarGAN을 제안합니다.

논문이 다루는 분야

이 논문은 **Image-to-Image Translation** 분야, 특히 **Multi-Domain** 설정을 다룹니다. 관련 용어 정의:

- **Attribute:** 이미지에 내재된 의미 있는 특성 (hair color, gender, age 등)
- **Attribute value:** 속성의 특정 값 (black/blond/brown, male/female 등)
- **Domain:** 동일한 attribute value를 공유하는 이미지 집합

주요 응용 태스크:

- **Facial attribute transfer:** 머리색, 성별, 나이 등 얼굴 속성 변환 (CelebA)
- **Facial expression synthesis:** 표정 합성 (RaFD)
- **Cross-dataset translation:** 서로 다른 데이터셋의 도메인을 결합한 변환

해당 task에서 기존 연구 한계점

k 개의 도메인을 다루려면 $k(k-1)$ 개의 generator를 별도로 학습해야 하므로, 확장성이 없고 전체 학습 데이터를 활용하지 못하며 서로 다른 데이터셋을 동시에 학습할 수 없다.

구체적으로 세 가지 문제점:

1. **비효율성 (Inefficiency)**: 4개 도메인이면 12개의 G를 따로 학습해야 함
2. **비효과성 (Ineffectiveness)**: 각 G는 k 개 도메인 중 2개만 학습 → 전체 데이터 미활용
3. **불가능성 (Incapability)**: 데이터셋마다 레이블이 부분적으로만 존재하여 서로 다른 데이터셋의 도메인을 jointly 학습 불가

논문의 contributions

1) StarGAN: 단일 G+D로 multi-domain translation

단 하나의 Generator G와 Discriminator D로 k 개 도메인 간 모든 매핑을 동시에 학습합니다.



핵심 아이디어: G에 이미지 x 와 타겟 도메인 레이블 c 를 함께 입력으로 주어, $G(x, c) \rightarrow y$ 매핑을 학습. 학습 시 c 를 랜덤하게 생성하여 G가 유연하게 임의 도메인으로 변환하도록 유도.

2) Mask Vector를 통한 다중 데이터셋 joint training

- 서로 다른 데이터셋(CelebA + RaFD)의 부분 레이블(partial label) 문제를 해결하기 위해 mask vector 도입
- 모델이 알 수 없는 레이블을 무시하고 주어진 레이블에만 집중하도록 유도
- 다중 데이터셋 간 cross-domain translation을 최초로 성공적으로 수행

3) 질적·양적 우월성 입증

- CelebA (facial attribute transfer), RaFD (expression synthesis) 두 태스크에서 기존 모델(DIAT, CycleGAN, IcGAN) 대비 우월한 성능
- 파라미터 수 측면에서도 CycleGAN 대비 14배 적은 파라미터로 동일 태스크 처리