

StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation

날짜	2026년 6월 22일
태그	Generative

Paper Review

StarGAN: Unified Generative Adversarial Networks for Multi-Domain...

Recent studies have shown remarkable success in image-to-image translation for two domains. However, existing approaches have limited scalability and robustness in handling more than two domains,...

<https://arxiv.org/abs/1711.09020>




Keyword : Image-to-Image Translation, Multi-Domain, GAN

1. Introduction

논문이 다루는 분야

Multi-Domain Image-to-Image Translation




- 주어진 이미지의 특정 측면을 다른 것으로 변환하는 image-to-image translation 태스크를 다룸 (예: 표정 변환, 머리색 변환 등)
- GAN의 도입 이후 이 분야에서 큰 발전이 이루어졌으며, 머리색 변경, edge map으로부터 사진 복원, 풍경 이미지의 계절 변환 등의 성과가 있었음

해당 task에서 기존 연구 한계점

- 기존 모델(CycleGAN, DiscoGAN 등)은 두 개의 도메인 간 변환만 학습 가능
- Multi-domain translation에서의 문제점
 - 비효율적 : k개 도메인 간 모든 매핑을 학습하려면 $k(k-1)$ 개의 generator를 독립적으로 학습해야 함 (예: 4개 도메인이면 12개의 generator 필요)

(a) Cross-domain models



- **비효과적** : 각 generator는 k 개 중 2개 도메인의 데이터만 사용하여 학습하므로, 모든 도메인에서 공유되는 global feature(예: 얼굴 형태)를 충분히 학습하지 못함 → 생성 이미지 품질 저하
- **다중 데이터셋 공동 학습 불가** : 각 데이터셋이 부분적으로만 label을 가지고 있어, 서로 다른 데이터셋의 도메인을 함께 학습할 수 없음

논문의 contributions

- **StarGAN 제안** : 단일 generator와 단일 discriminator만으로 다중 도메인 간 매핑을 학습하는 확장 가능한 접근법

(b) StarGAN



- 고정된 변환을 학습하는 대신, generator가 이미지와 도메인 정보(label)를 함께 입력받아 해당 도메인으로 유연하게 변환
- 학습 시 target domain label을 랜덤 생성하여, 테스트 시 도메인 label을 제어하여 원하는 도메인으로 변환 가능
- **Mask vector를 이용한 다중 데이터셋 공동 학습 방법 제안**
 - 서로 다른 label 집합을 가진 여러 데이터셋을 동시에 학습 가능하게 하는 간단하면서 효과적인 방법
 - 모델이 알 수 없는 label은 무시하고, 특정 데이터셋이 제공하는 label에만 집중하도록 함
 - 서로 다른 데이터셋 간 multi-domain image translation을 최초로 성공적으로 수행
- **성과**
 - Facial attribute transfer와 facial expression synthesis 태스크에서 정성적·정량적으로 baseline 모델 대비 우수한 성능 입증

2. Related Work

- **Generative Adversarial Networks (GANs)**
 - Discriminator는 real/fake 구분을 학습, generator는 discriminator를 속이는 fake 이미지 생성을 학습
 - Image generation, image translation, super-resolution, face synthesis 등 다양한 CV 태스크에서 성과
- **Conditional GANs**
 - Discriminator와 generator에 class 정보를 제공하여 조건부 이미지 생성
 - 텍스트 설명 기반 이미지 생성, domain transfer, super-resolution, photo editing 등에 적용
- **Image-to-Image Translation**
 - **pix2pix** : cGAN 기반 supervised 방식으로 Adversarial loss + L1 loss를 사용하며, paired data가 필요함

- **UNIT** : VAE + CoGAN 결합한 모델로 두 generator가 가중치를 공유하여 cross domain의 joint distribution을 학습
- **CycleGAN, DiscoGAN** : Cycle consistency loss를 활용한 unpaired image translation
- 한계 : 위 모든 방법은 한 번에 두 도메인 간의 관계만 학습 가능하며, 각 도메인 쌍마다 별도의 모델을 학습해야 함
- StarGAN의 차별점 : 단일 모델로 다중 도메인 간 관계를 학습

3. 제안 방법론


Main Idea

StarGAN

: 단일 generator가 이미지와 도메인 label을 함께 입력받아 다중 도메인 간 image-to-image translation을 수행하고, discriminator가 생성 이미지 여부와 도메인 분류를 수행하는 unified GAN 프레임워크

Task : 단일 데이터셋 내 multi-domain translation + 서로 다른 데이터셋 간 multi-domain translation

Multi-Domain Image-to-Image Translation



- **목표** : 단일 generator G가 하나의 데이터셋에서 다중 도메인 간 매핑을 학습
- **방법론**
 - 입력 이미지 x 와 target domain label c 를 함께 받아 출력 이미지 y 를 생성 : $G(x, c) \rightarrow y$
 - Auxiliary classifier를 도입하여 단일 discriminator가 다중 도메인을 제어
 - Discriminator는 source(real/fake)에 대한 확률 분포와 domain label에 대한 확률 분포를 함께 출력 : $D : x \rightarrow D_{src}(x), D_{cls}(x)$

Adversarial Loss

- 생성된 이미지를 실제 이미지와 구분할 수 없도록 하는 손실함수

$$L_{adv} = E_x[\log D_{src}(x)] + E_{x,c}[\log(1 - D_{src}(G(x, c)))]$$

- G 는 입력 이미지 x 와 target domain label c 를 조건으로 이미지 $G(x, c)$ 를 생성하고, D 는 real과 fake 이미지를 구분하려 함
- $D_{src}(x)$ 는 D 가 출력하는 source(real/fake)에 대한 확률 분포를 의미
- G 는 해당 손실함수를 최소화하고, D 는 최대화하는 것이 목적

Domain Classification Loss

- 생성된 이미지가 target domain c 로 올바르게 분류되도록 하는 손실 함수
- Real image에 대한 분류 손실 (D 최적화용)

$$L_{cls}^r = E_{x,c'}[-\log D_{cls}(c'|x)]$$

- $D_{cls}(c'|x)$ 는 D 가 계산하는 domain label에 대한 확률 분포
- 해당 손실함수를 최소화함으로써 D 는 real image x 를 해당 원본 도메인 c' 으로 올바르게 분류하는 것을 학습
- Fake image에 대한 분류 손실 (G 최적화용)

$$L_{cls}^f = E_{x,c}[-\log D_{cls}(c|G(x,c))]$$

- 해당 손실함수를 최소화함으로써 G 는 target domain c 로 분류될 수 있는 이미지를 생성하도록 학습

Reconstruction Loss

- Adversarial loss와 classification loss만으로는 입력 이미지의 domain 무관한 내용이 보존되는 것이 보장되지 않음 → CycleGAN의 cycle consistency loss를 적용

$$L_{rec} = E_{x,c,c'}[||x - G(G(x,c),c')||_1]$$

- 단일 generator를 두 번 사용 : 원본 → target domain 변환 → 원본 복원

Full Objective

$$\begin{aligned} L_D &= -L_{adv} + \lambda_{cls} \cdot L_{cls}^r \\ L_G &= L_{adv} + \lambda_{cls} \cdot L_{cls}^f + \lambda_{rec} \cdot L_{rec} \end{aligned}$$

- 하이퍼파라미터 : $\lambda_{cls} = 1, \lambda_{rec} = 10$

Training with Multiple Datasets

- 목표 : 단일 generator G 가 서로 다른 label 집합을 가진 여러 데이터셋에서 다중 도메인 간 매핑을 학습
- 문제점 : CelebA는 facial attribute label만, RaFD는 facial expression label만 가지고 있어 서로의 label이 부분적으로 누락

Mask Vector

- **Mask vector m** 도입 : n-dimensional one-hot vector (n = 데이터셋의 개수)
 - 통합 label vector : $\tilde{c} = [c_1, \dots, c_n, m]$
 - 알려진 데이터셋의 label은 binary 또는 one-hot vector로, 나머지 unknown label은 zero vector로 설정

Training Strategy

- Generator는 통합 label $\tilde{c}$ 를 입력으로 받아 zero vector인 unknown label을 무시하고 명시된 label에 집중
- Discriminator는 auxiliary classifier를 확장하여 모든 데이터셋의 label에 대한 확률 분포를 생성하되, 해당 이미지가 속한 데이터셋의 label에 대한 classification error만 최소화 (multi-task learning)
- CelebA와 RaFD를 교대로 학습하여 discriminator는 두 데이터셋의 discriminative feature를, generator는 두 데이터셋의 모든 label을 제어하는 방법을 학습

Implementation

Improved GAN Training

- 학습의 안정성과 생성 이미지 품질 향상을 위해 기존 adversarial loss를 **WGAN-GP** (Wasserstein GAN with gradient penalty)로 대체

$$L_{adv} = E_x[D_{src}(x)] - E_{x,c}[D_{src}(G(x,c))] - \lambda_{gp} E_{\hat{x}}[(\|\nabla_{\hat{x}} D_{src}(\hat{x})\|_2 - 1)^2]$$

- $\hat{x}$ 는 real 이미지와 생성 이미지 사이의 직선상에서 균일하게 샘플링한 것
- $\lambda_{gp} = 10$ 으로 설정

Network Architecture (CycleGAN 기반)

- **Generator** : Conv layer 2개 (downsampling, stride 2) → Residual block 6개 → Transposed Conv layer 2개 (upsampling, stride 2), Instance normalization 사용
- **Discriminator** : PatchGAN 기반 (local image patch의 real/fake를 분류), normalization 미사용

4. 실험 및 결과

Dataset

데이터셋	이미지 수	특징
CelebA	202,599장	40개의 binary attribute (머리색, 성별, 나이 등) 178×178 crop → 128×128 resize Test 2,000장
RaFD	4,824장	67명 참가자, 8가지 표정, 3가지 시선 방향, 3가지 촬영 각도 256×256 crop → 128×128 resize

Baseline

비교 모델

- **DIAT** : Adversarial loss로 두 도메인 간 매핑 학습 + face recognition 모델의 feature extractor로 identity 보존
- **CycleGAN** : Adversarial loss + cycle consistency loss. 도메인 쌍마다 2개의 generator와 discriminator 필요
- **IcGAN** : Encoder + cGAN 결합. Encoder가 latent vector z 와 conditional vector c 를 추출하고, c 만 변경하여 이미지 합성


학습 설정

- Optimizer : Adam ($\beta_1 = 0.5, \beta_2 = 0.999$)
- Data augmentation : 50% 확률로 horizontal flip
- Discriminator 5회 업데이트마다 generator 1회 업데이트
- Batch size : 16
- CelebA : LR 0.0001로 10 epochs 학습 후 10 epochs 동안 0으로 linear decay
- RaFD : LR 0.0001로 100 epochs 학습 후 100 epochs 동안 0으로 linear decay
- 학습 시간 : 단일 NVIDIA Tesla M40 GPU에서 약 1일

결과

Experimental Results on CelebA

정성적 평가



- StarGAN이 cross-domain 모델 대비 높은 시각적 품질의 변환 결과를 제공
 - Multi-task learning 프레임워크를 통한 regularization 효과 : 고정된 변환 대신 유연한 변환을 학습하여 overfitting 방지, 다양한 도메인에 범용적으로 적용 가능한 feature 학습
- IcGAN 대비 facial identity 보존에서 우수
 - 저차원 latent vector 대신 convolutional layer의 activation map을 사용하여 spatial 정보 유지

정량적 평가 (AMT)

- Single attribute transfer : StarGAN이 모든 attribute에서 과반수 선호 획득

Method	Hair color	Gender	Aged
DIAT	9.3%	31.4%	6.9%
CycleGAN	20.0%	16.6%	13.3%
IcGAN	4.5%	12.9%	9.2%
StarGAN	66.2%	39.1%	70.6%


- Multi-attribute transfer : 복잡한 다중 속성 변환에서 StarGAN의 우위가 더 두드러짐 (예: H+A에서 61.5% vs 2위 15.6%)

Method	H+G	H+A	G+A	H+G+A
DIAT	20.4%	15.6%	18.7%	15.6%
CycleGAN	14.0%	12.0%	11.2%	11.9%
IcGAN	18.2%	10.9%	20.3%	20.3%
StarGAN	47.4%	61.5%	49.8%	52.2%

- StarGAN은 학습 시 target domain label을 랜덤 생성하므로 다중 속성 변환을 자연스럽게 처리

Experimental Results on RaFD

정성적 평가



- StarGAN이 가장 자연스러운 표정을 생성하면서 입력의 개인 identity와 facial feature를 적절히 유지
- DIAT, CycleGAN은 identity를 보존하지만 결과가 흐릿하고 선명도가 떨어짐
- IcGAN은 성별을 바꾸는 등 identity 보존에 실패하는 경우 발생
- StarGAN의 우수한 이미지 품질은 multi-task learning의 implicit data augmentation 효과에 기인
 - DIAT/CycleGAN은 두 도메인 학습 시 1,000장만 사용하지만, StarGAN은 모든 도메인의 4,000장을 활용

정량적 평가

Method	Classification error	# of parameters
DIAT	4.10	$52.6\text{M} \times 7$
CycleGAN	5.99	$52.6\text{M} \times 14$
IcGAN	8.07	$67.8\text{M} \times 1$
StarGAN	2.12	$53.2\text{M} \times 1$
Real images	0.45	-

- StarGAN이 가장 낮은 classification error → 가장 사실적인 표정 합성
- 파라미터 수 : StarGAN은 도메인 개수와 관계없이 단일 generator-discriminator 쌍만 필요하여 DIAT 대비 7배, CycleGAN 대비 14배 적은 파라미터

Experimental Results on CelebA+RaFD


Effects of joint training

StarGAN-SNG (RaFD만 학습) vs StarGAN-JNT (CelebA+RaFD 공동 학습)



- CelebA 데이터에 얼굴 표정을 합성하는 task
 - StarGAN-JNT가 CelebA 이미지의 표정 합성에서 높은 시각적 품질을 보이는 반면, StarGAN-SNG는 합리적이지만 흐릿하고 회색 배경의 이미지를 생성
 - StarGAN-JNT는 양쪽 데이터셋을 활용하여 facial keypoint detection, segmentation 등 저수준 태스크를 개선할 수 있기 때문

Learned role of mask vector



- 올바른 mask vector [0, 1] (RaFD label 유효)를 사용하면 표정 합성 성공
- 잘못된 mask vector [1, 0] (CelebA label 유효)를 사용하면 표정 합성에 실패하고 대신 나이를 변환
→ facial expression label을 unknown으로 무시하고 facial attribute label을 유효한 것으로 처리하기 때문
- 다중 데이터셋의 라벨을 모두 포함해서 이미지 변환을 수행할 때, StarGAN이 mask vector의 의도된 역할을 올바르게 학습했음을 확인

5. 결론

- **StarGAN 제안** : 단일 generator와 discriminator를 사용하여 다중 도메인 간 확장 가능한 image-to-image translation 수행
- 확장성 외에도 multi-task learning의 일반화 능력 덕분에 기존 방법 대비 높은 시각적 품질의 이미지 생성
- Mask vector를 통해 서로 다른 label 집합을 가진 다중 데이터셋을 활용하여, 모든 label 처리 가능

Squeeze-and-Excitation Networks

날짜 2026년 6월 22일

태그 CV

Paper Review

Squeeze-and-Excitation Networks

The central building block of convolutional neural networks (CNNs) is the convolution operator, which enables networks to construct informative features by fusing both spatial and channel-wise...

<https://arxiv.org/abs/1709.01507>



Keyword : Channel Attention, Image Classification, Feature Recalibration

1. Introduction

논문이 다루는 분야

CNN의 Channel-wise Feature Recalibration


- Image classification을 중심으로 한 컴퓨터 비전 태스크를 다룸
- CNN의 convolution 연산은 각 layer에서 local receptive field 내의 spatial 정보와 channel 정보를 결합하여 feature를 구성
- 비선형 활성화 함수와 downsampling을 거치며 계층적 패턴을 포착하는 이미지 표현을 생성
- 컴퓨터 비전 연구의 핵심 주제 : 주어진 태스크에 가장 중요한 이미지 속성만을 포착하는 더 강력한 표현을 찾는 것

해당 task에서 기존 연구 한계점

- 기존 연구는 주로 **spatial** 측면에 집중하여 CNN의 표현력을 강화해 왔음
 - **Inception 계열** : multi-scale process를 네트워크 모듈에 통합하여 성능 향상
 - Spatial dependency를 더 잘 모델링하거나, spatial attention을 네트워크 구조에 도입하는 연구
- 반면 **channel** 간의 관계에 대한 탐구는 상대적으로 부족

논문의 contributions

- **Squeeze-and-Excitation (SE) block 제안** : 채널 간 상호의존성을 명시적으로 모델링하여 channel-wise feature response를 적응적으로 재조정하는 구조



- **Squeeze** : feature map을 spatial 차원(H×W)에 걸쳐 집계하여 channel descriptor를 생성 → 네트워크의 global receptive field 정보를 모든 layer에서 활용 가능하게 하는 global distribution embedding
- **Excitation** : channel descriptor를 입력으로 받아 per-channel modulation weight를 생성하는 simple self-gating mechanism → 이 weight를 feature map에 적용하여 유용한 feature는 강조하고 덜 유용한 feature는 억제
- **SE block의 특성**

- SE block을 쌓아 SENet 구조를 형성할 수 있으며, 기존 SOTA 모델의 블록을 SE 블록으로 drop-in 교체하는 것도 가능
- 네트워크 깊이에 따라 역할이 달라짐 - 초기 layer에서는 class-agnostic한 방식으로 공유된 저수준 표현을 강화하고, 후반 layer에서는 점점 특화되어 class-specific하게 반응
- 구조가 단순하고 계산 비용이 적어 기존 구조에 약간의 모델 복잡도와 연산 증가만으로 성능을 효과적으로 향상시킬 수 있음

• 성과

- ImageNet 데이터셋에서 광범위한 평가를 수행하고, ImageNet 외의 데이터셋에서도 효과를 확인
- ILSVRC 2017 classification 대회에서 1위 달성
- 최고 모델 앙상블이 test set에서 top-5 error 2.251% 기록 → 전년도 우승 모델(2.991%) 대비 약 25% 상대적 개선