



Squeeze-and-Excitation Networks

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

1. Introduction


논문이 다루는 분야

- CNN의 표현력을 어떻게 극대화할 수 있을까?
- 컨볼루션 레이어는 지역적 수용 영역(local receptive field) 내에서 공간적 정보와 채널 정보를 융합
 - 이 과정에서 채널 간의 상호 의존성을 명시적으로 재설계하여 이미지 표현 품질을 향상
 - 단순히 깊이나 폭을 늘리는 방식이 아닌 적응적 재보정(Adaptive Recalibration)을 통해 네트워크가 이미지의 전역적 정보를 활용하여 스스로 어떤 채널의 특징이 중요한지 판단하고 강조하게 만들

해당 task에서 기존 연구 한계점

- 기존 CNN 연구들은 주로 공간적 상관관계(spatial correlation)에 집중
 - Inception, ResNet과 같은 기존 연구들은 멀티 스케일 과정이나 skip connection을 통해 공간적 상관관계를 강화
 - 컨볼루션은 채널 정보를 섞어주지만, 이는 컨볼루션 연산 중 암묵적으로 일어나는 현상 — 네트워크가 채널 간의 중요도 차이를 동적으로 학습하기보다는 필터 커널 내에 고정된 가중치로 귀속됨
 - 네트워크의 상위 계층 제외하고는 각 레이어가 전체 이미지의 정보를 조망하지 X — 개별 채널의 중요도를 판단할 때 이미지의 전체 맥락을 반영하지 못하는 한계

논문의 contributions



- Squeeze-and-Excitation (SE) Block 제안
 - Squeeze: 전역적 통계량 생성
 - Global average pooling을 사용해 $H \times W \times C$ 차원의 특징 맵을 $1 \times 1 \times C$ 차원으로 압축
 - 각 채널이 가진 전역적 통계 정보를 추출해 채널별 지문(descriptor) 만들
 - Excitation: 비선형 채널 게이팅
 - 두 개의 FC 레이어와 시그모이드 함수로 구성된 병목구조로 채널 간의 복잡하고 비선형적인 관계 모델링
 - 각 채널에 가중치 부여하는 역할 — 중요한 정보는 증폭(excitation)하고 무의미한 정보는 억제
 - 채널 간의 상호 의존성을 명시적으로 모델링
 - 전역적 정보를 활용해 유용한 특징은 강조, 덜 중요한 특징은 억제하는 특징 재보정(feature recalibration) 매커니즘을 제안
- SE 블록은 기존의 sota CNN 아키텍처에 쉽게 통합할 수 있는 drop-in 모듈
 - 연산량 대비 성능 향상 폭이 큼, 계산 복잡도 증가 적음



StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. 제안 방법론

Main Idea

4. 실험 및 결과

Dataset

Baseline

결과

5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

- 멀티 도메인 이미지 간 변환(Multi-Domain Image-to-Image Translation)을 위한 생성적 대적 신경망(GAN) 프레임워크
 - 하나의 이미지를 다양한 타겟 도메인의 특성에 맞춰 변환
 - 단일 데이터셋 내의 다중 속성 변환뿐 아니라 서로 다른 종류의 레이블을 가진 복수의 데이터셋을 통합하여 학습하는 태스크

해당 task에서 기존 연구 한계점

- 기존 이미지 간 변환 모델(CycleGAN, DiscoGAN 등)은 주로 두 개의 서로 다른 도메인 간의 관계만을 학습 가능

→ k개의 도메인 간 변환 모두 학습하기 위해서는 총 $k(k-1)$ 개의 독립적인 생성자(generator) 모델을 각각 구축하고 훈련해야 하므로 매우 비효율적


- 각 생성자가 두 도메인의 데이터만을 활용하여 학습하기 때문에 모든 도메인이 공유할 수 있는 글로벌한 특징이 존재해도 전체 데이터를 완벽히 활용 X, 생성된 이미지의 품질 제한됨
- 각 데이터셋마다 레이블 정보가 부분적으로만 공개 → 서로 다른 레이블 가진 데이터셋의 동시 학습 불가능

논문의 contributions

(a) Cross-domain models



(b) StarGAN



- 단일 모델 기반의 통합 아키텍처 StarGAN 제안
 - 하나의 생성자와 판별자만을 사용하여 다중 도메인 간의 매핑을 성공적으로 학습할 수 있는 확장 가능한 모델
- 마스크 벡터를 통한 다중 데이터셋 공동 학습
 - 명시되지 않은 레이블 정보는 무시하고 아는 레이블에만 집중할 수 있도록 하는 마스크 벡터를 도입, 서로 다른 레이블을 가진 다중 데이터셋을 동시에 훈련 가능
- 얼굴 속성 변경 및 표정 합성 태스크에서 기존 베이스라인 모델들보다 우수한 품질과 효과적인 속성 반영 능력 보임

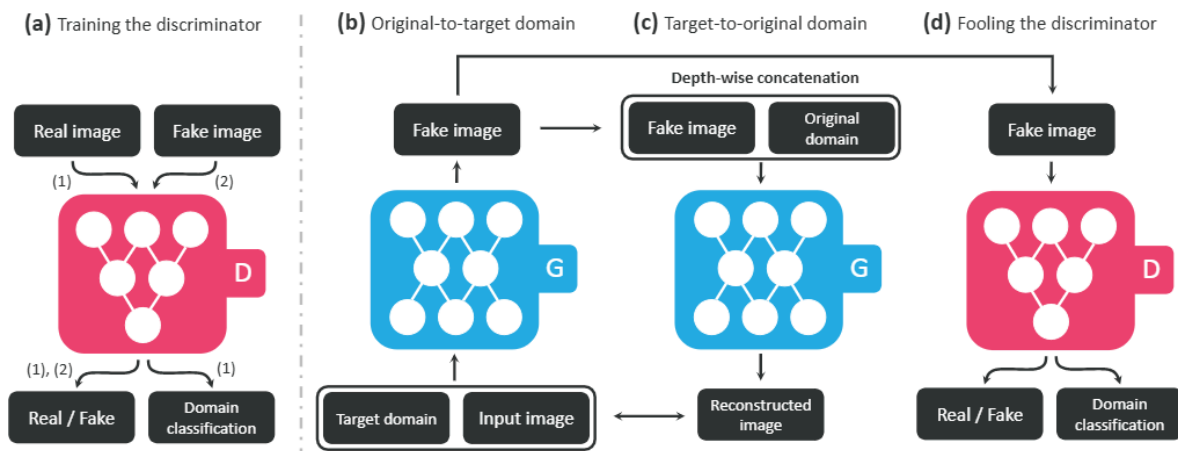
2. Related Work

- Generative Adversarial Networks(GANs)
 - 판별자와 생성자가 대적하며 실제와 유사한 샘플을 생성하는 구조

- 이미지의 현실성을 높이기 위해 적대적 손실(Adversarial loss) 활용
- Conditional GANs
 - 생성자와 판별자에 클래스 정보나 텍스트 설명을 추가 조건으로 제공하여 제어 가능한 이미지를 생성
 - 본 논문은 도메인 정보를 조건으로 주어 다중 도메인 변환을 제어
- Image-to-Image Translation(Pix2Pix, CycleGAN 등)
 - 기존 연구들은 쌍이 있는 데이터 혹은 쌍이 없는 데이터 환경에서 이미지 변환을 수행
 - 두 도메인 간의 1:1 관계만을 다루어 다중 도메인 확장 시 모델 개수가 기하급수적으로 늘어나는 한계

3. 제안 방법론

Main Idea



- 생성자가 고정된 변환만을 학습하는 대신 입력 이미지와 타겟 도메인 레이블(c)을 함께 입력받음(Depth-wise concatenation) → 타겟 도메인으로 변환
- 하나의 판별자가 여러 도메인을 제어할 수 있도록 판별자 상단에 보조 분류기(auxiliary classifier)를 추가
 - 이미지의 진위 여부(D_{src}) 판별과 해당 이미지의 도메인 분류(D_{cls})를 동시에 수행
- 이미지의 도메인 관련 부분만 바꾸고 원본 콘텐츠는 보존하기 위해 변환된 이미지를 다시 원본 도메인 레이블(c')과 함께 동일한 생성자에 통과시켜 원래 이미지로 복원하도록 하는 손실함수(L1) 사용

- 손실 함수

$$\mathcal{L}_D = -\mathcal{L}_{adv} + \lambda_{cls} \mathcal{L}_{cls}^r,$$

$$\mathcal{L}_G = \mathcal{L}_{adv} + \lambda_{cls} \mathcal{L}_{cls}^f + \lambda_{rec} \mathcal{L}_{rec},$$

- 적대적 손실(Adversarial Loss): 이미지의 현실성을 높이기 위해 사용. 안정적인 학습을 위해 그래디언트 패널티가 추가된 Wasserstein GAN(WGAN-GP) 목적 함수 사용

$$\mathcal{L}_{adv} = \mathbb{E}_x [\log D_{src}(x)] + \mathbb{E}_{x,c} [\log (1 - D_{src}(G(x, c)))],$$

$$\mathcal{L}_{adv} = \mathbb{E}_x [D_{src}(x)] - \mathbb{E}_{x,c} [D_{src}(G(x, c))] - \lambda_{gp} \mathbb{E}_{\hat{x}} [(\|\nabla_{\hat{x}} D_{src}(\hat{x})\|_2 - 1)^2],$$

- 도메인 분류 손실(Domain Classification Loss): 진짜 이미지를 올바른 원래 도메인으로 분류하도록 판별자를 학습시키는 손실($\mathcal{L}_{cls}^r$)과 생성된 이미지가 타겟 도메인으로 판별되도록 생성자를 학습시키는 손실($\mathcal{L}_{cls}^f$)

$$\mathcal{L}_{cls}^r = \mathbb{E}_{x,c'} [-\log D_{cls}(c'|x)],$$

$$\mathcal{L}_{cls}^f = \mathbb{E}_{x,c} [-\log D_{cls}(c|G(x, c))].$$

- 재구성 손실(Reconstruction Loss): 변환 후 다시 원본으로 역변환했을 때의 차이를 최소화하는 cycle consistency loss($\mathcal{L}_{rec}$)

$$\mathcal{L}_{rec} = \mathbb{E}_{x,c,c'} [\|x - G(G(x, c), c')\|_1],$$

- 다중 데이터셋 학습을 위한 마스크 벡터
 - 다른 데이터셋의 레이블 정보를 모를 때 공백으로 두고, 현재 입력 데이터셋이 무엇인지를 나타내는 n차원의 원-핫 벡터인 마스크 벡터 m을 도메인 레이블에 결합

(concatenate)

- 생성자는 지정되지 않은 레이블(0으로 채워진 벡터)은 무시하고 명시적으로 주어진 레이블에만 집중
- 판별자는 현재 명확히 알고 있는 데이터셋의 레이블에 대해서만 분류 오류를 최소화하도록 Multi-task learning 방식으로 훈련

4. 실험 및 결과

Dataset

- CelebA: 202,599개의 유명인 얼굴 이미지, 40개의 이진 속성 레이블로 구성
 - 본 논문에서는 머리 색상, 성별, 나이를 기준으로 7개 도메인 구축해 사용
- RaFD: 67명의 참가자로부터 수집된 4,824개의 고품질 얼굴 이미지 데이터셋(8가지 감정 표정)

Baseline

- DIAT/CycleGAN: 두 도메인 간의 매핑만 가능한 모델들로, 다중 도메인 및 다중 속성 변환 성능을 비교하기 위해 도메인 쌍마다 모델을 개별적으로 여러 번 학습시켜 비교
- IcGAN: Conditional GAN에 인코더를 결합하여 잠재 벡터 조작을 통해 속성을 변경하는 모

결과

- StarGAN은 베이스라인 모델들이 결과물을 흐릿하게 만들거나 입력 인물의 신원 정보를 잃어버리는 문제 극복, 가장 선명하면서 인물의 고유 특징을 잘 유지한 상태로 타겟 속성 반영하는 데 성공
- 사용자 평가(AMT Perceptual Test) 결과
 - 단일 속성 변환(머리색, 성별, 나이)과 다중 속성 혼합 변환 모두에서 StarGAN의 성능 우수
 - 복합 속성 변환일수록 타 모델과의 성능 차이 보임
- 변환된 이미지의 표정을 미리 학습한 분류기로 평가했을 때 StarGAN이 가장 낮은 분류 에러를 기록, 가장 사실적인 표정 생성하는 것을 보임
- 도메인이 늘어나도 하나의 생성자와 판별자만 유지하므로 도메인 조합마다 모델을 만들어야 하는 CycleGAN 대비 파라미터 수가 최대 14배 감소 → 높은 확장성, 효율성 입증

- CelebA와 RaFD를 마스크 벡터를 통해 공동 학습시킨 StarGAN-JNT 모델은 RaFD만 학습한 모델에 비해 CelebA 이미지의 표정을 더 자연스럽게 고품질로 표현, 마스크 벡터의 효과 검증

5. 결론 (배운점)

- 여러 개의 모델 구축할 필요 없이 하나의 생성자와 판별자 모델로 다중 도메인 간 이미지 변환을 가능하게 함 — GAN의 확장성 문제 개선
- 레이블이 불완전하거나 서로 다른 데이터셋 환경에서도 마스크 벡터를 도입해 다중 데이터셋 공동 학습을 가능하게 함
- 논문에서 다루는 이미지는 128x128 수준으로, 최신 Diffusion 모델이나 StyleGAN과 같은 고해상도 GAN 모델과 비교하면 텍스처나 세밀한 표현 등 해상도와 디테일의 한계 있음



- 도메인 개수가 늘어날 때 새로운 모델을 만드는 대신 하나의 모델이 도메인 간의 차이를 스스로 학습할 수 있도록 입력 데이터에 타겟 도메인 라벨을 부여한다는 StarGAN의 아이디어가 좋았다.
- 도메인을 binary나 one-hot으로만 정의하기 때문에 현실의 연속적인 속성 변화를 표현하는데 있어서의 한계나, 라벨 데이터가 전혀 없는 unsupervised 도메인으로의 확장이 어떻게 가능할 수 있을지가 궁금하다.