



Squeeze-and-Excitation Networks

1. Introduction

연구 분야 및 배경

- 연구 분야

CNN의 채널 관계 모델링 (Channel-wise Feature Recalibration)

CNN의 핵심 연산인 컨볼루션(Convolution)은 각 계층의 로컬 수용 영역(Local Receptive Field) 내에서 공간(Spatial) 정보와 채널(Channel) 정보를 융합하여 유의미한 특징을 구성.

컴퓨터 비전 연구의 핵심 주제는 주어진 태스크에 가장 중요한(salient) 속성만을 포착하는 더 강력한 표현(Representation)을 찾는 것.

- 연구 배경

공간적 관계 강화 연구의 발전

Inception 계열은 모듈에 멀티스케일(Multi-scale) 프로세스를 통합하여 성능을 향상.

이후 연구들은 공간적 의존성(Spatial Dependency)을 더 잘 모델링하거나, 네트워크 구조에 공간적 어텐션(Spatial Attention)을 통합하는 방향으로 발전.

그러나 채널 간의 관계(Relationship between Channels)를 명시적으로 다루는 연구는 상대적으로 부족했음.

기존 연구의 한계점

채널 관계의 암묵적·국소적 모델링 (Implicit & Local Channel Dependency)

컨볼루션 연산은 모든 채널에 대한 합산(summation)을 통해 출력을 생성하므로, 채널 의존성이 필터(vc)에 암묵적으로(implicitly) 내재되지만 필터가 포착하는 로컬 공간적 상관관계와 뒤섞여(entangled) 있음.

기존의 채널 관계 연구(Grouped Convolution, Multi-branch Convolution, 1×1 컨볼루션 등)는 대부분 모델·연산 복잡도를 줄이는 데 집중했으며, 채널 관계를 인스턴스에 무관한(instance-agnostic) 로컬 수용 영역 기반 함수의 조합으로 가정.

전역 정보(Global Information)를 활용하여 채널 간의 동적(dynamic)이고 비선형적(non-linear)인 의존성을 명시적으로 모델링하는 메커니즘이 부재.

이 논문의 핵심 기여



Squeeze-and-Excitation(SE) 블록의 핵심 아이디어

전역 정보를 사용하여 정보가 풍부한 특징을 선택적으로 강조하고 덜 유용한 특징은 억제하도록, 네트워크가 특징 재조정(Feature Recalibration)을 학습할 수 있게 하는 메커니즘. Squeeze 연산으로 채널별 전역 분포를 임베딩하고, Excitation 연산으로 채널별 가중치를 생성하여 원본 특징 맵에 곱함.

1 Squeeze 연산

: 특징 맵 U 를 공간 차원($H \times W$)에 대해 집계하여 채널별 전역 분포를 임베딩하는 채널 디스크립터를 생성.

2 Excitation 연산

: 임베딩을 입력으로 받아 채널별 조정 가중치 집합을 생성하는 간단한 자기-게이팅(self-gating) 메커니즘.

3 범용적 적응성

: SE 블록을 단순히 쌓아 SENet 구성 가능하며, 기존 아키텍처의 다양한 깊이에서 'Drop-in' 방식 대체 가능. 약간의 추가 연산만으로 기존 SOTA CNN 성능을 크게 향상.

4 계층별 역할의 차별화

: 초기 레이어에서는 class-agnostic하게 저수준 표현을 강화, 후기 레이어에서는 고도로 class-specific하게 반응 (Section 7.2).

2. Related Work

1 더 깊은 아키텍처 (Deeper Architectures)

VGGNet, Inception: 네트워크 깊이를 늘리면 학습 가능한 표현의 품질이 크게 향상됨을 입증.

Batch Normalization: 각 레이어 입력의 분포를 조정하여 심층 네트워크 학습 안정성 향상 및 매끄러운 최적화 표면 생성.

ResNet: 아이덴티티 기반 스킵 연결 (Identity-based Skip Connection)로 훨씬 깊고 강력한 네트워크 학습이 가능함을 입증.

Highway Networks: 스킵 연결의 정보 흐름을 조절하는 게이팅 메커니즘 도입.

2 연산 요소의 함수적 형태 개선

Grouped Convolution: 학습된 변환의 카디널리티(Cardinality)를 높이는 인기 있는 접근법.

Multi-branch Convolution: 그룹화 연산의 자연스러운 확장으로 더 유연한 연산자 조합 달성.

기존 채널 간 상관관계 연구는 공간 구조와 독립적으로, 또는 1×1 컨볼루션과 결합하여 새로운 특징 조합으로 매핑하는 데 집중.

본 논문은 이와 달리 전역 정보를 사용해 채널 간 동적·비선형 의존성을 명시적으로 모델링하는 메커니즘을 제안한다는 점에서 차별화.

3 알고리즘적 아키텍처 탐색 (Architecture Search)

진화 알고리즘 (Neuro-evolution), 강화학습 (Reinforcement Learning) 기반 탐색 등 수동 설계를 대체하려는 연구들. SE 블록은 이러한 탐색 알고리즘의 원자적 구성 요소 (atomic building block)로도 활용 가능성이 동시기 연구에서 입증됨.

4 어텐션 및 게이팅 메커니즘 (Attention and Gating)

어텐션은 신호 중 가장 정보가 풍부한 요소에 연산 자원을 편향적으로 할당하는 수단으로 해석 가능.

시퀀스 학습, 이미지 위치 파악, 이미지 캡셔닝, 입술 읽기 등 다양한 태스크에서 유용성 입증.

Wang et al.: hourglass 모듈 기반의 강력한 trunk-and-mask 어텐션 메커니즘을 심층 잔차 네트워크 중간 단계에 삽입.

3. Squeeze-and-Excitation Blocks



SE 블록의 기본 구조

변환 Ftr이 입력 X 를 특징 맵 $U (\in R^{(H \times W \times C)})$ 로 매핑할 때, 채널 의존성은 필터에 암묵적으로 내재되지만 로컬 공간적 상관관계와 뒤섞여 있음. SE 블록은 다음 변환 전에 Squeeze와 Excitation 두 단계를 거쳐 필터 응답을 재조정함으로써, 네트워크가 전역 정보 (Global Information)에 접근하도록 함.

3.1 Squeeze: 전역 정보 임베딩

- 문제: 각 학습된 필터는 로컬 수용 영역 (Local Receptive Field)에서만 작동하므로, 변환 출력 U 의 각 유닛은 이 영역 밖의 문맥 정보를 활용할 수 없음.
- 해결책: 전역 평균 풀링 (Global Average Pooling)을 사용하여 전역 공간 정보를 채널 디스크립터로 압축 (squeeze). 채널 c 의 통계량 z_c 는 U 의 공간 차원 ($H \times W$) 전체에 대한 평균으로 계산: $z_c = Fsq(u_c) = (1/HW) \sum \sum u_c(i,j)$.

- 의미: 변환 출력 U 는 전체 이미지에 대해 표현력 있는 통계량을 갖는 로컬 디스크립터들의 집합으로 해석 가능. 가장 단순한 집계 기법인 전역 평균 풀링을 채택했으나, 더 정교한 전략도 사용 가능.

3.2 Excitation: 적응적 재조정

- 목표: Squeeze로 집계된 정보를 활용하여 채널별 의존성을 완전히 포착하는 함수.

- 두 가지 조건 충족 필요:

- ① 채널 간 비선형적 상호작용을 학습할 수 있는 유연성,
- ② 여러 채널이 동시에 강조될 수 있도록 상호 배타적이지 않은(non-mutually-exclusive) 관계 학습.

$$s = \text{Flex}(z, W) = \sigma(W_2 \delta(W_1 z))$$

- δ 는 ReLU 함수, $W_1 \in \mathbb{R}^{(C/r \times C)}$, $W_2 \in \mathbb{R}^{(C \times C/r)}$.
 - 모델 복잡도를 제한하고 일반화를 돕기 위해, 두 개의 완전연결(FC) 레이어로 차원 축소(reduction ratio r) → ReLU → 차원 복원의 병목(bottleneck) 구조로 게이팅 메커니즘을 파라미터화.
- 최종 출력: $\tilde{x}_c = \text{Fscale}(u_c, s_c) = s_c \cdot u_c$ — 즉, 활성화 값 s 로 U 를 채널별로 스케일링(rescaling)하여 SE 블록의 최종 출력 생성.
 - 의미: Excitation 연산자는 입력 특정적(input-specific) 디스크립터 z 를 채널 가중치 집합으로 매핑. SE 블록은 본질적으로 입력에 조건화된 동적 특성을 가지며, 컨볼루션 필터의 로컬 수용 영역에 국한되지 않는 채널에 대한 셀프-어텐션(self-attention) 함수로 볼 수 있음.

5. 실험 및 결과

5.1 이미지 분류 (ImageNet)

- 데이터셋: ImageNet 2012 (학습 128만 장, 검증 5만 장, 1000개 클래스).
- 학습 설정: 분산학습 시스템 ROCS, Synchronous SGD(momentum 0.9), 배치 크기 1024, 초기 학습률 0.6(30 epoch마다 1/10), 100 epoch 학습. Reduction ratio $r=16$ (기본값).
- 네트워크 깊이별 비교

TABLE 2
Single-crop error rates (%) on the ImageNet validation set and complexity comparisons. The *original* column refers to the results reported in the original papers (the results of ResNets are obtained from the website: <https://github.com/Kaiminghe/deep-residual-networks>). To enable a fair comparison, we re-train the baseline models and report the scores in the *re-implementation* column. The *SENet* column refers to the corresponding architectures in which SE blocks have been added. The numbers in brackets denote the performance improvement over the re-implemented baselines. † indicates that the model has been evaluated on the non-blacklisted subset of the validation set (this is discussed in more detail in [21]), which may slightly improve results. VGG-16 and SE-VGG-16 are trained with batch normalization.

	original		re-implementation			SENet		
	top-1 err.	top-5 err.	top-1 err.	top-5 err.	GFLOPs	top-1 err.	top-5 err.	GFLOPs
ResNet-50 [13]	24.7	7.8	24.80	7.48	3.86	23.29 _(1.51)	6.62 _(0.86)	3.87
ResNet-101 [13]	23.6	7.1	23.17	6.52	7.58	22.38 _(0.79)	6.07 _(0.45)	7.60
ResNet-152 [13]	23.0	6.7	22.42	6.34	11.30	21.57 _(0.85)	5.73 _(0.61)	11.32
ResNeXt-50 [19]	22.2	-	22.11	5.90	4.24	21.10 _(1.01)	5.49 _(0.41)	4.25
ResNeXt-101 [19]	21.2	5.6	21.18	5.57	7.99	20.70 _(0.48)	5.01 _(0.56)	8.00
VGG-16 [11]	-	-	27.02	8.81	15.47	25.22 _(1.80)	7.70 _(1.11)	15.48
BN-Inception [6]	25.2	7.82	25.38	7.89	2.03	24.23 _(1.15)	7.14 _(0.75)	2.04
Inception-ResNet-v2 [21]	19.9†	4.9†	20.37	5.21	11.75	19.80 _(0.57)	4.79 _(0.42)	11.76


SE-ResNet-50(6.62% top-5)은 ResNet-50(7.48%)을 0.86%p 앞서며, 절반의 연산량(3.87 vs 7.58 GFLOPs)으로 더 깊은 ResNet-101(6.52%)에 근접.

SE-ResNeXt-50(5.49% top-5)은 거의 2배 연산량을 가진 더 깊은 ResNeXt-101(5.57%)보다도 우수.

- 모바일 환경 비교

TABLE 3
Single-crop error rates (%) on the ImageNet validation set and complexity comparisons. MobileNet refers to "1.0 MobileNet-224" in [64] and ShuffleNet refers to "ShuffleNet 1 × (g = 3)" in [65]. The numbers in brackets denote the performance improvement over the re-implementation.

	original		re-implementation				SENet			
	top-1 err.	top-5 err.	top-1 err.	top-5 err.	MFLOPs	Params	top-1 err.	top-5 err.	MFLOPs	Params
MobileNet [64]	29.4	-	28.4	9.4	569	4.2M	25.3(3.1)	7.7(1.7)	572	4.7M
ShuffleNet [65]	32.6	-	32.6	12.5	140	1.8M	31.0(1.6)	11.1(1.4)	142	2.4M



- CIFAR-10 / CIFAR-100

TABLE 4
Classification error (%) on CIFAR-10.

	original	SENet
ResNet-110 [14]	6.37	5.21
ResNet-164 [14]	5.46	4.39
WRN-16-8 [67]	4.27	3.88
Shake-Shake 26 2x96d [68] + Cutout [69]	2.56	2.12

TABLE 5
Classification error (%) on CIFAR-100.

	original	SENet
ResNet-110 [14]	26.88	23.85
ResNet-164 [14]	24.33	21.31
WRN-16-8 [67]	20.43	19.14
Shake-Even 29 2x4x64d [68] + Cutout [69]	15.85	15.41

5.2 장면 분류 (Places365)

- 데이터셋: 학습 800만 장, 검증 36,500장, 365개 카테고리. ResNet-152를 강력한 베이스라인으로 사용.

모델	Top-1 err.	Top-5 err.
Places-365-CNN (이전 SOTA)	41.07	11.48
ResNet-152 (재구현)	41.15	11.61
SE-ResNet-152 ✓	40.37	11.01

5.3 객체 탐지 (COCO)

- Faster R-CNN 프레임워크 사용, minival 프로토콜 적용. ImageNet 사전학습 가중치로 초기화.

모델	AP@IoU=0.5	AP
ResNet-50	57.9	38.0
SE-ResNet-50 ✓	61.0	40.4
ResNet-101	60.1	39.9
SE-ResNet-101 ✓	62.7	41.9

- SE-ResNet-50은 ResNet-50 대비 AP 기준 2.4%p(상대적 6.3%) 향상. SE-ResNet-101은 ResNet-101 대비 AP 기준 2.0%p(상대적 5.0%) 향상.

6. SE 블록의 역할 분석



NoSqueeze 비교 실험

전역 평균 풀링을 제거하고 1x1 컨볼루션으로 대체한 NoSqueeze 변형(동일 파라미터 수)과 비교한 결과, 전역 정보(Global Information) 사용이 성능에 유의미한 영향을 미침을 확인 (ResNet-50 6.55% → NoSqueeze 6.39% → SE 6.03%, Table 16). SE 블록은 이 전역 정보를 연산적으로 절약적인(parsimonious) 방식으로 활용.

• Excitation의 역할

goldfish, pug, plane, cliff 4개 클래스를 샘플링하여 SE-ResNet-50의 각 스테이지 마지막 SE 블록 활성화 분포 분석 (Fig. 6, 7).

- 관찰 1: 초기 레이어(SE_2_3)에서는 클래스 간 분포가 매우 유사 → 특징 채널의 중요도가 초기 단계에서는 클래스 간 공유됨.
- 관찰 2: 더 깊은 레이어(SE_4_6, SE_5_1)에서는 채널별 값이 클래스 특이적(class-specific)으로 변화 → 후기 레이어 특징이 더 특화됨을 시사.
- 관찰 3: 마지막 스테이지(SE_5_2, SE_5_3)에서는 활성화가 1에 가깝게 포화(saturated)되는 경향 → 이 경우 SE 블록이 거의 아이덴티티 연산자로 축소됨. 이는 Section 4의 발견(마지막 스테이지 SE 블록 제거 시 성능 손실 미미)과 일치.

클래스 내(within-class) 인스턴스 간에도 SE 블록의 동적 반응이 다르게 나타나며, 특히 후기 레이어에서 클래스 내 표현 다양성이 클 때 특징 재조정을 통해 판별 성능을 향상시킴.

7. Conclusion



최종 요약

SE 블록은 네트워크가 동적인 채널별 특징 재조정(Dynamic Channel-wise Feature Recalibration)을 수행할 수 있게 하여 표현력을 향상시키는 아키텍처 유닛. 광범위한 실험을 통해 SENet이 다수의 데이터셋과 태스크에서 SOTA 성능을 달성함을 입증. 또한 SE 블록은 기존 아키텍처가 채널별 특징 의존성을 충분히 모델링하지 못했다는 통찰을 제공하며, 생성된 특징 중요도(feature importance) 값은 네트워크 가지치기(pruning) 등 모델 압축 작업에도 활용 가능.

- **범용성 입증:** ImageNet, CIFAR-10/100, Places365(장면 분류), COCO(객체 탐지) 등 다양한 데이터셋-태스크에서 일관된 성능 향상을 확인.
- **경량성 입증:** SE-ResNet-50은 원본 대비 약 0.26% 연산량 증가, 약 10% 파라미터 증가(마지막 스테이지 제외 시 ~4%)라는 적은 비용으로 ResNet-101급 성능에 근접.
- **ILSVRC 2017 우승:** SENet 앙상블로 top-5 오류율 2.251% 달성, 전년 대비 약 25% 상대적 개선으로 채널 어텐션 메커니즘의 실효성을 대규모로 증명.

StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation

1. Introduction

연구 분야 및 배경

- 연구 분야



이미지 간 변환 (Image-to-Image Translation)

주어진 이미지의 특정 측면을 다른 것으로 바꾸는 작업. 예: 웃는 표정 → 찡그린 표정으로 변환.

GAN(Generative Adversarial Networks)의 등장 이후 헤어 색상 변경, 에지맵으로부터 사진 복원, 풍경 이미지의 계절 변경 등에서 크게 발전.

- 연구 배경

💡 속성(Attribute)·속성값(Attribute value)·도메인(Domain)의 정의

속성: 이미지에 내재된 의미 있는 특징(헤어 색상, 성별, 나이 등). 속성값: 속성의 특정 값(예: 헤어 색상의 black/blond/brown).

도메인: 동일한 속성값을 공유하는 이미지들의 집합. 예: 여성 이미지들은 하나의 도메인, 남성 이미지들은 또 다른 도메인을 구성.

CelebA 데이터셋은 헤어 색상·성별·나이 등 40개의 얼굴 속성 라벨을, RaFD 데이터셋은 'happy', 'angry' 등 8개의 표정 라벨을 보유 → 멀티 도메인 이미지 변환(Multi-domain Image-to-image Translation) 과제가 가능해짐.

기존 연구의 한계점

🔥 비효율성과 비효과성 (Inefficiency & Ineffectiveness)

비효율성: k개의 도메인 간 모든 매핑을 학습하려면 $k(k-1)$ 개의 생성자(Generator)를 각각 훈련해야 함. 예: 4개 도메인 간 변환을 위해 12개의 개별 생성자 네트워크가 필요.

비효과성: 얼굴 형태처럼 모든 도메인에 공통되는 전역적 특징이 존재함에도, 각 생성자는 k개 중 단 2개의 도메인만 학습하여 전체 학습 데이터를 충분히 활용하지 못함 → 생성 이미지 품질 제한.

서로 다른 데이터셋의 도메인을 함께 학습할 수 없음: 각 데이터셋은 부분적으로만 라벨링(partially labeled)되어 있기 때문 (Section 3.2에서 상세 논의).

이 논문의 핵심 기여



StarGAN의 핵심 아이디어

정된 변환(예: black-to-blond hair)을 학습하는 대신, 생성자가 이미지와 도메인 정보를 함께 입력받아 해당 도메인으로 유연하게 변환하도록 학습. 도메인 정보는 라벨(이진 또는 원-핫 벡터)로 표현하며, 학습 중 목표 도메인 라벨을 무작위로 생성하여 모델이 유연하게 변환하도록 훈련. 이를 통해 테스트 시 원하는 도메인 라벨을 지정하여 이미지를 자유롭게 변환 가능.

1 단일 생성자·판별자로 다중 도메인 학습

단 하나의 생성자와 판별자만으로 여러 도메인 간의 매핑을 학습하는 새로운 GAN을 제안. 모든 도메인의 이미지로부터 효과적으로 학습 가능.

2 마스크 벡터(Mask Vector)를 통한 다중 데이터셋 학습

마스크 벡터 기법을 활용하여, 서로 다른 라벨 집합을 가진 여러 데이터셋 간의 이미지 변환을 성공적으로 학습. 모델이 알려지지 않은(unknown) 라벨은 무시하고, 특정 데이터셋이 제공하는 라벨에만 집중하도록 함. 예: RaFD에서 학습한 특징으로 CelebA 이미지의 표정을 합성하는 등 다른 데이터셋 간 멀티 도메인 변환을 성공적으로 수행한 최초의 연구로 보고됨.

3 정성적·정량적 우수성 입증

얼굴 속성 변환(Facial Attribute Transfer)과 표정 합성(Facial Expression Synthesis) 과제에서 베이스라인 모델들 대비 StarGAN의 우수성을 정성적·정량적으로 입증.

Star Topology 구조

기존 Cross-domain 모델은 도메인 쌍마다 별도의 생성자(예: 4개 도메인 → G12, G21, G23, ... 등 12개)를 필요로 하는 반면, StarGAN은 하나의 생성자(G)가 모든 도메인을 중심으로 연결되는 별(Star) 형태의 토폴로지를 구성하여 멀티 도메인 간 매핑을 단일 모델로 학습.